MENTES E MÁQUINAS

T266m Teixeira, João de Fernandes

Mentes e máquinas: uma introdução à ciência cognitiva / João de Fernandes Teixeira. – Porto Alegre : Artes Médicas, 1998.

1. Psicologia cognitiva. I. Título.

CDU 159.922

Catalogação na publicação: Mônica Ballejo Canto - CRB 10/1023

ISBN 85-7307-329-2

JOÃO
DE
FERNANDES
TEIXEIRA

Doutor em Filosofia (PhD) pela University of Essex, Inglaterra. Professor do Departamento de Filosofia da Universidade Federal de São Carlos. Colaborador pleno do Grupo de Ciência Cognitiva do Instituto de Estudos Avançados da Universidade de São Paulo.

MENTES E MÁQUINAS

Uma introdução à ciência cognitiva

ARTES MÉDICAS

PORTO ALEGRE, 1998

© Artes Médicas Sul Ltda, 1998

Capa:
Mário Rönhelt

Preparação de original:
Maria Rita Quintella, Clarisse Fagundes

Supervisão editorial:
Leticia Bispo de Lima

Editoração eletrônica:
Formato Artes Gráficas

Reservados todos os direitos de publicação, em língua portuguesa à:
EDITORA ARTES MÉDICAS SUL LTDA.
Av. Jerônimo de Ornellas, 670 - Fones (051) 330-3444 e 330-2183
900040-340 - Porto Alegre, RS, Brasil

FILIAL SÃO PAULO
Rua Francisco Leitão, 146 - Pinheiros
Fone (011) 883-6160
05414-020 São Paulo, SP, Brasil

IMPRESSO NO BRASIL
PRINTED IN BRAZIL

Nenhum computador tem consciência do que faz,
Mas, na maior parte do tempo, nós também não.

Marvin Minsky

Sumário

INTRODUÇÃO 9

Primeira Parte

O Modelo Computacional da Mente

Máquinas de Turing e computabilidade 19
Funcionalismo, pensamento e símbolos 35
Sistemas especialistas 51
As grandes objeções: Searle e Penrose 67

Segunda Parte

Conexionismo e Redes Neurais

Uma nova concepção do funcionamento mental 83
Um sistema conexionista com memória distribuída 91

Conexionismo e filosofia da mente 103
Críticas ao modelo conexionista 111

Terceira Parte
Tendências Recentes

Vida artificial 121
A nova robótica: COG e o projeto do MIT 133
A Escola Chilena 143
O Futuro da Ciência Cognitiva 149

APÊNDICE A
Uma demonstração do Teorema da Parada 153

APÊNDICE B
O décimo problema de Hiltert, indecidibilidade e os Teoremas de Gödel 155

GLOSSÁRIO 165
PERIÓDICOS DE CIÊNCIA COGNITIVA 169
BIBLIOGRAFIA COMENTADA 171

Introdução

A IDÉIA DE UMA CIÊNCIA DA MENTE

No final de 1955, Herbert Simon, futuro prêmio Nobel de Economia, fez uma declaração chocante à comunidade científica: "Neste Natal eu e Allen Newell inventamos uma máquina pensante". Poucos meses depois, o programa de computador chamado de *Logical Theorist* produziu, pela primeira vez, a demonstração automática de um teorema. Logo em seguida, o programa foi aperfeiçoado e pôde produzir a prova de mais de 38 teoremas da lógica. Verificou-se, então, que algumas das demonstrações realizadas por este programa de computador eram mais elegantes do que quando realizadas por seres humanos. Isto foi motivo de orgulho para seus inventores que, de imediato, resolveram enviar as novas demonstrações para uma conceituada revista americana de lógica, o *Journal of Symbolic Logic*, que, no entanto, recusou-se a publicar um artigo no qual o *Logical Theorist* aparecia como co-autor.

Este evento pitoresco teve uma grande importância histórica para a formação e a institucionalização de uma nova disciplina científica que surgia durante a década de 50: a Inteligência Artificial. Com ela abria-se a perspectiva não apenas de replicar o pensamento humano, mas, também, de lançar mão de novos métodos para estudar nossas próprias atividades mentais.

A história que culmina com o aparecimento da Inteligência Artificial (IA) e, posteriormente, com a institucionalização das chamadas Ciências Cognitivas é bastante complexa e rodeada de vários episódios surpreendentes. A Física, a Matemática, a Biologia e as demais ciências da natureza passaram por grandes revoluções no decorrer do século XX – revoluções cujos resultados foram surpreendentes e levaram a uma modificação radical da nossa imagem do mundo. Era de se esperar que o mesmo pudesse ocorrer com a Psicologia, que esta pudesse sofrer uma revolução que finalmente abrisse as portas para um estudo científico da mente.

Desde o final dos anos 30 a Psicologia atravessava uma grande crise. É bem verdade que a Psicologia sempre enfrentou crises que puseram em questão sua validade como ciência, mas, desta vez, parece que a crise foi mais profunda. Exigia-se que a Psicologia finalmente estabelecesse um *paradigma* para suas investigações, ou seja, um ponto de partida consensual que permitisse fundar uma ciência da mente. Estabelecer um paradigma significa estabelecer clara e unificadamente o *objeto* e os *métodos* de uma disciplina científica.

As grandes escolas psicológicas do século XX pareciam estar longe de satisfazer esta expectativa. De um lado havia a Psicanálise e, de outro, o Behaviorismo ou Comportamentalismo, duas propostas que mantinham uma coexistência conflituosa. As neurociências também começavam a se impor, sobretudo após a Segunda Guerra Mundial e ameaçavam reduzir a Psicologia ao estudo do cérebro, transformando a última em Neuropsicologia. Estas três vertentes construíam o objeto da Psicologia de maneira diferente, ora como estudo da mente, ora como estudo do comportamento ou como estudo do cérebro. A cada uma destas maneiras de construir o objeto da Psicologia correspondiam propostas científicas e metodológicas diferentes, se não incompatíveis.

A Psicanálise sempre reconheceu a existência da mente ou do "aparelho psíquico", mas nunca foi capaz de estabelecer exatamente em que isto consistia. Após a morte de seu fundador, a Psicanálise parecia ter enveredado por uma rota de estagnação, na medida em que os seguidores de Freud não ousavam questionar seus fundamentos últimos. A Neuropsicologia apresentou mais promessas do que resultados. Por outro lado, os behavioristas começavam a perceber que a idéia de explicar o funcionamento mental por meio de um esquema rígido, tipo estímulo-resposta, não dava conta de fenômenos mais complexos ou atividades cerebrais superiores como era o caso da linguagem humana. Discussões sobre a natureza da linguagem humana e até que ponto esta poderia ser explicada por princípios comportamentais inflamaram a comunidade dos

psicólogos e dos filósofos, desde o final da década de 40, envolvendo nomes como Chomsky e Quine, e culminando com a publicação, em 1957, do *Verbal Behavior*, de Skinner.

Um episódio marcante neste debate foi o artigo *The Serial Order of Behavior*, do psicólogo Karl Lashley, apresentado em 1948. Deste estudo, revolucionário para a época, Lashley deriva a conclusão de que a linguagem não poderia ser explicada por meio de um esquema tipo estímulo-resposta; um fenômeno tão complexo como este exigia que se postulasse algo mais do que uma passagem de *input*s para *outputs*. A linguagem e outros comportamentos complexos exigiam algum tipo de planejamento, algo que não poderia ser concebido a não ser que se postulasse a existência de algum tipo de processamento de informação ou estados mentais no intervalo entre *input*s e *outputs*. Mas voltar a postular a existência de estados mentais ou representações e supor que estas alterariam a produção do comportamento jogava a Psicologia num dilema metodológico: como estudar esses estados internos ou essas representações sem voltar para o introspeccionismo ou a velha "Psicologia de poltrona" que todos queriam abandonar? Não seria isto um retrocesso para os velhos métodos de auto-exame ou de introspecção que haviam sido propostos no século XIX? Tratava-se de um dilema teórico que, em última análise, colocava em cheque a possibilidade de se construir uma ciência da mente. Era preciso, de alguma forma, conciliar o reconhecimento da existência de estados internos ou representações com uma proposta metodológica que afastasse a Psicologia do introspeccionismo.

Poucos anos depois, em 1956, realizou-se em Dartmouth, nos Estados Unidos, uma conferência que durou seis semanas reunindo os maiores especialistas em Ciência da Computação na época. O objetivo da conferência era estabelecer as bases para o desenvolvimento de uma ciência da mente, a qual deveria tomar como modelo o computador digital. A idéia de que processos mentais poderiam ser estudados à luz de um modelo computacional apresentava uma boa alternativa para os dilemas metodológicos da Psicologia: abandonar o comportamentalismo estrito sem, entretanto, incorrer na vaguidade do introspeccionismo. Esta proposta poderia ser o paradigma para uma ciência da mente. A Ciência da Computação ensaiava seus primeiros passos na década de 30, a partir dos trabalhos do matemático inglês Alan Turing, mas a possibilidade de construir computadores digitais só veio anos mais tarde com John von Neumann. O momento em que surgiu a idéia de que o computador digital poderia ser um bom modelo para entender o funcionamento do cérebro humano marca o início da Inteligência Artificial, que, posteriormente, se expandiria para algo mais amplo, que hoje denominamos de Ciência Cognitiva.

Esta conferência de 1956 produziu grandes frutos nas décadas seguintes. A idéia de estudar fenômenos mentais humanos à luz

de um modelo computacional expandiu-se rapidamente. O termo Inteligência Artificial, cunhado por um dos organizadores da conferência, John McCarthy, disseminou-se rapidamente. John McCarthy e Marvin Minsky, outro pesquisador norte-americano, associaram-se e fundaram o primeiro laboratório de pesquisas em Inteligência Artificial no MIT, em Massachusetts. A iniciativa foi logo seguida por outros investigadores que solicitaram a Minsky e McCarthy auxílio para fundar outro laboratório em Stanford, na Califórnia. Poucos anos depois, Alan Newell e Herbert Simon instalaram mais um laboratório de Inteligência Artificial, desta vez na Universidade Carnegie-Mellon, em Pittsburgh.

Destes laboratórios surgiram as primeiras máquinas de jogar xadrez, de demonstrar teoremas da lógica e outras grandes realizações da Inteligência Artificial nas décadas seguintes. Mas não era apenas com proezas computacionais que tais pesquisadores estavam preocupados: tratava-se de efetivamente *simular* processos mentais humanos e usar o computador para fundar uma ciência da mente. Para tanto, era preciso expandir a aplicação do modelo computacional para outros domínios além da simulação do raciocínio como acontecia com as máquinas de jogar xadrez ou de demonstrar teoremas da lógica. Por exemplo, simular computacionalmente a linguagem humana seria um grande feito; algo que possibilitaria a construção de máquinas para traduzir as várias línguas humanas. Mas para isto era preciso conhecer os mecanismos profundos da linguagem, era preciso associar-se com lingüistas, psicolingüistas e outros especialistas oriundos de outras áreas do conhecimento. O desafio de simular computacionalmente processos mentais humanos requeria a contribuição de todos aqueles que, direta ou indiretamente, estivessem envolvidos com o estudo da mente: psicólogos, lingüistas, filósofos, neurólogos, etc. Este esforço interdisciplinar levou à consolidação do que mais tarde ficou conhecido como *Ciência Cognitiva*, uma grande reorganização de tudo o que sabemos sobre a mente humana, tendo como um possível paradigma unificador o modelo computacional. Esta reorganização operou, contudo, um recorte metodológico específico que lhe conferiu uma peculiaridade: desafetizar os pensamentos para que estes possam ser objetos de modelagem científica. Não se tratava de ignorar a existência dos afetos, mas, simplesmente, de separá-los, mesmo que provisoriamente, do estudo da cognição, para que este não adquirisse uma abrangência excessiva.

Hoje em dia a ciência cognitiva encontra-se fortemente consolidada em centros de pesquisa e departamentos universitários em vários lugares do mundo onde se realizam pesquisas interdisciplinares. Suas múltiplas ramificações são habitualmente representadas através de diagramas, como o apresentado na Figura 1.1.

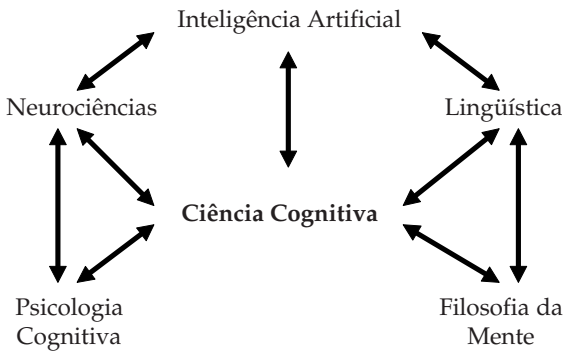

Figura 1.1. Diagrama das inter-relações entre algumas disciplinas que compõem a Ciência Cognitiva.

O termo "Ciência Cognitiva" passou a ser utilizado a partir de 1956 e, ao que tudo indica, foi criado pelo psicólogo George Miller. Ele foi cunhado para designar esta nova área de estudos que, na verdade, se expande para além das ramificações que já apresentamos e, hoje em dia, tende a incluir outras disciplinas, como, por exemplo, a Antropologia e a Filosofia da Ciência.

Apresentar um panorama histórico completo do desenvolvimento da Ciência Cognitiva nas últimas décadas constitui hoje uma tarefa monumental – uma tarefa que certamente não podemos abranger neste livro. Da mesma maneira, apresentar todos os contornos de uma ciência multidisciplinar e que requer conhecimentos especializados em diversas áreas constitui um desafio para aqueles que desejam se iniciar nesta nova área de estudos. Entretanto, é possível delinear um conjunto de informações básicas que permitam ao estudioso dominar um conjunto de conceitos fundamentais que sirvam de guia para seu desenvolvimento posterior. Neste livro apresentamos estes conceitos fundamentais seguidos de sugestões para leituras posteriores.

A Ciência Cognitiva tal como se apresenta hoje é muito mais do que simplesmente o que entendemos por Inteligência Artificial (ou IA). Contudo, foi a partir do desenvolvimento da IA, nas últimas décadas, que toda a idéia de uma ciência da mente se desenvolveu. A IA proporcionou o passo fundamental para se tentar relacionar mentes e computadores e estabelecer o que passamos a chamar de "modelo computacional da mente". Não fossem os desenvolvimentos e realizações da IA nas últimas décadas – suas máquinas de jogar xadrez, demonstrar teoremas matemáticos, realizar diagnósticos médicos – toda uma polêmica sobre a natureza da mente e da inteligência não teria surgido. Se a IA não conseguiu

realizar sua grande proeza, isto é, construir efetivamente máquinas inteligentes, ela nos obrigou a refletir sobre o significado do que é ser inteligente, o que é ter vida mental, consciência e muitos outros conceitos que freqüentemente são empregados pelos filósofos e psicólogos.

Debruçar-se sobre os conceitos fundamentais introduzidos pela IA – muitos dos quais tomados de empréstimo da própria Ciência da Computação – constitui, assim, um passo fundamental para entrarmos nesta nova área de estudos. Será a partir do exame destes conceitos fundamentais (algoritmo, máquinas de Turing, Problema da Parada e teste de Turing), empreendido na primeira parte deste livro (Capítulo 1), que poderemos entender o que significa o modelo computacional da mente; esta nova e perturbadora metáfora que aparece na segunda metade do século XX (Capítulo 2). A introdução destes conceitos no primeiro capítulo torna-o um pouco técnico. Sua leitura exige um pouco mais de atenção e de paciência por parte do leitor leigo. Em compensação, para os aficionados em Matemática e Ciência da Computação sugerimos uma leitura suplementar: os apêndices A e B, no final deste livro. O exame desta nova concepção de mente e de inteligência leva-nos ainda para uma incursão pelos chamados sistemas especialistas que são introduzidos como uma espécie de ilustração ou aplicação prática do modelo computacional da mente (Capítulo 3). Ainda neste capítulo, iniciamos a análise do impacto filosófico do modelo computacional da mente, impacto que se exerceu sobretudo na questão das relações mente-corpo ou mente-cérebro que vem ocupando os filósofos através dos séculos. No Capítulo 4 apresentamos as duas principais objeções ao modelo computacional da mente, formuladas pelo filósofo norte-americano John Searle e pelo físico inglês Roger Penrose. Tais objeções constituem fortes reações às tentativas de equiparar seres humanos e computadores, o que ainda é uma perspectiva assustadora neste final de século.

Esta primeira etapa é seguida pela apresentação de uma nova abordagem à mente que ganha ímpeto no panorama da Ciência Cognitiva a partir do início dos anos 80: o conexionismo. O conexionismo, que enfoca a replicação da inteligência pela construção de redes neurais artificiais, constitui hoje um verdadeiro subparadigma dentro da Ciência Cognitiva e muitas vezes é visto como uma alternativa ao modelo computacional da mente, proposto inicialmente pela Inteligência Artificial. A produção científica neste setor é, hoje em dia, imensa, e, assim sendo, apresentaremos apenas seus princípios gerais (Capítulos 1 e 2), suas conseqüências filosóficas (Capítulo 3) e algumas de suas dificuldades metodológicas (Capítulo 4).

A terceira parte deste trabalho aborda três movimentos recentes no âmbito da Ciência Cognitiva: a Vida Artificial, desenvolvida por Christopher Langton, e a Nova Robótica, um movimento que se iniciou a partir

dos trabalhos de Rodney Brooks no laboratório de IA do MIT, em Massachusetts, no final da década de 80. O terceiro movimento é a chamada Escola Chilena, liderada por Francisco Varela, Humberto Maturana e Evan Thompson. A importância destes três movimentos recentes reside no fato de eles restaurarem antigas ligações entre IA, Robótica e Biologia – ligações que aparentemente se perderam no curso das últimas décadas.

A leitura desta última parte levará o leitor a perceber o quanto a Ciência Cognitiva é uma área em ebulição que ainda tenta firmar seus próprios caminhos – uma área onde o consenso ainda está muito distante. Esperamos que a leitura da segunda e da terceira partes deste livro possa desfazer a concepção errônea – e quase popular – que identifica Ciência Cognitiva e Inteligência Artificial. Na realidade, esta identificação só é válida até o início dos anos 80 e só pode ser adequadamente entendida se tomarmos o termo Inteligência Artificial numa acepção *lato sensu*, isto é, como designando toda e qualquer tentativa de construir máquinas inteligentes.

A quantidade de literatura sobre Ciência Cognitiva de que dispomos hoje em dia é estarrecedora. Seria leviano dizer que este livro pode recobri-la. Por exemplo, não pudemos abordar muitos programas de pesquisa para o estudo da mente humana englobados pela Ciência Cognitiva como é o caso, por exemplo, da abordagem do funcionamento mental por meio de sistemas dinâmicos e o darwinismo neural, apenas para citar alguns. À medida que abordamos alguns temas, sugerimos algumas leituras e alguns *sites* (URLs) da *World Wide Web* no final de cada capítulo, que o leitor poderá consultar para obter informações mais específicas ou aprofundar alguns assuntos. Um pequeno glossário foi acrescentado no sentido de auxiliar o leitor a entender alguns termos técnicos. Na Bibliografia Comentada, que apresentamos no final do texto, relacionamos não apenas os livros citados e indicados ao longo desta obra, mas também livros recentes e importantes que são listados para que o leitor possa ter acesso a informações mais atualizadas.

O QUE LER

Sobre a história da Inteligência Artificial:

1 – Gardner, H. *A Nova Ciência da Mente*.
2 – Breton, P. *História da Informática*.
3 – Varela, F. *Conocer*.
4 – Dupuy, P. *Nas origens da Ciência Cognitiva*.

Primeira Parte

O modelo computacional da mente

- Máquinas de Turing e computabilidade
- Funcionalismo, pensamento e símbolos
- Sistemas especialistas
- As grandes objeções: Searle e Penrose

Capítulo 1

Máquinas de Turing e computabilidade

Conceitos introduzidos neste capítulo:
- Algoritmo.
- Máquina de Turing.
- Máquina de Turing Universal.
- Números não-computáveis.
- Problema da Parada da máquina de Turing.
- Problemas *P* e *NP*.
- Teste de Turing.

Há várias maneiras de contar a história de como a Ciência da Computação começou. A mais provável é que a revolução que possibilitou o aparecimento do computador tenha se iniciado em 1935, quando Alan Turing, um estudante do *King´s College*, em Cambridge, na Inglaterra, teve uma idéia para tentar resolver o chamado Problema de Hilbert, uma famosa questão matemática. Na mesma época, um grande debate entre os matemáticos de Princeton, nos Estados Unidos, levava ao aparecimento de um novo tipo de cálculo lógico, criado para fornecer uma base matemática para a idéia de realizar uma computação. Estas duas iniciativas diferentes formaram as bases para o que mais tarde ficou conhecido como "ciência da computação". Dez anos mais tarde, John von Neumann decidiu usar essas idéias para, efetivamente, construir os primeiros computadores modernos.

Em 1935, Turing estava assistindo a uma série de palestras ministradas pelo lógico matemático Max Newman. Durante o curso, Newman introduziu o *Entscheidungsproblem* (Problema da Decisão) formulado por Hilbert. O *Entscheidungsproblem* consistia em indagar se existe um procedimento efetivo (mecânico) para determinar se todos os enunciados matemáticos verdadeiros poderiam ou não ser provados, ou seja, serem deduzidos de um dado conjunto de premissas. Por exemplo: dada uma fórmula qualquer do cálculo de predicados, existe um procedimento sistemático, geral, efetivo, que permita determinar se essa fórmula é

demonstrável ou não? O significado do *Entscheidungsproblem* formulado por Hilbert era fundamental para o desenvolvimento da Matemática: tratava-se de saber se existiria um procedimento efetivo para a solução de todos os problemas matemáticos pertencentes a classes amplas mas bem definidas.

Ora, a grande dificuldade é que não havia, então, uma noção clara do que significava "procedimento efetivo". Após milhares de anos de história da Matemática, não se sabia o que era um algoritmo e tampouco o que era uma computação. Para responder a estas questões, Turing inventou uma *máquina teórica* que se tornou o conceito-chave de toda Ciência da Computação.

A seguir, introduziremos alguns conceitos fundamentais para a Ciência da Computação que estão direta ou indiretamente relacionados com a invenção matemática de Turing. Esta apresentação incluirá uma incursão pelas noções de **algoritmo, máquina de Turing, máquina de Turing universal** e **problema da parada da máquina de Turing** – todas noções fundamentais para o desenvolvimento da Ciência da Computação e posteriormente para a Ciência Cognitiva.

ALGORITMOS

O primeiro passo a ser dado para resolver o Problema de Hilbert (ou Problema da Decisão) era substituir a idéia intuitiva de procedimento efetivo por uma idéia formal, matemática. O resultado foi a construção de uma idéia matemática da noção de algoritmo, modelada a partir da maneira pela qual seres humanos procedem quando efetuam uma computação. A palavra "algoritmo" origina-se do nome de um matemático persa – al-Khowarizm – que escreveu um importante manual de álgebra no século IX. Exemplos de algoritmos já eram conhecidos muito antes do livro de al-Khowarizm, designando sempre a idéia de um procedimento sistemático. Seguindo esta tradição, Turing concebeu um algoritmo como sendo um processo ordenado por regras, que diz como se deve proceder para resolver um determinado problema. Um algoritmo é, pois, uma *receita* para se fazer alguma coisa. Tomemos como exemplo um algoritmo para preparar um *dry martini*:

Tome os seguintes ingredientes: ½ dose de vermute branco seco, 2 doses de gin, 1 gota de angostura, 1 gota de *orange bitter*, 1 cubo de gelo,1 azeitona.

Passos para a preparação:

1 – Coloque a ½ dose de vermute branco seco e as 2 doses de gin num copo.

2 – Adicione uma gota de angostura.

3 – Adicione uma gota de *orange bitter.*

3 – Coloque a pedra de gelo.
4 – Enfeite com a azeitona espetada num palito.

Cada passo específico constitui parte do algoritmo para fazer o *dry martini*. Em cada estágio, o algoritmo especifica de maneira não-ambígua exatamente o que deve ser feito, até que se chega a uma regra final que nos diz que o *dry martini* está pronto para ser servido. Não seria difícil imaginar um mecanismo que misturasse os ingredientes e preparasse o *dry martini* – uma verdadeira "máquina de fazer *dry martini*".

A noção de algoritmo constitui o núcleo de toda a teoria da computação. Vejamos agora como os algoritmos podem ser utilizados na Matemática.

O ALGORITMO DE EUCLIDES

Um exemplo de aplicação de algoritmo para resolver problemas matemáticos é o chamado algoritmo de Euclides. Este algoritmo, freqüentemente mencionado nos manuais de Ciência da Computação, é utilizado para achar o máximo divisor comum de dois números inteiros a e b. Há uma regra para isto, um algoritmo descoberto na Antigüidade, cujo princípio pode ser encontrado em qualquer livro elementar de teoria dos números. Vamos assumir, por definição, que a é maior do que b. Vamos introduzir também a notação "res {x/y}" para designar o resto após dividir o número x por um número y. O algoritmo euclidiano consiste em calcular a seqüência de inteiros {r1 , r2 ...} por meio da regra:

$$r1 = res\ \{a/b\}\ ,\ r2 = res\ \{b/\ r1\}\ ,\ r3 = res\ \{\ r1/\ r2\}\ ...,$$

onde o processo continua até que obtenhamos resto 0. O número r*, no qual o processo pára, será o máximo divisor comum de a e de b.

Suponhamos que $a = 137$ e $b = 6$. Seguindo os passos do algoritmo de Euclides, temos:

$$r1 = res\{137/6\} = 5\ ;\ r2 = res\{6/5\} = 1\ ;\ r3 = res\{5/1\} = 0$$

Concluímos, então, que r* =1 é o máximo divisor comum de 137 e 6. Na verdade nem precisaríamos do algoritmo para perceber isto, pois 137 é um número primo; os únicos números que podem dividi-lo são 1 e o próprio 137. Assim sendo, 137 e 6 são primos entre si.

Para quem tem alguma familiaridade com Ciência da Computação, este processo poderia ser representado através do seguinte fluxograma:

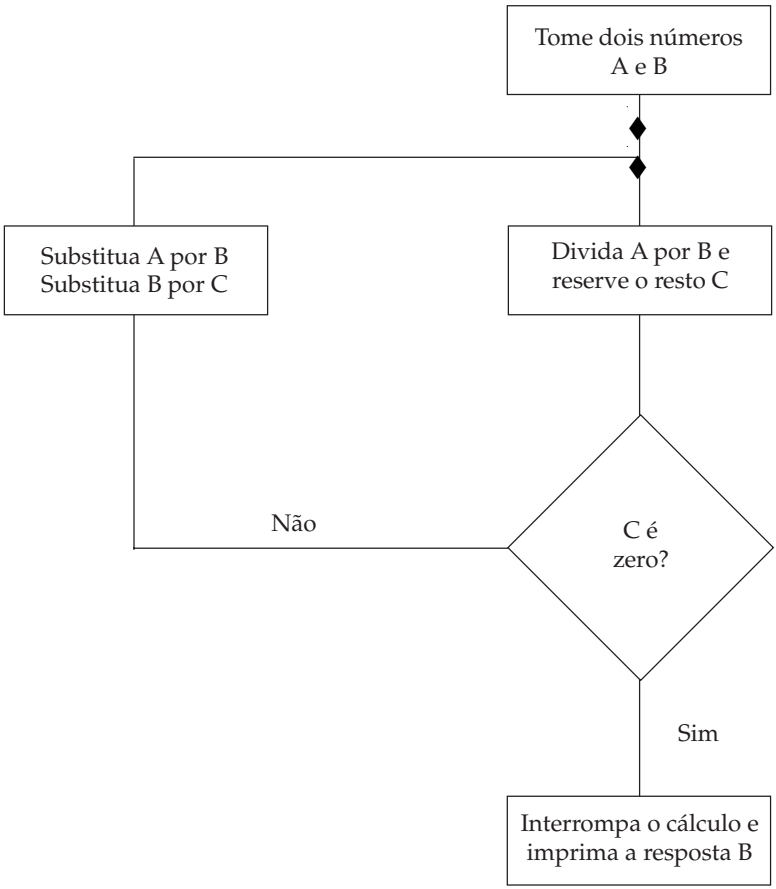

Figura 1.2. Fluxograma com representação do algoritmo de Euclides (adaptada de Penrose, 1989, p. 32.)

O importante aqui é que, da mesma maneira que na preparação do *dry martini*, os passos do algoritmo de Euclides são claramente estabelecidos de antemão. Apenas uma operação é especificada para cada passo, não há interpretação dos resultados intermediários e não é possível "pular" passos. O que temos é a repetição mecânica de operações de divisão e de restos. *Seguir cegamente um conjunto de regras constitui a essência de um algoritmo*. Foi na tentativa de expressar matematicamente esta idéia que Turing criou a *máquina de Turing*, um dispositivo virtual que reflete o que significa seguir os passos de um algoritmo e efetuar uma *computação*.

MÁQUINAS DE TURING

A máquina de Turing constitui a melhor formalização da noção de algoritmo de que se tem notícia na história da Matemática.

Uma máquina de Turing possui dois componentes:

a) Uma fita, infinitamente longa, dividida em pequenos quadrados; cada um deles contém um conjunto finito de símbolos.

b) Um *scanner* que pode ler, escrever e apagar símbolos dos quadrados da fita.

O *scanner* é um dispositivo mecânico qualquer que permite "ler" o símbolo que está no quadrado, além de apagar ou imprimir símbolos que ali se encontram.

Consideremos um alfabeto de símbolos para a máquina de Turing. Vamos supor que este alfabeto contém apenas dois símbolos, 0 e 1. Zero (0) e 1 aqui não devem ser tomados como os números naturais 0 e 1, mas apenas como os numerais representando estes números. Assim sendo, poderíamos ter escolhido os símbolos X e Y ou até I e II. A representação habitual da máquina de Turing é a seguinte:

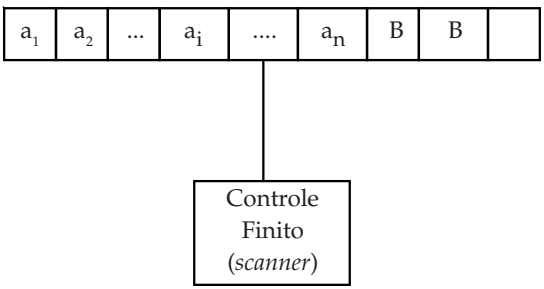

Figura 1.3. Esquema de uma máquina de Turing.

O comportamento da máquina de Turing é governado por um algoritmo, o qual se manifesta no que chamamos de *programa*. O programa é composto de um número finito de instruções, cada uma delas selecionada do seguinte conjunto de possibilidades:

IMPRIMA 0 NO QUADRADO QUE PASSA PELO *SCANNER*
IMPRIMA 1 NO QUADRADO QUE PASSA PELO *SCANNER*
VÁ UM QUADRADO PARA A ESQUERDA
VÁ UM QUADRADO PARA A DIREITA
VÁ PARA O PASSO *i* SE O QUADRADO QUE PASSA PELO *SCANNER* CONTÉM 0
VÁ PARA O PASSO *j* SE O QUADRADO QUE PASSA PELO *SCANNER* CONTÉM 1
PARE.

A partir destas sete instruções podemos construir o que chamamos *Programas de Post-Turing*, os quais informam à máquina o tipo de computação que ela deve efetuar.

Operar a máquina de Turing é muito simples. Em primeiro lugar, colocamos nela a fita com 0s e 1s (os dados de *input*). A máquina dispõe o *scanner* em algum ponto da fita que será o quadrado inicial. A partir daí todas as ações da máquina são governadas pelo programa. Vamos ver como isto acontece por meio de um exemplo.

Suponhamos que a configuração inicial da fita consiste de uma cadeia de 1s com 0s em cada uma das pontas:

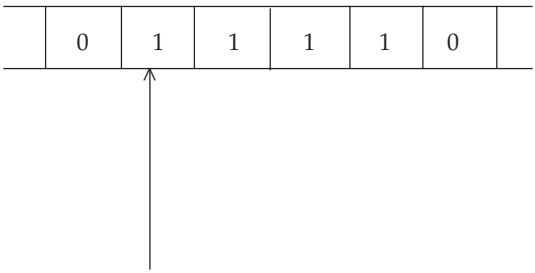

Figura 1.4. Exemplo de uma máquina de Turing funcionando.

Na fita acima, o número 1 sobre o qual a flecha incide indica o quadrado onde o *scanner* está localizado no momento. Suponhamos agora que queremos que a máquina de Turing mude os 0s que estão no fim da fita por 1s e em seguida pare. A máquina teria de efetuar o seguinte programa:

1 – VÁ UM QUADRADO PARA A DIREITA
2 – VÁ PARA O PASSO 1 SE O QUADRADO NO *SCANNER* CONTÉM 1
3 – IMPRIMA 1 NO QUADRADO ONDE ESTÁ O *SCANNER*
4 – VÁ PARA A ESQUERDA UM QUADRADO
5 – VÁ PARA O PASSO 4 SE O QUADRADO ONDE ESTÁ O *SCANNER* CONTÉM 1
6 – IMPRIMA 1 NO QUADRADO ONDE ESTÁ O *SCANNER*
7 – PARE.

Se seguirmos os passos deste programa, veremos que o *scanner* se move para a direita até encontrar o primeiro 0, que é, então, substituído por 1, através do comando "IMPRIMA 1". O *scanner*, em seguida, move-se para a esquerda, até parar. A Figura 1.5 ilustra melhor como a máquina de Turing funciona.

Lista do Estado da Máquina

A B C D E F G H . . .

Tabela da Máquina

Se no estado	lendo...	então imprima	mude para	vá para
A	0	1	E	D
A	1	0	D	B
B	0	0	D	A
B	1	1	E	B
. . .	. . .	. . .	. . .	. . .

SCANNER

0	0	1	1	0	1	1	1	0	1	1

Figura 1.5. Representação de operações na máquina de Turing.

Certamente os computadores de que dispomos hoje são, aparentemente, muito mais complexos do que esta máquina de Turing que acabamos de descrever. Contudo, qualquer computador digital é, *em princípio*, uma máquina de Turing. A máquina de Turing é o *princípio geral para a construção de computadores digitais*, pois, por meio dela, podemos executar *qualquer tipo de algoritmo*. Isto levou Turing à idéia de máquina de Turing universal, ou seja, à idéia de que qualquer computador pode, em princípio, ser concebido e reduzido a uma máquina de Turing.

A MÁQUINA DE TURING UNIVERSAL (MTU)

Para caracterizar a máquina de Turing universal (MTU), Turing supôs que não apenas os dados (*input*) de um problema como também o programa a ser executado pela máquina poderiam ser codificados através de uma série de 0s e 1s. O Quadro 1.1 a seguir oferece um exemplo deste tipo de codificação. Assim sendo, o programa também pode ser considerado como um *input* e podemos escrevê-lo na fita da mesma maneira que os dados que ele deve processar. A partir desta idéia, Turing construiu um programa que pode simular a ação de qualquer outro programa P, quando P é dado como parte de seu *input*.

Quadro 1.1. Esquema de código para a linguagem da máquina de Turing. Note-se que os passos 5 e 6 comportam repetições

Enunciado do Programa	Código
IMPRIMA 0 NO QUADRADO QUE ESTÁ SENDO "SCANNEADO"	000
IMPRIMA 1 NO QUADRADO QUE ESTÁ SENDO "SCANNEADO"	001
VÁ UM QUADRADO PARA A DIREITA	010
VÁ UM QUADRADO PARA A ESQUERDA	011
VÁ PARA O PASSO *i* SE O ATUAL QUADRADO CONTÉM 0	10100...01
VÁ PARA O PASSO *j* SE O ATUAL QUADRADO CONTÉM 1	11011...10
PARE	100

Vejamos como isto funciona. Suponhamos que temos um programa para máquina de Turing, o programa P, que especifica uma determinada máquina de Turing. Tudo o que temos de fazer é escrever este programa P na fita da MTU, junto com os dados (*input*) sobre os quais o programa P deve efetuar operações. Daqui para a frente, a MTU vai simular a ação de P sobre os dados, não haverá mais nenhuma diferença entre rodar o programa P na máquina original ou na MTU que simula P. A MTU pode, assim, imitar perfeitamente a máquina de Turing P.

A MTU é um objeto matemático formal: sua invenção permite saber, exatamente, o que significa computar alguma coisa. Daí sua importância. Mas aqui aparece uma questão: o que pode ser computado a partir deste dispositivo? Será que qualquer número pode ser computado utilizando-se este dispositivo? Ou haverá números não-computáveis?

NÚMEROS NÃO-COMPUTÁVEIS

Vejamos o que significa dizer que um número é computável. Um número inteiro *n* é *computável* se existe uma máquina de Turing que possa produzi-lo. Ou seja, um número *n* é computável se, começando com uma fita contendo apenas 0s, existe um programa de máquina de Turing que pára após um número finito de passos, com a fita contendo tantos 1s quantos forem necessários para representar *n*. O resto da fita conterá 0s. Esta é a definição de número computável de acordo com o modelo de computação baseado na máquina de Turing.

Computar um número real pode ser mais complicado. Muitos números reais contêm um número infinito de dígitos. Este é o caso, por exemplo, do número $\pi = 3.14159265....$, $\sqrt{3} = 1,732....$ Eles continuam indefinidamente e seus dígitos nunca produzem um ciclo repetitivo e finito de números. Isto quer dizer que só podemos chamar um número real de computável se existir uma máquina de Turing que imprima,

sucessivamente, os dígitos desse número, um após outro. Claro que, neste caso, a máquina não parará nunca. Mas ao afirmar isto estamos rompendo com uma das regras fundamentais que caracterizam um procedimento algorítmico: a idéia de que o programa da Máquina de Turing deve sempre parar, isto é, que o número de passos envolvido num algoritmo deve sempre ser finito.

O resultado a que chegamos aqui é quase paradoxal: a grande maioria dos números não podem ser produzidos usando uma máquina de Turing, ou seja, eles não podem ser produzidos através de um procedimento algorítmico. Os números computáveis constituem apenas um conjunto pequeno, formado pelos números inteiros. Como há muito mais números reais do que números inteiros, isto significa que a maioria dos números é incomputável.

O PROBLEMA DA PARADA DA MÁQUINA DE TURING

Um aspecto crucial da definição de número computável é o fato de o programa envolvido ter de parar após um número finito de passos. Isto nos leva a uma questão fundamental na teoria da computação: existirá algum procedimento geral, isto é, um algoritmo que possa nos dizer, *a priori*, se um determinado programa irá parar após um número finito de passos? Este é o famoso *problema da parada da máquina de Turing*.

Em outras palavras: dado um programa para máquina de Turing *P* e um conjunto de dados de *input I* , existirá um programa que aceite *P* e *I* como seus dados de *input* e que pare após um número finito de passos, determinando, assim, a configuração final da fita e especificando se *P* vai parar após um número finito de passos após processar os dados *I*? Estamos aqui buscando por um programa geral que funcionará para todas as instâncias de programas *P* e todos os possíveis dados de *input I*. Ou seja, esta é uma questão do tipo "metacomputacional", na medida em que indaga pela existência de um programa que poderá estipular características de todos os outros programas.

Suponhamos que temos um programa *P* que lê uma fita de máquina de Turing e pára quando nela aparece o primeiro 1. O programa diz: "Continue lendo até que o primeiro 1 apareça, então pare". Neste caso, se os dados de *input I* consistirem inteiramente de 1s o programa pára após o primeiro passo. Por outro lado, se os dados de *input* forem unicamente 0s, o programa não pararia nunca. Nestes casos temos um procedimento intuitivo para saber se o programa vai parar ou não: olhar para a fita. O programa parará se e somente se a fita contiver um 1; caso contrário, ele não pára.

Contudo, a maioria dos programas é muito mais complicada do que isto. A essência do problema da parada é perguntar se existe ou não um

procedimento efetivo que possa ser aplicado a qualquer programa e seus dados e que nos permita saber, *a priori*, se o programa vai parar ou não. Em 1936, Turing demonstrou que não existe tal procedimento efetivo. (O leitor que se interessar por saber como Turing fez esta demonstração poderá consultar o APÊNDICE A no final deste livro.)

COMPLEXIDADE COMPUTACIONAL: PROBLEMAS P E NP

Introduziremos agora alguns conceitos básicos da chamada teoria da Complexidade Computacional, um ramo relativamente recente da Ciência da Computação que se ocupa de aspectos práticos da elaboração de algoritmos. Tais aspectos práticos dizem respeito, primordialmente, a questões relativas à velocidade e à eficiência dos algoritmos – além de suas possíveis limitações.

Para começar, consideremos um problema matemático chamado Torre de Hanói. O problema é o seguinte: perto de Hanói, no Vietnã, há um mosteiro onde os monges se dedicam a uma tarefa assaz importante. Num de seus pátios há três postes, nos quais há 64 discos, cada um com um furo no centro e de tamanhos diferentes. Quando o mosteiro foi fundado, todos os discos estavam num poste, cada um sobre o imediatamente maior do que ele. Os monges têm uma tarefa a executar: deslocar todos os discos para um dos outros postes. Apenas um único disco pode ser deslocado por vez e os demais discos deverão estar em um dos postes. Além disso, em nenhum momento durante a transferência um disco maior poderá ser colocado em cima de um menor que ele. O terceiro poste pode ser utilizado como um lugar de repouso temporário para os discos. Qual a maneira mais rápida dos monges realizarem esta tarefa?

As figuras 1.6 e 1.7 apresentam esquemas representando estágios deste problema:

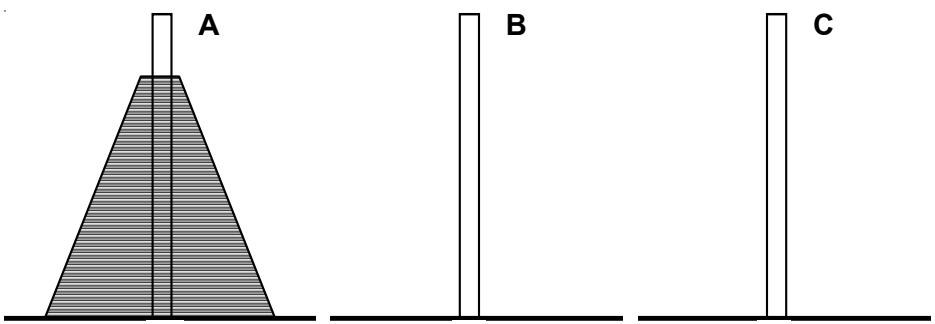

Figura 1.6. Representação do estágio inicial da torre de Hanói.

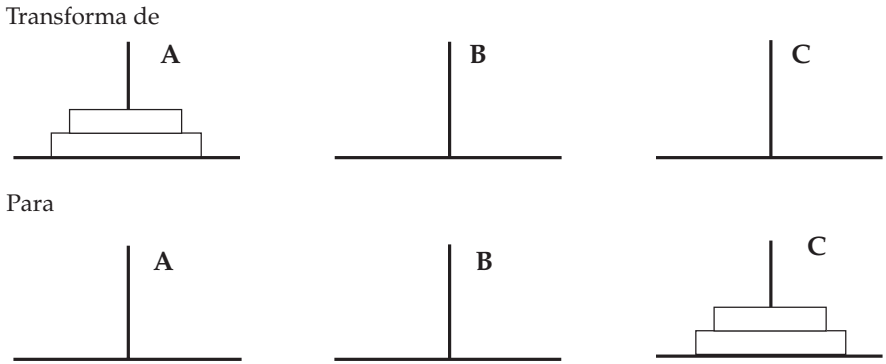

Figura 1.7. Representação parcial do estado final da resolução do problema da torre de Hanói.

Ora, existe um algoritmo que pode resolver este problema para qualquer número n de discos. Este programa mostra que o número mínimo de transferências necessárias é 2^n -1. No caso específico dos nossos monges, $n = 64$. Mesmo se supusermos que cada transferência de disco leve 10 segundos para realizar este algoritmo, ou seja, 2^{64} -1 passos, seriam necessários nada mais nada menos do que 5 trilhões de anos. Não é à toa que a lenda diz que quando este problema estiver resolvido o mundo terá acabado! O número de passos necessário para a solução do problema da Torre de Hanói cresce exponencialmente com o número n de discos. Estamos aqui diante de um problema computacional "complexo" no qual o número de passos para realizar um algoritmo cresce exponencialmente com o "tamanho" do problema.

Consideremos agora um problema "simples": separar as cartas de um baralho nos quatro naipes em ordem ascendente. Em primeiro lugar é preciso achar o ás de espadas e separá-lo. Em seguida volte para as outras cartas até que o 2 de espadas seja encontrado. Separe o 2 de espadas. Seguindo este método, rapidamente o baralho estará ordenado. Começando com n cartas, no pior caso você terá de examinar n^2 cartas. Assim sendo, o número de passos para resolver este problema é a função quadrática do tamanho do problema, ou seja, o número de cartas no baralho.

Problemas "simples" podem ser resolvidos em tempo polinomial, problemas "complexos" requerem um número de passos que cresce exponencialmente à medida que o tamanho do problema aumenta. Ou, para definir um pouco mais rigorosamente: um algoritmo roda em tempo polinomial se existem dois inteiros fixos, A e k tais que para um problema de tamanho n a computação será concluída no máximo com An^k passos. Chamamos este tipo de problema de P (P aqui significa "polinomial").

Algoritmos que não rodam em tempo polinomial são aqueles que requerem um tempo exponencial. Um algoritmo que, para ser rodado, requer 2^n passos ou $n!$ passos para resolver um problema é um algoritmo de tempo exponencial.

Algoritmos cujo número de passos cresce exponencialmente formam uma outra classe de problemas chamados de *NP. NP* significa "tempo não determinístico polinomial". Observe-se também que os problemas *P* são considerados tratáveis e os problemas *NP*, intratáveis.

Esta classificação pode então ser representada no seguinte diagrama:

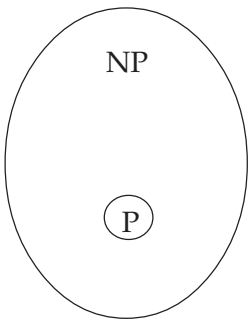

O termo "não-determinístico" não significa que existe algo probabilístico ou indeterminado nestes problemas. Ademais, o diagrama acima mostra que os problemas P são na verdade um subconjunto dos problemas *NP*, embora ninguém tenha conseguido, até hoje, demonstrar que *NP* = *P*. Vejamos alguns exemplos de problemas *NP*:

O problema do caixeiro viajante – O viajante tem de percorrer um número de cidades para visitar clientes e é preciso encontrar uma rota tal que ele não passe duas vezes pela mesma cidade. A questão então é a seguinte: dado o traçado das estradas, existe uma rota que começa e termina na mesma cidade e o permite visitar todas as demais cidades sem efetuar nenhuma repetição? Quando o número de cidades é maior do que 100, este problema torna-se intratável[1].

O problema da atribuição de horário – Dadas informações sobre horários de aulas, estudantes e cursos, existirá um horário para cada estudante que não cause conflitos ou superposições?

Desde a formulação desta classificação na Teoria da Complexidade Computacional a natureza dos problemas *NP* tem atraído cada vez mais a

[1] O problema do caixeiro viajante é, na verdade, um problema NP - completo, ou seja, pertence a uma classe específica de problemas NP. Contudo, não abordaremos detalhes técnicos aqui.

atenção dos cientistas da computação. Percebeu-se que muitos problemas que ocorrem na indústria tais como desenvolver algoritmos para projetar circuitos integrados automaticamente são do tipo *NP*. Poder resolver estes problemas de maneira eficiente significaria encontrar a chave para uma porção de "quebra-cabeças" que atormentam a vida prática de muitas pessoas, como, por exemplo, gerar ou decifrar códigos de segurança de agências militares governamentais. Voltaremos a falar de problemas *P* e *NP*, bem como da Teoria da Complexidade Computacional no Capítulo 4.

O TESTE DE TURING E O JOGO DA IMITAÇÃO

Em 1950, Alan Turing publicou um artigo intitulado "Computação e Inteligência" no qual formulou, pela primeira vez, de maneira explícita a questão: "Pode uma máquina pensar?" Além de formular esta questão, que ainda intriga a todos até hoje, Turing formulou, pela primeira vez, um teste para decidir quando poderíamos dizer que uma máquina pensa. Este teste ou critério geral ficou conhecido como *teste de Turing*, o qual se baseia no que ele chamava de "jogo da imitação".

O jogo da imitação envolve três pessoas, uma mulher (A), um homem (B) e um interrogador (C), que pode ser de qualquer sexo. O interrogador fica num quarto separado do homem e da mulher e seu objetivo – que constitui o objetivo do jogo – é determinar o sexo dos outros dois. Como o interrogador fica num quarto separado, ele conhece seus parceiros apenas por X ou Y e no final do jogo ele tem de dizer "X é A (uma mulher) e Y é B (um homem)" ou, alternativamente, "X é B (um homem) e Y é A (uma mulher)". Para determinar o sexo de X e de Y o interrogador deve formular uma bateria de questões. Por exemplo, ele pode começar perguntando:

C: O sr. ou a sra. Y poderia me dizer o comprimento de seu cabelo?

Se Y for de fato um homem, ele pode dar uma resposta evasiva e dizer "Meu cabelo é ondulado, o fio mais comprido deve ter uns 15 centímetros". As respostas sempre poderão ser evasivas e tanto X como Y poderão mentir. X pode também tentar tumultuar o jogo, despistando o interrogador com sentenças do tipo: "Ouça, eu sou o homem! Não ouça Y, ele o está tentando confundir. O que eu digo é verdade" Mas Y pode se utilizar da mesma estratégia. Assim sendo, cabe ao interrogador formular perguntas verdadeiramente capciosas para adivinhar o sexo de X e de Y.

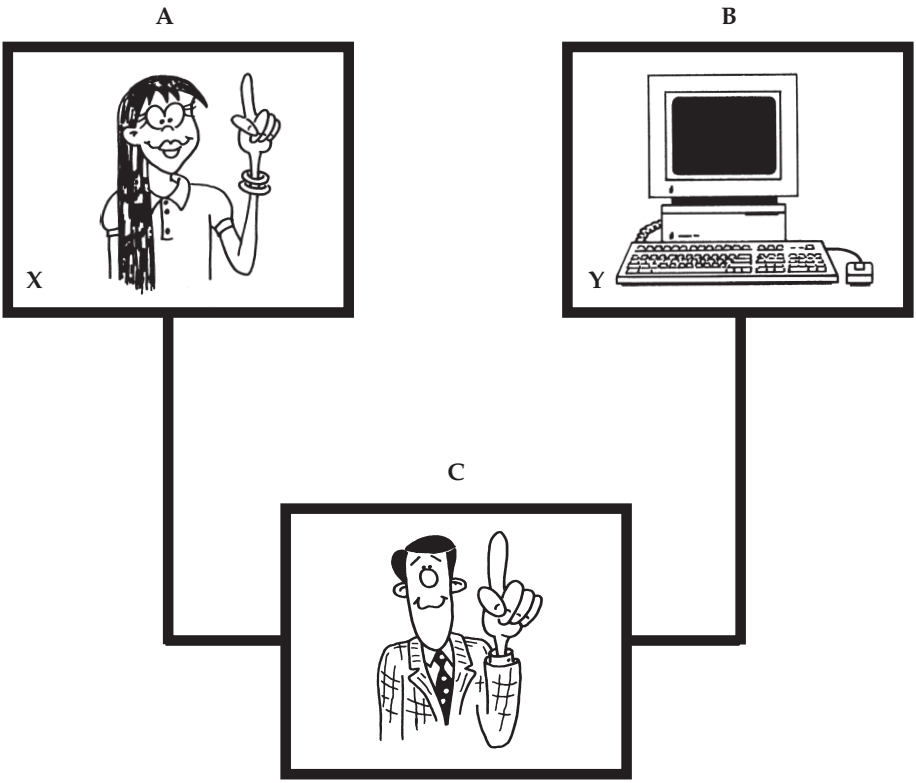

Figura 1.7. Esquema do jogo da imitação.

Para se jogar corretamente o jogo da imitação é preciso que seus participantes fiquem isolados uns dos outros, isto é, nenhum contato que permita a identificação do sexo de X ou de Y deve ser permitido. Isto significa dizer que C não poderá vê-los nem tampouco ouvir suas vozes. A comunicação entre C, X e Y deve ser feita por meio de um teclado de computador. As respostas devem aparecer numa tela.

Ora, suponhamos que em vez de um homem (B, ou Y), o jogo esteja sendo jogado por uma máquina. É possível que C nunca venha a descobrir o sexo de Y nem tampouco perceber que não estava jogando com um ser humano e sim com uma máquina! Se esta situação ocorrer – e é perfeitamente possível que ela ocorra – podemos *dizer que essa máquina passou no teste de Turing*. Em essência, o teste de Turing estabelece o seguinte critério para decidirmos se uma máquina pensa: se o comportamento de uma máquina for indistinguível daquele exibido por um ser humano, não há razão para não atribuir a essa máquina a capacidade de

pensar. No caso, o comportamento que estaria sendo perfeitamente simulado é o comportamento verbal.

À primeira vista, o teste de Turing choca-nos por parecer algo no mínimo bizarro, uma super-simplificação do que entendemos por "pensar". Mas, na verdade, ele oferece uma alternativa para a incapacidade de sabermos o que significa "pensar", "pensamento" ou "estados mentais". Mas qual será nosso critério cotidiano para sabermos quando alguém pensa? Nada além da observação de seu comportamento: se seu comportamento for idêntico ao nosso, sentimo-nos à vontade para atribuir pensamento a essa criatura. O critério de atribuição de pensamento baseia-se na aproximação com nossos possíveis comportamentos: é por intermédio desse critério que julgamos não apenas se outros seres humanos pensam, como também se os animais pensam. E não dispomos de nada melhor, uma vez que os filósofos nunca conseguiram chegar a um consenso sobre o que é pensar.

O teste de Turing recebeu muitas críticas por parte de vários filósofos que sempre apontaram para o fato de ele ser um critério exclusivamente comportamental para atribuir pensamento a criaturas humanas ou máquinas. De fato, é possível conceber algumas situações que mostram que o teste é insuficiente. Eu posso estar passando por uma rua e ouvir uma música, uma sonata de Beethoven vindo de algum lugar. Bato na porta da casa de onde julgo que a música vem, entro e constato que não havia ninguém tocando piano, apenas um aparelho de CD ligado. Todas as condições do teste se verificaram, ou seja, eu não estava vendo nada, apenas ouvindo sons e de repente me sentiria obrigado a atribuir estados mentais e pensamentos a um aparelho de CD! Neste caso, a aplicação do teste estaria me levando a uma afirmação bizarra. Por outro lado, eu poderia estar convivendo com uma pessoa, conversando e partilhando minha casa com ela. Um dia essa "pessoa" cai e bate a cabeça na borda da banheira e, em vez de miolos, dela saem *chips*. Percebo que eu estava convivendo o tempo todo com um robô, tão bem disfarçado e com um comportamento tão indistinguível do de um ser humano que a ele sempre atribuí pensamento, sem qualquer sombra de dúvida. Faria sentido agora, depois do acidente, eu dizer: "Não, na verdade você nunca teve pensamentos porque agora percebo que você era uma máquina"? Ou: "Sim, você pensava, mas agora que vi que você é feito de *chips* acho que você não pensa mais"?

Uma última observação: até hoje, o Museu do Computador de Boston promove, anualmente, uma competição de *softwares*. O melhor *software* é aquele que tem melhores condições de passar no teste de Turing e ganha o prêmio Loebner. Um dos melhores *softwares* foi o que venceu a competição em 1991, o *PC Therapist*, desenvolvido por Joseph Weintraub da *Thinking Software*. Este *software* conseguiu enganar cinco dos 10 juízes que compunham a banca examinadora do concurso.

O QUE LER

1 – Turing, A. *Computing Machinery and Intelligence*. Há tradução deste artigo para o português na coletânea *Cérebros, máquinas e consciência*, João de F. Teixeira (org.).
2 – Nagel, E. e Newman, J.R. *A Prova de Gödel.*
3 – Penrose, R. *A mente nova do rei* (primeira parte).

O leitor que quiser ampliar seu conhecimento sobre as noções introduzidas neste capítulo deve se remeter ao APÊNDICE B no final deste livro e também às seguintes obras:

4 – Epstein, R. e Carnielli, W. Computability: *Computable Functions, Logic and the Foundations of Mathematics*.
5 – Hopcroft, J. e Ullmann, J., *Introduction to Automata Theory, Languages and Computation.*
6 – Garey, M. e Johnson, D. *Computers and Intractability.*

Capítulo 2

Funcionalismo, pensamento e símbolos

Conceitos introduzidos neste capítulo:
- A idéia de um modelo computacional da mente.
- O neurônio de McCulloch.
- A Inteligência Artificial simbólica ou paradigma simbólico.
- O problema mente-cérebro.
- O funcionalismo.

Agora que estudamos as noções de computabilidade e máquina de Turing podemos delinear, com maior precisão, o que significa *o modelo computacional da mente*. A idéia de que a mente funciona como um computador digital e que este último pode servir de modelo ou metáfora para conceber a mente humana iniciou-se a partir da década de 40, quando o termo "Inteligência Artificial" sequer havia sido inventado. Naquela época, predominava um movimento chamado *cibernética,* do qual hoje mal ouvimos falar. Os ciberneticistas acreditavam que toda atividade psicológica humana poderia um dia ser estudada por meio de modelos matemáticos – da mesma maneira que podemos estudar fenômenos da natureza utilizando este tipo de modelo. Tratava-se de tornar a Psicologia uma ciência, nos mesmos moldes das ciências da natureza. Seu ponto de partida baseava-se na possibilidade de criar circuitos elétricos que pudessem modelar o funcionamento do cérebro, o que para eles seria suficiente para modelar também a atividade mental.

A grande intuição que orientou este movimento científico foi a analogia entre sistema nervoso e circuitos elétricos, ou seja, "de que se podia descrever em termos lógicos o funcionamento de certos sistemas materiais, mas que, inversamente, esses sistemas materiais podiam ser representados como encarnando a lógica"[1]. Dois grandes personagens se

[1]Dupuy (1994), p. 28.

sobressaem neste cenário: Claude Shannon, o criador da teoria matemática da informação, e o neurofisiólogo Warren McCulloch. Claude Shannon havia publicado, em 1938, a dissertação intitulada *A Symbolic Analysis of Relay and Switching Circuits* que originou estas idéias. McCulloch vai desenvolver um modelo do neurônio baseado na idéia de um sistema material que instancia o raciocínio lógico. Seu trabalho vai se celebrizar num artigo publicado em 1943 e que lhe valeu a fama: *A Logical Calculus of the Ideas Immanent in Nervous Activity*.

Passados os anos "cibernéticos" abandona-se a idéia de modelar o cérebro. Ganha força a idéia de que é possível modelar a *mente*, uma concepção que vai encontrar apoio na visão de que existe uma independência e uma relativa autonomia entre o *software* e o *hardware* das máquinas utilizadas para simular a inteligência. Marco desta nova tendência são os trabalhos de Newell e Simon, com seu programa para provar teoremas lógicos, o *Logical Theorist*, desenvolvido nos meados da década de 50. O grupo de Newell e Simon, que se tornou tendência dominante no panorama da Inteligência Artificial, sustentava que a analogia entre pensamento e circuitos neurais (entendidos como circuitos elétricos) não era muito proveitosa. Um caminho muito melhor seria simular os fenômenos mentais propriamente ditos, entendendo a mente como um conjunto de representações de tipo simbólico e regidas por um conjunto de regras sintáticas. O pensamento nada mais seria do que o resultado da ordenação mecânica de uma série de representações ou símbolos e, para obter esta ordenação não seria preciso, necessariamente, um cérebro.

É esta concepção de pensamento e inteligência – culminando nos anos 70 nos laboratórios do MIT – que vai levar ao aparecimento da RTM ou *Representational Theory of Mind* ou "Inteligência Artificial Simbólica". É também esta abordagem que teve maior repercussão filosófica, levando ao aparecimento de doutrinas específicas sobre as relações entre mente e cérebro (o funcionalismo) que examinaremos mais adiante.

OS ANOS 40 E O NEURÔNIO DE McCULLOCH

Conforme dissemos, a idéia de simular a mente iniciou-se com uma tentativa de simular o cérebro. Para simular o cérebro, é necessário simular a atividade de suas unidades básicas: os *neurônios*. Sabe-se também que os neurônios transmitem impulsos elétricos e que estes são fundamentais para o funcionamento do sistema nervoso. O sistema nervoso é uma vasta rede de neurônios distribuídos em estruturas com interconexões extremamente complexas. Esta rede recebe *input*s (sinais de entrada) de um grande número de receptores: as células dos olhos, os receptores de dor, frio, tato, os receptores de esforços musculares, etc.

Estes receptores transformam estes estímulos que provêm do mundo exterior em padrões de estímulos elétricos que fornecem informação para a rede de neurônios. Estes impulsos, por sua vez, interagem com padrões de estímulos elétricos que já se encontram presentes nos neurônios (calcula-se haver cerca de 10^{10} neurônios no cérebro humano) e provocam a emissão de outros impulsos que controlam os músculos e as glândulas, gerando as respostas ou comportamentos. Temos, assim, um sistema que poderia ser descrito, de forma esquemática, como funcionando em três grandes etapas: receptores, rede neural e efetores.

ESQUEMA NEURÔNIO

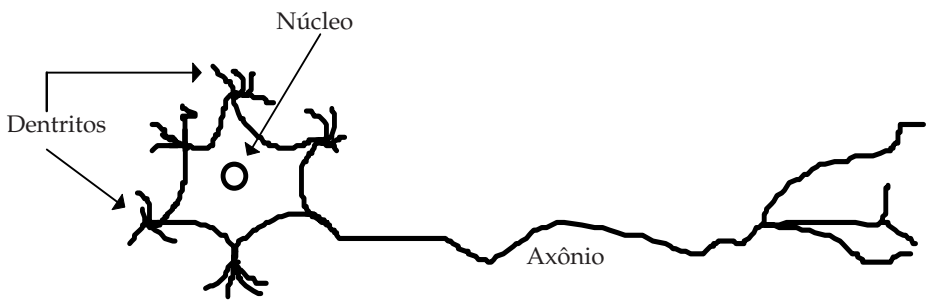

Figura 2.1. Esquema de um neurônio.

O neurônio é uma célula e, portanto, tem um núcleo contido no *soma* ou *corpo* da célula. Podemos imaginar os *dendritos* como filamentos muito finos, mais finos que os *axônios* e estes como um cilindro estreito que leva os impulsos do soma para outras células. O axônio divide-se numa delicada estrutura em forma de árvore cujos ramos terminam num pequeno *bulbo* que quase toca os dendritos de outro neurônio. Estes pontos de "quase-contato" denominam-se *sinapses*. Os impulsos que chegam a uma sinapse estabelecem sinais elétricos nos dendritos sobre os quais incide a sinapse. A transmissão interneuronal se faz por meio de substâncias denominadas neurotransmissores. Um determinado neurônio só dispara um impulso elétrico ao longo do axônio se o número de impulsos que chegam aos bulbos terminais de seus dendritos for suficiente. O tempo que leva para ocorrerem estes impulsos elétricos é chamado de *período de somação latente*. Tais impulsos que chegam podem ajudar ou impedir a ocorrência de um impulso pelo neurônio e se chamam, respectivamente de *excitadores* ou *inibidores*. A condição para a ativação de um neurônio é que a excitação supere a inibição numa quantidade crítica, chamada de *limiar do neurônio*.

Entre um período de somação latente e a passagem do impulso axonal correspondente aos bulbos terminais há um pequeno atraso, de

modo que a chegada dos impulsos aos dendritos de um neurônio não determina a ativação de seu axônio, a não ser após um certo intervalo de tempo.

Depois de passado um impulso pelo axônio, há um tempo, denominado de *período refratário*, durante o qual o axônio não transmite nenhum impulso. Assim sendo, durante um espaço de tempo equivalente a um período refratário um único impulso pode atravessar o axônio. Se tomamos como unidade de tempo o período refratário do neurônio, podemos determinar o comportamento deste, especificando se ele disparou durante os intervalos de tempo 1, 2, 3, etc.

Certamente este é um modelo supersimplificado do neurônio. Entretanto, foi a partir desta simplificação que se decidiu criar um modelo artificial do cérebro que pudesse simular a atividade mental como sendo, *grosso modo*, a somatória do funcionamento desta unidade básica. As bases para a construção deste modelo artificial foram lançadas por W. McCulloch e W. Pitts em 1943, tendo como ponto de partida este modelo simplificado do cérebro e as idéias de Claude Shannon, expostas na sua dissertação de mestrado de que falamos.

No final dos anos 30, Shannon defendeu a idéia de que os princípios da lógica (em termos de proposições verdadeiras ou falsas) poderiam ser usados para descrever os dois estados (ligado e desligado) de interruptores de relés eletromagnéticos. Assim sendo, os circuitos elétricos (do tipo dos do computador) poderiam expressar operações fundamentais do pensamento. Na realidade, Shannon mostrou que estes circuitos poderiam ser utilizados para expressar equações do tipo booleano. Tais equações tinham sido desenvolvidas por um matemático inglês, Georges Boole, na metade do século passado. Boole estudou as leis básicas do pensamento e as fundamentou sobre princípios de lógica. Para representar os componentes do pensamento, Boole utilizou-se de símbolos arbitrários (a, b, c, etc). Estes elementos simbólicos podiam ser combinados ou dissociados por meio de operações como adição, subtração, multiplicação, etc. de modo a formar novas expressões, resultantes das primeiras. Estas operações ficaram conhecidas como "álgebra de Boole" e, segundo seu autor, correspondem às leis do pensamento. Mais do que isto, Boole mostrou que sua lógica era um sistema de valores binário, ou seja, qualquer expressão podia receber um valor de verdade: 1 designaria expressões verdadeiras, 0 expressões falsas.

Reunindo as idéias de Boole, de Shannon e o modelo supersimplificado do cérebro humano de que falamos, W. McCulloch e W. Pitts propuseram um modelo de neurônio artificial. Eles acreditavam que, a partir deste modelo, seria possível simular redes de neurônios e, em última análise, a produção do pensamento. A intuição destes pesquisadores era que se neurônios artificiais pudessem efetuar computações lógicas, estaria aberto o caminho para simular o raciocínio humano.

Estes neurônios artificiais eram unidades binárias, i.e., podiam estar "ligados" ou "desligados". Cada unidade poderia receber *input*s excitatórios ou inibitórios de outras unidades. Quando uma unidade recebe um *input* inibitório ela vai para a posição "desligado". Quando não há *input* inibitório ela vai para a posição "ligado" (se a soma de *input*s excitatórios exceder o seu limiar). McCulloch e Pitts mostraram como a configuração destas unidades pode realizar as operações lógicas caracterizadas como "E", "OU" e "NÃO". As demais operações lógicas realizadas pela mente humana podem ser derivadas destas três e se com isto conseguimos implementá-las num circuito com neurônios artificiais teremos construído uma máquina de pensar.

Vejamos como isto acontece. Raciocinamos por meio de uma combinação de proposições, efetuada a partir dos chamados *conectivos lógicos*. A lógica nos ensina que estas combinações podem ser as seguintes: ou juntamos duas proposições (conectivo "E" ou $\wedge$) ou dissociamos duas proposições (conectivo "OU" também representado como $\vee$), ou negamos uma proposição (conectivo "NÃO" ou $\neg$), ou dizemos que uma proposição implica outra (conectivo "IMPLICA" ou $\Rightarrow$) ou que uma biimplica outra (conectivo SE E SOMENTE SE ou $\Leftrightarrow$). Além destes conectivos, temos ainda o "OU EXCLUSIVO" ou XOR (*Exclusive Or*), diferente do primeiro conectivo OU de que falamos acima. O primeiro conectivo "OU" ($\vee$) designa uma conjunção, como, por exemplo: "Você pode vir de terno ou de esporte fino". Isto significa que se eu puser um terno ou uma roupa esporte fino, ambas serão aceitáveis. No caso do OU EXCLUSIVO, temos uma situação do tipo: "No seu café da manhã você pode escolher panquecas ou cereais", significando que terei de escolher entre panquecas ou cereais – não posso optar por ambos. A lógica fornece-nos também uma tabela que, para cada conectivo, estipula as possíveis combinações de proposições e seus respectivos valores de verdade, ou seja, as chamadas *tabelas de verdade*. Por exemplo, para o conectivo "E" temos as seguintes possibilidades de combinação :

A	B	S
F	F	F
F	V	F
V	F	F
V	V	V

Na tabela anterior A e B simbolizam duas proposições; as duas colunas da esquerda apresentam o valor de verdade que estas proposições podem assumir e na coluna mais à direita o valor de verdade da combinação das mesmas.

Se podemos representar as proposições por meio de símbolos arbitrários, para simular o raciocínio humano precisamos conceber os neurônios artificiais de maneira a que eles simulem as operações lógicas, ou seja, simulem o que é feito pelos conectivos. Podemos convencionar que F será representado pelo estado 0, ou seja, aparelho desligado, ausência de corrente elétrica; o estado 1 representará aparelho ligado, corrente passando. A representação da função E é feita através do seguinte circuito:

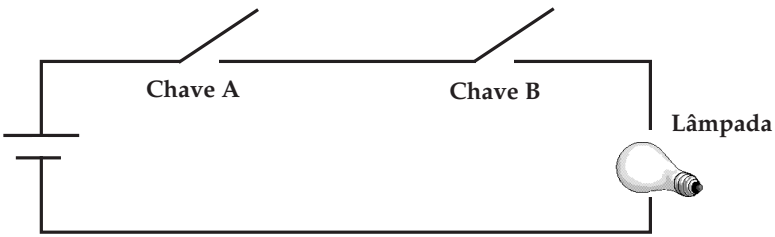

Figura 2.2. Representação de um circuito elétrico.

Convenções: E = energia, corrente. L= lâmpada, chave aberta = 0 , chave fechada =1, lâmpada apagada = 0, lâmpada acesa = 1.

Situações possíveis:

1 – Se a chave A estiver aberta (0) e a chave B aberta (0) não circula corrente no circuito e a lâmpada permanecerá apagada (0).

2 – Se temos a chave A aberta (0) e a chave B fechada (1) a lâmpada permanece apagada (0). ($A = 1, B = 0, A \wedge B = 0$).

3 – Se temos a chave A fechada (1) e a chave B aberta (0), a lâmpada permanece apagada (0). ($A = 1, B = 0, A \wedge B = 0$).

4 – Se a chave A estiver fechada (1) e a chave B fechada (1), a lâmpada acende, pois circula corrente. ($A = 1, B = 1, A \wedge B = 1$).

Podemos agora descrever a *porta lógica* i.e., o circuito que executa a função "E". Esta porta terá o seguinte formato:

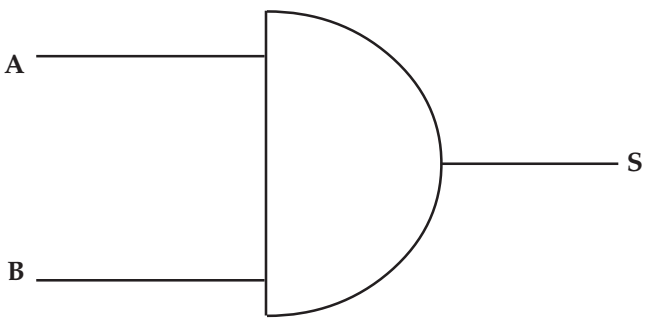

Figura 2.3. Representação de uma porta lógica.

Esta porta executa a função de verdade "E", ou seja, teremos a saída = 1 se e somente se as duas entradas forem 1 e temos a saída 0 nos demais casos.

Estivemos trabalhando até agora com duas variáveis de entrada, mas é possível estender esse conceito para qualquer número de entradas. Podemos imaginar uma porta lógica com *N* entradas e somente uma saída. A saída permanecerá no estado 1 se e somente se as *N* entradas forem iguais a 1 e permanecerá no estado 0 nos demais casos.

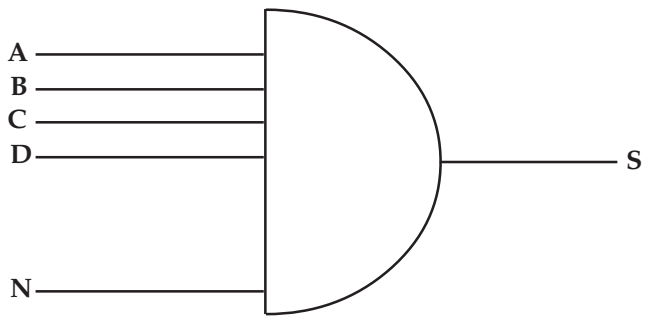

Figura 2.4. Representação de uma porta lógica com *n* entradas e uma única saída.

Esta é uma porta E de quatro entradas e sua tabela de verdade encontra-se a seguir:

A	B	C	D	S
0	0	0	0	0
0	0	0	1	0
0	0	1	0	0
0	0	1	1	0
0	1	0	0	0
0	1	0	1	0
0	1	1	0	0
0	1	1	1	0
1	0	0	0	0
1	0	0	1	0
1	0	1	0	0
1	0	1	1	0
1	1	0	0	0
1	1	0	1	0
1	1	1	0	0
1	1	1	1	1

Esta tabela de verdade mostra as 16 possíveis combinações das variáveis de entrada e seus resultados na saída. O número de situações é 2^N , onde N é o número de variáveis. Se $N = 4$, temos $2^4 = 16$, ou seja, 16 combinações possíveis para 4 variáveis de entrada.

Não analisaremos aqui as outras portas lógicas, correspondentes aos conectivos "OU", "NÃO", etc. por falta de espaço. Esta idéia de representar o raciocínio lógico humano através de circuitos e portas lógicas foi sendo progressivamente aperfeiçoada no decorrer da década de 50. Contudo, conforme veremos a seguir, este tipo de abordagem logo será substituída pela *abordagem simbólica* ou *paradigma simbólico* na Inteligência Artificial.

O MODELO SIMBÓLICO

As idéias e realizações de McCulloch e Pitts tiveram um grande sucesso, mas logo em seguida passaram a ser fortemente criticadas. Em 1947 os dois pesquisadores escrevem um novo trabalho investigando a possibilidade de construir circuitos com neurônios artificiais para efetuar o reconhecimento de padrões visuais. Eles estavam intrigados com a capacidade exibida por alguns animais e por humanos de reconhecer diferentes apresentações de um mesmo objeto – embora elas pudessem se manifestar de maneira bastante diferente. Na tentativa de resolver este problema, eles partiram da idéia de que as imagens com suas diferenças (entrando como *input* no sistema) seriam elaboradas até se conseguir uma representação canônica após múltiplas transformações. Eles projetaram uma rede de neurônios com duas camadas que poderia efetuar estas transformações.

Seguindo os passos de McCulloch e Pitts, Frank Rosenblatt projetou uma máquina semelhante para reconhecimento de padrões que passou a ser conhecida como *perceptron*. Contudo, o projeto de Rosenblatt seria fortemente criticado poucos anos mais tarde por Marvin Minsky e Seymour Papert – dois pesquisadores que lançaram as bases para o aparecimento do paradigma simbólico na Inteligência Artificial. Minsky e Papert analisaram e enfatizaram as limitações dos perceptrons. Segundo estes dois pesquisadores, as principais limitações dos perceptrons (pelo menos os de duas camadas de neurônios) estariam na gama de computações que eles podem efetuar. Haveria uma operação lógica, o "OU EXCLUSIVO" ou XOR que o perceptron não poderia realizar.

Ademais, nesta mesma época alguns avanços na Ciência da Computação estavam ocorrendo. Nos primeiros computadores, as regras para efetuar operações, isto é, as instruções ou programa do computador e os dados sobre os quais elas incidiam eram coisas distintas. As instruções tinham de ser ou parte do *hardware* da máquina ou este tinha de ser

manipulado especialmente para que as instruções fossem executadas passo a passo. Posteriormente, J. von Neumann mostrou que era possível colocar no mesmo plano instruções e dados. Não seriam necessários, dois conjuntos de memória separados, ou seja, um para os programas e outro para os dados. Isto foi uma imensa revolução em termos de como conceber a própria arquitetura dos computadores. Todos os computadores modernos seguem este tipo de arquitetura, chamado de "arquitetura von Neumann". É este tipo de arquitetura que proporciona a possibilidade de haver uma autonomia entre *hardware* e *software,* ou seja, a possibilidade de rodar programas diferentes no mesmo *hardware* e vice-versa. Mais do que isto: as máquinas com arquitetura von Neumann são todas seqüenciais. Estes dois fatores – tratamento igual de dados e programas e a seqüencialidade – estabeleceram um novo horizonte para a construção de computadores e para a possível simulação de atividades mentais que se distanciava muito do projeto de simulação do cérebro de McCulloch e Pitts, fortemente marcado pela dependência em relação a *hardware*s específicos, e paralelismo em vez de seqüencialidade.

Foi este horizonte que abriu as portas para se conceber a Inteligência Artificial simbólica, um paradigma que começou a ganhar contornos nítidos no final dos anos 60. A possibilidade de simulação da inteligência não estaria na construção de máquinas com *hardwares* específicos, mas no desenvolvimento de programas computacionais que operariam basicamente sobre dados ou representações. Esta segunda fase do modelo computacional da mente caracterizou-se pela idéia de que a inteligência resulta do encadeamento adequado de representações mentais – que nada mais seriam do que símbolos. *A mente é um programa computacional*, sua replicação depende de encontrar um programa computacional adequado que permita simulá-la. Retira-se a ênfase na construção de circuitos neurais elétricos: um programa pode ser rodado em diferentes tipos de *hardware*; o que importa é o programa em si e não o substrato material que possa instanciá-lo.

Isto significou uma mudança radical na direção das pesquisas; uma mudança que teria reflexos profundos nas décadas seguintes. A concepção de mente que é introduzida pela Inteligência Artificial simbólica concebe o aparato mental essencialmente como um dispositivo lógico que pode ser descrito por meio de um conjunto de computações abstratas, onde o que importa são as propriedades formais dos símbolos que são manipulados. Em outras palavras, a mente opera da mesma maneira que um *sistema formal* com suas propriedades sintáticas – entendendo-se por sistema formal um conjunto de símbolos e um conjunto de regras que nos permitem estipular as operações que podemos efetuar sobre esses símbolos. A semântica (o significado) dos símbolos é estabelecida pelo programador que constrói sua simulação computacional.

A mudança que se verifica nesta segunda fase – e que será predominante na IA até o fim dos anos 70 – é uma mudança em termos do próprio conceito de inteligência: inteligência resulta da representação mental, e esta nada mais é do que *atividade simbólica*. O que nos distingue de outros animais menos inteligentes é nossa *capacidade de produzir e manipular símbolos*. Este é o real caráter distintivo da inteligência humana: a produção e manipulação de símbolos que dão origem às atividades cognitivas superiores, como a Matemática e a linguagem.

Contudo, a manipulação de símbolos para produzir atividade inteligente deve ser voltada para a resolução de problemas. Esta é, aliás, a definição mais geral de inteligência: capacidade de resolver problemas. Assim sendo, para resolver um problema é preciso um caminho, um algoritmo que permita a manipulação adequada da atividade simbólica. É isto o que a mente faz, mas é isto que é feito também por uma máquina de Turing, que é o algoritmo mais geral possível. Daí a idéia que prevaleceu nos anos áureos da Inteligência Artificial (anos 70): *a máquina de Turing é o melhor modelo da atividade mental humana*. Pensar nada mais é do que realizar computações, uma em seguida da outra. Esta idéia encontrará eco no chamado modelo funcionalista da mente humana, que analisaremos logo a seguir.

A idéia de que proposições podem ser representadas em termos de 0s e 1s, como já se concebia nos "anos cibernéticos", levou também à idéia de que a mente nada mais é do que um *conjunto de proposições*. Pensar é encadear proposições por meio de conectivos lógicos e usar isto de forma a resolver problemas, isto é, de forma algorítmica.

Para resumir os principais delineamentos do modelo computacional da mente segundo a Inteligência Artificial simbólica, podemos nos valer do seguinte quadro:

1 – A mente é essencialmente um processador de informação.
2 – Informação pode ser representada na forma de símbolos.
3 – Símbolos combinam-se entre si por meio de um conjunto de regras.
4 – O funcionamento mental (ou cerebral) assemelha-se ao funcionamento de uma máquina de Turing.

Quem tem um pouco mais de familiaridade com Ciência da Computação pode conceber o modelo computacional da mente da seguinte maneira: Programas de computador consistem de estruturas de dados (*data structures*) e algoritmos. As linguagens de programação atuais incluem uma grande variedade de estruturas de dados que podem conter expressões do tipo "abc", números como 3, 4 e estruturas mais complexas, como, por exemplo, listas (A B C) e árvores. Os algoritmos operam sobre esses vários tipos de estruturas de dados. O modelo computacional da mente assume que a mente tem representações mentais análogas às

estruturas de dados e procedimentos computacionais análogos aos algoritmos. Podemos perceber isto no seguinte esquema:

Programa	Mente
estruturas de dados +	representações mentais +
algoritmos	procedimentos computacionais
= programas que rodam	= pensamento

O problema mente-cérebro

O aparecimento e a consolidação da Inteligência Artificial simbólica nos anos 70 trouxe um impacto profundo sobre outras áreas do conhecimento, sobretudo para a Filosofia. A questão que os filósofos levantavam nesta época era a seguinte: se computadores são um tipo especial de arranjo material, ou seja, uma combinação de elementos materiais de silício ou de qualquer outro elemento da natureza, e se eles puderem realizar tudo o que uma mente humana realiza, não haveria nenhuma razão para supor que mente e matéria são diferentes. Poderíamos igualar mentes e máquinas, cérebros e mentes. Este tipo de conjectura reavivou um dos debates mais tradicionais da Filosofia, qual seja, o problema das relações mente-cérebro.

Este é, na verdade, um problema filosófico milenar que tem suscitado, por parte dos filósofos, a produção de uma multiplicidade de diferentes teorias. Na Filosofia moderna este problema aparece pela primeira vez através da obra do filósofo francês René Descartes, no século XVII. Descartes foi o primeiro filósofo moderno a argumentar a favor da separação entre mente e corpo, sustentando a existência de uma assimetria essencial entre estas substâncias. Mente e cérebro (ou corpo) teriam propriedades irredutíveis entre si, como, por exemplo, a extensão e a divisibilidade, que seriam atributos do corpo – propriedades que em hipótese alguma poderiam ser atribuídas à mente ou à substância pensante.

A questão levantada por Descartes atravessa toda a Filosofia moderna, tendo sido alvo da atenção de vários filósofos nos séculos seguintes. Um dos problemas cruciais que emergem a partir da doutrina de Descartes é saber como é possível que uma substância imaterial (a mente) possa influir causalmente numa substância material (o corpo) e determinar a ação consciente ou deliberada.

No século XX, o problema das relações mente-cérebro passou a ser estudado mais intensamente, em grande parte pelo desenvolvimento das ciências do cérebro, que acalentavam a esperança de que ele poderia ser resolvido à medida que se compreendessem melhor os mecanismos cerebrais. Por outro lado, a partir da segunda metade do século XX aparece a

Filosofia da Mente, um ramo específico da Filosofia que tem por objetivo estudar a natureza do mental, tomando como pano de fundo as descobertas das neurociências e as teorias propostas pela Ciência Cognitiva.

Existe uma grande proliferação de doutrinas filosóficas que concebem, cada uma a seu modo, as relações entre cérebro e mente. É possível agrupá-las e classificá-las de diversas maneiras, cada uma respeitando as especificidades de cada concepção. Contudo, podemos sempre agrupá-las de acordo com as seguintes linhas-mestras:

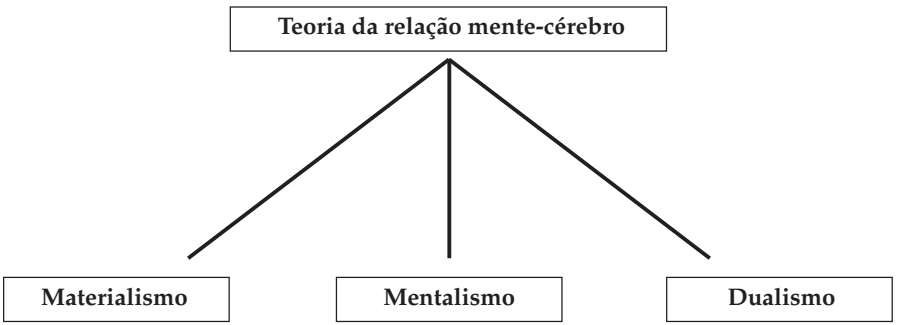

Figura 2.5. Doutrinas filosóficas sobre a relação mente-cérebro.

1 – *A visão dualista*: Sustenta que mente e corpo são substâncias diferentes. O corpo é uma substância extensa, ocupa lugar no espaço e tem propriedades físicas. A mente é outro tipo de substância, não ocupa lugar no espaço e não tem nenhum tipo de propriedade física. Mente e corpo são essencialmente distintos.

2 – *A visão mentalista*: Sustenta que a mente não é material, tampouco os objetos físicos com os quais ela interage no mundo. Objetos físicos nada mais são do que sensações produzidas pela mente. Esta visão não é muito desenvolvida no Ocidente, mas é defendida por várias religiões orientais.

3 – *A visão materialista*: Sustenta que a mente pode ser explicada a partir de leis físicas, da mesma maneira que o corpo.

Materialismo e mentalismo sustentam a existência de uma única substância no universo, seja ela física ou mental. Por isso, ambos constituem um tipo de monismo. Podemos falar de *monismo materialista* ou *monismo mentalista*, embora a palavra monismo seja freqüentemente utilizada para se referir ao monismo materialista. Já o dualismo sustenta que existem duas substâncias distintas e irredutíveis no universo: o físico e o mental.

Cada uma das concepções que apresentamos possui variedades específicas. As variedades da visão dualista, por exemplo, podem ser representadas no quadro a seguir:

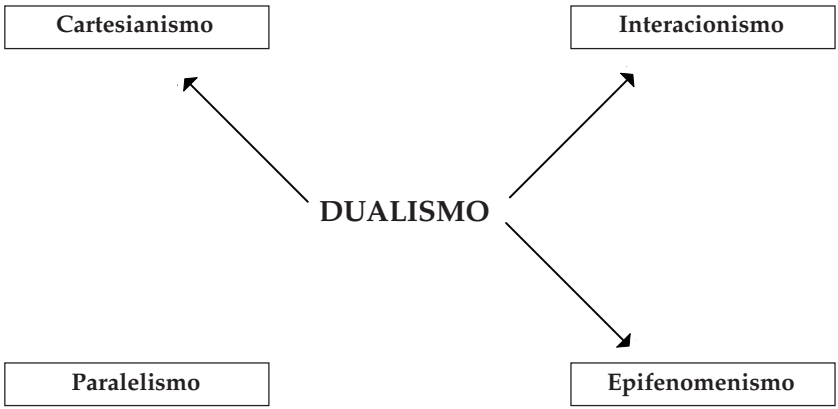

Figura 2.6. Concepções dualistas da relação mente-cérebro.

O *Cartesianismo* postula que mente e corpo são substâncias distintas, a primeira é inextensa e imaterial, a segunda é extensa e material.

O *Interacionismo* sustenta que a mente afeta o corpo e o corpo afeta a mente.

O *Paralelismo* dualista sustenta que corpo e mente correm em paralelo, nada tendo um a ver com o outro. É considerada uma doutrina bastante bizarra.

O *Epifenomenismo* sustenta que o corpo afeta a mente, mas a mente não afeta o corpo. Ou seja, o mental é uma espécie de subproduto da atividade cerebral, um subproduto que produz experiência subjetiva, mas é causalmente inerte.

Já as variedades do materialismo podem ser classificadas de acordo com o quadro a seguir:

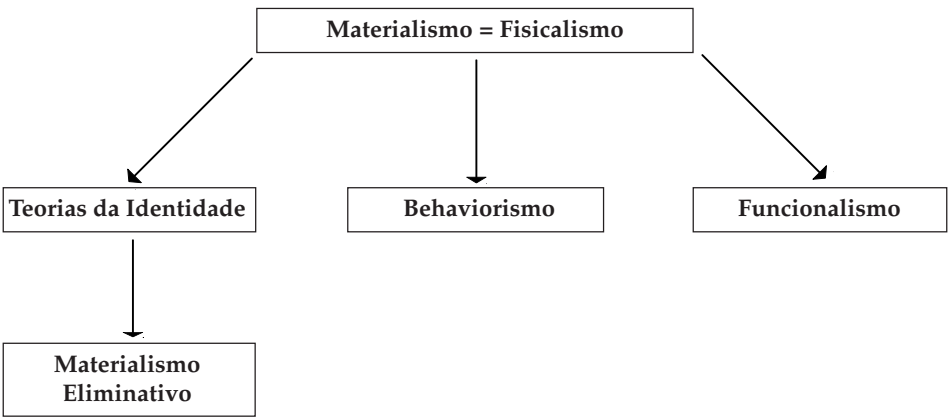

Figura 2.7. Concepções materialistas do problema mente-cérebro.

As *teorias da identidade* sustentam que estados mentais são estados cerebrais ou estados do sistema nervoso central. É uma teoria bastante recente, tendo sido sustentada por dois filósofos contemporâneos, J.J.C. Smart e U.T. Place.

O *behaviorismo* é um tipo de materialismo que sustenta que aquilo que chamamos de mente pode ser reduzido a comportamento manifesto. É preciso notar que o behaviorismo ou comportamentalismo possui muitas variedades ou subdivisões. O que dissemos, por exemplo, não se aplica ao behaviorismo radical.

Sobre o *funcionalismo* falaremos na seção seguinte. Resta, ainda, falar do *materialismo eliminativo* que classificamos como um tipo de teoria da identidade. O materialismo eliminativo sustenta que nossas teorias psicológicas habituais (a chamada *folk psychology*) que se utilizam de conceitos como intenções, crenças, desejos, etc., serão progressivamente substituídas por uma teoria científica, de forte base neurofisiológica. Tudo dependerá dos progressos futuros da neurofisiologia, que gradualmente eliminará tais conceitos, incluindo o próprio vocabulário psicológico oriundo destes e os substituirá por uma teoria científica da mente. A Psicologia, como ela se apresenta hoje em dia – envolvendo todos estes conceitos cotidianos –, não é mais do que uma teoria provisória que dará lugar a uma autêntica ciência do cérebro, da mesma maneira que nossa visão ingênua e cotidiana da natureza foi gradualmente substituída por uma teoria física com forte base científica. Retornaremos a este assunto – o materialismo eliminativo – na segunda parte deste livro, quando falarmos de conexionismo e redes neurais.

O FUNCIONALISMO

Como situar a teoria da mente defendida pelos partidários da Inteligência Artificial simbólica no quadro de "ismos" que apresentamos acima? Qual foi a contribuição da Inteligência Artificial para a reavaliação do problema mente-cérebro?

A noção de uma inteligência *artificial* como realização de tarefas inteligentes por dispositivos que não têm a mesma arquitetura nem a mesma composição biológica e fisico-química do cérebro levou à formulação de uma teoria específica das relações mente-cérebro: o *funcionalismo*. O funcionalismo, enquanto tese geral defendida pelos teóricos da Inteligência Artificial, sustenta que estados mentais são definidos e caracterizados pelo *papel funcional* que eles ocupam no caminho entre o *input* e o *output* de um organismo ou sistema. Este papel funcional caracteriza-se seja pela interação de um estado mental com outros que estejam presentes no organismo ou sistema, seja pela interação com a produção de determinados comportamentos. O funcionalismo consiste, assim, num nível

de descrição no qual é possível *abster-se* ou *suspender-se* considerações acerca da natureza última do mental, isto é, se ele é ou não, em última análise, redutível a uma estrutura física específica. A descrição das funções é uma descrição abstrata, que tem o mesmo estatuto da descrição de um *software* ou fluxograma que estipula quais as instruções que um computador deve seguir para realizar uma determinada tarefa.

É também com base nesta tese de que estados mentais se definem pelo seu papel funcional que um sistema pode apresentar predicados mentais independentemente do tipo de substrato físico do qual eles poderiam eventualmente resultar. Um mesmo papel funcional que caracteriza um determinado estado mental pode se instanciar em criaturas com sistemas nervosos completamente diferentes, e nesse caso diremos que eles estão no *mesmo* estado mental. Um marciano pode ter um sistema nervoso completamente diferente do meu, mas se o sistema nervoso desse marciano puder executar as mesmas *funções* que o meu, o marciano terá uma vida mental igual à minha – pelo menos na perspectiva do funcionalismo.

Ora, o funcionalismo não implica necessariamente uma postura materialista mas também não é incompatível com este último. Um aparelho de rádio (*hardware*) toca uma música (*software*): a música e o aparelho de rádio são coisas distintas, irredutíveis uma a outra, embora sejam ambas necessárias para que possamos ouvir uma música. A música (ondas eletromagnéticas) é diferente do aparelho de rádio (*hardware*), mas ambos fazem parte do mundo material. Neste sentido, podemos sustentar a compatibilidade do funcionalismo com o materialismo, uma visão preferida pelos filósofos da mente que repensaram o problema mente-cérebro à luz da Inteligência Artificial.

É também esta perspectiva que é explorada num célebre artigo sobre o problema mente-cérebro na Inteligência Artificial publicado em 1975 pelo filósofo norte-americano Hilary Putnam. A idéia de Putnam é que a máquina de Turing fornece-nos uma excelente analogia ou um bom modelo para concebermos a relação mente-cérebro: de um lado, há um conjunto de regras abstratas (instruções) e, de outro, a realização física dessas regras obtidas pelos diferentes estados da máquina. Assim, a analogia consiste basicamente em estabelecer uma correlação entre estados mentais (pensamentos) e o *software* (conjunto de instruções da máquina ou o programa do computador) de um lado e entre estados cerebrais e o *hardware* ou os diferentes estados físicos pelos quais passa a máquina ao obedecer às instruções. O psicoparalelismo torna-se, assim, concebível com base neste esquema conceitual – um psicoparalelismo que dispensaria qualquer tipo de pressuposição metafísica responsável pela possibilidade de interação entre o físico e o mental.

Finalmente, é preciso notar que há vários tipos de funcionalismo, sendo que o mais importante para a Inteligência Artificial simbólica é o

chamado funcionalismo *a la* máquina de Turing, segundo o qual a mente é a instanciação de uma máquina de Turing no substrato biológico do cérebro.

O QUE LER

Sobre o paradigma simbólico

1 – Pylyshyn, Z. *Computation and Cognition.*

Sobre o problema mente-cérebro:

2 – Churchland, P. *Matter and Consciousness.*
3 – Putnam, H. "Minds and Machines" in *Minds and Machines*, Anderson, A. (ed).
4 – Teixeira, J. de F. *O que é Filosofia da Mente.*
5 – Teixeira, J. de F. *Filosofia da Mente e Inteligência Artificial* (capítulo 5).

CAPÍTULO 3

Sistemas Especialistas

Conceitos introduzidos neste capítulo:
- A idéia de sistema especialista.
- Características dos sistemas especialistas.
- Exemplo de um sistema especialista.
- Áreas de aplicação dos sistemas especialistas.
- O problema da representação do conhecimento.
- Alguns métodos de representação do conhecimento: regras e *frames*.
- Os problemas enfrentados na construção de sistemas especialistas.

A Inteligência Artificial simbólica deixou um legado de grandes realizações. Desde o aparecimento do L.T. de Newell e Simon (ao qual aludimos na Introdução) até o final dos anos 80 proliferaram programas computacionais projetados para realizar tarefas específicas que requeriam inteligência. Alguns deles ficaram famosos, como é o caso do DENDRAL, do MACSYMA e do HEURISCO. O DENDRAL foi um programa projetado para determinar a fórmula estrutural dos compostos químicos. O MACSYMA foi projetado para efetuar manipulações algébricas na Física e na Matemática. Já o HEURISCO foi concebido como um solucionador geral de problemas que pode atuar em áreas diferentes, como a Biologia, a Matemática e jogos de xadrez e de damas.

Este tipo de programa que simula aspectos específicos da inteligência humana é chamado de *sistema especialista*. Os sistemas especialistas são solucionadores de problemas acoplados a imensos bancos de memória onde conhecimento humano acerca de uma determinada área ou disciplina encontra-se estocado. Este acoplamento permite ao sistema especialista responder a consultas, fornecer conselhos (sobre um determinado assunto) para leigos, auxiliar os especialistas humanos e até mesmo auxiliar no ensino de uma disciplina ou área de conhecimento específica.

A idéia subjacente à construção dos sistemas especialistas é que a inteligência não é apenas raciocínio, mas também *memória*. Cotidianamente, atribuímos inteligência a uma pessoa quando esta possui

grande quantidade de informação sobre um determinado assunto, ou seja, quando esta pessoa é capaz de *memorizar grande quantidade de informação*. Assim sendo, a construção dos sistemas especialistas obedece ao princípio de que

MEMÓRIA É CONDIÇÃO NECESSÁRIA PARA A INTELIGÊNCIA.

O grande sucesso de que desfrutaram os sistemas especialistas nas décadas de 70 e 80 foi também orientado pela idéia de preservar os conhecimentos de especialistas humanos, mesmo após o desaparecimento destes. Se há um mito que pode expressar este tipo de projeto, nós o encontramos num conto de Douglas Hofstadter, *A Conversation with Einstein´s Brain* (Uma conversa com o cérebro de Einstein) publicado na coletânea *The Mind´s I,* em 1981. Hofstadter imagina uma situação na qual toda informação contida no cérebro de Einstein é armazenada numa espécie de livro, pouco antes de sua morte. O livro é inserido, então, num sistema que permite realizar operações de vários tipos como, por exemplo, acessar informações, fazer perguntas e obter respostas, etc. O sistema como um todo simula a atividade do cérebro de Einstein e permite manter com ele uma conversa póstuma. Todas as respostas fornecidas são exatamente o que Einstein teria dito se estivesse vivo!

Este certamente seria o sonho de preservação de conhecimento dos construtores de sistemas especialistas. Um sonho ainda bastante distante da realidade, pois estocar conhecimento humano em estruturas de dados é uma tarefa que enfrenta vários desafios. Por exemplo, é preciso *representar* a totalidade dos conhecimentos que se quer estocar numa determinada estrutura de dados. E isto pode não ser fácil. Quando entrevistamos um especialista humano num determinado assunto – para fazer a coleta de informação e instruir nossa base de dados – muitas vezes deparamos com procedimentos sobre os quais o próprio especialista tem dificuldade de expressar. São procedimentos e conhecimentos que o especialista atribui a um "sexto sentido" ou a uma "intuição" que resiste à conceitualização ou a uma expressão clara. Este é o caso típico, por exemplo, daquela pessoa que sabe consertar o defeito do motor de um carro, mas não sabe dizer exatamente o que faz nem que tipo de função desempenham as peças desse motor. Casos deste tipo são um desafio para a chamada *aquisição de conhecimento*, uma etapa fundamental para a construção de sistemas especialistas.

A tentativa de construir sistemas especialistas para recobrir uma gama cada vez maior de tarefas humanas inteligentes acabou igualmente levantando uma série de questões importantes. Verificou-se que é muito mais fácil construir estes sistemas quando o domínio de conhecimento já possui ou pode receber facilmente uma *expressão simbólica*. Este é o caso, por exemplo, de domínios como a lógica, a matemática e do jogo de

xadrez, que são domínios formalizados ou passíveis de receber expressão formal (simbólica). O mesmo já não ocorre em outros domínios. Seria extremamente difícil construir um sistema especialista para ensinar uma criança a andar de bicicleta; mesmo porque encontraríamos grande dificuldade para expressar num conjunto de regras o que devemos fazer para andar de bicicleta.

Os problemas envolvidos na aquisição e na formalização do conhecimento levantam ainda outras questões para a Inteligência Artificial. Até que ponto a formalização é um instrumento eficiente para a representação do conhecimento? Haverá limites para a representação formal do conhecimento humano? Até que ponto um sistema especialista poderia gerar conhecimento *novo*? Poderia um sistema especialista realizar *descobertas* a partir da recombinação de dados de sua base de memória?

Examinaremos em primeiro lugar a arquitetura geral dos sistemas especialistas para em seguida voltar a falar de alguns aspectos envolvidos na questão da representação do conhecimento.

SISTEMAS ESPECIALISTAS: CARACTERÍSTICAS GERAIS

A construção de sistemas especialistas obedece ao princípio de que a simulação da inteligência pode ser feita a partir do desenvolvimento de ferramentas computacionais para fins específicos, o que torna tais sistemas verdadeiros especialistas em algum tipo de área de conhecimento. Um sistema especialista é muito mais do que um programa computacional. Na realidade, como já observamos, ele é um programa acoplado a um banco de memória que contém conhecimentos sobre uma determinada especialidade. Não se trata apenas de formalizar uma certa quantidade de conhecimento, mas de representá-lo de acordo com o modo como um especialista numa determinada área pode fazê-lo. E esta representação deve ser construída de tal modo que um computador possa manipulá-la através de uma linguagem formal apropriada. Por exemplo, um componente importante de uma base de conhecimento é o modo pelo qual os conceitos se relacionam mutuamente. Se tomarmos um sistema especialista para efetuar diagnóstico médico, este terá de ser capaz de relacionar sintomas de doenças com sintomas causados por efeitos colaterais de determinados tratamentos e enquadrá-los, por sua vez, em algum tipo de categoria geral que leve a uma definição de um determinado diagnóstico, e assim por diante.

O processo de construção destes sistemas especiais levou ao aparecimento de uma nova área na Ciência da Computação, *a Engenharia do Conhecimento*, isto porque a construção de um sistema especialista pressupõe uma forma especial de interação entre aqueles que o desenvolvem (o engenheiro de conhecimento) e os especialistas humanos de

uma determinada área. A tarefa do engenheiro de conhecimento é "extrair" dos especialistas humanos seus procedimentos, estratégias, raciocínios, etc. e codificá-los de forma a gerar bancos de dados. Tal atividade de construção de um sistema especialista pode ser representada da seguinte forma:

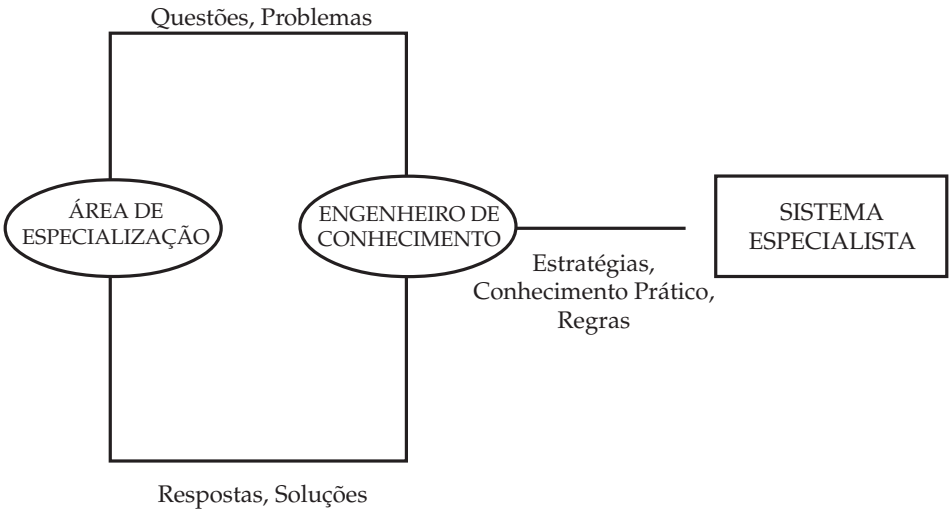

Figura 3.1. Esquema do conjunto de atividades necessárias para a construção de um sistema especialista.

O "coração" do sistema especialista é o *corpo de conhecimento,* elaborado durante sua construção. O conhecimento armazenado no corpo de conhecimentos deve ser *explícito* e *organizado*. Ou, em outras palavras, o conhecimento armazenado deve ser *público,* isto é, suscetível de ser transmitido. A habilidade de armazenar o conhecimento estratégica e adequadamente é fundamental para a construção de sistemas especialistas com grande eficiência e que simulem os melhores especialistas humanos de uma determinada área.

Outra característica importante do sistema especialista adequadamente construído é seu *poder preditivo* que o permite fornecer respostas para um problema mesmo quando novas situações aparecem.

O corpo de conhecimento determina igualmente mais uma característica do sistema especialista: *a memória institucional*. Se o corpo de conhecimento foi construído através de uma interação com os melhores especialistas de uma área (numa determinada época), isto significa que o sistema especialista se torna uma *memória permanente* ou retrato do conhecimento disponível numa determinada área, em uma determinada

época. Um retrato que subsiste posteriormente ao desaparecimento destes especialistas.

Vale ainda lembrar uma última característica dos sistemas especialistas: eles se tornam uma ferramenta para treinar seres humanos que estão se iniciando numa determinada área. Isto ocorre quando eles incluem uma interface amigável e incluem na sua construção algumas técnicas de ensino. Este tipo de característica pode ser muito útil na vida de uma empresa: quando alguns especialistas em áreas muito específicas saem da empresa, é possível treinar outros em curto espaço de tempo. Vejamos então como todas estas características se agregam, usando o diagrama a seguir:

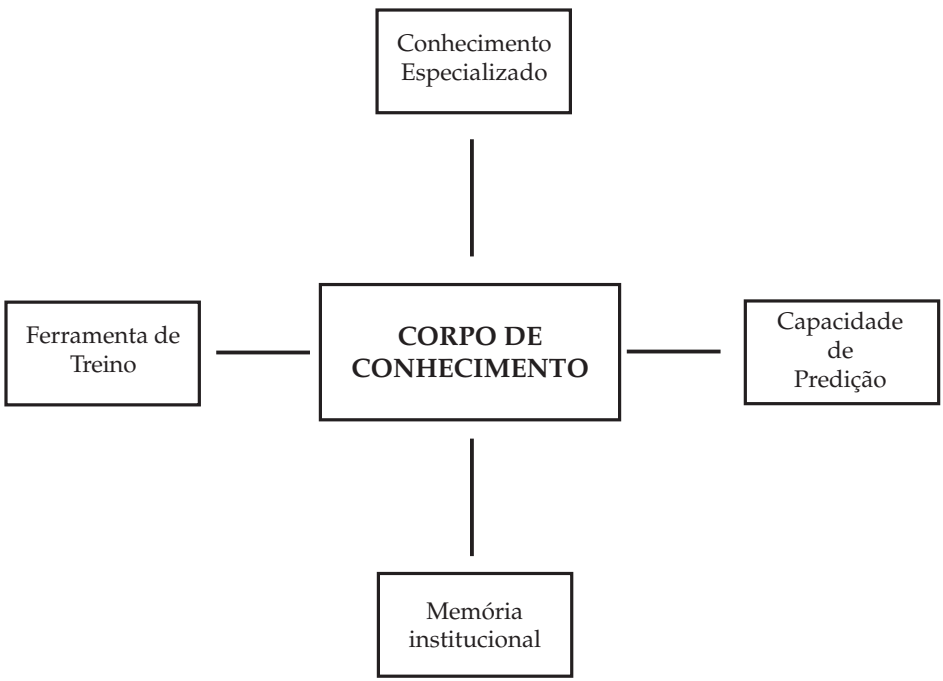

Figura 3.2. Características do corpo de conhecimento de um sistema especialista (adaptada de Waterman, 1986, p.6).

Dissemos que o conhecimento no sistema especialista é *organizado.* Conhecimentos acerca de uma área específica ficam separados de outros conhecimentos que estão no sistema, como, por exemplo, conhecimentos gerais acerca de resolução de problemas ou conhecimentos que permitem a interação com o usuário.

Este conhecimento acerca de uma área específica é chamado de *base de conhecimento* e aqueles sobre resolução de problemas são denominados de *mecanismo de inferência*. Programas projetados desta maneira são chamados *sistemas baseados em conhecimento*.

A base de conhecimento de um sistema especialista contém fatos (dados) e regras para usar estes fatos no processo de tomar decisões. O mecanismo de inferência contém um intérprete que decide como aplicar as regras de maneira a gerar novos conhecimentos. Esta maneira de organizar o sistema pode ser representada através da Figura 3.3.

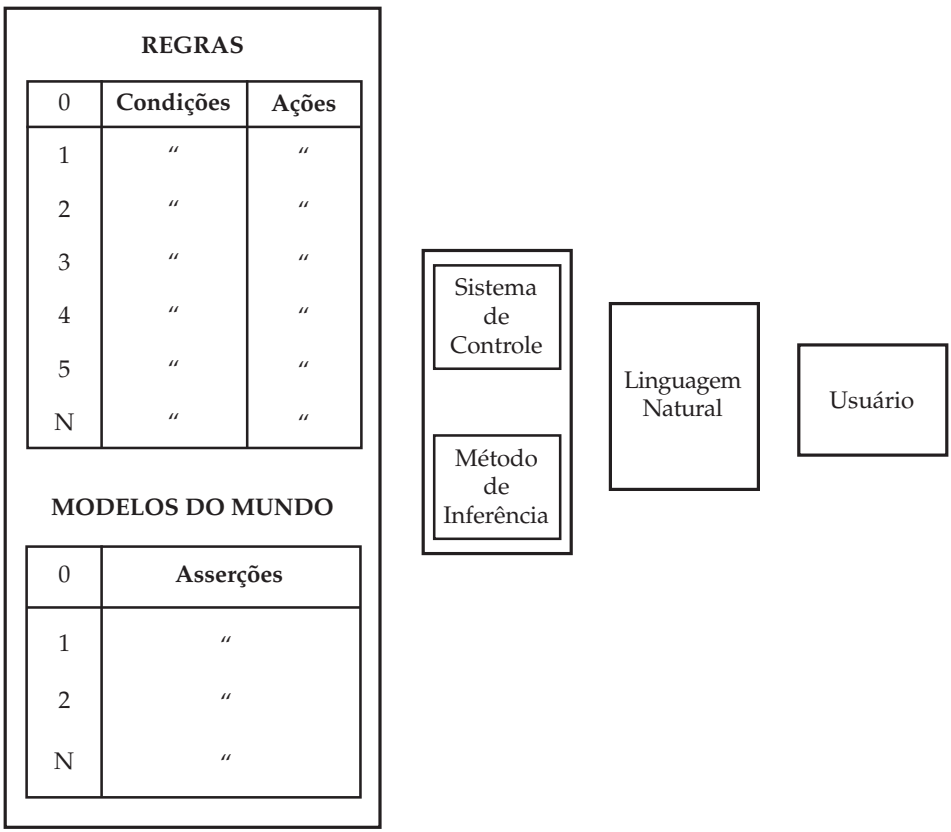

Figura 3.3. Representação da base de conhecimento de um sistema especialista e sua interação com o usuário.

Na figura anterior, no canto esquerdo, vemos *a base de conhecimento;* no canto direito, *a interface com o usuário,* que entra com fatos que descrevem um problema e fornece informação que o sistema pode necessitar durante seus processos de inferência. Em geral, os sistemas

especialistas utilizam-se de interfaces com linguagem natural para facilitar a comunicação usuário/sistema. O mecanismo de inferência (centro) tem um papel extremamente importante no sistema especialista: ele usa asserções (fatos) e estratégias de resolução de problemas para gerar conclusões.

EXEMPLOS DE SISTEMAS ESPECIALISTAS

Vamos agora examinar como funcionam os sistemas especialistas. Tomemos dois exemplos que ficaram famosos: o MYCIN, utilizado para auxiliar na diagnose médica e o PROSPECTOR, utilizado para ajudar geólogos na exploração mineral. Este segundo sistema especialista será examinado em maior detalhe.

O MYCIN foi um sistema especialista desenvolvido durante a década de 70, com a finalidade de prescrever medicação para pacientes com infecções bacterianas. Ora, não é muito difícil de imaginar como teria de funcionar um sistema deste tipo: ele teria de ter um sistema de raciocínio que permitisse, a partir de um conjunto de sintomas, identificar a moléstia a eles correspondente para, em seguida, emitir uma receita. Uma base de dados contendo os sintomas e um sistema de raciocínio do tipo SE... ENTÃO pareceria suficiente para construir um diagnosticador artificial. Uma aplicação desta regra seria mais ou menos assim:

SE
O paciente apresenta **febre**,
o paciente apresenta **vômitos e diarréia,**
o paciente está **desidratado**
ENTÃO o paciente sofre de **infecção intestinal**.
SE
O paciente sofre de **infecção intestinal,**
ENTÃO
o paciente deve tomar (um **determinado antibiótico**).

Este seria um caminho preliminar para construir um diagnosticador de infecções bacterianas. Infelizmente, o diagnóstico médico envolve uma grande margem de imprecisão, ou seja, ele envolve raciocínios inexatos e falta de conhecimento completo. Ou seja, existe um componente probabilístico no acerto de diagnósticos médicos, na medida em que, por exemplo, nem todos os sintomas ocorrem num paciente. Uma maneira de contornar esta dificuldade é através da atribuição de pesos diferentes a sintomas mais relevantes na caracterização de uma doença e, através

destes pesos, estipular, com grande margem de probabilidade, que o paciente está sofrendo de uma determinada moléstia. É aproximadamente desta maneira que o MYCIN opera: com uma margem de probabilidade que não fica muito distante daquela exibida pelos especialistas humanos.

Examinemos agora o PROSPECTOR, um sistema desenvolvido por Richard Duda, no *Stanford Research Institute* (SRI), e criado com a finalidade de ajudar os geólogos na exploração mineral (descrito em Waterman, 1986, pp. 55-57). O Prospector foi desenvolvido de 1974 a 1983 e para sua construção colaboraram nove geólogos e vários engenheiros do conhecimento. O longo tempo envolvido na sua construção deve-se à própria complexidade do sistema, que conta com mais de mil regras e estoca mais de mil termos geológicos. O PROSPECTOR foi um sistema especialista muito bem sucedido: em 1980 ele possibilitou a descoberta de uma reserva de molibdênio num local próximo a Washington – local que até então tinha sido apenas parcialmente explorado.

Como funciona o sistema? Em primeiro lugar, os usuários inserem no sistema informação geológica geral acerca de uma determinada região. A partir deste conjunto de informações preliminares, o PROSPECTOR aplica regras que estabelecem uma conexão entre evidência de descobertas geológicas (E) e certas hipóteses (H), de acordo com os fatores de certeza LS e LN. LS é o fator que indica o quanto podemos acreditar na hipótese e LN o quanto devemos duvidar da hipótese. A aplicação da regra toma então a seguinte forma:

SE (E) **ENTÃO** H (*EM GRAU*) LS, LN

LS e LN não são os únicos fatores de certeza do PROSPECTOR. Cada evidência e cada hipótese no sistema tem seu fator de certeza (P). (P) representa a probabilidade de que existe evidência ou que a hipótese é válida.

A evidência no PROSPECTOR é uma combinação lógica de vários tipos de evidência, como, por exemplo:

E1 e E2 e E3
E1 ou E2
E1 e (E2 ou E3)

A hipótese H é sempre um conceito independente; por exemplo, H2 pode ser usado no antecedente SE da regra para sugerir ou implicar outras hipóteses, como:

$$H2 \Rightarrow H1\ (LS2, LN2).$$

As regras no PROSPECTOR formam uma grande *rede de inferências* que indicam todas as conexões entre evidência e hipóteses, ou seja, todas as cadeias de inferência que podem ser geradas a partir das regras. A

cadeia de inferências que se forma a partir de três regras simples pode ser representada assim:

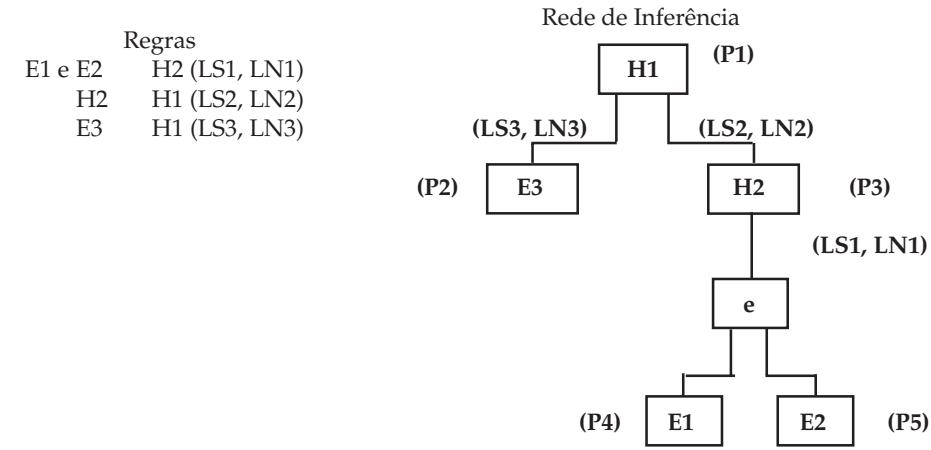

Figura 3.4. Representação das regras e rede de inferência em um sistema especialista, o PROSPECTOR (adaptada de Waterman, p. 56).

Cada um dos três modelos no PROSPECTOR é uma coleção de centenas de regras que forma uma rede de inferências. Os valores para os fatores de certeza LS e LN foram definidos quando o modelo foi construído e permanecem fixos durante a operação. Os valores de (P) – o fator de certeza para a evidência e para as hipóteses – também foram colocados no modelo, mas eles mudam à medida que nova informação é adicionada pelo usuário. Suponhamos, por exemplo, que o usuário adiciona a seguinte informação sobre a evidência E1 na figura anterior:

E1 pode estar presente na região

O PROSPECTOR mapeia essa expressão subjetiva de certeza acerca de E1 numa escala que vai de -5 a +5 . Neste caso, o número escolhido pode ser 2. O sistema usa então o número 2 para ajustar a probabilidade P4 que já estava associada com a evidência E1. Uma vez que 2 é maior do que 0, P4 é ajustada para cima. À medida que P4 muda, a probabilidade de E1 muda e a probabilidade de que H2 seja válida também muda.

Mudar a probabilidade de E1 causa uma mudança na probabilidade de H2, que, por sua vez, causa uma mudança na probabilidade de H1. Esta propagação de probabilidade ocorre automaticamente no PROSPECTOR. A propagação continua para cima, em direção aos nódulos superiores, mudando as probabilidades da hipótese inicial, por exemplo, de que a região possui determinado tipo de minério.

A parte do sistema que propaga as probabilidades para cima por meio da rede de inferências é o *mecanismo de inferência* do PROSPECTOR. A propagação de probabilidade não se inicia até que o usuário forneça

novas informações para o sistema. O mecanismo de inferência deve decidir as perguntas que devem ser feitas ao usuário.

Na figura anterior, se H1 for o objetivo, o sistema examinará as regras E3 ⇒ H1" e H2 ⇒ H1" para determinar se, saber E3 ou H2 afeta a probabilidade de H1. Se E3 tivesse o mesmo efeito, o sistema pediria ao usuário informações sobre E3. Se H2 tiver mais conseqüências, os sistema usará o mesmo procedimento para encontrar a questão que, uma vez formulada, afetará a probabilidade de H2. Esta é uma busca do tipo "de trás para a frente" (*backward chaining*) que continua até que uma questão seja escolhida.

APLICAÇÕES DE SISTEMAS ESPECIALISTAS

São várias as áreas do conhecimento que contam com o auxílio de sistemas especialistas. Para citar apenas algumas delas: Química, Engenharia, Direito, Medicina, etc. Nos diagramas a seguir, adaptados do livro *A Guide to Expert Systems*, de Donald Waterman, apresentamos os sistemas especialistas mais importantes em três diferentes áreas de aplicação: Química, Medicina e Engenharia.

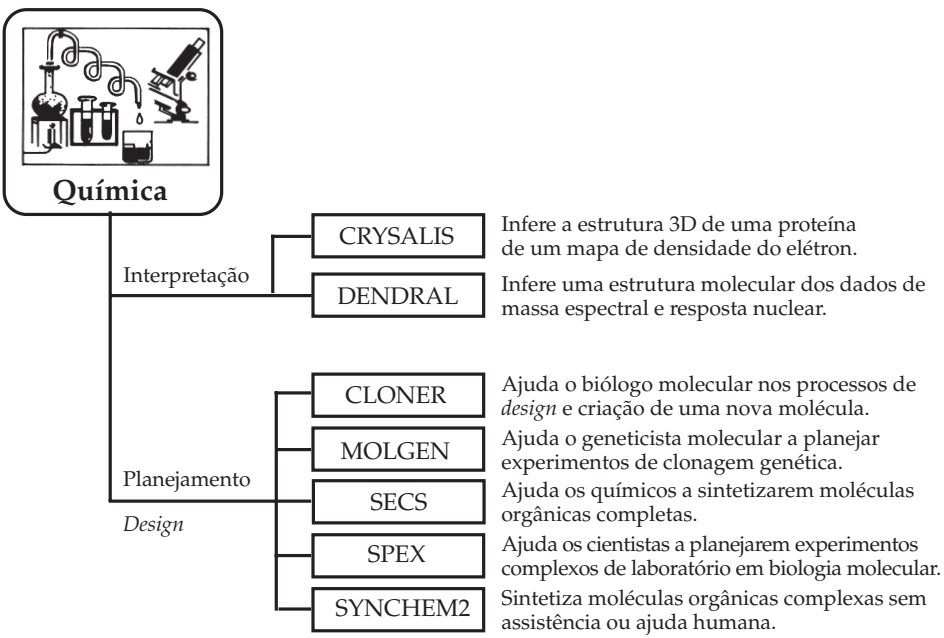

Figura 3.5. Esquema com exemplos de sistemas especialistas na área de Química com a descrição de sua principal função.

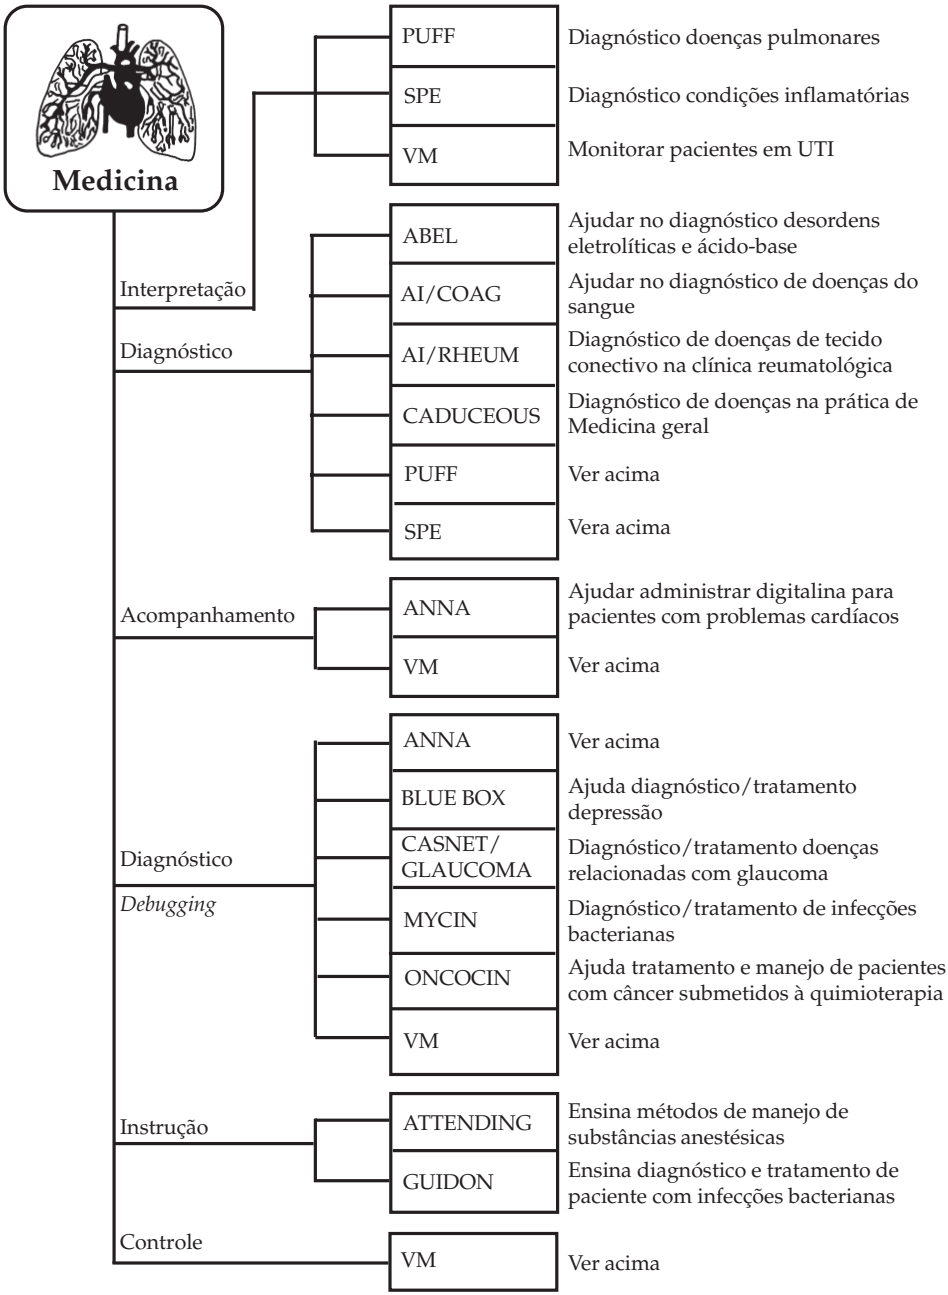

Figura 3.6. Esquema com exemplos de sistemas especialistas em Medicina, com a descrição de sua função.

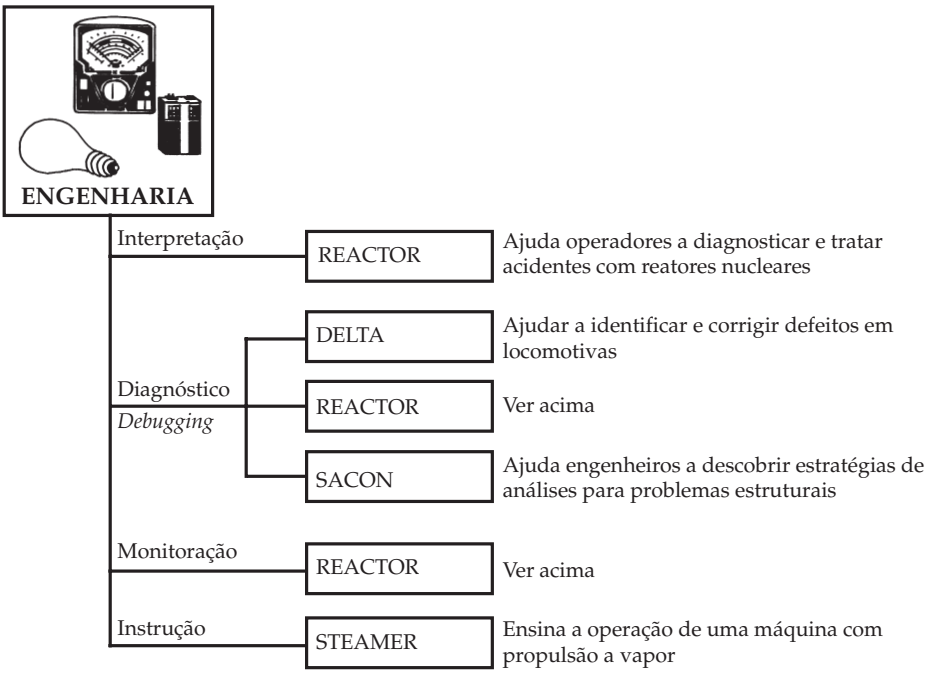

Figura 3.7. Esquema com exemplos de sistemas especialistas em Engenharia, com a descrição de sua função.

REPRESENTAÇÃO DO CONHECIMENTO EM SISTEMAS ESPECIALISTAS

Na análise do funcionamento do PROSPECTOR, o leitor deve ter notado que este sistema especialista funciona basicamente por meio de um sistema de regras do tipo **Se... então**. Esta é uma maneira muito freqüente de representar conhecimento em sistemas especialistas. Mas hoje em dia há ainda outras técnicas, além de redes de regras, para representar conhecimento nestes sistemas.

Regras do tipo **Se... então** são chamadas de *regras de produção.* Uma regra estabelece que certas conclusões (conseqüentes) seguem-se de certas condições (antecedentes). Quando um antecedente é verdadeiro, o conseqüente é verdadeiro e a regra "dispara". Uma regra num sistema complexo não leva necessariamente a uma conclusão final. Às vezes, uma série delas precisa ser disparada até que se chegue à conclusão final. Alguns sistemas podem incluir "regras acerca de suas próprias regras", ou seja, regras que estipulam quando certas regras devem ser usadas. Este tipo de regras são as chamadas *metarregras* e constituem o *metaconhecimento* do sistema, ou seja, uma espécie de conhecimento do sistema sobre si mesmo.

De modo geral, a representação do conhecimento através de regras pode reunir várias vantagens. Dentre elas está a possibilidade de adicionar regras, remover regras, etc., sem que, com isto, o sistema seja inteiramente alterado, o que torna a expansão e a manutenção da base de conhecimento uma tarefa relativamente fácil. Contudo, há desvantagens: é sempre necessário que o sistema procure a regra adequada a ser aplicada e para isto ele precisa percorrer todas as regras. O sistema pode, rapidamente, tornar-se lento, apesar da existência de algumas técnicas de busca para evitar que isto sempre ocorra. Outra limitação está no fato de que o sistema não pode "pular para uma conclusão final": ele sempre terá de percorrer todas as conclusões intermediárias a não ser que se estipulem certas condições para que uma ou mais conclusões intermediárias se tornem desnecessárias. Contudo, isto diminui, de certa forma, a auto-nomia do sistema.

Uma alternativa para a representação de conhecimento em sistemas especialistas são os chamados *frames* – uma organização hierárquica do conhecimento. Um *frame* é uma estrutura hierárquica de nós e relações onde os nós superiores representam conceitos gerais e os inferiores, instâncias específicas desses conceitos. Um conceito, situado em um nó, é definido por um conjunto de atributos (*slots*) e valores que são especificados para esses atributos. *Slots* podem ser associados a asserções, listas, regras, e aos próprios *frames*. Cada *slot* pode ter um procedimento associado a ele, que é ativado quando a informação nele contida muda. Muitos *slots* contêm também sub-*slots* chamados de *facetas*. Uma faceta é um sub-*slot* que contém conhecimento acerca da informação que está nos *slots*. Algumas facetas podem conter informação do tipo "SE tal coisa... ENTÃO... faça tal coisa". Este tipo de informação é chamado de informação procedimental (*procedural*), pois especifica um tipo de ação que deve ser executada quando um *slot* é adicionado ou modificado.

Um exemplo de *frame* pode ser encontrado no livro de M. Minsky, *A sociedade da mente*. Minsky fala-nos de um *frame* para representar uma festa de aniversário, uma situação onde:

Mary foi convidada para a festa de Jack.
Ficou imaginando se ele gostaria de ganhar uma pipa.

Consideremos agora, diz-nos Minsky, as suposições e conclusões habituais que todo mundo faria numa situação como a descrita antes:

A "festa" é uma festa de aniversário.
Jack e Mary são crianças:
"Ela" é Mary.
"Ele" é Jack.
Ela está pensando em dar uma pipa para Jack.
Ela imaginou se ele iria gostar da pipa.

O que ocorre é que as palavras "*Mary foi convidada para a festa de Jack*" despertam o *frame* "convite para festa" na mente das pessoas e isto, por sua vez, desperta outras preocupações do tipo: *"Quem é o anfitrião?" "Quem irá à festa*?" "*Que presente devo levar*?" "*Que roupa devo vestir*?" Cada uma destas preocupações está ligada, por sua vez, a um outro *frame*. Na realidade, a representação por *frame* trabalha com dois fatores: a experiência cotidiana das diversas situações e a idéia de que nossas representações estão ligadas por um fator de contigüidade.

Como ocorre o processo de inferência quando representamos o conhecimento por meio de *frames*? Um método bastante comum é chamado de "inferência através de expectativa": cada *slot* é preenchido através da execução de um procedimento. Se todos os *slots* puderem ser preenchidos, então o problema inicial pode ser considerado resolvido. No caso, por exemplo, da identificação de um objeto, se todos os *slots* forem preenchidos, o objeto é identificado, ou seja, referido a um determinado *frame*. Caso contrário, será necessário procurar, na base de conhecimento, outros *frames* com os quais o objeto possa eventualmente ser identificado. Se nem assim ele puder ser identificado , o sistema pedirá ao usuário que insira informação suplementar na base de conhecimento.

Este método de representação e de inferência apresenta muitas vantagens. Novos conceitos e objetos podem ser reconhecidos mais rapidamente e classificados em termos de conceitos já familiares. Sistemas especialistas que se utilizam de *frames* podem lidar com problemas cuja descrição se encontra incompleta. Mais do que isto: este tipo de representação é muito mais adequado para situações onde *contextos* desempenham um papel importante, tais como interpretação da linguagem, análise política e até mesmo áreas em que conhecimento contraditório pode aparecer.

A representação do conhecimento por *frames* foi muito utilizada na construção de sistemas especialistas no início dos anos 80. Posteriormente, surgiram outras técnicas, que precisam ser mencionadas, ainda que rapidamente, como, por exemplo, a *representação orientada para objetos*. Neste tipo de representação os conceitos são organizados em hierarquias; os objetos que compõem as partes mais altas da estrutura normalmente representam "classes" ou "generalizações" dos conceitos que ocupam os níveis hierárquicos inferiores.

A hierarquia baseada na generalização formaliza uma intuição trivial acerca das classes de objetos. Ou seja, a idéia de classe faz parte do raciocínio humano e fornece um princípio organizacional poderoso para a construção de sistemas especialistas. Através desta idéia podemos deduzir as propriedades de objetos e de conceitos novos. Por exemplo, se encontramos o objeto "baleia" e se é claro que "baleia" faz parte da classe dos mamíferos, podemos inferir várias de suas propriedades com base no que sabemos acerca da classe dos mamíferos. Este tipo de inferência ou "herança de propriedade" permite uma expansão e organização do

conhecimento sem que para isto seja necessário que toda informação relevante seja explícita e previamente representada, o que, sem dúvida, constitui um ganho em termos de flexibilidade na construção de um sistema especialista.

O FUTURO DOS SISTEMAS ESPECIALISTAS

O que dissemos até agora está ainda longe de recobrir todas as pesquisas que têm sido realizadas nesta área. Sistemas especialistas usando regras, *frames*, etc. floresceram nos anos 70 e início dos 80. Seguiu-se a este período um certo declínio de entusiasmo à medida que algumas de suas limitações começaram a aparecer. Hoje vivemos uma fase na qual tudo indica que o interesse por sistemas especialistas está ressurgindo. Pensa-se em novas possibilidades, como, por exemplo, sistemas especialistas híbridos, que utilizam uma arquitetura convencional acoplada a uma arquitetura conexionista (falaremos de arquiteturas conexionistas na segunda parte deste livro).

Contudo, é preciso assinalar que esta área ainda enfrenta pelo menos dois grandes desafios: o problema de estipular metodologias mais eficientes para a aquisição do conhecimento a partir de especialistas humanos e o problema da simulação do senso comum. Ainda há muitas dificuldades e ausência de técnicas definitivas para efetuar a aquisição de conhecimento. Por outro lado, o problema da simulação do senso comum ainda persiste, apesar de todas as tentativas de encontrar métodos alternativos para a representação do conhecimento. Exemplos típicos deste problema ocorrem quando, por exemplo, alguém nos pergunta qual o número de *fax* de Ludwig van Beethoven. Nós imediatamente descartamos a pergunta, pois sabemos que na época de Beethoven não havia aparelhos de *fax*. Um sistema especialista consultaria sua base de conhecimento e tentaria encontrar o número de *fax* de Beethoven para, depois de algum tempo, fornecer a resposta, ou seja, afirmar que tal número não existe. Pior do que isto, é possível que o sistema especialista acuse que sua base de conhecimento está incompleta e solicite ao usuário que forneça esta informação suplementar!

Através deste exemplo podemos perceber o quanto os sistemas especialistas ainda são extremamente "rígidos". Eles podem resolver uma série de problemas rotineiros, mas sempre que uma situação nova aparece seu desempenho é, no mínimo, precário. Dois pesquisadores contemporâneos, Lenat e Guha (1990), apresentam um exemplo de um sistema especialista para diagnóstico médico que, quando "reexamina" um paciente que fez uma consulta há alguns dias, refaz perguntas acerca da data de nascimento e sexo deste paciente – como se tais dados pudessem mudar de uma semana para outra...

Lenat e Guha argumentam que uma das principais razões deste comportamento rígido está no fato de que normalmente os sistemas especialistas têm uma base de conhecimento muito incompleta, que não permite uma utilização desse conhecimento de maneira flexível. Eles acreditam que estas dificuldades poderão ser superadas na medida em que sistemas especialistas forem dotados de um profundo conhecimento da natureza do mundo. Neste sentido, estes pesquisadores estão desenvolvendo o projeto CYC, uma tentativa de construir um agente inteligente cuja base de conhecimento possa fornecer uma representação explícita de nossa compreensão cotidiana do mundo – aí incluindo conceitos de espaço, tempo, objetos materiais, processos, eventos, etc. A base de conhecimento deste agente passaria a ser uma espécie de "componente *standard*" para todos os sistemas especialistas: sempre que houvesse problemas de "rigidez", os sistemas especialistas lançariam mão do CYC.

O CYC é um projeto cuja execução levará pelo menos 10 anos – trata-se de um dos projetos mais ambiciosos que apareceram na área de Engenharia do conhecimento. Seus primeiros resultados apareceram em 1994 e foram relativamente bem sucedidos. Se este sucesso persistir, o CYC constituirá, sem dúvida, um passo fundamental para ampliarmos nossa compreensão do modo como percebemos o mundo que está à nossa volta.

O QUE LER

1 – Minsky, M. "A Framework for Representing Knowledge" in *Mind Design.*
2 – Minsky, M. *A Sociedade da Mente* – capítulos 25 e 26.
3 – Waterman, D. *A Guide to Expert Systems.*

Capítulo 4

As grandes objeções: Searle e Penrose

Conceitos introduzidos neste capítulo:
- A Inteligência Artificial no sentido forte e fraco.
- Argumento do quarto do chinês.
- Problema da intencionalidade.
- Argumento de Lucas-Penrose.
- Intuição matemática

Como todo movimento científico de vanguarda, a Inteligência Artificial não deixou de ter os seus críticos. A idéia de que atividades mentais humanas possam ser replicadas mecanicamente é, no mínimo, assustadora, principalmente para os filósofos e intelectuais, que tanto prezam a razão humana. Foram estes que, no decorrer das últimas décadas, passaram a questionar os pressupostos teóricos envolvidos na formulação do modelo computacional da mente, em especial, a idéia de uma analogia entre mente e computador.

Para os filósofos, não se trata de procurar uma comparação entre mentes e máquinas simplesmente em termos práticos. Suas preocupações são muito mais radicais e se expandem para além das dificuldades tecnológicas que a Inteligência Artificial enfrenta ou poderá vir a enfrentar no futuro. Eles questionam se há alguma diferenciação *em princípio*, ou seja, intransponível, entre mentes e máquinas. Se houver esse critério de diferenciação, se pudermos formulá-lo com precisão, então estaríamos de volta à nossa confortável posição antropocêntrica que torna nossa inteligência única e inigualável – pelo menos em nosso planeta.

A primeira grande crítica ao projeto da Inteligência Artificial surgiu no início da década de 70, com a publicação do livro do filósofo Hubert Dreyfus, *What Computers Cannot Do*. Num tom panfletário e indignado, Dreyfus dispara uma série de ataques contra a Inteligência Artificial, enfatizando seus insucessos, sobretudo na área de tradução automática de

idiomas. Dreyfus insistia na existência de características "não-programáveis", seja na linguagem, seja no comportamento humano, o que inevitavelmente comprometeria o projeto de simulação mecânica. Aspectos contextuais envolvidos na linguagem e na percepção visual seriam uma barreira intransponível para a análise do comportamento humano em termos de manipulação normativa de um conjunto de dados, ou seja, pelo emprego do computador digital. "O projeto da Inteligência Artificial é essencialmente platonista", diria Dreyfus; "seu pressuposto parece ser de que tanto a linguagem quanto o comportamento humano são inteiramente passíveis de formalização, mas não é isto o que ocorre". Anos mais tarde, o próprio Dreyfus iria rever as suas próprias posições. Contudo, suas observações e críticas, sobretudo no que diz respeito à possibilidade de simulação da linguagem natural, serviram de plataforma para o início de um grande debate filosófico em torno dos limites da Inteligência Artificial.

Além dos trabalhos de Dreyfus poderíamos citar muitas outras críticas que a Inteligência Artificial tem recebido no decorrer das últimas décadas. Porém, neste capítulo, restringir-nos-emos a abordar duas delas, pelo papel e importância que passaram a desempenhar no domínio da Filosofia da Mente: a objeção do quarto do chinês, formulada pelo filósofo da mente norte-americano John Searle e a objeção formulada pelo físico e matemático inglês Roger Penrose, em 1989. Estas duas objeções são até hoje vistas como o grande calcanhar de Aquiles da Inteligência Artificial.

A CRÍTICA DE SEARLE: O ARGUMENTO DO QUARTO DO CHINÊS[1]

O debate em torno dos limites da Inteligência Artificial toma um impulso decisivo a partir da publicação do artigo de J. Searle, *Minds, Brains and Programs,* em 1980. Neste artigo, Searle apresenta uma crítica vigorosa à possibilidade de se obter um equivalente mecânico para o fenômeno cognitivo humano que normalmente denominamos *compreensão*. Seu ponto de partida é a análise dos programas para compreender histórias curtas desenvolvidas por R. Schank, em 1977, na Universidade de Yale, e que se concretizaram no trabalho *Scripts, Plans, Goals and Understanding.*

Os programas desenvolvidos por R. Schank – conforme assinalamos – tinham por objetivo a compreensão de histórias. Por exemplo, se se fornece a um computador o seguinte relato: um homem entra num restaurante, pede um sanduíche e sai sem pagar ou deixar gorjeta porque notou que o pão estava estragado, o programa de Schank é construído de

[1]Parte deste material foi publicado em Teixeira, J. de F., 1996, capítulo 1.

tal maneira que lhe é possível responder coerentemente a questões elaboradas com base no texto da história. Tendo em vista estes resultados, Schank sustenta que este tipo de programa é capaz de *compreender* o texto e constituir uma explicação para a capacidade do ser humano de compreender textos ou histórias curtas.

As críticas desenvolvidas por Searle às pretensões de que um tal programa realmente compreende baseiam-se na construção de um experimento mental que reproduz o procedimento do próprio programa. O caminho adotado por Searle para construir este experimento mental é o inverso do procedimento normalmente utilizado para elaborar simulações cognitivas: trata-se de instanciar o programa de Schank num sujeito humano.

Imagine um falante trancado num quarto. Este falante só conhece o português e tem em seu poder: a) um texto escrito em chinês, que pode, por exemplo, ser uma história; b) um conjunto de regras de transformação, em português, que permite executar operações sobre o texto em chinês. Estas operações são idênticas àquelas desempenhadas pelos programas de Schank: trata-se de operações de decomposição e recomposição de palavras com base num *script* que permite à máquina reconhecer palavras-chaves em uma determinada questão, comparar a presença destas palavras no texto e o decompor a partir destas informações. Este resultado é organizado na forma de sentenças, de maneira a gerar uma resposta estruturada.

O falante (trancado no quarto) recebe periodicamente novos textos e questões em chinês e aplica estas operações ou regras de transformação associando as seqüências anteriores com as seqüências mais recentes. Com base nestas regras de transformação ele passa a emitir ou escrever mais seqüências de símbolos em chinês. Claro que o falante preso no quarto não sabe precisamente o conteúdo das informações que ele está gerando com base nos dois textos e nas regras de transformação. O primeiro texto corresponde, em nosso experimento mental, ao relato que é fornecido ao computador; o segundo texto, ao conjunto de questões que é elaborado com base neste relato; e as novas seqüências geradas, às respostas a tais questões. As regras de transformação são bastante complexas e concebidas de maneira tal que elas simulem os processos mentais e o comportamento lingüístico de um falante nativo de chinês numa conversação habitual. Após um certo tempo, o falante aprendeu a manipular perfeitamente estas regras de transformação e, com base nos *outputs,* um observador externo poderia dizer que ele *compreende* chinês –, o que, no entender de Searle, constitui um contra-senso.

A instanciação dos programas de Schank num sujeito humano, reproduzida neste experimento mental, é, para Searle, bastante reveladora. Ela mostra que os programas desse tipo não estabelecem as condições necessárias para a simulação da atividade cognitiva da *com-*

preensão: o falante aplica as regras de transformação e compreende estas regras, mas as seqüências de símbolos em chinês não têm nenhum significado para ele. A manipulação de símbolos realizada no programa é inteiramente cega.

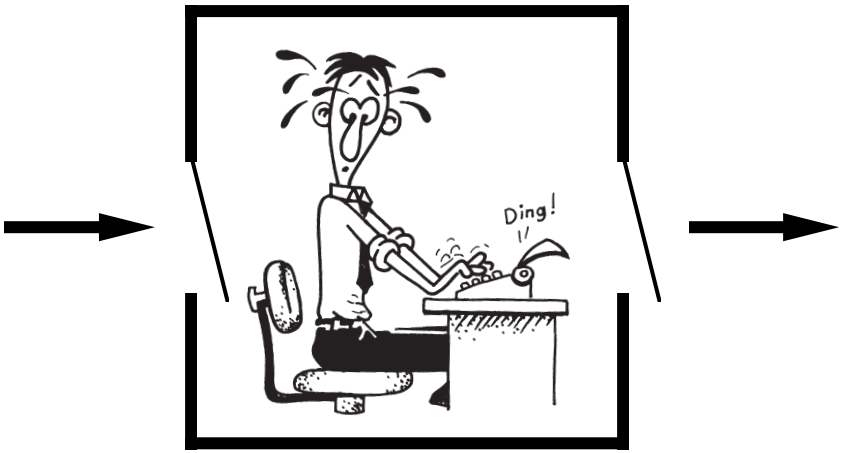

Figura 4.1. O argumento do quarto do chinês.

Ademais, como ressalta Searle na resposta às objeções ao seu texto *Minds,Brains and Programs*: "A manipulação de símbolos formais, por si só, não tem intencionalidade, não é sequer manipulação de símbolos, uma vez que esses símbolos não simbolizam nada. Eles têm apenas sintaxe, mas não semântica". Ainda na sua resposta às objeções, Searle ressalta que a esse programas "falta aquilo que chamarei de intencionalidade intrínseca ou de genuínos estados mentais".

A atribuição de intencionalidade ou de *significado*, diz Searle, é, nestes casos, sempre uma atribuição *a posteriori,* dependente da intencionalidade intrínseca dos sujeitos humanos que observam os *outputs* do programa.

Mas o que é "intencionalidade intrínseca" no entender de Searle, e que relação tem esta noção com a idéia de significado? O conceito de intencionalidade intrínseca não é largamente explorado em *Minds, Brains and Programs*. Searle o desenvolve com maior profundidade em outros artigos, tais como *Intrinsic Intentionality* e *What is an Intentional State* (1982), bem como no seu livro de 1983, *Intentionality*. A intencionalidade, segundo Searle, é uma "capacidade" apresentada pelos seres vivos, através da qual nossos estados mentais se relacionam com os objetos e estados de coisas no mundo. Assim, se tenho uma intenção, esta deve ser a intenção de fazer alguma coisa, se tenho um desejo ou um medo, este desejo e este medo devem ser um desejo ou medo de alguma coisa que está no mun-

do. Um estado intencional pode ser definido, *grosso modo*, como uma representação associada a um determinado estado psicológico.

Esta mesma capacidade – estritamente biológica, no entender de Searle – percorre nossa linguagem, convertendo-a num tipo particular de relação organismo/mundo. Contudo, ela não é uma propriedade da linguagem e sim uma propriedade específica que nossos estados mentais imprimem ao nosso discurso. Nesta operação, os sinais lingüísticos, sejam eles os sons que emitimos ou as marcas que fazemos no papel, passam a ser representações de coisas ou estados de coisas que ocorrem no mundo, e, no caso específico das representações lingüísticas, podemos afirmar que elas constituem descrições dessas representações ou mesmo representações de representações que estão na nossa mente. A intencionalidade dos estados mentais não é derivada de formas mais primárias da intencionalidade, mas é algo intrínseco aos próprios estados mentais. Neste sentido, a intencionalidade é a propriedade constitutiva do mental e sua base é estritamente biológica – só os organismos desempenham esta atividade relacional com o mundo, constituindo representações. Sua origem está nas próprias operações do cérebro e na sua estrutura, constituindo parte do sistema biológico humano, assim como a circulação do sangue e a digestão.

A intencionalidade intrínseca, presente no discurso lingüístico, constitui uma forma derivada de intencionalidade que consiste na relação das representações lingüísticas com os estados intencionais, o que permite que estas últimas sejam representações de alguma coisa do meio ambiente. Em outras palavras, esta relação entre representações lingüísticas e estados intencionais transforma o código lingüístico num conjunto de signos, ou seja, estabelece o seu *significado.* Neste sentido, a intencionalidade intrínseca constitui para Searle a condição necessária para que um sistema simbólico adquira uma dimensão *semântica.* Sem esta dimensão semântica, não podemos falar de compreensão; sem esta relação entre representações mentais ou conteúdos intencionais e representações lingüísticas, não podemos falar de compreensão de textos ou compreensão lingüística.

A ausência de intencionalidade intrínseca nos programas desenvolvidos por Schank está na base da afirmação de Searle de que estes últimos constituem um procedimento cego de associação de signos sem significado – um procedimento cego que não deve ser confundido com autêntica compreensão lingüística.

Ora, até que ponto podemos supor que as afirmações de Searle são corretas? Se o forem, a questão que formulamos no início desta seção estaria respondida em caráter definitivo, ou seja, sistemas artificiais não podem gerar estados intencionais e tampouco representar o mundo exterior.

Ocorre que vários filósofos favoráveis ao projeto da Inteligência Artificial apresentaram contra-argumentos às posições defendidas por

Searle. Alguns deles apontaram falhas no argumento principal, salientando que não sabemos se, de fato, os computadores podem ou não compreender alguma coisa. A situação seria semelhante àquela quando observamos um ser humano responder a perguntas a respeito de um texto qualquer: como podemos estar certos de que essa pessoa compreende o que está fazendo? Por acaso muitos de nossos processos mentais cotidianos não são tão rotineiros que os fazemos por uma associação tão mecânica e cega como as do computador? Se as operações efetuadas pelo falante trancado no quarto são cegas, será que não podemos afirmar o mesmo de nossas próprias operações mentais? Mesmo quando tentamos examinar o fluxo de nossos pensamentos, isto não nos dá nenhuma informação sobre como ocorrem as operações de nosso cérebro. Somos, em grande parte, opacos para nós mesmos – e não seria essa uma situação idêntica à de alguém que olha para os resultados das operações de um computador e, com base nestes últimos, quer sustentar a afirmação de que essa máquina nada compreende acerca dessas operações?

Mas não são estas as únicas objeções ao argumento do quarto do chinês. O próprio John Searle colecionou várias delas à medida que foi apresentando seu argumento em várias universidades e grupos de pesquisa em Ciência Cognitiva dos Estados Unidos. Depois de colecioná-las, tentou respondê-las uma a uma na versão do seu artigo *Minds, Brains and Programas,* publicado em 1980. Dentre essas objeções destaca-se o "argumento dos sistemas". Posteriormente, foi levantada uma outra objeção, conhecida como "argumento do Dr. Jekyll e Mr. Hyde". Este último argumento não aparece especificamente no artigo de Searle, e deve-se a William Poundstone (1991). Contudo, resolvemos apresentá-lo aqui, mesmo sem ter conhecimento de nenhuma resposta que Searle teria elaborado para refutá-lo.

O "argumento dos sistemas" diz o seguinte: é possível que a pessoa trancada no quarto não entenda chinês, mas nada nos indica que o sistema como um todo (a pessoa, mais o quarto fechado, etc.) não possa entender chinês. A pessoa que está trancada no quarto não constitui algo análogo à nossa mente, ela seria, no máximo, uma pequena parte (embora não sem importância) do nosso cérebro. Em outras palavras, o que se está dizendo é que o processo de compreensão (e de consciência) não se encontra localizado em nenhum neurônio ou conjunto de neurônios específico. Consciência e compreensão são resultado do processo como um todo.

Searle respondeu a este argumento da seguinte maneira: "Ok, vamos assumir que o sistema como um todo é o responsável pela produção da consciência e da compreensão. Vamos, contudo, subtrair algumas partes desse sistema: derrubemos as paredes do quarto, vamos jogar fora os pedaços de papel, o lápis, etc. Façamos a pessoa que estava no quarto memorizar as instruções e realizar todas as manipulações apenas na sua cabeça. O sistema fica reduzido apenas a uma pessoa". A pergunta que

podemos colocar agora é a seguinte: será que essa pessoa entende chinês? Certamente que não!

Vejamos agora o outro contra-argumento. Imaginemos agora que o ser humano trancado no quarto possa entender chinês, mas não estar ciente disto. Poderíamos compará-lo a alguém cujo cérebro foi danificado e por isso não pode efetuar traduções. Ou, talvez, alguém que sofra de um transtorno psíquico do tipo "múltiplas personalidades".

Suponhamos agora que Dr. Jekyll entre no quarto, falando apenas português. Em seguida, ele cria um certo Mr. Hyde que fala chinês. Jekyll não sabe da existência de Hyde e vice-versa. Assim sendo, Jekyll é incapaz de fazer qualquer tradução do português para o chinês, uma vez que ele não tem consciência de que Hyde fala chinês. Da mesma maneira, temos muitas habilidades mentais das quais não somos conscientes: pulsação, digestão e uma série de outras atividades neurovegetativas que não chegam ao limiar de nossa consciência. Contudo, todas elas são controladas pelo nosso cérebro – e cada um de nós tem apenas *um* cérebro. Mas se temos apenas *um* cérebro, como é possível que essas duas personalidades – Jekyll e Hyde (que fala chinês) não estejam integradas? Talvez isto se deva ao modo pelo qual o conhecimento do chinês foi "enxertado" ou "injetado" no cérebro. Mas, seja qual for a razão, abre-se a possibilidade de que alguém compreenda chinês e não esteja consciente disto! Ora que tipo de resposta poderia Searle apresentar a este tipo de contra-argumento?

É difícil saber quem tem razão num debate deste tipo: como todas as polêmicas filosóficas, esta também deve ser inconclusiva. Entretanto, é preciso fazer uma observação importante: a crítica de Searle pode ser considerada correta se levarmos em conta o tipo de modelo computacional da mente sobre o qual ela recai. Trata-se de um modelo muito específico e que vigorou até meados dos anos 80, qual seja: um modelo baseado nas idéias de algoritmo e de representação simbólica (ver o Capítulo 2). Seguir regras não significa compreender, da mesma maneira que executar determinadas funções e produzir um *output* esperado tampouco significa compreender. Estes são aspectos importantes levantados pela crítica de Searle. São críticas às pretensões da chamada *Inteligência Artificial no sentido forte*, segundo a qual um computador adequadamente programado *é* uma mente e reproduz estados mentais. A esta visão radical contrapõe-se à chamada *Inteligência Artificial no sentido fraco*, segundo a qual os programas são meramente ferramentas que nos habilitam a testar teorias acerca do funcionamento mental humano.

Mas há mais coisas ainda para serem ditas: o argumento do quarto do chinês mostra mais uma fraqueza do teste de Turing: o sistema (quarto, falante, etc) poderia facilmente passar no teste de Turing, mas isto não quer dizer que ele compreenda alguma coisa. Searle diria que o teste de Turing constitui uma condição necessária, mas não suficiente para atribuir

estados mentais a um organismo ou a um artefato. E no que diz respeito a este ponto específico ele parece estar certo.

A OBJEÇÃO DE PENROSE

A objeção de Penrose ao projeto da Inteligência Artificial tem como ponto de partida uma recapitulação das limitações intrínsecas aos sistemas formais – neles incluída a máquina de Turing, que também é um sistema formal. Ele enfatiza que, por uma espécie de ironia, a máquina de Turing, concebida como o dispositivo teórico fundamental para a Ciência da Computação acaba se tornando também o instrumento pelo qual pode ser mostrada sua *limitação* fundamental. Existe um problema que a máquina de Turing não pode resolver: saber se outra máquina de Turing pára ou não; reconhecer (mecanicamente) se um problema matemático pode ou não ser resolvido através de de um procedimento efetivo (com número finito de passos) ou não. Isto só pode ser realizado *intuitivamente*, é algo que requer uma inteligência que não pode ser expressa de forma algorítmica. Assim sendo, as bases da própria Ciência da Computação são muito mais movediças do que se imagina, na medida em que é somente através da intuição que podemos saber se um determinado programa vai parar ou não. Esta intuição marcaria uma diferença entre mentes e máquinas.

Mas não foram apenas os resultados de Turing que levaram, já na década de 30, a supor a existência de uma diferenciação entre mentes e máquinas. Foi também nessa década que o matemático K. Gödel apresentou um de seus teoremas revolucionários: o teorema da Incompletude. Em linhas gerais, o teorema da Incompletude (1931) estabelece que em qualquer sistema formal existem proposições que não são passíveis de prova ou refutação com base nos axiomas do sistema, e, como corolário, as contradições que há no seu interior não podem ser suprimidas pelo próprio sistema. Em outras palavras, a verdade ou falsidade dos próprios axiomas que servem de ponto de partida para a construção de um sistema formal não podem ser *decididas* no interior do sistema; elas têm de ser decididas externamente a ele. Estabelece-se um abismo entre *verdade* e *demonstração*, um abismo que só poderia ser coberto pela inteligência humana ou pela *intuição matemática*. Isto significa dizer que o valor de verdade de algumas proposições (indecidíveis) não pode ser obtido por meio de nenhum procedimento mecânico (algorítmico), uma conclusão que converge em direção aos resultados que Turing tinha obtido ao formular o *Halting Problem* (problema da parada da máquina de Turing). Posteriormente, foi demonstrada a equivalência do *Halting Problem* com o 10º problema de Hilbert, bem como o fato de que a insolubilidade deste problema é conseqüência direta do teorema da Incompletude de Gödel (o leitor interessado pode consultar o apêndice B).

O próprio Gödel estava convencido de que as conseqüências de seu teorema da Incompletude levavam a sérias limitações no que diz respeito à simulação mecânica das atividades mentais humanas pretendida pelos pesquisadores da Inteligência Artificial. A intuição matemática, que seria a base de todos os sistemas formais e da própria possibilidade de fundamentar a Matemática, não poderia ser expressa algoritmicamente. Teríamos encontrado um critério de diferenciação entre mentes e máquinas, aquele critério que os filósofos estariam buscando. Mas as afirmações de Gödel ficaram por muito tempo obscurecidas pelo sucesso e pelo entusiasmo que recobriram as realizações da Inteligência Artificial, esta nova disciplina que se consolidava cada vez mais por suas realizações – principalmente aquelas que se originavam das pesquisas realizadas no MIT. Os pesquisadores da Inteligência Artificial estavam convencidos de que haveria maneiras – ou pelo menos técnicas – para se contornar os problemas colocados por Turing e por Gödel. E, quem sabe, essa idéia de "intuição matemática" como algo exclusivamente humano não passaria, afinal de contas, de uma balela...

Em 1961, o filósofo inglês J.R. Lucas publica um artigo no *British Journal for the Philosophy of Science,* chamando a atenção dos pesquisadores da Inteligência Artificial para o fato de que as questões envolvendo indecidibilidade não poderiam ser contornadas com tanta facilidade. Como poderia uma máquina construída com base em procedimentos algorítmicos demonstrar a existência de proposições cujo valor de verdade não poderia ser decidido algoritmicamente? Lucas (1961) argumentava que:

> "Os paradoxos da consciência surgem porque um ser consciente sabe o que ocorre com ele e não pode ser dividido em partes. Isto significa que um ser consciente pode lidar com questões gödelianas: ele pode conceber seu próprio desempenho e ao mesmo tempo algo externo a esse desempenho, sem que para isso tenha de se dividir em partes. Isto não poderia ocorrer no caso de uma máquina. Uma máquina pode ser concebida de maneira a relatar o que ela faz, mas isto não seria possível sem que precisássemos adicionar uma nova máquina à original. É inerente à nossa própria idéia de consciência a capacidade de auto-reflexão, ou seja, a capacidade de relatar e criticar nossos próprios desempenhos sem que nenhuma parte suplementar seja necessária; a consciência é, neste sentido, completa e não possui nenhum calcanhar de Aquiles" (p.122).

O artigo de Lucas provocou um debate momentâneo; foi seguido de várias respostas no próprio *British Journal for the Philosophy of Science*, respostas que, se não foram conclusivas, serviram pelo menos para reativar um debate que merecia maior atenção. Os filósofos da mente passaram então a se agrupar em torno dos problemas suscitados pelo

Teorema de Gödel, ora fazendo defesas da concepção mecânica da mente, ora descartando-a como algo impreciso e mistificador. Filósofos como D. Dennett, J. Webb, J.J.C. Smart e D. Hofstadter rechaçaram as idéias de Lucas que então encontrava poucos defensores.

Em 1989, o físico e matemático inglês R. Penrose publica o livro *The Emperor's New Mind* (A Mente Nova do Rei). Desde então este livro vem causando uma grande reviravolta na Filosofia da Mente. Penrose refaz o argumento de Lucas passando por uma cuidadosa reconstrução dos resultados de Turing e de Gödel. O reconhecimento da existência da intuição matemática e de processos não-algorítmicos nas atividades mentais humanas faz com que Penrose se coloque um segundo tipo de questão: será que isto nos força a abandonar o modelo computacional de mente, isto é, a idéia de que processos mentais são análogos a uma máquina de Turing instanciada através do cérebro?

Penrose sustenta esta assimetria, afirmando que é possível estabelecer semelhanças entre intuição matemática, processos conscientes e processos não-algorítmicos, mas, afastando-se de Gödel e de Lucas, formula uma questão adicional: será que não haveria, *na própria natureza*, processos não-algorítmicos e assim sendo não poderíamos continuar sustentando uma possível identidade entre processos mentais e processos cerebrais? É preciso então investigar tudo aquilo que a Física pode nos dizer sobre a natureza e se nesta poderíamos de fato encontrar processos não-algorítmicos. O debate se amplia então: talvez a mecânica quântica pudesse nos fornecer esse ingrediente suplementar que caracteriza os processos não-algorítmicos típicos do cérebro humano. A idéia desenvolvida por alguns pesquisadores seria que fenômenos quânticos possuem algumas propriedades especiais, como o indeterminismo e a não-localidade – fenômenos que se supõe ocorrerem no cérebro humano.

Penrose defende esta perspectiva no seu segundo livro, *Shadows of the Mind*, publicado em 1994 e ainda não traduzido. Trata-se de uma perspectiva um pouco diferente daquela apresentada em *The Emperor´s New Mind,* que termina com uma resposta negativa à possibilidade de simulação mecânica plena das atividades mentais humanas e com uma defesa da existência da intuição matemática como algo caracteristicamente humano, não replicável pelas máquinas. Em *Shadows of the Mind,* Penrose identifica a existência de "estados não-computáveis" (não-algorítmicos) no cérebro humano que seriam responsáveis pelo que chamamos de "compreensão" ou "intuição matemática" que o distingue de um computador e o torna capaz de saber o que está fazendo – o que não ocorre no caso de uma máquina digital.

Toda a hipótese desenvolvida por Penrose assenta-se, em última análise, na idéia de que estados conscientes podem ser identificados com estados não-computáveis, como é o caso da intuição matemática que nos permite resolver o problema da parada da máquina de Turing e o valor de

verdade de algumas proposições indecidíveis. Estes estados conscientes desempenham o papel de um "observador externo" que toma "decisões" diante de processos não-computáveis. Ora, como conceber um análogo a estes estados não-computáveis sem romper com uma hipótese materialista? É preciso encontrar na natureza algo semelhante, algo que possa servir de fundamento para uma abordagem científica da consciência. Penrose supõe que um processo análogo ocorre na mecânica quântica, uma área da física na qual se reconhece a existência de processos não-deterministas – a ruptura com o determinismo seria então o elemento característico da não-algoritmicidade (vale lembrar que um processo algorítmico é sempre finito e determinístico). A mecânica quântica seria – pelo menos de acordo com uma certa interpretação – a chave para uma ciência da consciência.

Ora, serão válidos estes argumentos contra o modelo computacional da mente formulados por Penrose? Ao que parece, sua profissão de fé materialista o impede de enriquecer seus próprios argumentos acerca da natureza da intuição matemática. Por exemplo, um aspecto que não parece ter sido explorado neste debate são as possíveis limitações físicas para a capacidade de uma máquina replicar atividades mentais humanas.

Estipular este tipo de relação remete-nos para a chamada Teoria da Complexidade Computacional (cujos principais delineamentos já apresentamos no final do Capítulo 1), uma teoria que lida com questões práticas relativas à velocidade e à eficiência na execução de procedimentos algorítmicos para resolver problemas. Lembremo-nos de que a Teoria da Complexidade Computacional parte da idéia de que podemos dividir os problemas computacionais em duas classes, os chamados problemas *tratáveis* e os *intratáveis*. Esta classificação baseia-se no número de passos e, conseqüentemente, no tempo requerido para se rodar um determinado algoritmo num computador. Problemas intratáveis são aqueles que comportam uma solução algorítmica, porém o tempo requerido para se executar este algoritmo o torna ineficiente. Certamente alguém poderia dizer que os problemas levantados pela teoria da Complexidade, ou seja, a velocidade de computação depende do tipo de máquina na qual o algoritmo é rodado. Pode-se argumentar que avanços na arquitetura de *hardware* poderiam levar a uma diminuição no tempo requerido para se rodar um algoritmo e, portanto, que a eficiência para se resolver problemas intratáveis poderia gradualmente ser atingida. Assim concebido, este seria um problema *prático* ou *tecnológico* que não imporia nenhum tipo de limitação física *a priori* sobre o que um computador poderia fazer.

Contudo, trabalhos pioneiros na área de teoria da Complexidade desenvolvidos por H.J. Bremermann (1977) mostram que há *limites físicos* na arquitetura de computadores de qualquer tipo e que estes limites físicos condicionam o tempo para computar problemas consumido por

estas máquinas não importando o quanto seu *hardware* estiver aperfeiçoado. De acordo com Bremermann, há dois limites físicos a serem considerados: o *tempo de propagação* e o *tempo de comutação*. Estes dois limites compõem o chamado *limite fundamental* para a velocidade dos computadores que não pode ser ultrapassado. Tal limite fundamental deriva-se da idéia de que a velocidade máxima de transmissão de sinal entre os componentes internos de um computador é limitada pela velocidade da luz, ou seja, 3.10^8 m/segundo. O tempo de propagação ou intervalo de transmissão de sinal entre os componentes internos do computador é determinado pela distância na qual se situam tais componentes e, por sua vez, é limitado por aquilo que se chama *tempo de comutação.* O tempo de comutação é o intervalo para o processamento de informação através de dispositivos discretos. Mesmo que suponhamos a possibilidade tecnológica de construir um computador muito pequeno para minimizar e otimizar a trajetória de transmissão de sinal, tal limite fundamental não pode ser ultrapassado – sob pena de estarmos ignorando tudo o que a Física contemporânea nos diz.

A possibilidade tecnológica de construir uma máquina ideal em tamanho, cuja velocidade de transmissão de sinal se aproximasse da velocidade da luz não pode ser descartada como algo a ser obtido no futuro. Contudo, mesmo com um *hardware* assim poderoso, haveria problemas cuja complexidade é *transcomputável.* Um problema transcomputável é um problema intratável cujo procedimento algorítmico de solução não pode ser obtido em tempo eficiente a despeito de qualquer aperfeiçoamento do *hardware* do computador utilizado.

O intervalo de tempo requerido para rodar alguns algoritmos transcomputáveis pode ser tão longo quanto a própria idade do universo. Este crescimento em complexidade temporal requerido para a realização de algoritmos transcomputáveis aplica-se igualmente ao cérebro humano se este for concebido como um sistema físico – e portanto submetido ao conceito de limite fundamental desenvolvido por Bremermann. Processamento de sinal neuronal não pode ocorrer a uma velocidade maior do que a da luz.

Estes trabalhos pioneiros de Bremermann permitem-nos fazer uma especulação interessante acerca das limitações físicas exibidas pelos computadores. Como é possível que nossa mente, através de intuição matemática ou *insight* específico possa resolver, instantaneamente, alguns problemas transcomputáveis? Isto significa dizer que, se nossa mente funciona algoritmicamente, ela é capaz de processar informação com uma extraordinária rapidez – uma rapidez que superaria o limite fundamental proposto por Bremermann. A superação deste limite fundamental, ou seja, processar informação a uma velocidade maior que a da luz tem como conseqüência metafísica imediata a possibilidade de sustentar que pelo menos parte das atividades mentais humanas não teria as características

atribuíveis a sistemas físicos. Mente e cérebro teriam de ser diferentes, caso contrário a intuição matemática não poderia existir. Estaríamos aqui diante de um forte argumento em favor da distinção entre mente e cérebro! – um tipo de argumento que parece ter passado completamente despercebido pelo próprio Penrose que, na *Mente Nova do Rei,* aborda, muito rapidamente e de passagem, os problemas suscitados pela teoria da Complexidade Computacional.

Finalizando, é preciso dizer que os argumentos de Lucas e de Penrose ainda suscitam muita inquietação entre os filósofos da mente. No livro de D. Dennett, *Darwin's Dangerous Idea*, publicado em 1995, encontramos um capítulo inteiro dedicado à refutação dos pontos de vista de Penrose. O legado deste debate em torno das possibilidades da computação simbólica e da abordagem formal de processos cognitivos encaminha a filosofia da mente para mais uma questão fundamental que passa a ocupar um papel central no seu cenário: o estudo da natureza da *consciência*, esta última trincheira que ainda parece resistir à possibilidade de replicação mecânica. Nos últimos dois anos tem havido uma verdadeira proliferação de teorias sobre a natureza da consciência; os simpósios realizados em Tucson, no Arizona, em abril de 1994 e em abril de 1996, constituem um marco decisivo desta nova tendência. O reconhecimento da irredutibilidade de fenômenos conscientes a qualquer tipo de base, seja neurofisiológica ou física, defendida por filósofos como D. Chalmers (1996), parece dominar esta nova etapa da história da Filosofia da Mente.

O QUE LER

1 – Dreyfus, H. *What Computers Cannot Do.*
2 – Dreyfus, H. *What Computers Still Cannot Do.*
3 – Penrose, R. *A Mente Nova do Rei.*
4 – Searle, J. *Mente, Cérebro e Ciência.*
5 – Searle, J. *Minds, Brains and Programs*. Há tradução deste artigo para o português na coletânea *Cérebros, Máquinas e Consciência*, João de F. Teixeira (org).
6 – Teixeira, J. de F., *O que é Inteligência Artificial* – capítulo 4.

Segunda Parte

Conexionismo e redes neurais

- Uma nova concepção do funcionamento mental
- Um sistema conexionista com memória distribuída
- Conexionismo e filosofia da mente
- Críticas ao modelo conexionista

Capítulo 5

Uma nova concepção do funcionamento mental

Conceitos introduzidos neste capítulo:
- Principais características dos sistemas conexionistas.
- Os componentes principais dos sistemas conexionistas.
- A solução conexionista para o conectivo XOR.
- Sumário do paradigma conexionista.

Desde os anos 40, quando surgiu o movimento cibernético, o projeto de simular as atividades mentais esteve dividido entre duas grandes alternativas: estudar a mente humana ou o cérebro humano. Da primeira vertente surgiu a IA simbólica, que privilegiou o estudo das representações mentais e da sua simulação através de programas computacionais que apresentavam grande autonomia em relação ao *hardware* onde eles poderiam ser rodados. Da segunda vertente – que tenta simular o cérebro como caminho para simular a atividade mental – surgiu o conexionismo. O conexionismo não teve sucesso até o início da década de 80, quando surgiram os trabalhos de Hinton e Anderson (e, posteriormente, de Rumelhart e McClelland), tendo ficado abafado, principalmente, durante os anos 70, quando havia grande entusiasmo pelas possibilidades abertas pela IA simbólica.

O conexionismo, funcionalismo neurocomputacional ou processamento paralelo distribuído (PDP = *Parallel Distributed Processing*) não endossa a visão de que processos mentais possam ser estudados como computações abstratas, independentemente de sua base física e do meio ambiente onde se situa o organismo ou o sistema onde elas ocorrem. Conhecimentos acerca do funcionamento do cérebro e conhecimentos sobre computação devem convergir no estudo da natureza dos estados mentais. O cérebro humano é visto como um dispositivo computacional em paralelo que opera com milhões de unidades computacionais cha-

madas "neurônios" ou *neuron-like units*. Computadores e cérebros são sistemas cuja função principal é processar informação e, assim, podem-se utilizar redes artificialmente construídas para simular esse processamento. Tais redes constituem um intrincado conjunto de conexões entre essas *neuron-like units* que estão dispostas em camadas hierarquicamente organizadas. Dado um determinado *input*, diferentes estados mentais podem ocorrer como conseqüência de mudanças nas conexões, que podem ser inibidas ou ativadas, variando de acordo com a interação do sistema com o meio ambiente e com seus outros estados internos. As conexões entre unidades estimuladas via *inputs* externos geram os chamados *padrões de conectividade*. As unidades estão *conectadas* umas com as outras: unidades ativas excitam ou inibem outras unidades. A rede funciona como um *sistema dinâmico* ou seja, uma vez dado o *input* inicial, este espalha excitações e inibições entre as unidades. Em alguns tipos de rede, este processo não pára até que um *estado estável* seja atingido.

Sistemas conexionistas e simbólicos são sistemas computacionais, mas há uma grande diferença no tipo de computação que eles realizam. Na perspectiva simbólica, a computação é essencialmente a transformação de símbolos de acordo com regras – regras que estão estabelecidas num programa. A idéia de computação subjacente a um sistema conexionista é diferente: seu princípio é um conjunto de processos causais através dos quais as unidades se excitam ou se inibem, sem empregar símbolos ou tampouco regras para manipulá-los. Abandona-se a idéia de uma mente que executa passos algorítmicos discretos (como uma máquina de Turing) e a suposição de que processos mentais seriam uma justaposição inferencial de raciocínios lógicos. Em vez, o que temos é um conjunto de neurônios artificiais para modelar a cognição; neurônios cujo peso de conexão sináptica pode ser alterado através da estimulação positiva ou negativa da conexão (esta é chamada regra *hebbiana* em homenagem a Donald Hebb). Cada neurônio tem um valor de ativação, e cada sinapse que chega até ele tem uma força, positiva ou negativa, de conexão.

Alguns sistemas conexionistas são fortemente inspirados em modelos físicos. Este é o caso dos sistemas que se baseiam num outro tipo de máquina virtual, a máquina de Boltzmann, inspirada num modelo termodinâmico. A máquina de Boltzman é composta de uma série de unidades simples operando em paralelo e conectadas com unidades vizinhas através de ligações bidirecionais. Tais ligações recebem um determinado *peso* que pode ser positivo ou negativo. Suponhamos agora que a um determinado momento concebamos cada uma das unidades como representando informações recebidas através de um determinado *input*. Uma determinada unidade é então ativada na medida em que ela "acredita" que aquela informação seja verdadeira. Duas unidades que representam informações contraditórias serão ligadas por uma conexão

de peso negativo, enquanto que unidades que representam hipóteses coincidentes tenderão a incrementar o peso de sua conexão. Em outras palavras, as ligações permitem que as unidades individuais se excitem e se inibam entre si de uma maneira sistemática. O estado de uma unidade num determinado momento dependerá, em parte, do estado de todas as outras unidades com a qual ela está ligada. E essas unidades, por sua vez, serão influenciadas ainda por outras com as quais estão conectadas no interior da rede. A produção de um determinado *output* dependerá, assim, de um processo interativo de ajustamento mútuo de inibições e excitações, até que uma decisão final seja atingida – a decisão que chamamos de "decisão comunitária". Este processo de ajustamento é também denominado de "processo de relaxamento", num ciclo que guarda muita semelhança com o modelo de prazer/desprazer e o princípio de constância que norteou o modelo hidráulico da mente proposto por Freud[1].

A abordagem conexionista é uma tentativa de construir um modelo de mente mais próximo de sua realidade biológica. Embora estes sistemas não sejam um modelo completo do cérebro e de seu funcionamento, pode-se pelo menos dizer que eles são inspirados na estrutura do cérebro. Processamento paralelo distribuído também tem uma inspiração neurológica: emprega vários processadores simples ligados em paralelo, de uma forma bastante intrincada. Uma forte analogia entre modelos conexionistas e o cérebro se estabelece na medida em que nos primeiros, da mesma maneira que no cérebro, a informação estocada pode subsistir apesar da destruição de alguns "neurônios". Os cérebros e as redes neurais não perdem tão facilmente a informação porque ela está distribuída no sistema.

COMPONENTES DOS SISTEMAS CONEXIONISTAS

A construção de sistemas conexionistas envolve os seguintes componentes:

1 – Um conjunto de unidades de processamento (*neuron-like units*).
2 – Um padrão de conectividade entre as unidades.
3 – Pesos (ou força) entre as conexões.
4 – Uma regra de ativação que toma os *inputs* que recaem sobre uma unidade num determinado estado e os combina para produzir um novo nível de ativação para essa unidade.
5 – Uma regra de aprendizado, a partir da qual padrões de conectividade mudam com a experiência.

[1] Já notamos esta semelhança em Teixeira, J de F. (1996), capítulo 5.

A especificação do conjunto de *unidades de processamento* (*neuron-like units*) é o primeiro passo para a construção de um sistema conexionista. Cada uma dessas unidades cumpre sua função, qual seja, a de receber um *input* das unidades vizinhas e computar um valor de *output* que é, então, passado para outras unidades vizinhas. Uma vez que o sistema funciona em paralelo, muitas unidades podem realizar computações simultaneamente.

Há três tipos de unidades: unidades de *input*, unidades de *output* e unidades *ocultas*. De modo geral, as unidades de *input* recebem estímulos de fontes externas ao sistema. Contudo, unidades de *input* podem também receber estímulos oriundos do próprio sistema, ou seja, de outras unidades. As unidades de *output* enviam sinais para fora do sistema – sinais que podem afetar componentes motores acoplados a este último. Finalmente, as unidades ocultas são aquelas cujos *inputs* e *outputs* provêm do interior do sistema que estamos construindo.

As unidades estão conectadas umas com as outras. É o *padrão de conectividade* que determina o que o sistema "sabe" e determina como ele responderá a um *input* qualquer. O padrão de conectividade existente entre as unidades permite especificar o sistema de processamento e o conhecimento que o sistema contém.

O peso (ou força) corresponde a um número real que é associado a cada conexão entre as unidades e que determina o quanto uma unidade afetará outra.

Além dos pesos e do padrão de conectividade, a construção de sistemas conexionistas exige a determinação de uma *regra de ativação*. Esta regra estabelece como os *inputs* que recaem sobre uma certa unidade se combinam entre si e com o estado presente da unidade, produzindo um novo estado de ativação.

Finalmente, a *regra de aprendizado* descreve mudanças no conhecimento contido num sistema conexionista. Estas mudanças são fundamentalmente modificações nos padrões de conectividade. Basicamente, há três tipos de modificações que podem ocorrer: o aparecimento de novas conexões, a perda de conexões já existentes ou a modificação do peso entre conexões. O terceiro tipo de modificação engloba as outras duas, pois quando o valor de uma conexão passa de 0 para 1 obtemos, na verdade, uma nova conexão. O oposto vale para o desaparecimento de conexões já existentes.

O PROBLEMA DO XOR

Conforme afirmamos, a abordagem conexionista originou-se da Cibernética, a partir dos trabalhos de McCulloch e Pitts (1943) e, posteriormente, Hebb (1949) e Rosemblatt (1962). McCulloch e Pitts

demonstraram que uma rede de neurônios com ligações excitatórias e inibitórias pode computar as funções lógicas "e", "ou" e "não" (ver o Capítulo 2 da primeira parte deste livro), o que se supunha equivaler à capacidade de modelar qualquer tipo de expressão lógica.

Além das tentativas de estabelecer uma caracterização formal do comportamento das redes de neurônios, esta pesquisa direcionou-se para a modelagem de funções cognitivas. Num trabalho de 1947, McCulloch e Pitts exploraram a possibilidade de construir redes para efetuar o reconhecimento de padrões visuais. Eles investigavam a habilidade de humanos e animais de reconhecer diferentes modos de apresentação de um mesmo objeto e como as múltiplas transformações de uma imagem (*input*) poderiam gerar uma representação canônica (*standard*) desse objeto. Seriam necessárias duas redes para realizar esta tarefa: a primeira deveria identificar as propriedades invariantes de um padrão e a segunda produziria uma representação *standard*.

Rosenblatt liderou esta pesquisa. Ele desenvolveu redes com várias camadas de neurônios binários, ou seja, redes que recebem *inputs* de fora e mandam excitações ou inibições para um outro conjunto de neurônios que podem, por sua vez, enviar *inputs* para um terceiro conjunto. Rosenblatt chamou estes sistemas de *perceptrons.* Várias novidades foram introduzidas na construção dos perceptrons: as conexões entre as unidades eram contínuas e não propriamente binárias, camadas de neurônios ativados podiam enviar excitações de volta para camadas anteriormente excitadas e a rede podia ser treinada para mudar suas respostas. Ou seja, a rede podia modificar os pesos das conexões de modo a modificar as respostas incorretas. Rosenblatt demonstrou um teorema importante acerca deste procedimento de treino, o chamado teorema da Convergência do Perceptron, mostrando que através de um número finito de sessões de treino a rede aprenderia a responder corretamente.

Além do reconhecimento de padrões visuais estudavam-se redes para modelar a memória humana. Um dos problemas nesta área era saber como redes poderiam estocar associações entre "lembranças diferentes". Donald Hebb (1949) desenvolveu uma proposta para resolver este problema que passou a ser conhecida, posteriormente, como a "regra de Hebb" (já nos referimos a ela no início deste capítulo). A regra de aprendizado de Hebb consiste em estipular que, se duas unidades de uma rede são excitadas simultaneamente, há um aumento na força de conexão entre elas. Esta regra vale também para sua variante inibitória.

Contudo, o desenvolvimento das pesquisas na área de redes neurais foi subitamente interrompido pela publicação do livro *Perceptrons,* por Minsky e Papert, em 1969. Por intermédio de uma análise matemática rigorosa, Minsky e Papert mostraram que a explosão combinatorial na quantidade de tempo requerida para o perceptron aprender a resolver certos problemas o tornava inviável. Ademais, eles mostraram que havia

certos problemas que o perceptron não poderia resolver: este era o caso da operação lógica XOR ou "ou exclusivo". Com isto, pretendia-se sepultar, de maneira definitiva, a abordagem conexionista na simulação de atividades mentais. Neste sentido, Minsky e Papert foram bem sucedidos: após sua crítica, foram precisos 20 anos para que os trabalhos de Hinton, Anderson, Rumelhart e McClelland voltassem a chamar a atenção da comunidade científica para as perspectivas que poderiam ser abertas pelo estudo das redes neurais artificiais.

Hoje em dia, o problema da modelagem da operação lógica XOR com o uso de redes neurais foi superado. Como os conexionistas solucionaram o problema do XOR? Um "ou" torna-se "ou exclusivo" se estabelecemos que um *input*, mas não ambos, assumem o valor 1 para se obter um *output* 1. Posso vir de terno ou de esporte fino, mas não posso vestir os dois. Em outras palavras, o *output* do XOR será 1 se os dois *inputs* forem diferentes. Um único neurônio não é capaz de implementar o XOR, mas uma rede resolve o problema. A figura a seguir mostra o tipo de rede que estamos procurando:

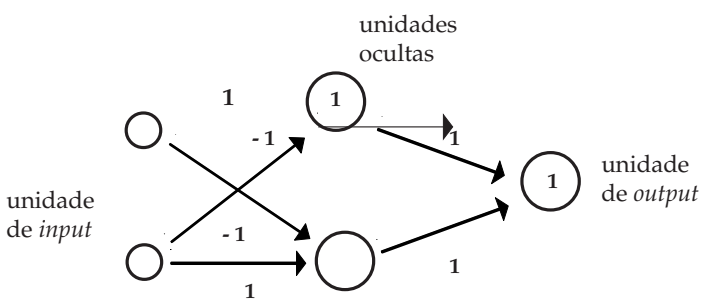

Figura 5.1. Rede XOR (adaptada de Franklin, 1995, p.128.)

Na figura anterior, os círculos à esquerda representam unidades geradoras de *input*. As duas unidades centrais são chamadas de *unidades ocultas*, pois não recebem *inputs* diretamente nem geram *outputs* diretamente. A unidade mais à direita produz o *output* da rede. As unidades ocultas e a unidade de *output* disparam quando um determinado limiar é atingido.

Dados dois 0s como *input*, a soma de ambos os pesos das unidades ocultas está abaixo do limiar, e, assim sendo, a unidade de *output* recebe apenas *inputs* 0, produzindo o *output* desejado. Suponhamos que a unidade superior recebe um 1 e a inferior um 0. No passo seguinte, a soma dos pesos da unidade superior oculta atinge o limiar, mas a inferior não. No terceiro passo, a unidade de *output* recebe um *input* de 1 e um de 0, produzindo uma soma de pesos que atinge o limiar e gera um *output* de 1, conforme o desejado. Se os *inputs* de 1 e 0 são invertidos, a situação se mantém simétrica e o resultado é o mesmo. A situação torna-se um pouco

mais delicada quando ambos os *inputs* são 1. No segundo passo, a soma dos pesos das unidades ocultas é 0, em decorrência do fato de que *inputs* excitatórios e inibitórios se cancelam mutuamente. Assim sendo, no terceiro passo a unidade de *output* recebe 0 e produz 0, conforme o desejado.

A resolução do problema do XOR abriu novas perspectivas para a abordagem conexionista. A partir dos anos 80, pesquisas na linha que vinha sendo desenvolvida por Rosenblatt passaram novamente a atrair atenção. Trabalhos sobre redes neurais começaram a ressurgir. Em 1981, Hinton e Anderson publicam o livro *Parallel Models of Associative Memory* e, em 1986, o clássico de Rumelhart e McClelland, *Parallel Distributed Processing*, que teve sua primeira edição esgotada antes mesmo de ser publicado. Vários fatores influenciaram o reaparecimento do conexionismo: o descontentamento com modelos simbólicos, a tentativa de reaproximar a abordagem da cognição com a pesquisa na área de neurociência que começava a ganhar cada vez mais força e o aperfeiçoamento de novas técnicas para treinar redes de múltiplas camadas. Este reaparecimento do conexionismo a partir da década de 80 influenciou de modo decisivo o desenvolvimento da Ciência Cognitiva modificando, de maneira drástica, seu desenvolvimento e suas perspectivas futuras.

SUMÁRIO DO PARADIGMA CONEXIONISTA

No seu ensaio *Conocer* (1988), Francisco Varela apresenta as linhas gerais do paradigma conexionista que reproduzimos a seguir:

> O que é a cognição?
> A emergência de estados globais numa rede de componentes simples.
> Como funciona esta rede?
> Por meio de regras locais que governam as operações individuais e de regras de mudança que governam a conexão entre os elementos da rede.
> Como saber se um sistema cognitivo funciona adequadamente?
> Quando verificamos que as propriedades emergentes e a estrutura resultante correspondem a uma atitude cognitiva específica: uma solução satisfatória para a tarefa em questão.

No paradigma conexionista, os símbolos não desempenham um papel central. A computação simbólica é substituída por operações numéricas, como, por exemplo, as equações diferenciais que governam um sistema dinâmico. Neste tipo de sistema o que realmente conta não são os símbolos, mas complexos padrões de atividade entre as múltiplas

unidades que constituem a rede. Esta mudança de enfoque implica abandonar o pressuposto básico da IA simbólica, qual seja, de que deve haver um nível simbólico independente do *hardware* na abordagem da cognição.

Ademais, na abordagem conexionista, o significado não está localizado em símbolos específicos: este emerge do estado global do sistema. Como este estado global emerge de uma rede de unidades mais básicas que os próprios símbolos, o paradigma conexionista é também chamado de "paradigma subsimbólico" (Smolensky, 1988). O nível subsimbólico superpõe-se ao biológico, embora esteja mais próximo deste do que na IA simbólica. No paradigma subsimbólico, o significado emerge de complexos padrões de atividade sem, entretanto, residir especificamente em cada um dos componentes da rede.

O QUE LER

1 – McClelland e Rumelhart . *Parallel Distributed Processing.*
2 – Smolensky, P . *On the Proper Treatment of Connectionism.*

Capítulo 6

Um sistema conexionista com memória distribuída

Conceitos introduzidos neste capítulo:
- Sistemas com representação distribuída.
- As propriedades de sistemas conexionistas:
  a) Memória endereçável por conteúdo
  b) Degeneração gradual
  c) Atribuição *default*
  d) Generalização flexível
  e) Propriedades emergentes
  f) Aprendizado

Redes conexionistas são sistemas complexos de unidades simples que se adaptam ao seu meio ambiente. Alguns deles têm milhares de unidades, mas mesmo aqueles que têm apenas algumas poucas podem apresentar um comportamento complexo e, por vezes, surpreendente. Seu processamento ocorre em paralelo e de forma interativa, distinguindo-se do processamento serial utilizado pela Inteligência Artificial simbólica.

De um modo geral, tais sistemas podem ser divididos em duas grandes classes, de acordo com o tipo de representação que eles utilizam. O primeiro tipo utiliza-se de *representações locais*, ou seja, as unidades neste tipo de sistema têm interpretações bem definidas (por exemplo, uma unidade específica pode tornar-se ativa se e somente se o *input* é a cor vermelha; assim sendo, a unidade pode ser interpretada como significando "vermelho"). O segundo tipo utiliza-se de *representações distribuídas* por meio de várias unidades (um nó ou unidade pode fazer parte de diferentes representações: ele pode estar ativado quando o vermelho está presente, mas também quando o alaranjado está). Neste caso, a interpretação só é possível considerando-se um conjunto de unidades.

É preciso notar que quando falamos em representação num sistema conexionista estamos empregando esta palavra num sentido diferente daquele utilizado pela Inteligência Artificial simbólica. Representar, num sistema conexionista, significa estabelecer relações entre unidades ou

neuron-like units – relações que podem ser expressas matematicamente na forma de um conjunto de equações. Neste sentido, a própria idéia de como a atividade mental produz representações é profundamente alterada na concepção conexionista, ou seja, não podemos conceber a existência de um nível representacional abstrato e simbólico, com total independência em relação ao *hardware* que o instancia.

UM EXEMPLO DE SISTEMA COM REPRESENTAÇÃO DISTRIBUÍDA

Um dos melhores exemplos do funcionamento de um sistema conexionista com representação distribuída encontra-se no livro de McClelland, Rumelhart e Hinton (1986). Alguns comentários e complementações a este exemplo foram feitos posteriormente por Clark (1989), que reproduzimos aqui. McClelland, Rumelhart e Hinton nos convidam a imaginar duas gangues que agem nas ruas de Nova Iorque: os JETS e os SHARKS. Características destas gangues estão representadas na tabela a seguir:

Nome	Guangue	Idade	Escolaridade	Estado Civil	Profissão
Art	Jets	40	Primário	solteiro	traficante
Al	Jets	30	Primário	casado	assaltante
Sam	Jets	20	Superior	solteiro	banqueiro
Clyde	Jets	40	Primário	solteiro	banqueiro
Mike	Jets	30	Primário	solteiro	banqueiro
Jim	Jets	20	Primário	divorciado	assaltante
Greg	Jets	20	Secundário	casado	traficante
John	Jets	20	Primário	casado	assaltante
Doug	Jets	30	Secundário	solteiro	banqueiro
Lance	Jets	20	Primário	casado	assaltante
George	Jets	20	Primário	divorciado	assaltante
Pete	Jets	20	Secundário	solteiro	banqueiro
Fred	Jets	20	Secundário	solteiro	traficante
Gene	Jets	20	Superior	solteiro	traficante
Ralph	Jets	30	Primário	solteiro	traficante
Phil	Sharks	30	Superior	casado	traficante
Ike	Sharks	30	Primário	solteiro	traficante
Nick	Sharks	30	Secundário	solteiro	traficante
Don	Sharks	30	Superior	casado	assaltante
Ned	Sharks	30	Superior	casado	banqueiro
Karl	Sharks	40	Secundário	casado	banqueiro
Ken	Sharks	20	Secundário	solteiro	assaltante
Earl	Sharks	40	Secundário	casado	assaltante
Rick	Sharks	30	Secundário	divorciado	assaltante
Ol	Sharks	30	Superior	casado	traficante
Neal	Sharks	30	Secundário	solteiro	banqueiro
Dave	Sharks	30	Secundário	divorciado	traficante

(Note-se que as idades são aproximadas, 40= ao redor de 40 anos, 20= em torno de 20 anos. Note-se também que banqueiro = banqueiro de bicho).

Estas características podem, por sua vez, ser representadas através do seguinte diagrama:

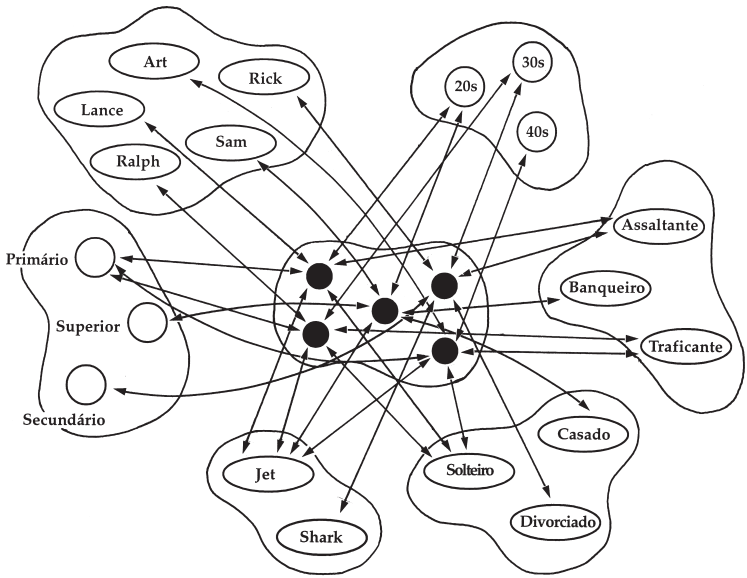

Figura 6.1. Modelo de rede conexionista distribuída (adaptada de McClelland & Rumelhart, 1986, p. 28).

Note-se, no diagrama apresentado que:

Círculos irregulares significam a existência de conexões mutuamente inibitórias entre as unidades dentro do círculo. Assim, a primeira figura está composta de três unidades, uma delas significando que o indivíduo em questão tem em torno de 20 anos, outra significando que o indivíduo tem em torno de 30 anos, e assim por diante. Na medida em que ninguém pode, simultaneamente, estar em torno de seus 30 anos e de seus 40 anos também, as unidades têm de ser mutuamente inibitórias. Se uma delas é excitada, as outras duas terão de ser inibidas.

As linhas com flechas na extremidade representam conexões excitatórias. Se a linha possui flechas em ambas as extremidades, a conexão é mutuamente excitatória. Assim sendo, suponha que todos os assaltantes tenham idade em torno de 30 anos. Haveria uma conexão excitatória entre cada unidade correspondente a um assaltante e a unidade correspondendo à idade em torno de 30 anos. Se, além disto, *somente* os assaltantes estão em idade em torno de 30 anos, a unidade correspondente a "30 anos" estaria conectada, de maneira excitatória, com as unidades que representam assaltantes.

Os círculos pretos significam indivíduos e estão conectados com as propriedades exibidas pelo indivíduo por meio de conexões excitatórias. Por exemplo, uma destas unidades está ligada às unidades representando Lance, 20 anos, assaltante, solteiro, Jet e aluno de escola primária.

Estocando informação desta maneira, o sistema passa a exibir as seguintes propriedades, que examinaremos a seguir: memória endereçável por conteúdo (*content addressable memory*), degeneração gradual (*Graceful Degradation*) e generalização.

Memória endereçável por conteúdo (*Content Addressable Memory*): considere a informação que a rede estoca acerca de Rick. Rick é divorciado, é um assaltante com curso secundário e tem em torno de 30 anos. Num sistema convencional, esta informação seria estocada em um ou vários endereços e sua recuperação (*retrieval*) dependeria de se saber o endereço. Contudo, é possível tornar toda esta informação acessível através de qualquer uma das rotas escolhidas. Por exemplo, pode-se querer saber dados acerca de um Shark em torno de 30 anos ou se pode ter uma descrição que seja adequada para identificar um indivíduo específico. Contudo, esta descrição pode conter alguns erros. Este acesso à informação, apesar da "descrição com alguns erros", é a memória endereçável por conteúdo. Podemos facilmente encontrar o item que satisfaz a descrição: "É um ator, é inteligente, é um político," apesar da descrição ser incompleta. Num sistema tradicional, a descrição incompleta ou com erros exige uma busca extremamente complexa. O mesmo não ocorre se se estoca a informação numa rede como a que acabamos de descrever, que se comportará de uma das seguintes maneiras:

1 – Quando um padrão familiar (já estocado) entra na memória do sistema, ele é expandido e o sistema responde com uma versão mais forte do *input*, numa espécie de atividade de recognição.
2 – Se um padrão totalmente desconhecido entra na memória do sistema, ele é simplesmente descartado.
3 – Quando somente uma parte do padrão entra na memória do sistema, este completa as partes que faltam. Este é o caso típico da memória endereçável por conteúdo (*Content Addressable Memory System*).

Vejamos como (3) ocorre tomando como exemplo a rede de que estamos falando. Suponhamos que queiramos saber quem satisfaz a descrição "é um Shark em torno de 30 anos". As unidades correspondentes a "Sharks" e "tem em torno de 30 anos" são ativadas e passam valores positivos para as unidades com as quais elas estão conectadas por meio de ligações excitatórias. Espalha-se uma ativação que se inicia com a primeira unidade e depois com as outras. O resultado é um padrão de ativação envolvendo as unidades correspondentes a "Shark", "tem em torno de 30 anos", "assaltante", "divorciado", "tem curso secundário" e "Rick". O processo aparece na figura a seguir:

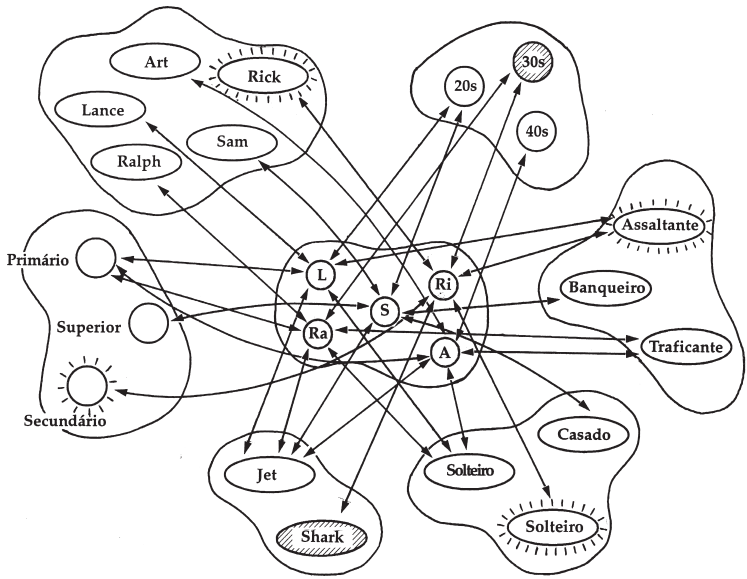

Figura 6.2. Padrão de ativação para um Shark em torno de 30 anos. As partes hachuradas correspondem a *inputs* e as ressaltadas correspondem às unidades pelas quais a ativação se espalha (adaptada de McClelland & Rumelhart, 1986, p.28).

O ponto importante que deve ser notado é o seguinte: o mesmo padrão final de ativação (isto é, o padrão geral de unidades ativas após espalhar-se a ativação) poderia ter sido obtido dando-se ao sistema qualquer uma das descrições parciais, por exemplo, os *inputs* "Shark, educação secundária", "Rick, em torno dos 30 anos", e assim por diante. Usando-se uma rede para a representação dos dados, obtém-se uma memória flexível, endereçável por conteúdo.

Degeneração gradual (*Graceful Degradation*): Clark aponta que há duas variedades de degeneração gradual. A primeira consiste na capacidade de um sistema em continuar a funcionar apesar de seu *hardware* ter sofrido algum dano. A segunda consiste na capacidade de um sistema de operar com base em dados que podem ser parciais ou incluir erros.

A capacidade de tolerar danos no *hardware* é uma propriedade que aproxima os sistemas com memória distribuída do modo como funciona a memória humana: a perda de alguns componentes do sistema faz com que a informação degrade, mas não implica a sua perda total. A plausibilidade da memória distribuída torna-se evidente no célebre caso da "memória da vovó": se todas as minhas memórias acerca de minha avó

estivessem estocadas localmente, ou seja, em apenas um neurônio no meu cérebro e se por acaso esse neurônio desaparecesse ou se degenerasse, no dia seguinte eu seria incapaz de reconhecer minha avó. Tal fato não ocorreria se minhas memórias acerca de minha avó estivessem distribuídas na rede; no máximo eu me tornaria incapaz de me lembrar de alguma característica específica de minha avó ou de algum evento relacionado com a sua vida.

Vejamos agora o segundo tipo de degeneração gradual. Suponhamos que queiramos recuperar o nome de um indivíduo que acreditamos ser um Jet, banqueiro de bicho, casado e com educação primária. Ninguém em nosso modelo satisfaz esta descrição. O que melhor se encaixa é Sam, que é banqueiro de bicho, Jet, casado, mas tem educação superior. A rede pode lidar com estes dados, graças à conexões inibitórias. As unidades para "banqueiro de bicho", "casado", "Jet" e unidade (errada) para "educação primária" são ativadas. As unidades para "banqueiro de bicho" e "casado" excitam apenas uma das unidades que especifica indivíduos. Elas aparecem na figura a seguir:

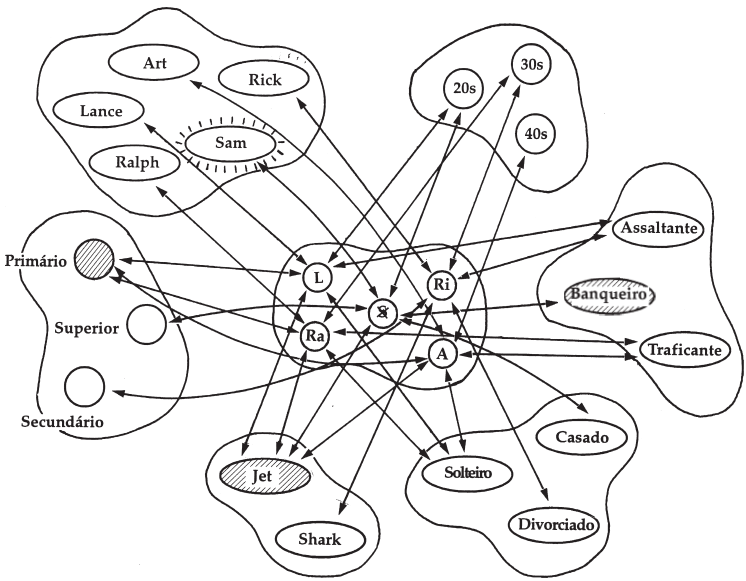

Figura 6.3. Padrão de ativação para um Jet que é banqueiro de bicho e com educação primária. As unidades no centro da figura estão marcadas com as iniciais dos membros da gangue. Os *inputs* estão hachurados. As unidades individuais mais ativadas estão marcadas com um *x* e as unidades correspondentes a nomes que são excitadas, ressaltadas (adaptada de McClelland & Rumelhart, 1986, p. 28).

A unidade "Jet" excita as unidades correspondentes a indivíduos marcadas como *A, S, Ra,* e *L.* (somente Rick, cuja unidade correspondente está marcada como *ri* é um Shark). A unidade "escola primária" excita *L, Ra* e *A*. Ou seja:

A unidade "banqueiro de bicho" excita *S.*

A unidade "casado" excita *S.*

A unidade "Jet" excita *A, S, Ra, L.*

A unidade "escola primária" excita *L, Ra, A.*

Assim sendo, a unidade *S* é estimulada três vezes e as unidades *L, Ra* e *A,* duas vezes. Mas as várias unidades que representam indivíduos são conectadas entre elas numa maneira mutuamente inibitória e, assim, a tripla ativação da unidade *S* tende a inibir a ativação dupla, mais fraca das unidades *A, L* e *Ra*. Quando a ativação se espalha a partir das unidades individuais, a unidade *S* transmite o valor excitatório mais importante. A unidade *S* está conectada, de forma excitatória, com a unidade correspondente a Sam. E as diversas unidades correspondentes a nomes estão também conectadas, competitivamente, através de ligações mutuamente inibitórias. Assim sendo, "Sam" vai ser o resultado da descrição incompleta que começa com "Jet", "banqueiro de bicho" , "casado", "educação primária" . O caminho da ativação aparece na figura anterior.

Atribuição default: Suponhamos que não saibamos que Lance é um assaltante. Mas sabemos que a maior parte dos Jets com educação primária e em torno de 20 anos são assaltantes e não banqueiros de bicho ou traficantes. Seria razoável supor que Lance também é um assaltante, até prova em contrário. Este tipo de pressuposição é chamada de *atribuição default*. É prática comum pressupor que podemos sempre estender os dados disponíveis de maneira a recobrir casos novos. A rede que estamos examinando recobre, por atribuição *default*, casos novos. Como isto ocorre? Suponhamos que não saibamos que Lance, é um assaltante. Mesmo assim, quando ativamos a unidade com o nome Lance, esta ativará as unidades relacionadas a todas as propriedades conhecidas de Lance (Jet, escola primária, casado, em torno de 20 anos). Estas unidades correspondentes a propriedades vão, por sua vez, excitar as unidades de outros que também têm estas propriedades. Se a maioria daqueles que têm as propriedades de Lance têm também uma propriedade adicional, então a ativação a partir destas unidades vai se combinar para ativar, no caso de Lance, a unidade representando a propriedade adicional em questão. Neste sentido, a unidade correspondente a "assaltante" é ativada como uma espécie de atribuição *default* de Lance.

Generalização flexível: A generalização flexível é uma propriedade muito similar à atribuição *default*. Num certo sentido, podemos considerar todas as propriedades de nosso exemplo como envolvendo descrições em níveis diferentes e usos da mesma estratégia computacional para lidar

com casos de descrição incompleta. Neste caso, a capacidade do sistema de completar a descrição é usada para gerar um conjunto típico de propriedades associadas com essa descrição. O sistema "sabe" sobre indivíduos e nenhum deles precisa ser uma perfeita instanciação da descrição em questão. Assim, suponhamos que queiramos encontrar o esquema do Jet típico. Existem padrões que definem se um indivíduo é ou não um Jet, embora nenhum indivíduo instancie todos esses padrões. Assim, a maioria dos Jets são solteiros, em torno de 20 anos e com educação primária. Não existe nenhum padrão, que, por si só, especifique que um indivíduo seja um Jet. Se se dá o *input* "Jet" para o sistema, as unidades correspondentes a "solteiro", "em torno de 20 anos", e "com escola primária" entrarão em atividade, e as restantes se inibirão mutuamente. Desta maneira, o sistema generaliza a natureza típica de um Jet, embora nenhum indivíduo de fato possua as três propriedades simultaneamente.

O interessante aqui não é apenas a capacidade de generalizar, mas a flexibilidade do sistema. Um sistema convencional poderia criar e estocar várias generalizações. Mas o PDP pode generalizar de uma maneira muito flexível, sem necessidade de uma estocagem explícita ou decisões anteriores quanto à forma da generalização. A rede pode fornecer generalizações a partir de qualquer tipo de dado que entre como *input*, desde que este dado esteja de alguma maneira estocado nela. Por exemplo, em vez de pedir detalhes de um Jet típico, podemos pedir detalhes de uma pessoa em torno de 20 anos, com educação primária ou um típico traficante casado. A generalização efetuada pela rede é flexível, ela pode alinhar dados de uma maneira nova e até impredizível: esta é uma das grandes vantagens do PDP no que diz respeito à representação do conhecimento.

Propriedades emergentes: em nosso capítulo sobre sistemas especialistas vimos brevemente a idéia de representação utilizando *frames*. Os *frames* funcionam como uma espécie de esquema, uma estrutura de dados que estoca – de forma estereotipada – itens ou eventos associados com alguma descrição. O problema envolvido na construção destes esquemas é a enorme quantidade de informação implícita ou simplesmente pressuposta, o que torna a sua construção por vezes problemática. Por exemplo, uma das dificuldades que surgem é o fato de eles se comportarem de maneira "rígida". Qualquer variante da situação expressa no esquema exige que se construa um subesquema, e isto pode exigir a construção de uma enorme quantidade de subesquemas se procedermos na maneira tradicional da Inteligência Artificial simbólica. O custo computacional envolvido neste tipo de tarefa pode se tornar enorme.

McClelland e Rumelhart desenvolveram um sistema conexionista no qual as propriedades de um esquema simplesmente *emergem* da atividade de uma rede de unidades que reagem à variação de características

(variantes) do esquema em questão. Estes esquemas emergentes são apresentados como uma solução parcial para o dilema que surge na abordagem tradicional: eles caracterizam-se por um tipo de maleabilidade que falta na abordagem tradicional ou que teria de ser suprida passo a passo. Já no modelo PDP não há um esquema explícito representado: ele emerge no momento necessário, a partir da interação de vários elementos simples, ou seja, de padrões ou subpadrões de unidades que se conectam a partir de ligações excitatórias. Não é preciso estabelecer de antemão as variantes de um esquema, pois este sistema pode aprendê-las e mobilizá-las quando for necessário.

Estas idéias são ilustradas por McClelland e Rumelhart, que analisam o modo de conceber um quarto, uma cozinha ou um escritório. Tais exemplos ilustram melhor ainda a idéia de representação distribuída, além de mostrar como caracterizações simbólicas típicas (por exemplo, uma idéia de quarto ou cozinha) podem emergir a partir de uma rede de entidades mais simples.

Um quarto padrão tem mobílias típicas; o mesmo ocorre com uma cozinha. Em geral, quando entramos num cômodo com um fogão, há nele também uma pia, mas não há uma cama. Suponhamos agora que temos um conjunto de unidades PDP sensíveis à presença de mobília doméstica. Unidades que se ligam o fazem através de conexões excitatórias, enquanto unidades que não se ligam mantêm entre si conexões inibitórias. Quando se excita um item que se encontra numa cozinha, todos os itens que normalmente são encontrados numa cozinha são igualmente excitados: este é um *esquema emergente*.

Vejamos em maior detalhe este modo de representar informação. A primeira propriedade interessante é, neste caso, a natureza distribuída da representação da cozinha. O conceito de cozinha, nesta perspectiva, envolve muitas características implícitas (ou microcaracterísticas, como, por exemplo, propriedades funcionais ou geométricas dos objetos). A estratégia de construir correlatos de conceitos a partir de pequenas partes (microcaracterísticas) tem vantagens: degradação gradual, possibilidade de esquemas emergentes, para citar apenas duas.

Encontramos aqui um exemplo concreto de como uma rede pode simular aspectos típicos da inteligência e cognição humanas, com sua característica essencial: a flexibilidade. Esquemas emergentes dispensam a necessidade de decidir previamente quais as situações possíveis com as quais o sistema precisará lidar, dando lugar a uma espécie de "holismo informacional" que simula a flexibilidade da inteligência humana.

Aprendizado e memória: McClelland e Rumelhart desenvolveram um modelo de memória no qual experiências específicas, uma vez estocadas, geram uma compreensão geral da natureza do domínio em questão. Por exemplo, estocar características de experiências específicas de ver

cachorros vai gerar um protótipo de cachorro. A compreensão prototípica surge como uma propriedade emergente gerada pelo sistema após uma série de experiências. No modelo desenvolvido por McClelland e Rumelhart, a rede é exposta a um conjunto sucessivo de *inputs* que contém primitivos representacionais, ou seja, um conjunto de características (cor, tamanho, nome, etc) que causa uma reação nas unidades do sistema. A tarefa do sistema é a seguinte: dado um *input* com as características f1....f10, o sistema deve estocar o *input* de tal maneira que seja capaz de recriá-lo a partir de um fragmento dele que sirva como pista. Assim, se se dão ao sistema os valores f1..f4, queremos que ele preencha f5...f10 com valores apropriados, ou seja, derivados da experiência anterior.

Uma regra simples de aprendizado, chamada de *regra delta* produz este tipo de comportamento. O que faz a regra delta? Fazer com que um sistema recrie um padrão de ativação anterior f1...f10 quando o fragmento f1...f4 é dado significa fazer com que as conexões internas entre as unidades na rede sejam de tal maneira que a ativação do fragmento f1...f4 cause a ativação do resto, ou seja, f1...f10. É preciso que haja ligações excitatórias fortes entre f1...f4 e f5...f10. Uma vez que o sistema recebe o *input* f1...f10, a regra delta faz com que o sistema verifique se as conexões internas entre as unidades que estavam ativas podem levar a recriar a totalidade do *input*. Se este não for o caso, ela modifica o padrão de conectividade para que isto aconteça. Na verdade, redes neurais podem ser treinadas para ajustar seu padrão de conectividade. A fase de treinamento é uma fase de aprendizado. A rede recebe um *input* e produz um *output*. Este *output* é, então, comparado com o *output* que seria correto. Calcula-se o erro e a rede então ajusta seus padrões de conectividade para ver se consegue aproximar seu *output* daquilo que se considera o *output* correto. Uma vez tendo feito todo o aprendizado, a rede torna-se capaz não apenas de processar o *input* típico como também suas instâncias mais próximas e a partir delas gerar protótipos.

Vejamos como isto acontece no exemplo com cachorros, que tiramos de McClelland e Rumelhart. Em primeiro lugar, é preciso delimitar o domínio, ou seja, estabelecer um protótipo de cachorro. Digamos que neste protótipo participam 16 primitivos representacionais. Em seguida, precisamos criar uma série de descrições de cachorros específicos, nenhuma das quais é igual ao protótipo. No passo seguinte damos um nome para cada cachorro. Para cada cachorro com um nome haverá um padrão de ativação entre oito unidades. Damos para a rede uma série de experiências de cachorros individuais ativando as unidades que correspondem à descrição do cachorro e os nomes de cachorros. Após isto, deixamos o sistema utilizar-se da regra delta para formar um traço de memória na forma de um padrão de conectividade alterada e para facilitar a chamada da última descrição de cachorro.

Após 50 exposições, o sistema não foi exposto a nenhum cachorro prototípico, mas apenas a instâncias distorcidas. O sistema recebeu apenas um fragmento do protótipo como *input*, mas foi capaz de completá-lo. Nenhuma unidade com nomes foi ativada. O que a rede fez foi extrair um padrão comum de todos os *inputs* distorcidos. Da mesma forma, a rede será capaz de recriar o padrão de ativação de um cachorro específico, se o *input* que for dado tiver algum tipo de dica que aponte para esse animal: o seu nome ou alguma característica física particular.

O QUE LER

1 – McClelland e Rumelhart. *Parallel Distributed Processing*.

Capítulo 7

Conexionismo e filosofia da mente

Conceitos introduzidos neste capítulo:
- O problema mente-cérebro na perspectiva conexionista.
- As implicações filosóficas do conexionismo para a questão do estatuto da *folk-psychology*.
- As implicações filosóficas do conexionismo para a filosofia da ciência (modelos explicativos).
- Os limites da abordagem conexionista (problema da descrição e problema epistêmico).

Quais as implicações filosóficas da abordagem conexionista? Embora muitos tenham questionado se o conexionismo realmente representa uma ruptura com as concepções tradicionais de computabilidade, não partilhamos deste ponto de vista. O conexionismo introduz uma nova concepção do funcionamento mental – uma concepção radicalmente diferente da visão cartesiana pressuposta pelo paradigma simbólico. Se há raízes filosóficas para o conexionismo, estas devem ser buscadas em concepções materialistas da mente, como, por exemplo, a defendida pelo filósofo francês La Mettrie, no século XVIII. Mesmo que sistemas conexionistas possam ser simulados em computadores digitais – máquinas com arquitetura von Neumann – isto não deve nos iludir: há uma diferença radical, paradigmática, entre a Inteligência Artificial simbólica e a conexionista.

No seu livro *L´Homme machine* – um verdadeiro arauto em defesa do materialismo e da Inteligência Artificial, perdido no século XVIII – La Mettrie fazia referência à possibilidade de aparecer um segundo Prometeu que um dia construiria um homem mecânico que poderia falar. Contrariamente a Descartes, La Mettrie explicava o fato de que animais não possam falar pela sua anatomia, que teria algum defeito ou incompletude que poderia eventualmente ser corrigido, restando então a tarefa de treinar o animal para que ele pudesse falar. Embora este tipo de afirmação possa nos parecer estranha ou ingênua hoje em dia, ela nos

remete para algo que será fundamental para o conexionismo, séculos depois: a ênfase na importância do *hardware* ou da arquitetura física utilizada para simular a atividade mental. Na perspectiva conexionista, a mente não é simplesmente um programa computacional, um enlace de representações que realiza um algoritmo e que pode ser instanciado em qualquer tipo de substrato físico, independentemente de sua arquitetura específica. A Inteligência Artificial simbólica herdou uma metafísica cartesiana ao estabelecer uma dualidade entre *software* e *hardware* como metáfora para conceber as relações mente/cérebro. O mais paradoxal disto é que Descartes era precisamente o filósofo que não concordava com a possibilidade de se atribuir vida mental legítima a animais ou a autômatos. Ao mesmo tempo, Descartes foi o pai da IA forte, da IA que sustenta que é o programa que deve comandar a seqüência das transformações físicas no *hardware*, ou, em outras palavras, que é a consciência que controla os processos cerebrais e não vice-versa. E a IA forte por muitos anos omitiu-se de falar qualquer coisa sobre a consciência, na medida em que seus defensores sabiam que simular estados conscientes seria quase impossível. No final dos anos 70, a IA forte começou a admitir as mesmas conclusões de Descartes, ou seja, a idéia de que pelo fato de não podermos simular a consciência, a possibilidade de gerar uma simulação completa da atividade mental encontraria sempre um hiato intransponível entre mentes e máquinas.

A retomada do conexionismo e de seu projeto de simulação do cérebro nos meados dos anos 80 representou uma aposta no materialismo, ou seja, na idéia de que é a complexidade de certos sistemas físicos que os qualifica para produzir vida mental. Estados mentais *emergem* das redes: a ordem da programação é substituída pela própria organização ou auto-organização do *hardware*, ou, em outras palavras, estados mentais são a realização de certas disposições que exigem uma arquitetura específica da máquina.

O PROBLEMA MENTE-CÉREBRO NO CONEXIONISMO

Qual a contribuição do conexionismo para o problema mente-cérebro? O conexionismo não resolve este problema, mas dele surgem perspectivas que merecem comentário. Com efeito, o conexionismo abre novas perspectivas para se sustentar uma teoria materialista da mente, apontando para possíveis soluções de algumas de suas dificuldades conceituais.

Uma dessas dificuldades conceituais é o chamado paradoxo da localização espacial dos estados mentais. Se queremos estipular uma teoria materialista da mente de acordo com bases científicas, é inevitável que estados mentais devam se conformar às leis da Física. Se estas últimas estão corretas e, se, além disto, estados mentais ocorrem no tempo (o que

parece difícil ou quase impossível de negar), então devemos igualmente supor que estados mentais ocorrem *no espaço*, ou seja, que eles devam ter algum tipo de localização espacial. Facilmente enveredamos por paradoxos semânticos ao tentar localizar estados mentais no espaço: que sentido haveria em afirmar que meu sonho ocorreu a 5 cm do hemisfério esquerdo do meu cérebro? Ou que a minha ansiedade está localizada a 5 cm do hemisfério esquerdo do meu cérebro? Note-se, entretanto, que a geração destes paradoxos semânticos só ocorre em contextos particularmente limitados: com efeito, não faz sentido afirmar que o meu sonho ocorreu a 5 cm do hemisfério esquerdo do meu cérebro, ou no neurônio que convencionei ter o número 235. Contudo, não parece ser paradoxal afirmar que o meu sonho ocorreu no quarto onde eu dormia, nem afirmar que o meu sonho ocorreu *no mundo*. Se meu sonho não tivesse ocorrido no mundo, como poderia falar dele quando retorno à vida desperta? A questão da possibilidade de se falar da localização de estados mentais é fundamental para a idéia de que estados mentais são estados materiais, ou seja, para uma visão materialista da mente.

Ora, os modelos conexionistas tornam possível conceber estados mentais como estados materiais sem cair nos paradoxos de que falamos. Estados mentais ocorrem no espaço, embora não possamos dizer exatamente *onde* eles ocorrem: eles estão em algum lugar da rede de conexões entre as unidades e na forma de um processo global do sistema. Não faz sentido afirmar "meu sonho ocorre a 5 cm do hemisfério esquerdo do meu cérebro", mas faz sentido afirmar que meu sonho ocorre no quarto ou meu sonho ocorre no mundo, da mesma maneira que o faz afirmar que ele ocorre em algum lugar da rede. Não podemos identificar um estado mental com um estado cerebral específico da mesma maneira que não podemos localizá-lo nem dizer que ele é o resultado de uma única e possível combinação de ativações de uma determinada rede. A identidade será sempre identidade com um determinado processo (uma ativação ou inibição) e não com um grupo específico de neurônios. Conteúdos mentais não são fenômenos localizados, mas o resultado de uma arquitetura específica das redes de conexões ou de um *design* específico que instancia um determinado *software*. A produção do mental depende não de um material específico nem de uma combinação simbólica, mas desse *design* específico no qual a ordem semântica e a ordem causal das leis da natureza constituem um mesmo e indistinguível objeto dando lugar à representação implícita ou a um estado mental.

Neste modelo, os conteúdos mentais *emergem* da atividade das redes e suas conexões: caminhamos aqui numa direção inversa àquela do funcionalismo tradicional onde estados mentais são *atribuídos* a estados do *hardware*. Ou, para empregar uma terminologia filosófica, podemos afirmar que estados mentais são *supervenientes* à atividade das redes. A noção de emergência ou de superveniência que introduzimos aqui é

compatível com a hipótese materialista que procuramos manter até agora e encontra paralelo numa série de fenômenos físicos cotidianos. A formação do gelo, após o resfriamento da água, constitui um bom exemplo do que estamos afirmando. Ninguém negaria que o gelo é água, mas, por outro lado, a ele podem ser atribuídos predicados que não se encontram na água, como "ser sólida". A solidez é um predicado emergente que se forma a partir de leis físicas bem estabelecidas e conhecidas. Contudo, "ser sólido" não é um predicado que possamos atribuir a cada uma das moléculas de uma barra de gelo, mas só ao sistema físico como um todo. A mesma coisa podemos afirmar, *mutatis mutandis*, da emergência de estados mentais a partir das configurações neuronais e da conectividade: estados mentais podem surgir destas últimas, mas dificilmente poderíamos atribuir suas propriedades a cada um dos neurônios considerados isoladamente.

É também esta concepção de conectividade que possibilita que indipvíduos inicialmente com uma mesma rede e recebendo um mesmo *input* possam formar conteúdos mentais diferenciados, seja do ponto de vista qualitativo, seja do ponto de vista da intensidade de uma determinada sensação: é impossível determinar *a priori* quais serão as conexões a serem ativadas e como será a distribuição dos pesos pela rede. Esta seria a contribuição dos modelos conexionistas para uma possível solução do problema dos *qualia*. Conteúdos mentais são, assim, essencialmente indetermináveis não apenas na medida em que não podemos antever quais as redes que serão ativadas por um *input* sensorial, como também pelo fato de se poder estabelecer uma diferença entre conteúdos sensoriais e conteúdos representacionais em diferentes indivíduos. Conteúdos representacionais, na medida em que supervêm à atividade da rede, podem se tornar privados e inescrutáveis. Um exemplo que ilustra esta afirmação e, conseqüentemente, a diferença entre conteúdo sensorial e conteúdo representacional pode ser encontrado no livro de I. Rock, *Introduction to Perception*. Nele, Rock apresenta ao leitor a figura composta por pontos[1].

O que há de interessante nesta figura de *Gestalt* é o fato de que quem a vê pode relatar sua percepção, seja como "três linhas com pontos cheios" ou como "quatro colunas com três pontos cheios". O mesmo *input* visual, ou seja, o mesmo conteúdo sensorial pode dar lugar a dois tipos diferentes de conteúdo representacional. A variação de conteúdo representacional poderia ser explicada pela ativação de diferentes redes ou diferentes conexões que podem variar de indivíduo para indivíduo ou até ocorrer no mesmo indivíduo em tempos diferentes – uma diferença de ativação que por sua peculiaridade torna a formação de conteúdos representacionais imprevisíveis para um observador externo.

[1]Este exemplo bem como esta discussão foram apresentados em Teixeira, J. de F. (1996), capítulo 5.

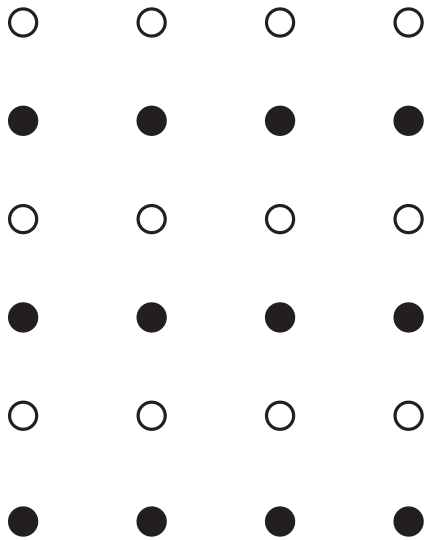

Figura 7.1. Figura composta por pontos.

OUTROS ASPECTOS FILOSÓFICOS DO CONEXIONISMO

Há ainda outras implicações filosóficas que emergem do paradigma conexionista que precisam ser comentadas, ainda que brevemente:

A questão da folk-psychology – vimos no capítulo anterior que a relação entre conexionismo e as neurociências, bem como a plausibilidade neurológica dos modelos conexionistas ocupam um lugar de destaque. Embora modelos conexionistas não sejam modelos do cérebro, eles apontam para uma possível relação de seus componentes com componentes cerebrais. A questão que podemos colocar é a seguinte: até que ponto esta relação não pode, em certos casos, constituir algum tipo de *redução*? Esta questão torna-se mais importante no caso da *folk-psychology*, cuja redução a componentes cerebrais significaria seu desaparecimento progressivo. Este é o ponto de vista defendido por filósofos como Rorty (1965) e Feyerabend (1963), que sustentam que a *folk-psychology* desaparecerá à medida que tivermos teorias mais adequadas de como o cérebro funciona. Chegamos, assim, ao materialismo eliminativo, de que tivemos oportunidade de falar no Capítulo 2 da primeira parte deste livro. Este ponto de vista é também defendido por Patricia e Paul Churchland. Para os Churchlands, a *folk-psychology* é uma teoria falsa, que deve ser abandonada. Contudo, este ponto de vista é ainda bastante controverso: a possibilidade de estabelecer correlatos cerebrais para a *folk-psychology* usando vocabulário conexionista não implica, por si só, que esta seja necessariamente falsa.

O problema da intencionalidade: vimos no Capítulo 4 da primeira parte deste livro que o problema da intencionalidade constitui um sério obstáculo a ser superado pela Inteligência Artificial simbólica. A questão da intencionalidade consiste em saber como os símbolos utilizados por um programa de computador podem ter referentes no mundo. Numa abordagem formal e sintática, como é o caso da Inteligência Artificial simbólica, é praticamente impossível superar este problema – o Argumento do Quarto do Chinês, formulado por John Searle, vai nesta direção. Esta incapacidade de referir-se ao mundo torna-se mais evidente ainda no caso da linguagem natural: os símbolos são atômicos e incapazes de representar contextos, na medida em que são símbolos que não variam.

Uma das vantagens da abordagem conexionista é o modo como o processamento de informação que ocorre nos sistemas estabelece uma continuidade com os processos que ocorrem no mundo exterior. Há a possibilidade de situar o sistema cognitivo no mundo fazendo com que seus *inputs* e o processamento destes varie à medida que o mundo se transforma: este seria o processo de "adaptação" do sistema. Haveria, assim, pelo menos uma esperança de superar o problema da intencionalidade. Infelizmente, a maioria dos sistemas conexionistas ainda funciona com representações que são em grande parte fornecidas pelo programador, e, assim sendo, não podemos afirmar que tais sistemas estão efetivamente em contato com o mundo exterior. Esta limitação ainda inerente aos sistemas conexionistas motivou em grande parte a crítica dos partidários da Vida Artificial e da Nova Robótica e sua insistência na necessidade de ligar diretamente sistemas artificiais ao mundo exterior – críticas que teremos oportunidade de examinar na terceira parte deste livro.

Questões de Filosofia da Ciência: uma das questões centrais discutidas pelos filósofos da ciência é a natureza das explicações científicas. Tradicionalmente, uma explicação científica envolve leis gerais, a partir das quais um evento específico pode ser explicado. Paul Churchland (1989) sustenta que explicar um fenômeno envolve a ativação de um protótipo ou modelo que capacita o organismo a lidar com uma situação específica que se quer explicar. A idéia de Churchland é que a explicação deve ser vista como a ativação de protótipos codificados em redes distribuídas. Por exemplo, explicar por que um certo pássaro tem pescoço comprido ocorre pela ativação de um conjunto de nós que representam *cisne*.

Outras abordagens ao problema da explicação utilizando modelos conexionistas podem ser construídas em termos da teoria da coerência explicativa desenvolvida por Paul Thagard. Thagard (1996) fornece um exemplo de como funciona seu programa ECHO, desenvolvido para ilustrar a teoria da coerência explicativa. Suponhamos que alguém queira explicar um evento simples, como, por exemplo, o fato de que estamos

esperando encontrar uma pessoa no restaurante e essa pessoa (Fred) não comparece ao encontro. O conhecimento que temos de Fred e de outras pessoas semelhantes a ele pode sugerir várias hipóteses de por que ele não compareceu, mas será necessário escolher dentre essas hipóteses qual é a mais plausível. Talvez Fred tenha decidido que seria melhor ficar estudando ou talvez tenha decidido que seria melhor ir a uma festa. No meio destas hipóteses pode também surgir uma informação suplementar: a de que Fred foi visto na biblioteca da universidade.

Como isso pode ser representado num sistema conexionista? As unidades representando hipóteses são ligadas a uma unidade especial que as ativa e a ativação espalha-se para outras unidades. Existe uma ligação inibitória conectando as unidades que representam hipóteses excludentes, como, por exemplo, que Fred estava na biblioteca e que Fred foi a uma festa. A escolha da melhor explicação pode envolver não apenas evidências em favor da melhor hipótese, como também explicações de por que tais hipóteses podem ser verdadeiras. Por exemplo, Fred pode ter ficado estudando, pois precisa de notas para passar de ano; alternativamente, ele pode ter ido a uma festa, uma vez que gosta deste tipo de atividade. Quando a rede se estabilizar, ela terá fornecido uma interpretação coerente do comportamento de Fred. Se a rede se estabilizar quando a unidade para "Fred está estudando" for ativada, isto significará que esta unidade tem mais força excitatória do que as demais, como, por exemplo, a unidade "Fred foi a uma festa".

O QUE LER

Sobre conexionismo e o problema mente-cérebro:

1 – Teixeira, J. de F – *Filosofia da Mente e Inteligência Artificial* – capítulo 5.

Sobre conseqüências filosóficas do conexionismo:

2 – Bechtel, W. "Connectionism and the Philosophy of Mind" in *Mind and Cognition*, Lycan, W. (ed).

Capítulo 8

Críticas ao modelo conexionista

Conceitos introduzidos neste capítulo:
- O problema da composicionalidade (Fodor e Pylyshyn).
- Limitações filosóficas à abordagem conexionista.

Neste capítulo examinaremos dois tipos de críticas ao modelo conexionista: a primeira, oriunda de defensores do paradigma simbólico, qual seja, a objeção de Fodor e Pylyshyn, constitui uma crítica metodológica à utilização de redes neurais para a modelagem de fenômenos cognitivos. A segunda crítica diz respeito a limitações em princípio ou *a priori* à abordagem conexionista – trata-se de uma crítica filosófica ou epistemológica que recai sobre os problemas inerentes à modelagem do cérebro bem como a possibilidade de sua replicação através de sistemas artificiais.

FODOR E PYLYSHYN

Fodor e Pylyshyn começam sua crítica ao conexionismo por distinguir entre abordagens representacionalistas e eliminativistas. Os eliminativistas querem prescindir de noções semânticas (como é o caso da representação) e supõem que podem explicar integralmente os fenômenos cognitivos por meio de sua redução a estruturas cerebrais. Já os representacionalistas sustentam que os estados internos do sistema cognitivo (as representações de estados do mundo) são necessários para abordar a cognição. O conexionismo, segundo Fodor e Pylyshyn, está do lado dos representacionalistas, uma vez que seus partidários fornecem interpre-

tações semânticas para a atividade das unidades de seus sistemas. Na verdade, o conexionismo não rompe totalmente com o representacionalismo: a atribuição de interpretações semânticas para as unidades de um sistema equivale em certa medida à atribuição de representações, mesmo que estas adquiram a forma de um conjunto de subsímbolos. Ora, com base neste ponto de vista, Fodor e Pylyshyn formulam as seguintes questões: até que ponto serão os sistemas conexionistas suficientemente adequados para modelar a cognição como o fazem os sistemas representacionalistas tradicionais, isto é, simbólicos? Haverá características de sistemas representacionais simbólicos que não podem ser reproduzidas por sistemas conexionistas? Fodor e Pylyshyn argumentam em favor da idéia de que sem os recursos de um sistema representacional simbólico não é possível construir um sistema para modelar adequadamente os processos cognitivos.

O ponto de partida desta crítica é o reconhecimento do caráter lingüístico das representações simbólicas. Representações simbólicas exibem uma *semântica e sintaxe combinatorial* – ou seja, a cognição consiste fundamentalmente no processo de formação de representações moleculares (compostas), que, por sua vez, são formadas a partir de seus elementos constitutivos (representações atômicas). As regras de composição (da mesma maneira que outras regras para manipulação simbólica) são sintáticas e podem ser aplicadas aos símbolos, independentemente de sua semântica. Contudo, a própria possibilidade de se construir interpretações semânticas está condicionada pela existência da sintaxe, que permite a composição das partes e possibilita construção de interpretações de representações lingüísticas compostas. Ou seja, a semântica do todo depende das partes, e todo este processo depende, por sua vez, de uma sintaxe composicional. Em outras palavras, não há semântica sem sintaxe e, embora não possamos afirmar que tudo que for sintaticamente bem construído será igualmente semanticamente bem construído, não podemos negar que a semântica espelha a sintaxe. Ora, segundo Fodor e Pylyshyn, sistemas conexionistas não têm nem uma sintaxe nem uma semântica combinatorial. Embora unidades individuais e conjuntos de unidades num sistema conexionista possam ser interpretadas semanticamente, elas não podem se tornar expressões lingüísticas e ser manipuladas de acordo com regras sintáticas. Isto ocorre porque as unidades dos sistemas conexionistas não são símbolos, o que torna este tipo de sistema inadequado para modelar representações compostas. Em outras palavras, somente um sistema com representações simbólicas dotadas de uma estrutura constitutiva (composicional) pode modelar adequadamente os processos cognitivos.

Fodor e Pylyshyn sustentam que não é só a linguagem que é estruturada. O mesmo se aplica ao pensamento, cujo espelho é a linguagem. O pensamento é sistemático na medida em que as representações

internas também o são. Esta sistematicidade é decorrente de uma relação abstrata entre símbolos, daí o fato de ela se encontrar ausente nos sistemas conexionistas que têm como ponto de partida um conjunto de representações não estruturadas entre si. A sistematicidade decorre de uma estrutura profunda da organização do pensamento e da cognição humana, exibindo as três principais características necessárias requeridas por uma sintaxe e uma semântica combinatoriais:

1 – A *produtividade do pensamento*: refere-se à capacidade de produzir e de entender proposições a partir de um conjunto infinito de possibilidades. Uma vez que esta capacidade é realizada utilizando-se recursos finitos, operações de recombinação são necessárias – operações cuja existência pressupõe a própria sistematicidade do pensamento como ponto de partida.

2 – A *sistematicidade do pensamento:* resulta de uma conexão intrínseca entre a habilidade de compreender ou pensar um pensamento e a habilidade de compreender ou pensar outros. Dizemos, por exemplo, que qualquer um que tenha o pensamento "Antônio ama a açougueira" é igualmente capaz de pensar que "a açougueira ama Antônio". O falante aprende a construir sentenças com significado a partir da combinação de suas partes de um modo específico. A compreensão do significado das palavras "Antônio", "ama", "açougueira" associada a uma regra de composição do tipo "sujeito + verbo + objeto imediatamente possibilita a produção da sentença "a açougueira ama Antônio".

3 – A *coerência* da inferência envolve a habilidade de fazer inferências plausíveis, sintática ou semanticamente. Por exemplo, pode-se inferir de "x é uma vaca amarela" que "x é uma vaca" e "x é amarela" , ou seja, da conjunção verdadeira ($A \wedge B$) que ambos os elementos são verdadeiros (A é verdadeiro e B é verdadeiro).

Fodor e Pylyshyn sustentam que sistemas conexionistas não podem compor representações complexas a partir de representações simples. Seu argumento é o seguinte: considere um sistema conexionista onde cada unidade representacional é atômica e onde exista apenas uma maneira pela qual as unidades se relacionem umas com as outras numa relação causal entre pares de unidades. Assim, $A \wedge B$ e A são dois nós na rede; o peso da conexão de $A \wedge B$ para A é de tal maneira que, ao ativar $A \wedge B$, causa-se a ativação de A. Esta seria uma espécie de inferência, mas a representação de A não é parte da representação $A \wedge B$. Qualquer par de nós poderia ser conectado para resultar no mesmo tipo de relação, por exemplo, nós $A \wedge B$ poderiam excitar o nó Z. Assim sendo, a conexão não é de natureza composicional e a inferência não ocorre por causa da relação sintática entre os nós. A inferência precisa ser construída – sustentam Fodor e Pylyshyn – para cada caso de conjunção e não através de uma

regra que utiliza variáveis para especificar a relação sintática de inclusão. Por exemplo, a unidade B $\wedge$ C deve estar especificamente conectada à unidade B se a inferência de B $\wedge$ C para B deve ocorrer, da mesma maneira que A $\wedge$ B tem de estar ligada à unidade A.

Vejamos agora o que ocorre com sistemas distribuídos. Em redes deste tipo, as unidades que são ativadas para se obter uma representação específica instanciam características ou microcaracterísticas da entidade que está sendo representada. Mas a representação distribuída não resolve o problema da composicionalidade – pelo menos no entender de Fodor e Pylyshyn. O modo pelo qual uma característica é parte de uma representação de um objeto não é o mesmo pelo qual uma unidade sintática é parte de uma unidade maior. No paradigma simbólico, se tomamos a proposição "Antônio ama a açougueira", a representação "açougueira" está numa relação sintática específica com o resto da proposição, de tal maneira que esta última não poderia ser confundida com "a açougueira ama Antônio". Isto não ocorre no caso da representação distribuída. Por exemplo, uma representação distribuída da proposição "Antônio ama a açougueira" pode ser obtida numa rede cujas unidades correspondam aos conceitos "Antônio", "ama", e "açougueira". Ao ativar estas três unidades, teríamos uma representação distribuída da proposição. Contudo, esta representação não seria distinta da representação "A açougueira ama Antônio". Não há como representar o fato de que é Antônio que ama a açougueira e não vice-versa, pois as unidades não têm uma estrutura sintática. De nada adiantaria adicionar unidades que representem a relação, marcando, através de algum tipo de estrutura hierárquica, a unidade que corresponde ao sujeito. Isto não impediria que as três unidades fossem ativadas simultaneamente e que a unidade "açougueira" passasse a ocupar o lugar da unidade marcada para ser o sujeito da sentença. Em outras palavras, na construção de um sistema conexionista é impossível distinguir, dentre suas unidades, aquelas que correspondem a funções sintáticas específicas, na medida em que estas são *relações entre representações* e não entre unidades causalmente conectadas através de uma ativação. Grande parte da cognição (a atividade lingüística, por exemplo) obedece a um conjunto de regras lógicas que se estabelecem entre representações – regras que muitas vezes não podem ser adequadamente mapeadas por relações causais.

Na sua defesa do paradigma simbólico, Fodor e Pylyshyn reconhecem que o sistema nervoso no qual nossas representações simbólicas são implementadas pode ser um sistema conexionista. Contudo, somente a análise ao nível simbólico interessa para a investigação cognitiva. Esta deve se ocupar unicamente com um nível mais abstrato de análise (o nível simbólico), ou seja, construir uma sintaxe e uma semântica combinatorial através de operações efetuadas sobre cadeias de símbolos. O conexionismo não é nada além de uma

implementação possível do sistema simbólico representacional. Suas vantagens são apenas aparentes: quando sistemas simbólicos passarem a ser implementados em *hardware* semelhante ao do sistema nervoso, estes sistemas passarão a exibir as mesmas características cognitivas exibidas pelos sistemas conexionistas. Ademais, nada impede que operações sobre símbolos sejam implementadas em arquiteturas paralelas que operem a uma velocidade muito maior do que aquela exibida pelas máquinas com arquitetura von Neumann.

Ora, poderíamos nos perguntar até que ponto as críticas de Fodor e Pylyshyn são corretas. Não há dúvida de que as objeções levantadas pelo argumento da composicionalidade e sistematicidade do pensamento apontam para dificuldades importantes a serem enfrentadas pelos partidários do conexionismo. Contudo, é preciso notar que a estas objeções também cabem respostas. Uma delas – que apenas mencionaremos – foi elaborada por Clark (1989) e consiste em apontar para a possibilidade de que talvez a sistematicidade do pensamento não seja uma maneira intrínseca de organização da cognição humana que exigiria que esta só pudesse receber uma abordagem simbólica. Talvez a sistematicidade seja o modo pelo qual interpretamos nossas próprias habilidades cognitivas. Assim sendo, a sistematicidade, resultando de uma interpretação, não leva necessariamente à necessidade de pressupor a existência de um nível simbólico ao qual teríamos de reconhecer uma independência: sistemas conexionistas também poderiam vir a exibi-la na medida em que recebessem este mesmo tipo de interpretação do funcionamento de nossas atividades mentais, independentemente do fato de terem como ponto de partida um conjunto de representações atômicas e não estruturadas previamente.

OS LIMITES DA ABORDAGEM CONEXIONISTA

Além das críticas metodológicas de Fodor e Pylyshyn, é possível ainda levantar outros tipos de objeções à abordagem conexionista, quais sejam, objeções filosóficas mais gerais a partir das quais podemos formular questões do seguinte tipo: haverá limites para a abordagem conexionista? O que podemos esperar deste tipo de abordagem? No Capítulo 4 da primeira parte deste livro falamos de limites para a Inteligência Artificial simbólica; vejamos agora o que precisa ser dito acerca do conexionismo.

As grandes dificuldades para o conexionismo parecem situar-se na possibilidade de modelagem do cérebro. Neste sentido, dois grandes problemas podem surgir: nós os chamaremos de *problema da descrição* e *problema epistêmico*.

Ambos os problemas apontam para um obstáculo comum: até que ponto podemos conhecer nosso próprio cérebro? Numa perspectiva conexionista com forte ênfase no materialismo eliminativo (como é a abordagem dos Churchlands), fenômenos mentais poderão ser explicados como o resultado do alto grau de conectividade cerebral, além de outras características (anatômicas, neurofisiológicas, etc.) do cérebro. Mas será que poderemos algum dia produzir uma descrição do cérebro tão completa e detalhada que nos permita estabelecer um mapeamento entre estados mentais e estados cerebrais de forma a tornar possível – no futuro – uma simulação da vida mental através de sistemas conexionistas? Responder a esta última questão leva-nos diretamente para o que chamamos de problema da descrição: será nosso cérebro capaz de produzir uma noção de complexidade que nos permita descrevê-lo? Este problema se desdobra imediatamente na dificuldade envolvida em representar a multiplicidade das conexões que devem estar presentes no cérebro. Esta multiplicidade pode ser tão complexa e intrincada que, mesmo que nela encontremos algum tipo de padrão, a geração de um modelo de cérebro, mesmo com o auxílio de computadores, pode facilmente levar-nos a um problema do tipo NP (ver o final do Capítulo 1, primeira parte), ou seja, não poderíamos, num tempo razoável, produzir sequer um "retrato" aproximado de nosso próprio cérebro. E, neste caso, como poderíamos estabelecer todas as possíveis conexões entre seus neurônios – conexões que seriam responsáveis pelo aparecimento de formas mais complexas de vida mental. Em outras palavras, como simular aquilo que não podemos sequer representar?

O segundo problema, qual seja, o problema epistêmico consiste no seguinte: uma descrição completa do cérebro será sempre mais complexa do que o próprio cérebro que a produz. Ora, como pode o cérebro produzir algo mais complexo do que ele mesmo? E como o próprio cérebro poderia compreender e reconhecer como sendo verdadeiro algo mais complexo do que ele mesmo? O problema do reconhecimento de tal teoria ou descrição pode levar a um impasse de difícil solução: não seria possível assegurar que tal descrição, uma vez atingida, é a correta. Ora, se o cérebro não pode produzir algo mais complexo do que ele mesmo, a possibilidade de replicá-lo através de sistemas artificiais fica afastada. Pelo menos a possibilidade de construir uma réplica do cérebro em laboratório.

Já na década de 50, John von Neumann, um dos proponentes do que futuramente se tornou o conexionismo, reconhecia os limites deste tipo de abordagem – sobretudo aquelas limitações oriundas do problema epistêmico. Sua estratégia para superar este problema foi a proposta de robôs capazes de se auto-reproduzir, imitando artificialmente o processo evolucionário de seleção natural, que permite a geração sucessiva de

organismos (no caso máquinas) cada vez mais complexos. Por meio deste processo de geração sucessiva seria possível, em última análise, conseguir reproduzir o extraordinário grau de complexidade do cérebro, superando, assim, o problema da descrição e o problema epistêmico. Mas a proposta de von Neumann permaneceu ignorada por muitos anos e só foi revivida recentemente, no chamado projeto de Vida Artificial de que falaremos na terceira parte deste livro.

O QUE LER

1 – Fodor e Pylyshyn . *Connectionism and Cognitive Architecture – a critical analysis.*
2 – Fodor, J. *Psychosemantics.*
3 – Clark, A *Microcognition,* capítulos 8 e 9.

Terceira Parte

Tendências recentes

- Vida artificial
- A nova robótica: COG e o projeto do MIT
- A Escola Chilena
- O futuro da Ciência Cognitiva

Capítulo 9

Vida artificial

Conceitos introduzidos neste capítulo:
- O que é a Vida Artificial.
- Os autômatas celulares de von Neumann.
- Exemplos de programas de Vida Artificial.
- O que é algoritmo genético.

Vimos na primeira parte deste livro que a Inteligência Artificial simbólica preocupou-se com a simulação das chamadas *atividades cognitivas superiores*, ou seja, aquelas atividades que envolvem simbolização e que freqüentemente são realizadas em domínios restritos (este é o caso do cálculo matemático e lógico, do jogo de xadrez, etc). A partir da década de 90, o descontentamento e as críticas ao paradigma simbólico tornaram-se crescentes. Sistemas de IA simbólica passaram a ser fortemente criticados pelo fato de precisarem de que seu *input* fosse previamente processado pelos programadores. Da mesma forma, alegava-se que os *outputs* deste sistema só fazem sentido para um intérprete humano. Quase o mesmo tipo de crítica era dirigida aos sistemas conexionistas: estes também estariam ignorando fatores fundamentais da cognição, tais como a percepção e a locomoção.[1]

Além da percepção e da locomoção – ou seja, de uma ligação com o meio ambiente que sistemas simbólicos ou conexionistas não exibem – a observação de alguns comportamentos de seres vivos sugeria a hipótese de que seu sistema nervoso deveria ter grande capacidade computacional apesar de sua relativa simplicidade. Este era o caso, por exemplo:

[1] A maioria dos sistemas conexionistas ainda funciona com representações que são escolhidas pelo programador e, neste sentido, não se pode dizer que estes sistemas estejam efetivamente ligados ao mundo exterior.

a) o comportamento de interceptação para o acasalamento da mosca doméstica;
b) o comportamento da rã que projeta sua língua para capturar o inseto que se movimenta à sua frente (estudado por Lettvin, Maturana e McCulloch);
c) o comportamento do *kingfisher* para capturar o peixe dentro da água;
d) a distinção entre linhas horizontais e verticais pelo gato recém-nascido;
e) o comportamento do cão que abocanha, no ar, a bola atirada pelo dono.

Como poderiam esses animais, a partir de um sistema nervoso relativamente simples, executar comportamentos tão complexos que requereriam uma grande capacidade computacional? E como poderiam eles ser executados tão rapidamente e com tanta precisão?

Descrever matematicamente tais comportamentos envolveria, no mínimo, uma grande quantidade de equações diferenciais. Por outro lado, imaginar um algoritmo que execute estes comportamentos significa também percorrer um grande leque de opções que certamente levaria a uma explosão combinatorial típica de um problema NP. Entretanto, estes animais executam estes comportamentos automaticamente. De alguma forma eles são capazes de superar os problemas da complexidade computacional – sua estrutura biológica seria a grande chave para se saber como estas dificuldades poderiam ser contornadas.

Já na década de 50, von Neumann havia percebido que o estudo do comportamento animal seria particularmente frutífero para desenvolver algoritmos eficientes. Ele sustentava que "a natureza produz máquinas automáticas incríveis" e se perguntava como isto era possível. Também nesta época, von Neumann já suspeitava que qualquer tentativa de descrever em termos simples algo tão complexo como o sistema nervoso do ser humano levaria, inevitavelmente, a uma série de complicações e paradoxos. Como o cérebro poderia descrever-se a si mesmo? Não seria esta descrição, obrigatoriamente, algo mais complexo do que o próprio cérebro?

Tentativas de dividir o cérebro humano em partes para depois saber como elas funcionam em conjunto não poderiam dar certo: apesar de podermos algum dia vir a saber como cada uma destas partes funciona, juntá-las para reproduzir algo tão complexo como o cérebro implicava que este pudesse gerar um conhecimento de si mesmo que suplantasse sua própria capacidade – um paradoxo intransponível. A resposta estaria, então, na própria natureza: em vez de tentar gerar uma descrição completa do cérebro instantaneamente, poderíamos mimetizar o curso da evolução, onde do simples se chega ao mais complexo. Para refazer o

curso da evolução, contudo, era necessário construir máquinas que fossem capazes de se auto-reproduzir: autômatas que fossem capazes de gerar cópias de si mesmos. A partir da reprodução, a adaptação e a mutação encarregar-se-iam de criar outros autômatas cada vez mais complexos e com maior capacidade computacional. Von Neumann mostrou, então, que não há nenhuma contradição em pressupor que do simples se chega – através do processo evolucionário – a algo mais complexo e forneceu uma descrição detalhada de um autômata que se auto-reproduz.

Além disto, Von Neumann criou vários modelos que mostravam como máquinas automáticas similares aos computadores desenvolvidos por Turing poderiam simular a auto-replicação: estas seriam máquinas de Turing com instruções específicas para se duplicarem. Mas a teoria dos autômatas que se auto-reproduzem, desenvolvida por von Neumann, ficou esquecida até recentemente, ou seja, no final da década de 80, quando surgiu o movimento chamado de Vida Artificial ou *A-Life* (de *Artificial Life*), protagonizada por Christofer Langton. Seguindo as mesmas intuições de von Neumann, mas utilizando uma estratégia diferente, Langton projetou programas computacionais para simular a evolução biológica. Posteriormente, a invenção do chamado algoritmo genético por G. Holland representou um passo decisivo para a consolidação do projeto de Vida Artificial.

O AUTÔMATA DE VON NEUMANN

A história da Vida Artificial data de aproximadamente 40 anos atrás, quando John von Neumann projetou um "organismo" que se reproduzia como uma criatura real. Von Neumann concebia a vida como essencialmente *transmissão de informação* realizada através de um sistema dinâmico suficientemente poderoso para se reproduzir e gerar um descendente mais complexo do que seus genitores. Atrás disto estava a intuição de que os seres vivos eram os melhores modelos para inspirar a construção de sistemas artificiais mais poderosos.

O "organismo" projetado por von Neumann era um autômato capaz de se reproduzir. Além dos componentes computacionais normais, este "organismo" tinha ainda as seguintes partes:

1 – Um instrumento para manipular objetos no mundo (algo como uma mão) e que aceitasse instruções oriundas do seu sistema de controle;
2 – Um "elemento cortante" que pudesse desconectar duas partes quando recebesse instruções para proceder desta maneira;
3 – Um elemento que pudesse juntar duas partes;

4 – Um elemento sensorial, que pudesse transmitir informação oriunda do mundo externo e acerca de suas próprias partes.

Este autômata teria também um "habitat" especial: um imenso reservatório, cheio de peças de substituição para que ele pudesse se reproduzir. As partes do corpo do autômata consistiriam de três subsistemas: o componente (A) seria uma espécie de "fábrica" capaz de reunir peças do reservatório para montá-las de acordo com instruções que estariam no sistema de controle da máquina. A segunda parte (B) seria um duplicador: um elemento capaz de ler as instruções do sistema de controle e copiá-las. O componente (C) é o próprio sistema de controle do autômata. Haveria ainda um componente (D), que seria uma longa fita com perfurações na qual estariam contidas as informações que o autômata deveria seguir.

A auto-reprodução começa quando o autômata adquire "vida" ao ler as instruções da fita. O componente (C) lê as instruções, alimenta o duplicador (B) que as copia e passa esta duplicata de instruções para a fábrica , mantendo, entretanto, o original. A fábrica volta-se então para o reservatório de peças e pega as primeiras partes para começar a construir seu descendente. Quando uma peça é encaixada, o autômata sai buscando outra. Quando a tarefa de construir um descendente termina, o autômata inicia a construção de uma segunda fábrica, um duplicador e um sistema de controle. Mas aqui há ainda um ponto essencial: o autômata transmite, para o seu descendente, as instruções que estão na fita, inserindo uma cópia desta no "organismo" que acaba de surgir. Isto garante que ele seja "fértil" e que possa iniciar um novo ciclo de reprodução. Pela reprodução e mutação torna-se possível que os descendentes do autômata sejam mais complexos e exibam maior capacidade computacional do que seus genitores.

Certamente esta criatura concebida por Von Neumann foi apenas um projeto; nunca chegou a ser construída. Contudo, é interessante notar que toda esta arquitetura imaginária já antecipava características do DNA dos seres vivos que foi descoberto alguns anos depois. O mesmo se aplica ao processo de auto-reprodução que acabou sendo confirmado à medida que avançaram os estudos embriológicos. Mas não foi apenas isto que von Neumann antecipou: sua idéia de que a vida depende não apenas da transmissão de informação, mas também de um certo grau de complexidade "crítica" que certos sistemas devem possuir foi confirmada por teorias bastante recentes que estudam o caos e sistemas dinâmicos não lineares. Sem esta "complexidade crítica", os organismos não evoluem e entram em processo de extinção progressiva.

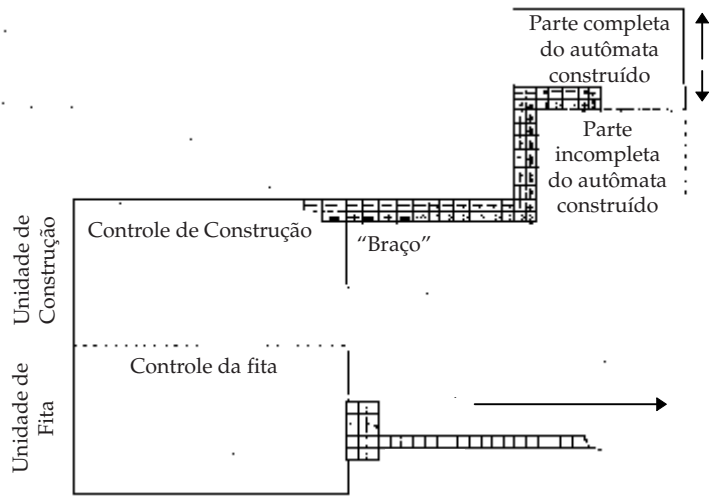

Figura 9.1. O autômata celular de von Neumann (adaptado de Levy. 1992, p.44).

ALGUNS PROGRAMAS DE VIDA ARTIFICIAL[2]

Somente vários anos após a conferência de Hixon (onde von Neumann falou de seu autômata celular que se auto-reproduzia), as pesquisas sobre simulação de processos vitais foram retomadas. Em 1963, o inglês John Conway criou uma das primeiras simulações de vida artificial num computador. O "*Game of Life*", programa desenvolvido por Conway, simulava o comportamento de animais unicelulares.

Mas a aceitação do estudo da vida artificial como ciência só ocorreu em 1987, com os trabalhos de Christopher Langton. Neste ano, Langton organizou o primeiro simpósio sobre Vida Artificial no Novo México.

A esta iniciativa juntou-se Thomas Ray, um biólogo evolucionário que decidiu simular o processo de evolução num computador. Ray desenvolveu um mundo computadorizado chamado TIERRA, onde programas de computador automultiplicadores competem por tempo de computação (representando energia) e memória do computador (representando recursos). Inicialmente o TIERRA tinha um único organismo artificial, mas outros organismos se desenvolveram nele, ativados pelas funções de mutação que Ray incorporou no seu programa. Um tipo de mutação, projetado para simular os efeitos de fatores ambientais, como a

[2]Alguns programas apresentados nesta seção estão descritos em Walnum (1993).

radiação solar, ocorre quando um *bit* no programa de uma criatura é trocado aleatoriamente. Outras mutações ocorrem durante a reprodução incluindo erros na multiplicação que podem mudar o programa resultante.

Outros pesquisadores também contribuíram com a criação de programas de vida artificial. Dan Hillis, da Thinking Machines Corporation, de Massachusetts, desenvolveu um programa que usa processos darwinianos para melhorar a capacidade de resolução de problemas de um programa. Robert Collins, da Universidade da Califórnia (Los Angeles) criou uma simulação chamada *ArtAnt*, na qual organismos em evolução semelhantes a formigas competem pela sobrevivência, aprendendo a encontrar comida e a evitar conflitos. As formigas de Collins têm cromossomos de 10.000 bits que controlam a resposta de cada formiga ao meio ambiente. Cromossomos mutantes geram novos tipos de formigas com capacidades diferentes, que podem ou não aumentar as possibilidades de sobrevivência.

Craig Reynolds, da Symbolics Inc., criou objetos parecidos com pássaros, chamados *boids,* que são criaturas governadas por três regras: mantenha uma distância específica de outros *boids*, voe na mesma velocidade que os outros *boids* e voe em direção ao maior número de *boids*. Embora a simulação de Reynolds não tenha um ponto de partida fixo, os *boids* rapidamente formam bandos e demonstram comportamentos semelhantes aos de seres vivos. *Boids* que batem em obstáculos cambaleiam e depois juntam-se novamente ao bando; *boids* desgarrados também procuram se juntar ao bando. Não há nenhuma instrução no programa original que sugira esse tipo de comportamento, o que demonstra que até as regras mais simples, quando válidas para uma grande população, podem gerar resultados surpreendentes. Este é o típico caso de formação de um *comportamento emergente.*

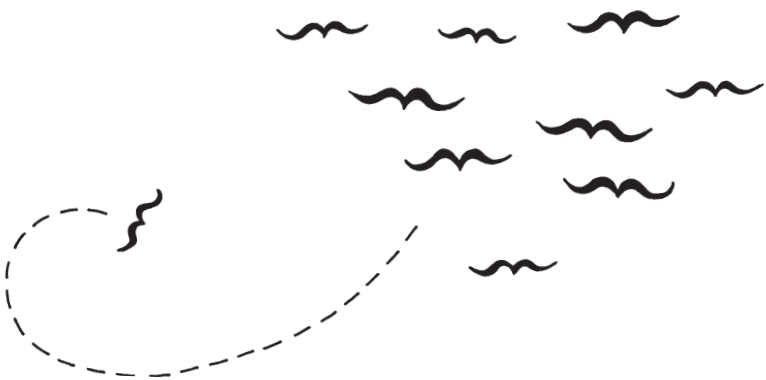

Figura 9.2. Os *boids* desenvolvidos por Craig Reynolds (adaptada de Walnum, p. 26, 1993).

Peter Oppenheimer, do *New York Institute of Technology*, desenvolveu um programa que usa regras de evolução para criar vários tipos de árvores no computador. Cada árvore tem 15 gens que controlam sua aparência física, inclusive o número de galhos torcidos e a cor da casca. No programa ocorre, porém, uma influência evolutiva que só permite a sobrevivência de árvores que tenham uma aparência bonita. Por exemplo, se Oppenheimer decidir que prefere as árvores azuis e não as vermelhas, a cor azul torna-se a característica da sobrevivência. Esta "seleção artificial" gera árvores com as características escolhidas pelo programador.

ALGORITMOS GENÉTICOS

Assim como as idéias de evolução e de seleção natural são centrais na Biologia, o mesmo ocorre com os sistemas de Vida Artificial. Nas décadas de 50 e 60, foram estudados vários modelos de sistemas evolucionários para resolver problemas de Engenharia – verdadeiros precursores dos chamados *algoritmos genéticos*.

A primeira descrição completa de um algoritmo genético apareceu no início da década de 60 e foi feita pelo seu inventor oficial, John Holland, na Universidade de Michigan. No seu livro publicado em 1975, *Adaptation in Natural and Artificial Systems*, Holland apresenta o algoritmo genético como uma abstração da evolução biológica. Seu modelo de algoritmo genético constituía um método para passar de uma população de "cromossomos" (cadeias de *bits* representando organismos ou possíveis soluções para um problema) para uma nova população, usando seleção natural e operadores genéticos, tais como cruzamento, mutação e inversão. Cada cromossomo consiste de "gens" (p.ex., *bits*) e cada gen constitui um exemplo de um "alelo" específico. A seleção escolhe quais desses cromossomos na população pode se reproduzir e quantos descendentes vão nascer. Os cromossomos mais adaptados produzirão mais descendentes do que os outros. O cruzamento consiste na troca mútua de algumas partes de dois cromossomos; a mutação muda, ao acaso, os valores de alguns lugares no cromossomo e a inversão reverte a ordem de uma seção do cromossomo. O procedimento de inversão é, hoje em dia, raramente usado nos algoritmos genéticos.

A forma típica de um algoritmo genético é, então:

1 – Comece com uma população de cromossomos gerada ao acaso (por exemplo, possíveis soluções para um problema).
2 – Calcule a adaptabilidade de cada cromossomo na população.
3 – Aplique seleção e operadores genéticos (cruzamento e mutação) na população, de forma a criar uma nova população.
4 – Vá para o passo 2.

Este procedimento é aplicado várias vezes, cada um sendo considerado uma "geração". Após várias gerações, obtêm-se cromossomos altamente adaptados.

A idéia de criar um algoritmo baseado no conceito de uma população, com cruzamento e inversão constitui a grande inovação trazida por Holland. Desde então, algoritmos genéticos passaram a ser utilizados nas seguintes áreas:

Otimização: problemas de otimização numérica, problemas de otimização combinatorial no projeto de circuitos elétricos, etc.

Programação automática: algoritmos genéticos podem gerar programas de computador para tarefas específicas.

Aprendizado automático e em robôs: algoritmos genéticos já foram usados para tarefas de classificação e predição (em sistemas dinâmicos, na predição do tempo e de estruturas protéicas). Também já foram utilizados para projetar redes neurais bem como para controlar robôs.

Modelos em economia: os algoritmos genéticos também já foram utilizados para elaborar modelos de situações econômicas, como, por exemplo, mercados emergentes.

Modelos do sistema imunológico: os algoritmos genéticos foram usados para modelar o sistema imune.

Modelos ecológicos: algoritmos genéticos foram usados para simular o processo de co-evolução de algumas parasitas.

Modelos de sistemas sociais: vários modelos de sistemas sociais, incluindo a evolução de sistemas cooperativos, evolução da comunicação nas sociedades humanas e animais (formigas).

A utilização progressiva de algoritmos genéticos de vários tipos levou ao aparecimento de uma nova disciplina no âmbito da Ciência Cognitiva: a *computação evolucionária*.

COMO FUNCIONA UM ALGORITMO GENÉTICO?

Vamos agora estudar em maior detalhe o funcionamento de um algoritmo genético, utilizando-nos de um exemplo fornecido por Franklin (1995). Focalizaremos um algoritmo genético em ação. Retomemos a rede neural que implementa um "OU EXCLUSIVO" ou "XOR" de que falamos na nossa seção sobre conexionismo e redes neurais. Uma rede neural deste tipo produz *output* 0 se seus dois *inputs* são iguais e *output* 1 se eles são diferentes. (Ver a figura a seguir).

IN	OUT
0 0	0
0 1	1
1 0	1
1 1	0

XOR

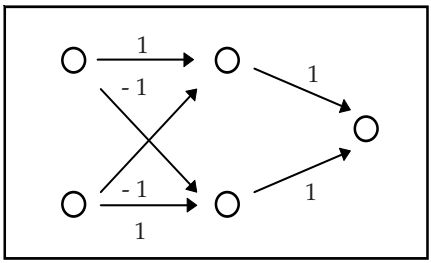

Rede XOR

Figura 9.3. Uma rede neural para XOR (adaptada de Franklin, 1995).

Cada nó da rede produz 1 se a soma ponderada de seus *inputs* é igual ou maior do que o limiar (1, no caso); caso contrário, ela produz 0.

Certamente o que faz com que a rede funcione é a escolha dos pesos. Suponhamos que não soubéssemos que pesos escolher, isto é, que os 1s e -1s na figura desaparecessem. Teríamos, então, o problema de encontrar esses pesos para que a rede pudesse implementar o XOR. Ora, podemos resolver este problema usando o algoritmo genético.

A primeira coisa que temos de fazer é arranjar um código para transformar redes em genótipos. Podemos começar especificando as flechas através de números, os quais funcionarão como marcadores de posição. Usando estes marcadores de posição, um genótipo pode ser uma cadeia de seis números, cada um deles representando o peso na sua posição. Vejamos como isto fica, na seguinte figura:

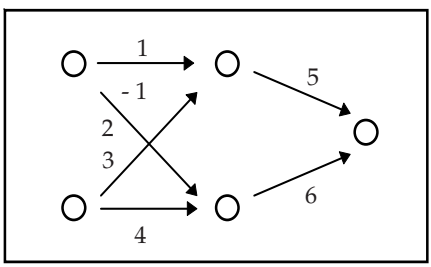

1	2	3	4	5	6
- 1.2	2.4	0.4	- 0.9	- 0.3	3.0

Figura 9.4. Genótipo para uma rede neural (adaptada de Franklin, 1995).

O genótipo atribui, por exemplo, o peso -0,9 para a flecha de número 4. Agora que temos esta cadeia de pesos que funciona como um genótipo, como podemos calcular sua adaptabilidade? Em primeiro lugar, é preciso construir o seu fenótipo, cuja rede neural é determinada pela cadeia de pesos que mostramos acima. Esta rede toma então a seguinte forma:

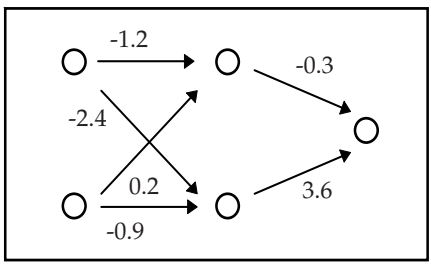

Figura 9.5. Rede Fenótipo (adaptada de Franklin, 1995).

Em seguida, é preciso avaliar o que a rede produz a partir de cada um dos quatro *inputs*. Calculemos então o erro para cada *input* e somemos os erros produzidos. Quanto menor for o número, maior será a adaptabilidade. Vejamos como isto fica, neste caso.

IN	OUT	ERR
0 0	0	0
0 1	0	1
1 0	0	1
1 1	1	1

Figura 9.6. Cálculo de erro (adaptada de Franklin, 1995).

Com um erro total de 3, onde 4 seria o pior resultado e 0, o melhor, este certamente não é o melhor fenótipo e teria uma chance muito baixa de se cruzar com outro.

Uma vez determinada a adaptabilidade, é preciso selecionar os vencedores deste jogo de cruzamentos. Podemos imaginar os níveis de adaptabilidade representando-os na seguinte roda:

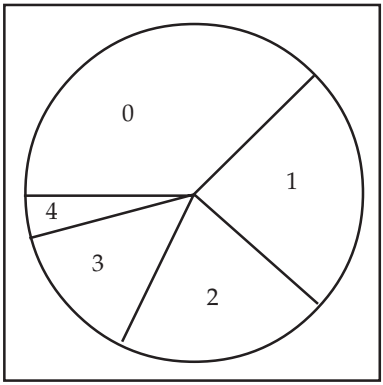

Figura 9.7. Adaptada de Franklin (1995).

Girando a roda ao acaso, selecionemos um nível de adaptabilidade. Em seguida, escolhemos, também ao acaso, uma cadeia com essa adaptabilidade para reproduzir. Continuamos repetindo este processo até que se selecione um número de cadeias igual ao da população inicial.

Uma vez selecionadas as cadeias, é preciso cruzá-las. Isto é feito escolhendo pares dentre as cadeias – uma escolha norteada apenas pelo acaso. Para cada par escolhe-se um ponto de cruzamento também ao acaso. Uma vez que se tem pares de cadeias, trocam-se os segmentos nos pontos de cruzamento para gerar duas novas cadeias:

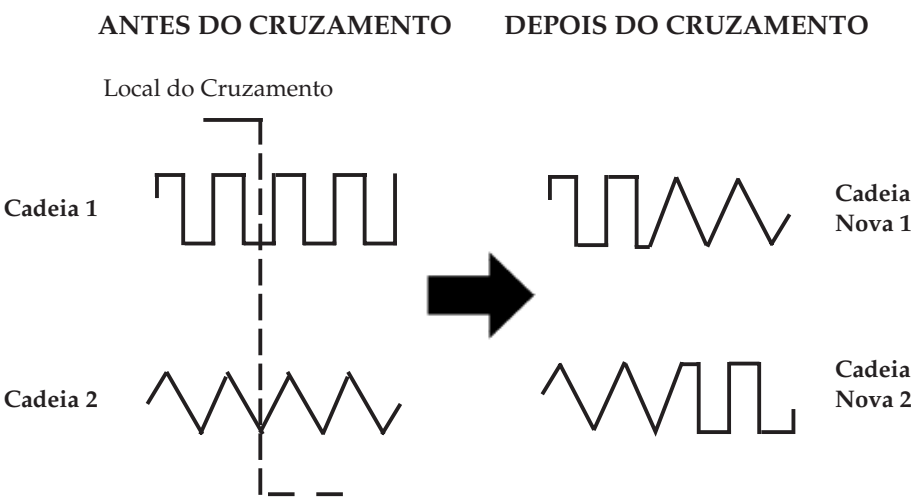

Figura 9.8. Adaptada de Franklin, 1995.

Agora podemos iniciar as mutações. Escolhemos novamente uma cadeia qualquer e um lugar nela. Escolhemos um alelo substitutivo para aquele lugar e retornamos à cadeia modificada para a população. Neste algoritmo genético, o tamanho do genótipo (comprimento) mantém-se constante. Mudamos apenas os pesos, não a arquitetura. O que estamos gerando é um algoritmo paralelo do tipo "gere-e-teste" que nos leva a um ciclo do tipo: geram-se soluções possíveis, estas são testadas e então usadas como o melhor candidato para gerar outras.

Ou seja, o algoritmo genético estabelece uma busca a partir de uma população de cadeias, e não a partir de um único ponto delas. Após uma seleção a partir de uma função de adaptabilidade, elas são cruzadas, estabelecem mutações e a busca se reinicia a partir de uma população mais adaptada. A solução é encontrada quando se encontra aquela que tem maior adaptabilidade – um procedimento idêntico ao operado pela natureza no caso dos seres vivos.

CONCLUSÃO

A Vida Artificial é um campo novo de estudos que ainda não possui uma institucionalização plena nas universidades. A primeira revista específica focalizando esta disciplina nova começa agora a ser publicada (*Artificial Life,* MIT Press). Poucos biólogos sabem da existência deste movimento, que parece atrair mais os cientistas da computação e físicos. Contudo, esperam-se mudanças para os próximos anos.

Não poderíamos finalizar este capítulo sem mencionar um dos mais famosos programas de vida artificial, o ANIMAT, desenvolvido por Wilson (1985). O ANIMAT é um modelo de animal que executa comportamentos, tais como maximizar o prazer e minimizar a dor (comportamento típico de um ser vivo). ANIMAT quase não possui representações internas, a maioria de seus comportamentos é uma reação a situações reais que ele encontra no mundo, como, por exemplo, encontrar comida. ANIMAT aprende a encontrar comida em situações diversas, e nesta tarefa observa-se que a maioria de seus comportamentos aprendidos não é pré-programada: são comportamentos emergentes. Neste sentido, ANIMAT é uma espécie de precursor de alguns princípios da Nova Robótica, que examinaremos no capítulo seguinte.

O QUE LER

1 – Levy, S. *Artificial Life.*
2 – Walnum, C. *Aventuras em Realidade Virtual.*

Capítulo 10

A nova robótica: COG e o projeto do MIT

Conceitos introduzidos neste capítulo:
- A proposta geral da nova robótica.
- A arquitetura de subsunção.
- Alguns robôs desenvolvidos no MIT.

O movimento conhecido hoje como "Nova Robótica" ou "*Nouvelle AI*" surgiu no laboratório de Inteligência Artificial do MIT, a partir dos trabalhos de Rodney Brooks, no final da década de 80. Em dois artigos fundamentais "*Intelligence without representation*" e "*Intelligence without reason*" (publicados em 1991), Brooks desenvolve uma crítica ao representacionalismo na IA e sua estratégia *top-down* que leva a uma equiparação entre cognição e representação, entre inteligência e pensamento simbólico. Ao partir do pressuposto de que cognição e representação são a mesma coisa, a IA se concentrou na simulação de atividades cognitivas superiores (linguagem, raciocínio matemático, etc.) para, então, tentar simular atividades mais básicas, como, por exemplo, o senso comum. Esta estratégia, do tipo "de cima para baixo" (ou *top-down*), encontra rapidamente suas limitações. A cognição e a inteligência não podem ser equiparadas à representação e ao pensamento simbólico e nem a partir destes podemos simular atividades mais básicas dos organismos – atividades que inevitavelmente requerem inteligência. Num artigo anterior, publicado em 1990 ("*Elephants do not Play Chess*"), Brooks chama a atenção para o fato de que elefantes não podem jogar xadrez, mas nem por isso deixam de apresentar algo que identificamos como inteligência.

O que é a proposta da nova robótica e o que muda em relação à concepção de cognição? A associação entre cognição e representação concebe a simulação do comportamento inteligente como a descoberta de

um programa computacional correto que mimetize os processos cognitivos entendidos como estados internos de um organismo. A estratégia proposta por Brooks vai na direção contrária: rompe-se com a idéia de que para produzir comportamento inteligente é preciso manipular um conjunto de regras ou representações explícitas. A estratégia de Brooks será *bottom-up* (de baixo para cima): a simulação do comportamento inteligente deve ter como ponto de partida os comportamentos simples, mundanos, que não requerem a existência prévia de representações. Isto constitui uma guinada radical em relação ao estatuto da representação, que passa a ser vista como um fenômeno tardio na ordem vital. A cognição não se inicia com a representação e sim com a interação do organismo com o seu meio ambiente onde dois fatores são fundamentais: a percepção e a locomoção.

A idéia central da nova abordagem será construir um *agente autônomo*, um robô móvel que realize um conjunto de tarefas num ambiente que não foi previamente adaptado para isto. Uma reaproximação entre robótica e IA é novamente proposta. O comportamento de um robô deste tipo é gerado a partir de vários *módulos*. Cada módulo desenvolve, independentemente, mecanismos para perceber, modelar, planejar ação, etc. Há um árbitro ou um esquema de mediação que determina qual módulo produtor de comportamento tem controle de qual parte do robô numa determinada ocasião. Há pelo menos quatro conceitos fundamentais que norteiam este projeto e que o distanciam da abordagem da IA tradicional, seja ela conexionista ou simbólica:

1 – **Situação Física** (*situatedness*): os robôs estão situados no mundo. São uma forma de inteligência *encarnada*. Rompe-se com o mito do cérebro na proveta, o pressuposto de que para simular a inteligência ou a vida mental basta simular a mente ou o cérebro. Os robôs estão "ligados" com o meio ambiente. Situar significa também abrir mão de construir um modelo completo ou uma representação completa do meio ambiente para então agir sobre ele. A idéia expressa por Brooks é "*The world is its own best model*", ou seja, o mundo real e concreto (e não uma representação dele) deve servir de guia para o comportamento do robô. Para estes robôs não haveria necessidade de se criar uma representação ou mapa interno que intermedie sua relação com o mundo.

2 – **Corporeidade**: (*embodiment*) os robôs têm corpos e experienciam o mundo diretamente. Suas ações são parte da dinâmica do mundo e têm *feedback* de suas próprias "sensações". A necessidade de introduzir a corporeidade para a simulação da inteligência já aparece nos últimos escritos de Turing (1948), num artigo não-publicado chamado "*Intelligent Machinery*". Neste artigo ele discute a possibilidade de construir uma máquina de jogar xadrez, mas ressalta a necessidade de corporeidade.

3 – **Inteligência**: a idéia central é a de que a inteligência simbólica é algo tardio no processo evolucionário dos seres vivos. Anteriormente à inteligência simbólica existe uma inteligência mais simples, básica, que aparece a partir da percepção e da ação. A estratégia para simular a inteligência deve começar com a replicação de atividades simples em animais – uma verdadeira estratégia *bottom-up*. A complexidade do comportamento é derivada da complexidade do meio ambiente e a inteligência surge desta interação ambiental. "*Intelligence is determined by the dynamics of interaction with the world*" (A inteligência é determinada pela dinâmica interativa com o mundo). Pensamento e consciência são epifenômenos que emergem a partir de uma interação complexa entre organismo e mundo.

4 – **Emergência**: uma vez que a inteligência do sistema surge a partir de sua interação com o meio ambiente, ela não precisa ser pré-programada. Comportamentos inteligentes, mais complexos, surgem a partir de uma multiplicidade de comportamentos simples. A idéia central da emergência é que "*intelligence can only be determined by the total behaviour of the system and how that behaviour appears in relation to the environment*" (Brooks, 1991, p. 16). Ou seja, uma inteligência coerente pode emergir de subcomponentes independentes interagindo com o mundo.

Para se ter uma idéia do que significam, por exemplo, as duas primeiras características, ou seja, situação física e corporeidade, basta que imaginemos dois contra-exemplos. Um sistema de reserva de passagens aéreas está situado mas não tem corporeidade: ele responde a centenas de questões, etc., mas interage com o mundo apenas pelo envio e recebimento de mensagens. Um robô numa indústria, destinado a pintar carros, tem corporeidade mas não está situado: ele tem rotinas para corrigir sua interação com os carros que aparecem na sua frente, mas não percebe nenhum aspecto da forma do objeto que lhe é apresentado. Ele simplesmente segue uma rotina preestabelecida.

A crítica da noção de representação, ou seja, a idéia de que *representações internas* servindo como modelos completos do meio ambiente seriam impossíveis de serem obtidas e tampouco necessárias para que agentes autônomos possam gerar comportamento inteligente constitui um dos aspectos teóricos mais polêmicos da proposta de Brooks. Com seus agentes autônomos, Brooks pretende mostrar que modelar grande parte do comportamento inteligente pode ser feito prescindindo das noções de representação interna e de controle central. Seria igualmente este pressuposto tácito da Inteligência Artificial tradicional (simbólica ou conexionista) que teria sido em grande parte responsável por suas limitações. Representação, inteligência e conhecimento não precisam necessariamente ser equiparados. Aliás, esta parece ter sido a causa do insucesso dos sistemas especialistas no final dos anos 70. A idéia de

conhecimento como representação parece estar na raiz das dificuldades tecnológicas aparentes envolvidas na construção dos sistemas inteligentes da IA tradicional: explosão combinatorial, rigidez de estrutura, e assim por diante. A estratégia *top-down* falha nestes casos. Contudo, é preciso ver até que ponto a estratégia *bottom-up* proposta por Brooks pode efetivamente levar à possibilidade de modelar comportamentos inteligentes comple-xos, decorrentes de funções cognitivas superiores, a partir da simulação de comportamentos inteligentes simples. Se isto for efetivamente possí-vel, será preciso revisar todos os fundamentos teóricos que a Ciência Cognitiva assumiu até hoje, a começar pela sua tácita dicotomia entre cognição e mundo. Neste sentido, o sucesso do projeto COG que hoje está sendo desenvolvido no MIT pela equipe de Brooks (do qual falaremos adiante) será decisivo para definir novos rumos para a Ciência Cognitiva.

A ARQUITETURA DE SUBSUNÇÃO

A idéia de *arquitetura de subsunção* é fundamental para a proposta desenvolvida por Brooks. Através dela é possível conceber uma relação estreita entre percepção e ação. Esta relação torna-se possível na medida em que os robôs são construídos como
pendentes que reagem ao mundo, conec
camada é uma *máquina de estado finito am*
"*timer*", além de um alfabeto finito de
estados e uma função de transição. A
determinado *input* e o devolve na form
constitui o *output* da máquina.

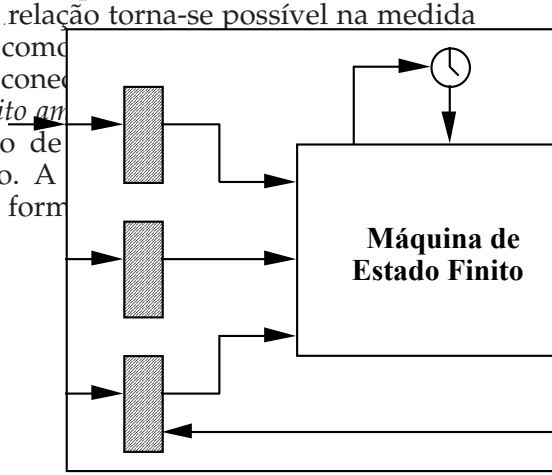

Figura 10.1. Representação da máquina de estado finito.

Ao olharmos a figura acima, podemos ver como funciona esta máquina de estado finito ampliada. Os retângulos em destaque são os "registradores" que coletam os *inputs* para a máquina. O círculo pequeno representa os "*timers*" da máquina. A máquina pode mudar de estado ou produzir um *output* quando o *timer* é acionado. Os *outputs* aparecem representados pelas setas à direita na figura.

Inputs podem também ser produzidos por sensores acoplados à máquina. Um *output* da máquina pode se tornar o *input* de outra máquina ou de si mesma. Alternativamente, ele pode acionar a produção de um movimento através de um "atuador", ligando seu motor. Ou até mesmo, na qualidade de *input* de outra máquina, inibir ou suprimir o *output* desta segunda máquina.

Dissemos que uma máquina de estado finito ampliada (MEFA) pode inibir *outputs* ou suprimi-los. No caso da inibição, o que existe é um adiamento na produção do *output* e, no caso da supressão, uma substituição de *output* ocorre: o novo *output* substitui o original. Estes são os mecanismos fundamentais da arquitetura de subsunção, mecanismos através dos quais as situações de conflito são resolvidas. Note-se, porém, que as prioridades a serem seguidas pelo sistema já são fixadas de antemão no seu *hardware*.

Um grupo de MEFAs forma um comportamento, por exemplo, *pegar alguma coisa*. Transmitir mensagens, suprimir e inibir podem ocorrer num único comportamento ou entre comportamentos distintos. O repertório de comportamentos é expandido pela adição de mais MEFAs produtoras de comportamento àquelas já existentes. Este processo é chamado de *layering* e constitui, na verdade, uma analogia simplista com o processo evolucionário. Desta concepção emerge a idéia de que o "critério de decomposição" de um ser inteligente não é por módulos funcionais e sim por módulos de atividade: o ponto de partida da cognição é a ação e não a representação. Isto leva a uma arquitetura completamente diferente: o agente autônomo terá camadas que executam atividades, sendo que cada uma delas é independente e nunca é chamada como sub-rotina de uma outra. Cada uma das camadas reage ao meio ambiente de forma independente. Assim sendo, quando se adiciona uma camada, esta passa a funcionar independentemente. A camada anterior não sabe da existência da segunda. Na verdade, um agente autônomo ou uma "*Creature*" é uma coleção de comportamentos competindo entre si. Do caos inicial, um padrão coerente de comportamento vai sendo gerado; há uma aposta na auto-organização do comportamento.

Contudo, é preciso um dispositivo que resolva possíveis conflitos entre comportamentos a serem produzidos; caso contrário, o agente autônomo ou robô pode entrar em estagnação ou *dead lock.* Esta é a função da arquitetura de subsunção: por exemplo, quando alguma coisa aparece entre o robô e sua meta, um novo comportamento toma o lugar ou inibe o

comportamento atual até que a crise seja resolvida. Em seguida, o comportamento original reaparece. Suponhamos, por exemplo, que um robô esteja executando um de seus comportamentos, qual seja, localizar uma presa. O robô começa a ir para a frente em direção à presa. Contudo, antes de alcançá-la ele bate em um obstáculo que está no chão. O comportamento *levantar a perna* inibe o comportamento *ir para a frente*, permitindo que o robô suba em cima do obstáculo. Quando a perna estiver levantada, o *ir para frente* retoma o controle e o robô começa a escalar o objeto. A mudança de peso ativa o comportamento *dobrar as juntas,* que inibe *ir para frente* até que o robô esteja com os pés firmes na superfície.

A novidade desta arquitetura de camadas consiste no fato de ela não pressupor a existência de um modelo central do mundo representado explicitamente dentro do agente autônomo. Não existe uma separação implícita entre dados e computações – ambas são distribuídas sobre a mesma rede de elementos. Tampouco existe um controle central; sistema perceptual, sistema central e sistema de atuação encontram-se intimamente mesclados. Todas as partes do sistema podem atuar como perceptores e atuadores dependendo das circunstâncias, ou seja, não há hierarquização prévia. Computações estão disponíveis imediatamente para os *inputs* que chegam. Os limites entre computação e mundo ficam tênues, uma vez que os sistemas se baseiam muito na dinâmica de suas interações com o mundo para produzir seus resultados. Isto possibilita que o robô *reaja ao meio ambiente*, ou seja, em função dos resultados de uma ação que ele mesmo fez sobre o mundo e não simplesmente execute duas ações numa seqüência pré-programada. Recupera-se assim a idéia de situação física e de corporeidade de que falamos antes.

ALGUNS ROBÔS DE R. BROOKS

Examinaremos agora três agentes autônomos ou robôs desenvolvidos no laboratório de R. Brooks no MIT: ALLEN, HERBERT e o COG. Allen tem sonares que desempenham o papel de sensores e um odômetro que permite saber quais as distâncias que ele percorre. Ele é controlado por cabo, através de uma máquina LISP que simula sua arquitetura de subsunção. Allen tem três camadas: a primeira evita obstáculos. Por exemplo, se ele se encontra num aposento, é capaz de correr evitando obstáculos. Cada um dos sonares funciona através do envio de uma força de repulsão. Allen pára quando se defronta com um obstáculo. É isso que faz a primeira camada.

A segunda camada faz com que ele se mova aleatoriamente a intervalos de 10 segundos. O comportamento da primeira camada, qual seja, evitar obstáculos nunca é inibido nem suprimido. Allen praticamente não tem estados internos e não se lembra de quase nada. Tampouco

gera representações daquilo que está acontecendo no mundo nem regras do tipo simbólico. Todos os seus comportamentos estão gravados no seu *hardware*.

A terceira camada faz com que ele identifique lugares distantes e se mova em direção a eles. O odômetro, que está acoplado nele, permite que estes movimentos sejam monitorados. O sonar informa quão distante ele está destes objetos e em que direção ele está indo. Trata-se de um robô que executa movimentos bastante simples, um dos primeiros a ser contruído pela equipe de Brooks no laboratório do MIT.

Examinemos agora um robô mais complexo, o Herbert. Ele vaga em ambientes cheios de objetos e pega latas de refrigerantes vazias. Em seguida, ele as devolve para o lugar onde elas estavam.

Herbert é dotado de um computador com um processador alimentado por uma bateria bem leve. Seus sensores são compostos de 30 portas infravermelhas e um sistema de *laser* que o permite identificar objetos a uma distância de 3 a 4 metros, proporcionando algo como uma visão tridimensional. Seus "atuadores" são motores com rodas que o direcionam e um braço que permite que ele manipule objetos ao seu redor.

A arquitetura de subsunção de Herbert permite que ele evite obstáculos, siga em linha reta e reconheça objetos parecidos com latas de refrigerantes. Para pegar uma lata de refrigerante, ele é capaz de exibir 15 diferentes tipos de comportamento.

Herbert usa o mundo como seu modelo: não há comunicação interna entre os módulos que geram seus diferentes comportamentos, a não ser supressão e inibição. Cada comportamento está conectado a sensores e a um sistema que arbitra qual dentre as várias ações possíveis deve ser executada num determinado momento.

Quando Herbert se mexe, ele segue em linha reta até que seu sistema de visão identifique uma lata de refrigerante. Ele pára em frente da lata de refrigerante e então seus braços começam a se mexer e agarram a lata.

A arquitetura de Herbert apresenta várias vantagens. Não se sabe nunca o que ele vai fazer no momento seguinte, sua ação é organizada de maneira oportunista. Se Herbert está se movendo pára pegar uma lata de refrigerante e alguém coloca uma em sua mão, ele pára de se mover e volta para o lugar onde se encontrava inicialmente. Isto significa que Herbert facilmente adapta seu comportamento às mudanças do meio ambiente. Mais do que isto: ele é capaz de localizar latas de refrigerantes sobre escrivaninhas cheias de papéis e outras coisas, embora não tenha nenhuma representação interna de uma escrivaninha.

Finalmente, é preciso dizer algumas palavras sobre o COG, o projeto mais ambicioso do laboratório de agentes autônomos do MIT. O COG está sendo projetado por Rodney Brooks e por Lynn Andrea Stein e pretende ser um robô humanóide completo. COG deverá simular não apenas os pensamentos, mas também os sentimentos humanos. Apesar de ter a

forma de um homem, o COG consiste de um conjunto de sensores e de atuadores que simulam a dinâmica sensório-motora do corpo humano. COG está equipado para ter interações naturais com seres humanos e com o meio ambiente. Pessoas comuns serão designadas para ensinar ao COG as coisas mais triviais do dia-a-dia, como ocorre com as crianças. Até o momento foram projetadas e construídas as seguintes partes do COG: cérebro, cabeça, tronco, braços (pinças), sistema de visão e de controle motor.

O aspecto mais interessante do COG é que ele não será desde o início um adulto. Ele está sendo projetado para passar por um período de infância artificial, onde aprenderá com a experiência e se ambientará com o mundo. Ele "nascerá" com um *software* de reconhecimento facial – e este item será fundamental para o seu desenvolvimento. Mais do que isto, o COG terá uma "mãe", a ser escolhida entre as estudantes que trabalham no projeto. COG reconhecerá a sua mãe e fará de tudo para que ela não saia de seu lado, como faz uma criança. Tudo o que não for desde o início estabelecido como inato, mas for aprendido com a experiência, será programado como inato na segunda versão do COG, o COG-2. Assim sendo, as várias versões do COG percorrerão os milhões de anos de evolução do homem em poucos anos de laboratório.

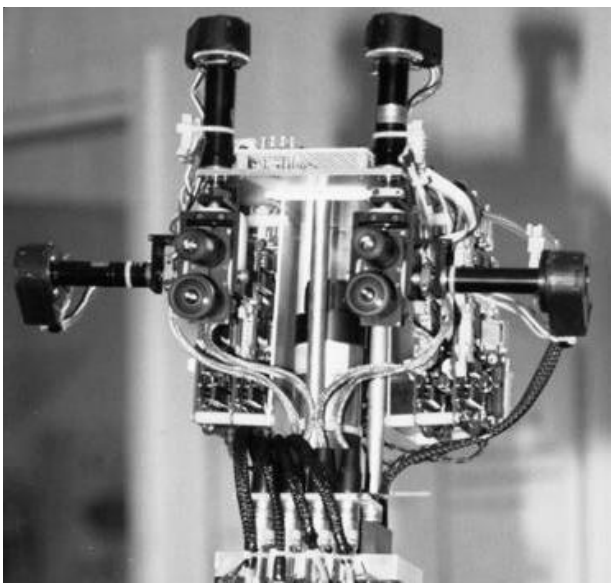

Figura 10.2. O sistema visual do COG. Um dos aspectos mais impressionantes deste sistema visual é a sua capacidade de "seguir" as pessoas com os olhos, ou seja, virar o globo ocular em direção às pessoas que se movem ao redor dele, tal qual um ser humano o faria.

O complexo de computadores que está sendo construído para servir de plataforma para o sistema nervoso artificial do COG corresponde a 64 MacIntosh reunidos numa arquitetura paralela. São 239 nós de processamento – embora até agora apenas oito estejam em uso. O cérebro e o sistema de captura de vídeo do COG ocupam dois *racks* localizados próximo do console de controle do robô. A linguagem de programação do COG é a linguagem L, uma nova versão da linguagem LISP desenvolvida por Rodney Brooks.

O QUE LER

1 – Brooks, R. *Elephants do not play chess.*
2 – Brooks, R. *Intelligence without representation*.
3 – Brooks, R. *Intelligence without reason*.
4 – Brooks, R. *New Approaches to Robotics*.
Visitar o *site* http://www.ai.mit.edu/people/brooks/projects.html

Capítulo 11

A Escola Chilena

Conceitos introduzidos neste capítulo:
- A noção de enação.
- A crítica da noção de representação elaborada pela Escola Chilena.
- As principais linhas do paradigma enativo.

A Escola Chilena, representada por nomes como Francisco Varela, Humberto Maturana e Evan Thompson, nasce de uma insatisfação profunda com o conexionismo e com a Inteligência Artificial simbólica. Tanto no representacionalismo como no conexionismo, a idéia de cognição continua envolvendo o conceito de representação de um mundo externo que já se encontra predefinido. A Escola Chilena adota um outro ponto de partida: o mundo emerge a partir da ação dos agentes cognitivos; a ação precede o aparecimento da própria representação. Agente e mundo se especificam mutuamente, ou melhor, é o meu aparato sensório-motor que especifica meu mundo. Como agente autônomo que sou, sou parte do meu mundo ao mesmo tempo em que sou especificado por ele. O conhecimento advém do fato de eu estar num mundo que é inseparável de meu corpo, de minha linguagem e de toda minha história social. É esta ação, que faz emergir um mundo ao mesmo tempo que torna o agente parte dele, que é chamada, neste paradigma, de *enação*.

Como ocorre a enação? Tomemos como exemplo o caso da visão (Varela, 1988). O que apareceu primeiro, o mundo ou a imagem? Há duas respostas tradicionais a esta pergunta. A primeira consiste em sustentar que o mundo exterior tem leis fixas e precede à imagem que é projetada no sistema cognitivo. A segunda resposta consiste em sustentar que o sistema cognitivo cria seu próprio mundo e que, se neste há leis, estas são derivadas dos aspectos internos do próprio organismo. A perspectiva

enativa propõe um caminho intermediário: mundo e imagem se definem mutuamente; o processo contínuo da vida modela nosso mundo a partir de uma perspectiva perceptiva da qual participam limitações externas e atividade gerada internamente, numa co-determinação.

A CRÍTICA DA NOÇÃO DE REPRESENTAÇÃO

Se o mundo em que vivemos vai surgindo ou é modelado em vez de ser predefinido, a noção de representação não pode ter um papel essencial na cognição. A crítica que a Escola Chilena faz à noção de representação é de dois tipos: uma crítica à arquitetura de sistemas baseados em representações e uma crítica filosófica à utilização da noção de representação como fundamento da cognição. O primeiro tipo de crítica é semelhante àquele desenvolvido pela Nova Robótica, que tivemos oportunidade de examinar no capítulo anterior: sistemas representacionalistas, ao tomar como ponto de partida a simulação de atividades cognitivas superiores, tornam-se incapazes de dar conta do senso comum. Já o segundo tipo de crítica traz algumas novidades.

O primeiro aspecto ressaltado pela Escola Chilena consiste em apontar que a IA simbólica parte da identificação errônea entre *conhecimento* e *representação*. A IA simbólica é herdeira da teoria clássica da representação que começa no século XVII com o cartesianismo e parte da pressuposição da estranheza do mundo em relação à mente que o concebe – uma estranheza que resulta de uma caracterização da mente como algo distinto e separado do mundo. Neste sentido, a representação tem de recuperar esse mundo do qual a mente não faz parte; é preciso instaurar uma garantia de correspondência com aquilo que se tornou exterior ou *externo*.

Mas além de uma garantia de correspondência, a visão clássica exigia que as representações fossem diáfanas, pois só assim poderiam desempenhar o papel de espelho do mundo. A representação tinha de ter propriedades especiais que a distinguisse dos objetos representados, *ela não poderia ser um objeto entre outros*; ela tinha de ser *algo a mais* do que uma relação física ou uma relação entre coisas no mundo. Idéias, intenções, sonhos, etc. não poderiam ser eventos no mundo: a relação intencional nunca poderia ser concebida como uma relação entre objetos situados no espaço. Paradoxalmente, as representações e o sujeito cognoscente que os retêm *teriam de ser excluídos do mundo* para que se mantivesse este caráter distintivo das representações. Sustentar a imaterialidade da mente era a melhor estratégia para garantir este caráter diáfano das representações, ao mesmo tempo que se reforçava o pressuposto básico da interioridade do mental e sua separação em relação ao mundo. A imaterialidade da mente com suas representações voláteis só poderia ser sustentada de maneira plena se se tornasse o mental inescrutável, ou seja, era necessário rebatê-lo para aquém de qualquer manifestação: tratava-se

de postular a existência de um fantasma na máquina, um substrato invisível e intangível que seria o verdadeiro e único responsável pela consciência e pelo *significado* (ou, mesmo, a intencionalidade) que as representações poderiam adquirir.

A Ciência Cognitiva contemporânea – o representacionalismo e a IA desenvolvida pelo MIT nos anos 70 – herdou estes pressupostos da teoria clássica da representação. Este tipo de Ciência Cognitiva, que em grande parte prevalece até hoje, desenvolveu uma visão da cognição e do chamado "modelo computacional da mente" onde ambos são definidos como computações de representações simbólicas. A idéia de repre-sentação mental identificada com *símbolo* não está tão distante da noção de idéia cartesiana, definida por imagem intelectual que concebia as "idéias" com signos. Mas não é apenas a idéia da representação mental identificada com símbolos (ou "imagens intelectuais") que é herdada pela IA dos anos 70. Ela herda também, talvez sem perceber ou a contragosto, a pressuposição do *ghost in the machine* (o fantasma no interior da máquina), a mesma pressuposição que fazia com que Descartes sustentasse a existência de limitações para as habilidades mentais dos autômatas – limitações *em princípio* que os impediriam de vir a ter uma vida mental semelhante à nossa por mais que a tecnologia pudesse avançar. Por mais que os autômatas pudessem fazer tudo o que fazemos, a eles faltaria um ingrediente suplementar, qual seja, a consciência do que estão fazendo, e só a partir desta última seus "estados mentais" poderiam adquirir significado autêntico ou intencionalidade.

O problema do *ghost in the machine* reaparece nas críticas à IA esboçadas no início dos anos 80, sob a forma do argumento intencional ou argumento do quarto do chinês desenvolvido por J. Searle (1980). O problema da intencionalidade ou do significado como algo indissociável de uma consciência (seja esta resultado de um fantasma oculto ou da atividade biológica dos organismos como queria Searle) não constitui uma efetiva crítica da IA no sentido forte: ele é menos uma ruptura do que a constatação natural dos limites da computação simbólica; um desdobramento natural da tradição cartesiana herdada pela IA dos anos 70.

Ora, o problema da intencionalidade é intransponível para a computação simbólica. Mais do que isto, ele marca os limites da teoria clássica da representação adotada pela Ciência Cognitiva ou pelo cognitivismo nos seus anos florescentes. A manipulação simbólica, por mais sofisticada que seja, não pode fazer com que os símbolos se refiram ou passem a ser "acerca de algo no mundo".

Os partidários da Escola Chilena apontam que o desenvolvimento da Ciência Cognitiva nas últimas décadas esteve na contra-mão de toda história da Filosofia no século XX: se de um lado a Ciência Cognitiva tentou se consolidar fundamentando-se na noção de representação, a história da Filosofia parece ter realizado um percurso inverso. Esta tentou, de seu lado, desmantelar a noção de representação e evitar o mentalismo

nas suas concepções sobre o conhecimento. Foi numa aliança com a Filosofia Analítica (a filosofia de tradição anglo-saxã deste século) que a Ciência Cognitiva procurou encontrar seus fundamentos e ferramentas conceituais – definições de conhecimento, representação, inferência, etc. Esta foi uma aliança jamais questionada, uma vez que dela derivariam os cânones de racionalidade e clareza que devem servir para a construção de uma disciplina legitimamente científica. Contudo, a própria Filosofia Analítica, nos últimos anos, tem colocado em questão suas noções tradicionais de *representação* e *conhecimento*.

Ocorre que a própria Filosofia Analítica tentou implodir a noção de representação. A derrocada de empreendimentos filosóficos como o *Tractatus Logico-Philosophicus* do filósofo austríaco Ludwig Wittgenstein implicava a falência de uma visão da linguagem como representação e, certamente, a necessidade de revisão do próprio estatuto deste conceito. Mais do que isto, a Ciência Cognitiva, ao ignorar a evolução da própria Filosofia que lhe serviria de fundamento, parece ter incorrido na ilusão ingênua de que a consolidação de uma disciplina como científica implica uma recusa positivista em discutir seus fundamentos filosóficos.

O preço desta surdez deliberada e da recusa de se dissociar de pressupostos assumidos de maneira não-crítica pode ser tão alto a ponto de a Ciência Cognitiva comprometer seu futuro como programa de pesquisa. No caso específico da IA, esta atitude começa a se refletir como estagnação teórica e até mesmo tecnológica. O insucesso das tentativas de construção das máquinas de tradução na década de 60 – impiedosamente avaliado e criticado pelas agências financeiras americanas – nada mais veio do que apontar para a impossibilidade de se assumir o pressuposto cognitivista da linguagem entendida como representação; um insucesso filosoficamente previsível se a própria noção de representação tivesse sido questionada e se a Ciência Cognitiva não tivesse virado as costas para a Filosofia contemporânea. Mas as dificuldades encontradas na construção da máquina de tradução – por exemplo, o problema da contextualização e da construção de uma semântica a partir da sintaxe – não foram reconhecidas como dificuldades filosóficas e sim tecnológicas. Para que estas fosse reconhecidas como filosóficas, seria preciso rever o próprio conceito de linguagem e com este o conceito de representação – o que a comunidade científica da IA não queria fazer. A mesma parceria filosófica infeliz parece ter sido a causa do insucesso dos sistemas especialistas no final dos anos 70. Em suma, a idéia de *conhecimento como representação* parece estar na raiz das dificuldades tecnológicas aparentes envolvidas na construção destes sistemas: explosão combinatorial, comportamento rígido e assim por diante[1].

---

[1] Desenvolvo este ponto de vista mais detalhadamente no meu ensaio "A Ciência Cognitiva para além da Representação".

AS LINHAS GERAIS DO PARADIGMA ENATIVO

Varela (1988) apresenta uma síntese das principais linhas do paradigma enativo utilizando-se para isto do seguinte diálogo:

> O que é a cognição?
> A cognição é ação efetiva: história do acoplamento estrutural que faz emergir um mundo.
>
> Como isto é possível?
> Através de uma rede de elementos interconectados capazes de mudanças estruturais ao longo de uma história ininterrupta.
>
> Como saber se um sistema cognitivo funciona adequadamente?
> Quando se transforma em parte de um mundo de significação preexistente (como ocorre com indivíduos de toda uma espécie) ou configura um novo (como ocorre na história evolucionária).

A noção de *inteligência* é também alterada no paradigma enativo: em vez de ser definida como capacidade de resolver problemas, ela passa a ser a capacidade de *ingressar num mundo compartilhado.* O processo evolutivo passa a substituir o *design* orientado para tarefas específicas. Outra importante mudança trazida pelo paradigma enativo é o modo de conceber a linguagem: a atividade de comunicação não consiste na transferência de informação do emissor para o receptor, mas na modelação mútua de um mundo comum através de uma ação conjunta.

O QUE LER

1 – Maturana, H. & Varela, F. *Autopoiesis and Cognition.* Há tradução para o português de uma parte substancial deste livro, com o título *De Máquinas e Seres Vivos*, publicado pela Artes Médicas, 1997.
2 – Varela, F . *Conocer*, capítulo 5.
3 – Varela, F.; Thompson, E.; Rosch, E. *The Embodied Mind.*

Capítulo 12

O futuro da Ciência Cognitiva

A Ciência Cognitiva é uma disciplina jovem que provavelmente entrará no próximo século na mesma situação de dispersão pré-paradigmática em que se encontra hoje. Para superar esta dificuldade seria preciso encontrar uma teoria unificada da cognição que integrasse todas as abordagens de que falamos até agora. Contudo, esta teoria unificada só poderia ser consensualmente aceita se explicasse de uma vez por todas um problema milenar: o das relações entre mente e cérebro. Só assim poderíamos saber *do que* estamos falando quando nos referimos a fenômenos mentais. Mas, apesar das várias soluções propostas, o problema mente-cérebro ainda parece resistir a qualquer tipo de abordagem unívoca, motivando, sucessivamente, não apenas a proposição de novas soluções possíveis como também novas estratégias teóricas para sua própria formulação.

Um sintoma destas dificuldades é o problema da natureza da consciência, questão que se arrasta há já alguns séculos e que agora retorna à agenda dos filósofos da mente depois de um período de aparente esquecimento.

O problema da consciência tem forçado a Ciência Cognitiva a conviver com mais uma dispersão: aquela provocada pelo avanço notável da Neurobiologia no decorrer da década de 90. Na virada desta década, os filósofos da mente passaram a escrever insistentemente sobre o problema da consciência tentando esclarecê-lo com o auxílio de modelos

explicativos derivados da Ciência Cognitiva. Foi nesta retomada que apareceram alguns trabalhos marcantes, como os de Baars (1987), Jackendoff (1988) e de Dennett (1991). Mas é a partir dos meados dos anos 90 que a Neurobiologia começa a delinear seu papel decisivo na abordagem de problemas filosóficos e cognitivos. Uma estratégia adotada pelos neurobiólogos para investigar o problema da consciência foi dividi-lo numa série de subproblemas específicos, antes de tentar delinear uma teoria geral. Dois destes subproblemas vêm atraindo a atenção dos neurobiólogos: as bases neuronais que permitem uma diferenciação entre sono e vigília e a integração da informação cognitiva, principalmente na percepção (*binding problem*). A diferenciação entre sono e vigília abre uma primeira porta para sabermos o que significa estar consciente. O *binding problem* consiste em saber como o cérebro pode integrar diferentes modalidades de informação acerca de um objeto de forma a poder percebê-lo de forma unificada. Por exemplo, posso perceber um cão de diversas maneiras – diferentes perspectivas visuais. Existem várias raças de cães; uso a palavra "cão" para referir-me a esses objetos e uso também a palavra escrita "cão". Contudo, meu cérebro é capaz de integrar todas estas modalidades de informação de maneira que invoco um único objeto quando ouço a palavra "cão". Esta unificação operada pelo meu cérebro é particularmente importante na medida em que a partir dela componho objetos fora de mim, o que é um primeiro passo para definir-me como um ser consciente.

A investigação destes dois subproblemas – a diferença entre sono e vigília e o *binding problem* – levaram a resultados surpreendentes. Francis Crick (1994), um cientista do California Institute of Technology descobriu uma correlação entre a ocorrência do *binding* e uma constância em certas oscilações de grupos de neurônios no córtex – uma oscilação que se situa sempre entre 35-40Mhz. Esta descoberta (que lhe valeu um Prêmio Nobel) levou-o a escrever um livro, *The Astonishing Hypothesis*, que se tornou um *best-seller* de divulgação científica. O mais polêmico no livro de Crick é sua afirmação de que nossas alegrias e tristezas, nosso sentido de identidade e de liberdade talvez não sejam nada mais do que o comportamento de um vasto conjunto de neurônios e suas reações químicas.

A investigação da diferença entre sono e vigília também trouxe resultados não menos surpreendentes. Llinás e Pare (1991) mostraram que os mecanismos de implementação do sono e da vigília no cérebro são idênticos, ou seja, não há diferença nas bases neuronais responsáveis pela produção destes dois tipos de estado. Mas o mais surpreendente ainda foi eles terem mostrado que não há diferenças neurológicas e funcionais entre sonhar e perceber: estes dois estados também têm uma base comum, qual seja, as oscilações de grupos de neurônios na faixa de 35-40 Mhz. Se há muito de percepção no sonho, esta última está também muito próxima dos estados oníricos.

É bem provável que haja muito de exagero nas afirmações de Crick e que suas investigações não constituam ainda uma explicação completa das bases neuronais da visão consciente. Com certeza, os dualistas diriam que isolar os correlatos neuronais da consciência é ainda insuficiente para explicar como o cérebro produz experiências conscientes. Contudo, este tipo de investigação iniciado por Crick abre o caminho para futuras pesquisas sobre a natureza da consciência – pesquisas que terão como ponto de partida um forte componente empírico derivado das neurociências. De qualquer forma, é preciso superar uma visão filosófica tradicional que pretende abordar o problema da consciência de modo puramente especulativo. Este tipo de abordagem puramente especulativa hoje em dia só pode ser equiparada ao temor daqueles que, no século XVII, recusavam-se a estudar o funcionamento do coração para continuar sustentando que nele está a sede das emoções e sentimentos.

Mas não é apenas na investigação do problema da consciência que a Neurobiologia tem surpreendido. Outros trabalhos, como, por exemplo, o *best-seller* de António Damasio (*Descartes'Error*), um neurobiólogo português radicado em Iowa, reabre a discussão de um dos pressupostos básicos da Ciência Cognitiva: a possibilidade de separação, mesmo que apenas metodológica, entre emoção e cognição, além de questionar até que ponto podemos conceber fenômenos cognitivos independentemente de sua base biológica. Compreender as emoções humanas é algo que exige mais do que um modelo computacional da mente: é preciso entender como o corpo humano e seu cérebro desenvolvem mecanismos especiais para gerar a experiência consciente e como as emoções contribuem decisivamente para o foco da atenção e a opção por determinados comportamentos.

A questão das emoções leva-nos para um território que só agora começa a ser explorado: o estudo dos neurotransmissores. Há mais de 50 neurotransmissores já detectados, todos eles envolvidos na passagem de informação de um neurônio para outro. A serotonina, por exemplo, é um dos mais importantes, na medida em que afeta diretamente as emoções e o comportamento. Mas ainda não sabemos exatamente em que sentido ela afeta o pensamento e a cognição.

Não há dúvida de que até agora as respostas tradicionais ao problema mente-cérebro têm menosprezado as relações entre emoções e pensamento. O dualismo, por exemplo, enfatiza a experiência emocional consciente mas negligencia sua base neurofisiológica. Por outro lado, o materialismo, reducionista ou eliminativista, enfatiza excessivamente a base biológica das emoções e o papel do cérebro, esquecendo dos aspectos experienciais e computacionais envolvidos nas emoções.

Livros como os de Damasio ampliam cada vez mais o desafio de superar a dispersão crescente que circunda o conhecimento da mente e caminhar em direção a uma teoria unificada e paradigmática. Talvez o que

a Ciência Cognitiva precise desenvolver é um tipo novo de materialismo, o *materialismo integrativo* (Thagard, 1996) que unifique, pelo menos, os aspectos neurofisiológicos envolvidos na emoção e no pensamento, além de seus aspectos computacionais. A simples proliferação de dados e experimentos na Neurobiologia não é suficiente para dar este passo, sobretudo se sua interpretação for filosoficamente ingênua. Como já dissemos, o grande desafio a ser enfrentado pela Ciência Cognitiva continua sendo, em grande parte, efetuar progressos conceituais e empíricos que nos permitam saber *do que* estamos falando quando nos referimos à mente ou à consciência.

Apêndice A

Uma demonstração do Teorema da Parada

Neste apêndice apresentamos um esboço da demonstração do teorema da parada da máquina de Turing (*Halting Problem*) que mencionamos no capítulo I. Este teorema diz o seguinte:

Para qualquer programa de máquina de Turing H, construído para decidir se programas de máquina de Turing param ou não, existe um programa P e dados de *input* I, tais que o programa H não pode determinar se P vai parar ou não, quando processa os dados I.

Para proceder à sua demonstração, Turing irá supor a existência de uma máquina de Turing (*A*) que decide se uma computação específica sobre um número *n* vai parar ou não. Para isto, é preciso imaginar uma lista de todos os *outputs* de todas as máquinas de Turing possíveis, atuando sobre todos os possíveis *inputs* diferentes. Isto pode ser feito da seguinte forma:

Consideremos uma computação sobre um número natural *n*. Chamemos esta computação $C_{(n)}$ e podemos concebê-la como parte de uma família de computações sobre números naturais 0, 1, 2, 3,... ou seja, as computações C(0), C(1), C(2)....C(*n*).

Suponhamos que temos uma computação A de tal forma que quando A para isto constitui uma demonstração de que uma computação C(*n*) não para. Ou seja, se A parar, isto é uma demonstração de que a computação específica que está sendo realizada não irá parar.

Para aplicar A a computações em geral, precisamos listar todas as possíveis computações C da seguinte maneira:

$C_0, C_1, C_2, C_3, C_4.....C_q$.

Podemos nos referir a C_q como a q-entupla computação.

Quando estas computações são aplicadas a um número particular *n*, escrevemos:

$C_0(n), C_1(n), C_2(n), C_3(n)....$

Esta é uma ordenação numérica de programas de computador. Esta lista é *computável*, isto é, existe uma computação C* que nos dá C*q* quando

ela atua sobre q , ou melhor, uma computação C* que atua sobre um par de números q, n. e que nos dá $C_q(n)$.

A computação A pode ser concebida como uma computação específica que quando atua sobre um par de números q, n, mostra que a computação $Cq(n)$ não vai parar. Assim, quando a computação A pára, temos uma demonstração de que $C_q(n)$ *não pára*. A computação realizada por A pode ser escrita como $A(q,n)$ e temos:

(1) – Se $A(q,n)$ pára então $C_n(n)$ não pára.

Imaginemos agora que q seja igual a n. Neste caso temos:

(2) – Se $A(n, n)$ pára, então $C_n(n)$ não pára.

A(n,n) depende apenas de um número, qual seja, n, e por isso ela deve ser uma das computações C_0,C_1,C_2,C_3 aplicadas a n, pois esta é uma lista de todas as computações que podem ser aplicadas sobre um número natural n qualquer. Suponhamos que esta computação é C_k, neste caso temos:

(3) – $A(n, n)=C_k(n)$.

Examinemos agora o que ocorre quando $n = k$. Temos:

(4) – $A(k, k)=C_k(k)$

e, com $n=k$:

(5) – Se $A(k, k)$ pára, então $C_k(k)$ não pára.

Substituindo k no enunciado acima temos:

(6) – Se $C_k(k)$ pára, então $C_k(k)$ não pára.

Disso devemos deduzir que a computação $C_k(k)$ *não pára*, pois se parasse ela não pararia, como vimos no enunciado (6). Mas $A(k,k)$ não pode parar tampouco, pois por (4) ela é o mesmo que $C_k(k)$. Assim sendo, chegamos a uma contradição em termos: a computação A é incapaz de mostrar que esta computação específica $C_k(k)$ não pára, mesmo quando ela pára.

Apêndice B

O décimo problema de Hilbert, indecidibilidade e os Teoremas de Gödel

O DÉCIMO PROBLEMA DE HILBERT

O problema da parada da máquina de Turing que vimos no Capítulo 1 da primeira parte deste livro (e no apêndice anterior) tem uma importância teórica fundamental: ele mostra que existem problemas que não podem ser resolvidos através de algoritmos. Da mesma maneira, a existência de números não-computáveis marca um limite para o que pode ser representado através de um procedimento algorítmico. Ora, haverá outros tipos de problemas que não podem ser resolvidos mecanicamente, ou seja, por meio de algoritmos? Esta questão constituiu uma preocupação central para os matemáticos e lógicos na década de 30.

No Capítulo 1 fizemos uma alusão a Hilbert e ao seu Décimo Problema (*Entscheidungsproblem).* Veremos a seguir que este problema deu origem a todo um capítulo da história da computabilidade e que da tentativa de resolvê-lo surgiu não apenas a máquina de Turing, mas também uma profunda revolução conceitual na Matemática: os teoremas de Gödel. Posteriormente, verificou-se a existência de uma equivalência entre o teorema da Incompletude de Gödel e o problema da parada da máquina de Turing – uma equivalência da qual se deriva a existência de um conjunto de problemas que não podem receber solução algorítmica. Delineava-se a idéia de que há mais coisas que a razão humana faz do que uma máquina de Turing pode fazer.

No Congresso Internacional de Matemática de 1928, que ocorreu em Bolonha, na Itália, o matemático alemão David Hilbert questionou a relação entre verdade e demonstração. Isto significava questionar se seria possível fornecer uma prova para todos os enunciados matemáticos verdadeiros. Hilbert estava buscando algo como uma "máquina de gerar enunciados matemáticos verdadeiros", uma máquina que, uma vez alimentada com um enunciado matemático, poderia dizer se o enunciado é falso ou verdadeiro. Na verdade, Hilbert havia formulado uma lista de 23 problemas fundamentais que deveriam nortear a pesquisa matemática no decorrer do século XX. Dentre estes 23 problemas destacava-se o Décimo Problema ou *Entscheidungsproblem,* o qual questionava se haveria ou não um procedimento mecânico (algorítmico) geral que pudesse resolver, *em princípio,* todos os problemas da Matemática. Além deste problema, Hilbert tinha também um programa para a fundamentação da matemática que visava colocá-la em bases rigorosamente sólidas, com axiomas e regras de procedimento que deveriam ser estabelecidos em caráter definitivo.

Hilbert acreditava que uma maneira de eliminar a possibilidade de aparecerem paradoxos na matemática (paradoxos são sentenças do tipo "Esta sentença é falsa" ou "Todos os cretenses são mentirosos, diz Epimênides, pensador cretense") seria criar uma linguagem puramente sintática, "sem significado," a partir da qual poderíamos falar acerca da verdade ou da falsidade de enunciados matemáticos. Nessa linguagem os enunciados matemáticos seriam expressos usando-se apenas símbolos abstratos que não teriam nenhum significado, a não ser o que fosse estabelecido por definição. Tal linguagem é chamada de *sistema formal* .

Os "enunciados sem significado" de um sistema formal são compostos de seqüências finitas de *símbolos* abstratos. Os símbolos são freqüentemente chamados de *alfabeto* do sistema, e as "palavras" do sistema são as *expressões*. Os símbolos podem ser objetos do tipo *, @ e # . Num sistema formal, um número finito de expressões é tomado como sendo o conjunto de *axiomas* do sistema. O sistema tem também um conjunto de *regras de transformação* e um conjunto de *regras de inferência*. Tais regras especificam como uma dada expressão pode ser convertida numa outra.

A idéia de prova num sistema formal consiste em começar com um dos axiomas e aplicar uma seqüência finita de transformações, convertendo o axioma numa sucessão de novas expressões, onde cada uma delas ou é um dos axiomas do sistema ou é derivada deles pela aplicação das regras de transformação. A última expressão de tal seqüência é chamada de um *teorema* do sistema. A totalidade dos teoremas constitui o que pode ser provado no sistema. Mas note-se que tais enunciados na verdade não dizem nada, eles são apenas um conjunto de expressões construídas com símbolos abstratos. Vejamos um exemplo de como isto pode funcionar[1]

[1] Este exemplo foi adaptado de Casti (1996).

Suponhamos que os símbolos de nosso sistema são estes três objetos: *, @ e #. Tomemos a expressão com dois símbolos *@ como sendo o único axioma de nosso sistema. Se x denota uma expressão finita e arbitrária de estrelas, arrobas e quadradinhos, as regras de transformação de nosso sistema serão:

Regra 1	x@	→	x@*
Regra 2	#x	→	#xx
Regra 3	@@@	→	*
Regra 4	x**x	→	xx

Nestas regras, → significa "é substituído por". Por exemplo, a Regra 1 diz que podemos formar uma nova expressão acrescentando uma estrela a qualquer expressão que termina com um quadradinho. A regra 4 diz que toda vez que duas estrelas aparecem juntas numa expressão, elas podem ser suprimidas na formação de uma nova expressão. Vejamos como estas regras podem ser usadas para provar um teorema.

Começando com a expressão @#, podemos deduzir que a expressão #*@ é um teorema aplicando as regras de transformação na seguinte ordem:

→ #@	→ #@@	→ #@@@@	→ #*@.
(Axioma)	(Regra 2)	(Regra 2)	(Regra 3)

Tal seqüência de passos, começando com um axioma e terminando num enunciado como #*@ é chamado de uma prova seqüencial para o teorema representado pela última expressão da seqüência. Note-se que quando aplicamos a Regra 3 no passo final, poderíamos ter substituído os últimos três @s da expressão precedente, terminando com o teorema #@* em vez de #*@. É fácil notar igualmente que todas as expressões intermediárias obtidas no caminho do axioma para o teorema começam com #. Fica evidente também pelo axioma e pela ação das regras de transformação que todas as expressões terão esta propriedade. Esta é uma propriedade *metamatemática* do sistema, ou seja, um enunciado *acerca* do sistema e não um enunciado feito *dentro* do sistema. Tal distinção entre o que o sistema diz e o que podemos dizer acerca do sistema, observando-o externamente, é de extrema importância, como veremos a seguir.

Se compararmos o funcionamento do programa de uma máquina de Turing e a aplicação das regras de transformação num sistema formal, veremos que não existe diferença entre os dois. Uma possível correspondência entre máquinas de Turing e sistemas formais é mostrada na tabela a seguir:

TABELA B.1. Correspondência entre sistema formal e máquina de Turing

Máquina de Turing	**Sistema Formal**
Símbolos na fita	Alfabeto
Padrão da fita	Conjunto de símbolos
Dados de *input*	Axiomas
Instrução do Programa	Regras de inferência
Output	Teorema

Falamos anteriormente do problema de Hilbert, que pergunta se existe um procedimento algorítmico para decidir se uma determinada expressão é ou não um teorema de um sistema formal. Usando as correspondências da tabela acima entre máquinas de Turing e sistemas formais, Turing pôde traduzir o problema de Hilbert para seu equivalente em termos de linguagem de máquinas. Este equivalente computacional é o problema da parada, cuja solução negativa implica também uma solução negativa para o problema de Hilbert.

Examinemos agora como um sistema formal (sintático) se relaciona com um mundo de objetos matemáticos aos quais estão associados significados. Esta relação se dá através da noção de *interpretação.* A interpretação confere significado aos objetos e entidades matemáticas, tais como linhas, pontos, números, símbolos abstratos, etc. Assim sendo, todos os teoremas do sistema formal podem ser interpretados como enunciados verdadeiros acerca desses objetos matemáticos. A Figura B-1 mostra com clareza a distinção entre o mundo puramente sintático dos sistemas formais e o mundo dos objetos matemáticos, associados com um significado.

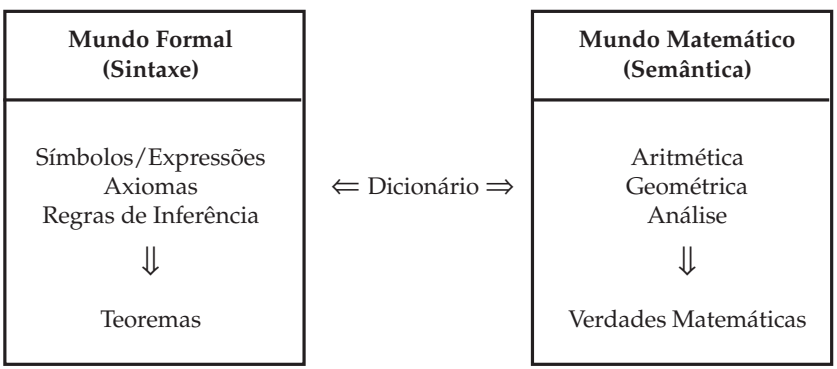

Figura B-1. O Mundo da Matemática e o Mundo Formal (adaptado de Casti, 1996, p. 157).

É de se esperar que exista uma correspondência perfeita, um a um, entre os fatos verdadeiros da Matemática e os teoremas do sistema formal. O sonho de Hilbert era encontrar um sistema formal no qual todas as verdades matemáticas fossem traduzíveis para teoremas e vice-versa. Tal sistema é denominado *completo*. Se uma linguagem deve evitar contradição, uma verdade matemática e sua negação não podem ambas ser traduzíveis para teoremas, ou seja, não podem ser provadas num sistema formal. Tal sistema, no qual enunciados contraditórios não podem igualmente ser provados, é chamado de *consistente.*

INDECIDIBILIDADE

Em 1928, quando Hilbert proferiu sua conferência em Bolonha, os matemáticos já sabiam que proposições geométricas e outros tipos de asserções podiam ser expressas como asserções acerca de números. Assim sendo, o problema da consistência da matemática como um todo era redutível à determinação da consistência da aritmética, ou seja, às propriedades e relações entre números naturais (inteiros positivos: 1, 2, 3..). O problema era então construir uma teoria da aritmética, ou seja, um sistema formal que fosse: a) finitamente descritível, b) consistente, c) completo e d) suficientemente forte para representar todos os enunciados que podemos construir acerca de números naturais. Com a palavra *finitamente descritível* Hilbert queria dizer não apenas que a quantidade de axiomas e regras do sistema tinha de ser construtível com um número finito de passos, mas também que qualquer enunciado passível de prova no sistema – todos os teoremas – tinham de ser provados com um número finito de passos.

Uma questão fundamental envolvida neste projeto de formalização da aritmética era perguntar se existe um procedimento finito pelo qual possamos decidir a verdade ou falsidade de qualquer enunciado aritmético. Assim, por exemplo, se tomamos o enunciado: "A soma de dois números ímpares é sempre um número par" queremos um procedimento finito – um programa computacional – que pare após um número finito de passos e que nos diga se tal enunciado pode ser provado ou não em algum sistema formal poderoso o suficiente para abranger a aritmética. Por exemplo, no sistema formal acima, *@#, tal procedimento de decisão é dado por condições não inteiramente óbvias: "Uma expressão é um teorema se e somente se (1) se ela começa com #, (2) se o restante da expressão é constituído por *s e #s, e (3) o número de #s não é um múltiplo de 3".

Hilbert achava que a formalização da aritmética seria possível, mas, em 1931, Kurt Gödel provou o seguinte fato metamatemático:

A ARITMÉTICA NÃO É INTEIRAMENTE FORMALIZÁVEL.

Três anos após a conferência de Bologna, o matemático austríaco Kurt Gödel assombrou o mundo com a publicação de um artigo que reduzia a cinzas o programa de Hilbert. Em seu artigo, Gödel mostrou que existem enunciados matemáticos que são verdadeiros, mas que não são suscetíveis de prova, ou seja, há um abismo entre *verdade* e *demonstração*. A idéia de axiomatizar a Matemática – como Hilbert queria – foi por água abaixo.

Gödel reconheceu a importância da percepção de Hilbert de que toda formalização de um ramo da Matemática constitui também um objeto matemático: quando dizemos que "formalizamos" algo, significa que criamos uma estrutura matemática a partir da qual podemos falar acerca do que queremos formalizar. Assim, se criamos um sistema formal para expressar as verdades da aritmética, tal sistema formal pode ser estudado não apenas como um conjunto de regras cegas para manipular símbolos, mas como um objeto que tem propriedades matemáticas, isto é, propriedades semânticas. Como Gödel estava interessado em relações entre números, seu objetivo era representar um sistema formal que contivesse a aritmética nela mesma. Ou seja, mostrar como codificar *qualquer* enunciado acerca de números e suas relações através de um único número. Tratava-se de representar enunciados acerca das relações entre números naturais usando os próprios números naturais.

Esta última idéia fica mais clara no contexto da linguagem natural, na qual usamos palavras em português para falar a respeito de nossa própria linguagem natural. Usamos palavras para descrever propriedades das palavras, para descrevê-las como sendo nomes próprios ou verbos, escrevemos gramáticas de português usando a língua portuguesa. Em ambos os casos, estamos usando a linguagem de duas maneiras diferentes: (1) como uma coleção de expressões *não-interpretadas* de símbolos alfabéticos que são manipuladas de acordo com as regras da gramática e sintaxe da língua portuguesa e (2) como um conjunto de expressões *interpretadas* tendo um significado dentro do contexto. A idéia-chave é que os mesmos objetos podem ser considerados de duas maneiras diferentes, abrindo a possibilidade de que o objeto fale sobre si mesmo. Esta era a idéia subjacente à demonstração de Gödel – uma demonstração complexa, mas que apresentaremos de forma simplificada, baseando-nos, passo a passo, no trabalho de Casti (1996).

Casti toma como ponto de partida uma versão supersimplificada da linguagem da lógica – a versão desenvolvida por Ernest Nagel e James Newman (1958) com símbolos elementares e variáveis. Suponhamos que temos 10 símbolos lógicos, como é mostrado na Tabela 1.3, cada um deles com um número de código, um número inteiro entre 1 e 10.

Tabela B.2. Correspondência entre um símbolo, seu número de Gödel e seu significado.

Símbolo	Número de Gödel	Significado
~	1	Não
/	2	Ou
…	3	Se...então...
$	4	Existe
=	5	Igual
0	6	Zero
s	7	O sucessor imediato de ...
(	8	Pontuação
)	9	Pontuação
¢	10	Pontuação

Além dos símbolos elementares, esta linguagem contém variáveis lógicas que são ligadas por meio dos símbolos. Estas variáveis são de três tipos, representando uma ordenação hierárquica que depende do papel que a variável desempenha na expressão lógica. Algumas variáveis são *numéricas*, o que quer dizer que elas podem assumir valores numéricos. Outras variáveis designam expressões lógicas ou fórmulas (variáveis *sentenciais*). Finalmente, temos as variáveis de *predicados* que expressam propriedades dos números ou das expressões numéricas, tais como "par", "ímpar" "primo," etc. Todas as expressões lógicas e suas relações podem ser escritas usando estes três tipos de variáveis, conectando-as por símbolos lógicos. Nesta versão simplificada da linguagem da lógica há apenas 10 símbolos lógicos; o sistema numérico de Gödel codifica variáveis numéricas por números primos maiores do que 10, variáveis sentenciais por quadrados de números primos maiores do que dez e variáveis de predicados pelo cubo dos números primos maiores do que 10.

Para ter uma idéia de como este processo de numeração funciona, considere a fórmula lógica $(\exists x)(x = \mathbf{s}y)$ que, traduzida para nossa linguagem natural, isto é, o português, quer dizer: "Existe um número x que é o sucessor imediato do número y". Uma vez que x e y são variáveis numéricas, a codificação de Gödel nos diz que façamos a atribuição $x \to 11, y \to 13$, uma vez que 11 e 13 são os dois primeiros números primos maiores do que 10. Os outros símbolos na fórmula podem ser codificados substituindo-os por números, conforme mostra a tabela de correspondência. Isto nos leva à seqüência de números 8, 4, 11, 9, 8, 11, 5, 7, 13, 9. Esta seqüência de 10 números traduz a fórmula lógica. Mas uma vez que a aritmética fala de propriedades de números e não de seqüências de números, seria interessante representar a fórmula usando um único número. O procedimento gödeliano para fazer isto consiste em tomar os 10 primeiros números primos (na medida em que há 10 símbolos na fórmula)

e multiplicá-los juntos, sendo que cada número primo é elevado à potência igual ao número de Gödel do elemento correspondente na fórmula. Uma vez que os 10 primeiros números primos pela ordem são 2, 3, 5, 7, 11, 13, 17, 19, 23 e 29, fazemos as substituições ($\rightarrow$, 2^8, $\exists$, $\rightarrow$, 3^4, $x \rightarrow 5^{11}$), e assim por diante. O número de Gödel para a fórmula acima é então:

$$(\exists x)(x = \mathbf{s}y) \rightarrow 2^8 \text{ x } 3^4 \text{ x } 5^{11} \text{ x } 7^9 \text{ x } 11^8 \text{ x } 13^{11} \text{ x } 17^5 \text{ x } 19^7 \text{ x } 23^{13} \text{ x } 29^9$$

Usando este esquema de numeração, Gödel pôde relacionar um único número para cada enunciado e seqüência de enunciados sobre a aritmética que pudesse ser expresso nesta linguagem lógica. Qualquer proposição acerca de números naturais pode ser expressa como um número, e, assim sendo, pode-se usar a aritmética para examinar suas próprias verdades.

O segundo passo dado por Gödel foi lançar mão da noção cotidiana de verdade e a tradução de um paradoxo lógico numa proposição aritmética. O paradoxo utilizado envolve auto-referência, ou seja, proposições que se referem a si mesmas, como é o caso da seguinte:

ESTA SENTENÇA É FALSA.

A sentença diz que ela é falsa. Se esta asserção não corresponde à realidade, então a sentença deve ser verdadeira. Por outro lado, se a sentença é verdadeira, isto significa que o que ela diz corresponde à realidade. Mas esta sentença verdadeira diz que ela é falsa. Assim sendo, a sentença deve ser falsa. Se assumimos que a sentença é falsa ou se assumimos que a sentença é verdadeira, somos obrigados a concluir o oposto. Este é um caso de paradoxo.

O que Gödel queria fazer era achar uma maneira de expressar estes paradoxos de sentenças auto-referentes na linguagem da aritmética. Com isto, ele procurava uma exceção à tese de Hilbert de que todas as sentenças devem ser passíveis de prova num sistema formal. Em vez de usar a noção de "verdade," Gödel a substitui por algo que é formalizável: a noção de *ser passível de prova*. O paradoxo pode então ser modificado para:

ESTE ENUNCIADO NÃO É PASSÍVEL DE PROVA.

Esta sentença é uma asserção auto-referente acerca de um enunciado particular, qual seja, o enunciado mencionado na sentença. Contudo, por meio de seu esquema de numeração Gödel pôde codificar esta asserção

num enunciado metamatemático auto-referencial, expresso na linguagem da aritmética. Vejamos as conseqüências disto.

Ocorre que o enunciado acima *é passível de prova* e, assim sendo, ele deve ser verdadeiro. Logo, *o que ele diz* deve ser verdadeiro. Mas ele diz que ele *não é passível de prova*. Logo, o enunciado e sua negação são *ambos passíveis de prova*. Há, então, uma inconsistência no nosso esquema de prova. Por outro lado, se o enunciado não é passível de prova, então o que ele diz é correto, o enunciado é verdadeiro, mas não é passível de prova. Temos um enunciado verdadeiro, mas que não é passível de prova, implicando que o sistema formal que estamos usando para provar enunciados é incompleto.

Como Gödel efetuou uma tradução deste enunciado auto-referente num enunciado equivalente no sistema formal, isto significa que nossas conclusões acerca de inconsistência e incompletude aplicam-se inteiramente à aritmética. Se o sistema formal usado para a aritmética é consistente ele deve, necessariamente, ser incompleto.

Gödel pôde mostrar que para *qualquer* sistema formal consistente, poderoso o suficiente para expressar todos os enunciados acerca da aritmética, esta sentença de Gödel deve existir, logo, a formalização deve ser incompleta. Existirá, nestes sistemas formais, sempre um enunciado que não poderá ser provado usando as regras do sistema. É preciso estar *fora* do sistema para perceber sua verdade. Em seguida, Gödel mostrou como construir um enunciado aritmético A que é traduzido na asserção metamatemática "a aritmética é consistente". Ele demonstrou que o enunciado A não é passível de prova, o que implica que a consistência da aritmética não pode ser estabelecida usando-se qualquer sistema formal que represente a própria aritmética. Chegamos então à formulação do seguinte teorema:

> TEOREMA DE GÖDEL – *Em toda formalização consistente da aritmética existem verdades aritméticas que não são passíveis de prova no interior do sistema formal.*

Comparemos agora o teorema de Gödel com o teorema da parada de Turing:

> TEOREMA DA PARADA – *Para qualquer programa de máquina de Turing H, construído para decidir se programas de máquina de Turing param ou não, existe um programa P e dados de input I, tais que o programa H não pode determinar se P vai parar ou não quando processa os dados I.*

O teorema da parada nada mais é do que um caso de indecidibilidade como outros que são exibidos pelo teorema de Gödel, embora expresso em termos de máquinas de Turing e programas computacionais

em vez da linguagem lógica dos sistemas dedutivos. A equivalência do teorema da parada e o Décimo Programa de Hilbert, além da correspondência entre máquinas de Turing e sistemas formais, permitem-nos concluir que não pode existir um programa para máquina de Turing que imprima todos os enunciados verdadeiros da aritmética.

Os resultados de Gödel mostram que existem enunciados sobre os números que sabemos ser verdadeiros – embora sua verdade não possa ser provada através de raciocínios lógicos. Há uma defasagem entre verdade e demonstração, mais verdades do que aquilo que pode ser provado.

Glossário

Alelo – Membro de um par de gens que ocupa uma posição específica num determinado cromossomo.

Arquitetura von Neumann – Tipo de arquitetura mais usado para a construção de computadores, foi desenvolvida por John von Neumann. Este tipo de arquitetura permite que programas sejam estocados na memória do computador, como se fossem dados. Ademais, este tipo de arquitetura faz com que as instruções sejam executadas seqüencialmente no computador, uma a uma. Quase todos os computadores modernos utilizam-se da arquitetura von Neumann.

Autômato – Do grego *automatos* e latim *automatu*. A melhor definição de autômato foi dada por uma enciclopédia alemã, publicada em 1732 e que diz: " São instrumentos mecânicos preparados de modo tão sutil e engenhoso, segundo as artes da geometria, que se movem e andam sem a ajuda de força externa", ou "máquina que traz em si o princípio de seu próprio movimento". Quando elas têm aparência humana são também chamadas de "andróides".

Behaviorismo ou Comportamentalismo – Em Psicologia, o behaviorismo *metodológico* é a visão segundo a qual a tarefa do psicólogo consiste em estabelecer leis relacionando estímulos com respostas. Ainda segundo o behaviorismo metodológico, o psicólogo deve evitar o estudo de estados mentais. Em Filosofia, o behaviorismo *lógico* é uma forma de **reducionismo**, segundo o qual o significado da atribuição de estados mentais deve ser feito de acordo com o papel que eles desempenham na produção de comportamentos. Tais atribuições podem, em princípio, ser traduzidas em sentenças que façam referência unicamente a circunstâncias comportamentais e físicas.

Cálculo de Predicados – Uma linguagem matemática inventada por G. Frege e Ch.S. Peirce no final do século XIX), na qual é possível representar a forma lógica de sentenças da linguagem natural. Esta linguagem permite estabelecer critérios precisos para a validade das inferências, a verdade das sentenças de diferentes formas e a **consistência** lógica de conjuntos de sentenças.

Cibernética – Do grego *kybernetiké* – ciência que estuda as comunicações e o sistema de controle de máquinas e organismos vivos. A cibernética teve seu auge nos anos 40 e início dos anos 50. Seus pioneiros foram Norbert Wiener e John von Neumann.

Ciência Cognitiva – Estudo do funcionamento mental (humano ou não) que toma como modelo o computador. A Ciência Cognitiva é essencialmente interdisciplinar, reunindo, na tentativa de fazer uma ciência da mente, disciplinas como a Psicologia, a Lingüística, a Ciência da Computação, as Ciências do Cérebro e a Filosofia.

COG – Protótipo de robô humanóide que está sendo desenvolvido no MIT pela equipe de Rodney Brooks.

Condições de verdade – Dada uma **proposição**, as condições de verdade são aquelas condições que devem ser satisfeitas para que a proposição seja verdadeira ou falsa.

Conexionismo – Concepção alternativa de modelagem da mente humana usando o computador. O conexionismo tenta modelar processos inteligentes tomando como base o sistema nervoso (cérebro) e suas características biológicas, tentando reproduzir, artificialmente, os neurônios e suas conexões cerebrais. Para o conexionista, a simulação da inteligência deve começar por uma simulação do cérebro. Freqüentemente, as palavras "conexionismo", "redes neurais" e PDPs (*Parallel Distributed Processing* ou processamento distribuído) são tomadas como equivalentes.

Consistência – Um sistema lógico é dito consistente se de seus axiomas não se deduzem proposições contraditórias entre si.

Dualismo – Doutrina filosófica que sustenta a existência de uma distinção (ou assimetria) entre fenômenos mentais e fenômenos cerebrais. O dualismo moderno origina-se a partir da filosofia de R. Descartes (1596-1650). Opõe-se ao materialismo ou monismo (ver).

Epifenomenismo – Teoria filosófica segundo a qual os estados mentais e a consciência acompanham os estados corpóreos, mas são incapazes de reagir ou atuar sobre eles. Para o epifenomenista, estados mentais e estados conscientes são subprodutos da atividade cerebral.

Fenótipo – Conjunto de características físicas e bioquímicas de um organismo, determinadas seja pela sua composição genética, seja pelas influências ambientais. A palavra fenótipo é também empregada para designar uma característica específica de um organismo, como, por exemplo, estatura ou tipo sangüíneo a partir de influências genéticas ou ambientais.

Filosofia da Mente – Ramo da Filosofia contemporânea que reestuda questões tradicionais da Filosofia (problema mente-cérebro, problema da identidade pessoal, problema da natureza das representações mentais, etc.) à luz dos recentes avanços da Inteligência Artificial, da Ciência Cognitiva e das Ciências do Cérebro.

Fisicalismo – Visão segundo a qual tudo o que se passa na mente pode ser explicado na linguagem da Física, da Química e da Fisiologia. De acordo com o fisicalismo, todos os fatos mentais e psicológicos são redutíveis a fatos físicos.

Folk Psychology – Conjunto de teorias habituais e cotidianas a partir das quais explicamos o comportamento e a vida mental de outras pessoas. Segundo alguns teóricos e filósofos da mente a *folk psychology* é fragmentária e incoerente.

Funcionalismo – Doutrina que sustenta que o que torna um estado *mental* é o papel que ele desempenha num sistema em questão. São as relações causais e funcionais com outros estados do sistema que tornam um estado *mental*.

Genótipo – Constituição genética de um organismo ou grupo de organismos. A palavra é também usada para designar organismos que têm a mesma constituição genética.

GOFAI – (*Good and Old Fashioned Artificial Intelligence*) – Termo recentemente cunhado pelo pesquisador John Haugeland, da Universidade de Pittsburgh, EUA. A GOFAI designa a pesquisa em Inteligência Artificial que se fez nas últimas décadas, excluindo, contudo, movimentos mais recentes, como, por exemplo, o Conexionismo (ver).

IA forte – Visão da IA segundo a qual o computador adequadamente programado *é* uma mente e reproduz estados mentais. Os programas não são meramente ferramentas que nos habilitam a testar teorias acerca do funcionamento mental humano.

IA fraca – A IA-fraca ou "visão fraca" da IA sustenta que a criação de programas inteligentes é simplesmente um meio de testar teorias sobre como os seres humanos talvez executem operações cognitivas.

Inteligência Artificial (IA) – Disciplina que estuda e desenvolve programas computacionais com a finalidade de simular atividades mentais humanas cuja realização envolve inteligência. O termo "Inteligência Artificial" foi inventado pelo matemático John McCarthy na década de 50.

Linguagem natural – Ou linguagem ordinária, é freqüentemente definida por oposição às linguagens formais ou artificiais. O português, o inglês, o francês, etc. são, todas, linguagens naturais.

LISP – Linguagem computacional inventada por John McCarthy. Ainda muito usada em Inteligência Artificial.

Materialismo/Monismo – Doutrina filosófica que sustenta que fenômenos mentais são, em última análise, fenômenos cerebrais. Embora não sejam exatamente a mesma coisa, as palavras "materialismo" e "monismo" são usadas como sendo equivalentes. A grande maioria dos pesquisadores da IA e da Ciência Cognitiva defende o Materialismo.

Materialismo Eliminativo – Concepção segundo a qual nossa atribuição cotidiana de estados mentais a nós mesmos e a outros é falsa, pois esta atribuição se faz a partir de uma teoria errada. De acordo com o materialismo eliminativo, nossa psicologia cotidiana (***folk-psychology***) e nosso vocabulário psicológico comum devem ser substituídos, no futuro, por uma teoria neurocientífica que trará, igualmente, um vocabulário neurocientífico.

MIT – Abreviatura de *Massachusetts Institute of Technology.*

Proposição – O conteúdo de uma crença ou de uma asserção, freqüentemente expressa em linguagem natural incluindo uma cláusula do tipo "que". Por exemplo na sentença: "Eu acredito que o sol está brilhando" – "o sol está brilhando" constitui a proposição.

Reducionismo – Na acepção usada em Psicologia ou em **Filosofia da Mente**, o reducionismo é uma teoria que sustenta que fatos psicológicos ou estados mentais podem ser reduzidos a fatos ou estados fisiológicos ou comportamentais.

Tempo Exponencial – Se n é o parâmetro do qual depende a dificuldade de uma determinada tarefa matemática (por exemplo, o tamanho de um *input*, o número de *inputs,* etc.), esta tarefa será realizada em tempo exponencial se, para um número m e um algoritmo, o número de passos necessários para realizar a tarefa é sempre menor ou igual a m^n. Tarefas que requerem tempo exponencial para serem realizadas são tarefas *intratávei*s.

Tempo polinomial – Se n é o parâmetro do qual depende a dificuldade para realizar uma tarefa matemática – o tamanho de um número que serve de *input*, o número de *inputs,* etc. – então a tarefa é realizada em tempo polinomial se, para um dado número m e um dado algoritmo, o número de passos necessários para realizar a tarefa é sempre menor ou igual a n^m. Se uma tarefa pode ser realizada em tempo polinomial, ela é uma tarefa *tratável*.

Teoria da Complexidade – Ramo da Ciência da Computação que estuda o grau de dificuldade envolvido na resolução algorítmica de classes de problemas. Um dos principais tópicos abordados por esta disciplina é a eficiência (extensão de tempo) envolvida na execução de um algoritmo.

Periódicos de Ciência Cognitiva

A cada dia que passa, maior é o número de revistas especializadas que abordam assuntos relacionados à Ciência Cognitiva. Assim sendo, a lista que apresentamos a seguir não é completa:

1 – **Revistas interdisciplinares**
Behavioral and Brain Sciences
Cognition
Cognitive Science
Mind and Language

2 – **Revistas filosóficas**
Mind
Minds and Machines
Philosophical Psychology
Journal of Consciousness Studies
(*web: Http://www.zynet.co.uk/imprint*)

3 – **Revistas psicológicas**
Cognitive Psychology
Psychological Review

4 – **Revistas de Inteligência Artificial**
Artificial Intelligence
Computational Intelligence
Connection Science

5 – **Revistas de Neurociência**
Cognitive Neuroscience
Neural Networks
Biological Cybernetics

6 – **Revistas de Lingüística**
Foundations of Language
Language
Linguistic Inquiry

7 – **Revistas sobre conexionismo/redes neurais**
Neural Computation
The Journal of Computational Neuroscience

8 – **Revistas eletrônicas**
Psyche
http//psyche.cs.monash.edu.au/
Journal of Artificial Intelligence Research
http//www.cs.washington.edu/research/Jair/home.html
Think Quarterly
http://tkwww.kub.nl:2080/tki/Docs/Think

Sociedades e organizações
American Association for Artificial Intelligence
Cognitive Neuroscience Society
Cognitive Science Society
Society for Machines and Mentality
Society for Philosophy and Psychology

Sociedades e organizações no Brasil

Grupo de Ciência Cognitiva do Instituto de Estudos Avançados da USP – São Paulo

Grupo de Ciência Cognitiva – Instituto de Estudos Avançados da Universidade Federal do Rio Grande do Sul – UFRGS – Porto Alegre

Sociedade Brasileira de Inteligência Artificial – SBIA

Cursos e programas de pós-graduação em Ciência Cognitiva

Informação sobre cursos de pós-graduação em Ciência Cognitiva no Exterior pode ser encontrada acessando-se as seguintes URLs da www:

http://www-psych.stanford.edu/cogsci/.

http://www.cog.brown.edu/pointers/cognitive.html.

Bibliografia comentada

Os livros e artigos assinalados com um asterisco (*) estão comentados e são especialmente recomendados para aqueles que desejam se aprofundar no estudo da Ciência Cognitiva e da Filosofia da Mente. Estão incluídos nesta Bibliografia também os livros e artigos citados neste trabalho.

Abraham, R. H., & C. D. Shaw. 1992. *Dynamics:the geometry of behavior* 2. ed. Redwood City, California: Addison-Wesley.

Allen, R. H., ed. 1992. *Expert systems for civil engineers: knowledge representation* New York: American Society of Civil Engineers.

*Anderson, A.R. (1964). *Minds and Machines* New York: Prentice Hall.

Antologia clássica de textos sobre Filosofia da Mente e Inteligência Artificial. Inclui diversos artigos de Turing, Lucas, e o famoso artigo de Putnam "Minds and Machines". Há tradução para o castelhano em *Controversia sobre Mentes y Máquinas – Cuadernos Infimos 124, Tusquets Editores, Espanha.*

Anderson, J. R. 1983. *The architecture of cognition.* Cambridge, MA: Harvard University Press.

Anderson, J. R. 1990. *Cognitive science and its implications* New York: Freeman.

Anderson, J. R. 1993. *Rules of the mind.* Hillsdale, NJ: Erlbaum.

*Baars, B. J. 1988. *A cognitive theory of consciousness.* Cambridge: Cambridge University Press.

Livro sobre o problema da consciência. Propõe a teoria do *global workspace,* no qual a consciência aparece como elemento integrador das várias funções mentais e cerebrais.

Bremermann, H.J. 1977. "Transcomputability and Complexity" in Smith, M. & Duncan, R. (eds) *The Encyclopedia of Ignorance* London: Routledge & Kegan Paul.

*Boden, M. 1987. *Artificial Intelligence and Natural Man* 2.ed. London: MIT Press.
Livro importante para quem quer ter um panorama da IA até o início dos anos 80. Descreve uma série de programas de IA e suas características.

Boden, M. 1988. *Computer models of mind.* Cambridge U.K.: Cambridge University Press.

*Boden, M. (ed.) (1990). *The Philosophy of Artificial Intelligence.* New York: Oxford University Press.
Importante coletânea de artigos na área de IA. Contém artigos recentes e artigos de importância histórica, como, por exemplo, o de McCulloch e Pitts, publicado em 1943.

*Boden, M. (ed.) 1996. *The Philosophy of Artificial Life.* New York: Oxford University Press.
Coletânea atualizada com artigos recentes sobre vida artificial. Contém artigos de Langton e de Thomas Ray.

*Borst, C.V. 1970. *The mind/brain identity theory.* London:Macmillan.
Coletânea clássica sobre o problema mente-cérebro. Contém artigos de U.T. Place e de J. J. Smart.

Brooks, R.A. 1990. Elephants do not play chess in P. Maes (ed) *Designing autonomous agents* p. 3-15. Cambridge, MA: The MIT Press.

*Brooks, R. A. 1991. lntelligence without representation. *Artificial Intelligence* **47:**139-159.
Artigo fundamental onde são lançadas as bases teóricas para o desenvolvimento da Nova Robótica. Contém também forte crítica à Inteligência Artificial representacionalista. Para Brooks, o conceito de representação é desnecessário para conceber o comportamento inteligente.

Brooks, R.A. 1991. Intelligence without reason – *Proceedings of the 12th. IJCAI* pp. 565-95, San Mateo, CA: Morgan Kauffmann.

*Casti, J. (1996). *Five Golden Rules.* New York: John Wiley.
Livro excelente que expõe as cinco grandes realizações da Matemática no século XX. Contém um capítulo sobre o teorema da parada de Turing, onde também são explicados, de maneira accessível, o teorema da incompletude de Gödel e o Décimo Problema de Hilbert, bem como outros conceitos fundamentais para a teoria da computabilidade.

*Chalmers, D. 1996. *The Conscious Mind.* New York: Oxford University Press.
Um dos livros mais recentes e polêmicos sobre o problema da consciência na Filosofia da Mente. Nele o autor sustenta que a consciência não pode ser reduzida a qualquer outro tipo de fenômeno, seja este neurológico ou de outra natureza. Advoga um dualismo peculiar, que ele batiza de "dualismo naturalista".

Chomsky, N. 1957. *Syntatic structures.* The Hague: Mouton.

Chomsky, N. 1959. A review of B. F. Skinner's *Verbal behavior. Language,* 35, 26-58.

*Churchland, P. S. 1986. *Neurophilosophy.* Cambridge, Mass.: MIT Press.
Livro de grande fôlego, dividido em duas partes. Na primeira expõe as principais concepções sobre o funcionamento do cérebro e na segunda explora teorias filosóficas e computacionais acerca do funcionamento mental.

*Churchland, P. S. & Sejnowski, T. 1992. *The computational brain.* Cambridge, Mass.: MIT Press.

Livro importante, explora teorias computacionais acerca do funcionamento cerebral. Aborda também temas como plasticidade cerebral e integração sensório-motora.

*Churchland, P. 1986. *Matter and Consciousness.* Cambridge, MA: The MIT Press.

Uma excelente introdução à Filosofia da Mente, recomendável para todos os que quiserem se iniciar neste assunto.

Clark, A. 1989. *Microcognition: philosophy, cognitive science and parallel distributed processing*. Cambridge, MA:MIT/Bradford Books.

Crick, F. 1994. *The astonishing hypothesis: The scientific search for the soul.* London: Simon and Schuster.

*Damasio, A.R. 1994. *Descartes´error.* New York: Putnam.

Livro instigante, escrito pelo neurobiólogo português radicado em Iowa, nos Estados Unidos. Argumenta que não é possível obter uma separação integral entre emoções e inteligência, pondo em questão os principais pressupostos do cognitivismo e do cartesianismo. De leitura extremamente agradável. Há tradução para o português (Companhia das Letras).

*Dennett, D. 1969. *Content and Consciousness.* London: Routledge & Kegan Paul.

Um dos primeiros livros do filósofo norte-americano Daniel Dennett. Nele são lançados os principais conceitos que levarão à elaboração do conceito de sistema intencional, fundamental para sua teoria da mente.

*Dennett, D. 1978. *Brainstorms* Cambridge, MA: The MIT Press.

Coletânea de artigos do filósofo norte-americano Daniel Dennett. Nesta coletânea são tratados vários assuntos relevantes para a Inteligência Artificial e suas relações com a Filosofia da Mente.

*Dennett, D. 1991. *Consciousness explained.* Boston: Little, Brown.

Livro importante para quem se interessa pelo problema da consciência em Filosofia da Mente. Nele é proposto um modelo anticartesiano e antidualista de consciência, baseado em idéias computacionais.

Dennett, D. (1995). *Darwin's dangerous idea.* New York: Simon & Schuster.

Dietrich, E., ed. 1994. *Thinking computers and virtual persons: Essays on the intentionality of machines.* San Diego, California: Academic Press.

*Dreyfus, H.L. 1972. *What computers cannot do.* New York: Harper & Row.

Um libelo contra a Inteligência Artificial. Nele o autor argumenta (de maneira muitas vezes emocional) contra a possibilidade de simulação mecânica de atividades mentais humanas. Um de seus pontos de apoio foi o fracasso dos programas para traduzir linguagens naturais durante a década de 70.

Dreyfus, H. L. 1991. *Beíng-in-the-world.* Cambridge, Mass.: MIT Press.

Dreyfus, H. L. 1992. *What computers still can't do.* 3. ed. Cambridge, Mass.: MIT Press.

*Dupuy, P. 1994. *Aux Origines des Sciences Cognitives.* Paris: Éditions La Découverte.

Livro histórico, relata o aparecimento da Cibernética, um ramo que as Ciências Cognitivas preferem esquecer. Nele se mostra como que da cibernética se originaram a IA simbólica e o conexionismo. Há tradução para o português (EDUNESP. Editora da UNESP).

*Epstein, R. & Carnielli, W. 1989. *Computability: Computable Functions, Logic and the Foundations of Mathematics.* Pacific Grove, California: Wardsworth & Brooks/Cole.
Um dos livros mais completos acerca de computabilidade. Possui passagens de matemáticos e lógicos importantes como Hilbert, Gödel onde eles relatam seus pontos de vista acerca de questões de Computabilidade e Filosofia da Matemática.

Feyerabend, P.K. 1963. "Materialism and the mind-body problem." *Review of Metaphysics* **17.** 14-29.
Flanagan, O. 1992. *Consciousness reconsidered.* Cambridge, MA.: MIT Press.
Flanagan, O. 1995. Deconstructing dreams: The spandrels of sleep. *Journal of Philosophy* 92, 5-27.
Franklin, S. 1995. *Artificial Minds.* Cambridge, MA: The MIT Press.

*Fodor, J. 1975. *The language of thought.* New York: Crowell.
Livro fundamental para quem se interessa pelo paradigma representacionalista. É considerado uma espécie de "bíblia" do cognitivismo clássico. Nele se argumenta pela existência de uma linguagem do pensamento, que procederia através de computações sucessivas. Esta linguagem do pensamento possibilitaria a cognição e a linguagem. Oferece algumas dificuldades de leitura.

*Fodor, J. 1983. *The modularity of mind.* Cambridge, MA: The MIT Press.
Livro importante para aqueles que se interessam pelo paradigma simbólico. Nele argumenta-se que o aparato cognitivo humano está organizado em módulos estanques, sendo que alguns deles funcionam automaticamente, sem passar pela consciência.

Fodor, J. 1987. *Psychosemantics.* Cambridge, Mass.: MIT Press.

*Fodor, J.& Pylyshyn, Z. 1988. Connectionism and cognitive architecture: a critical analysis. *Cognition* **28:**3-71.
Artigo de leitura obrigatória para aqueles que se interessam por conexionismo. Nele estão contidas as principais críticas a este tipo de abordagem à cognição.

*Gardner, H. 1985. *The mind's new science.* New York: Basic Books.
Uma história do surgimento e desenvolvimento da Ciência Cognitiva. Muita informação, embora de maneira um pouco esparsa, constitui livro importante para se ter um panorama desta disciplina.

*Garey, M. & Johnson, D. 1979. *Computers and Intractability.* San Francisco: W.H. Freeman and Co.
Livro clássico acerca da Teoria da Complexidade Computacional.

Giere, R. 1988. *Explaining science: A cognitive approach.* Chicago: University of Chicago Press.
Gleick, J. 1987. *Chaos: Making a new science.* New York: Viking.
Graham, G. 1993. *Philosophy of mind: An introduction.* Oxford: Blackwell.

*Haugeland, J. 1981. *Mind Design* Cambridge, MA, The MIT Press
Uma das melhores coletâneas sobre Inteligência Artificial, Ciência Cognitiva e Filosofia da Mente. Reúne artigos de Newell, Simon, Putnam, Dennett, Searle, Davidson e outros. Uma nova edição, ampliada, intitulada *Mind Design II* acaba de ser publicada pela MIT Press.

*Haugeland, J. 1985. *Artificial Intelligence: the very idea,* Cambridge MA: The MIT Press.
Uma discussão filosófica acerca dos potenciais da IA. No livro, Haugeland caracteriza a GOFAI (ver Glossário) e a concepção de inteligência derivada deste conceito.

Hinton, G. E. & A. Anderson, eds. 1981. *Parallel models of associative memory.* Hillsdale, NJ.: Erlbaum.

*Hofstadter, D. 1979. *Gödel, Escher, Bach: An eternal golden braid.* New York: Basic Books.
Livro instigante, trata de vários problemas filosóficos da IA e sustenta que a questão da auto-referência contém a chave para resolver a maioria destes problemas.

Hofstadter, D. & Dennett, D. 1981. *The Mind´s I* Sussex: The Harvester Press.
Hofstadter, D. 1995. *Fluid concepts and creative analogies: Computer models of the fundamental mechanisms of thought.* New York: Basic Books.
Holland, J. H. 1975. *Adaptation in Natural and Artificial Systems.* Ann Arbor: University of Michigan Press.
Holland, J. H.; Holyoak, K.J.; Nisbett, R. E; Thagard, P. R. 1986. *Induction: Processes of inference, learning, and discovery.* Cambridge, MA: The MIT Press.
Holtzman, S. 1989. *Intelligent decision systems.* Reading, MA.: Addison-Wesley.
Holyoak, K. J., & J. A. Barnden, eds. 1994. *Advances in connectionist and neural computatíonal theory.* Vol. 2, *Analogical connections.* Norwood, NJ.: Ablex.
Holyoak, K. J., & Thagard, P. 1995. *Mental leaps: Analogy in creative thought.* Cambridge, Mass.: MIT Press.

*Hopcroft, J. & Ullmann, J. 1979. *Introduction to Automata Theory, Languages and Computation.* New York: Addison Wesley.
Um dos livros mais completos sobre computabilidade. De abordagem técnica, oferece algumas dificuldades para o leitor leigo.

*Humphrey, N. 1992. *A History of the Mind.* London: Chatto & Windus.
Livro que aborda vários aspectos e questões da Filosofia da Mente. Há tradução para o português (Editora Campus – Rio de Janeiro).

Jackendoff, R. 1987. *Consciousness and the computational mind.* Cambridge, MA.: MIT Press.
Keil, F. 1989. *Concepts, kinds, and cognitive development.* Cambridge, MA.: MIT Press.
Kim, J. 1996. *Philosophy of Mind.* Boulder, CO: Westview Press.
Kosslyn, S. M. 1980. *Image and mind.* Cambridge, MA.: Harvard University Press.
Kosslyn, S. M. 1994. *Image and brain: the resolution of the imagery debate.* Cambridge, MA: The MIT Press.
Kosslyn, S. M., & Koenig, O. 1992. *Wet mind: The new cognitive neuroscience.* New York: Free Press.
Langton, C. (ed). 1989. *Artificial Life.* Reading, MA: Addison-Wesley.
Lashley, K.S. 1951. "The problem of serial order in behavior" in Jeffress, L.A., (ed) *Cerebral mechanism in behavior.* New York, John Wiley & Sons.112-146.
Latour, B., & Woolgar, S. 1986. *Laboratory life: The construction of scientific facts.* Princeton, NJ.: Princeton University Press.
Lenat, D., & Guha, R. 1990. *Building large knowledge-based systems.* Reading, MA.: Addison-Wesley.
Levine, D. S. 1991. *Introduction to neural and cognitive modeling.* Hillsdale, NJ.: Erlbaum.

*Levy, S. 1992. *Artificial Life.* London: Jonathan Cape.
Uma das melhores exposições do surgimento e desenvolvimento da Vida Artificial. Em linguagem simples e jornalística, contém informações importantes para quem quer se iniciar neste tópico.

Llinás, R.R. & Paré, D. 1991. "Of Dreaming and Wakefulness". *Neuroscience* **44**, n. 3, 521-535.

*Lucas, J. R. 1961. Minds, machines, and Gödel. *Philosophy* **36:** 120-124.
Artigo polêmico onde Lucas argumenta que o teorema da incompletude de Gödel constitui um obstáculo intransponível para a simulação completa das atividades mentais humanas e marca uma assimetria entre mentes e máquinas. Há tradução para o castelhano em *Controversia sobre Mentes y máquinas – Cuadernos Infimos 124, Espanha Tusquets Editores.*

*Maturana, H. & Varela, F. 1980. *Autopoiesis and Cognition.* Boston: D. Reidel.
Livro fundamental para a compreensão do paradigma inativo. Divide-se em dois ensaios = "The biology of Cognition" e "Autopoiesis: the organization of the living". O segundo ensaio foi publicado separadamente e dele há tradução para o português com o título *De máquinas e Seres Vivos.*

Maturana, H. & Varela, F. 1997. *De Máquinas e Seres Vivos,* Porto Alegre: Artes Artes Médicas.
*McCorduck, P. 1979. *Machines who think.* New York: Freeman.
Uma história do surgimento e desenvolvimento da Inteligência Artificial. Embora em linguagem jornalística, contém muitas informações relevantes.

McCulloch, W. & Pitts, W. (1943). A Logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*. **5:**115-133.
McKworth, A. 1993. On seeing robots. ln A. Basu and X. Li, eds., *Computer vision: Systems, theory, and applications,* 1-13. Singapore: World Scientific.
Maida, A. S. 1990. Frame theory. ln S. C. Shapiro, ed., *Encyclopedia of artificial intelligence,* 302-312. New York: Wiley.
McClelland, J. L. & Rumelhart, D. E. 1989. *Explorations in parallel distributed processing.* Cambridge, MA: The MIT Press.
Medin, D. L. & Ross, B. H. 1992. *Cognitive psychology.* Fort Worth, Tex.: Harcourt Brace Jovanovich.
Michalski, R, Carbonell, J. & Mitchell, T. (eds.) 1986. *Machine learning: An artificial intelligence approach.* Vol. 2. Los Altos, California: Morgan Kaufmann.
Miller, G. A. 1956. The magical number seven, plus or minus two: Some limits on our capacity for processing information. *Psychological Review* 63, 81-97.
Miller, G. A. 1991. *The science of words.* New York: Scientific American Library.
Minsky, M. & Papert, S. 1969. *Perceptrons.* Cambridge, MA: The MIT Press.
Minsky, M. 1975. A frame work for representing knowledge. In P. H. Winston, ed., *The psychology of computer vision,* 211-277. New York: McGraw-Hill.

*Minsky, M. 1985. *The Society of Mind.* New York: Simon & Schuster.
Livro bastante importante na literatura da IA. Nele está explicada a teoria dos "*frames*" proposta por Minsky. Há versão em CD-ROM para McIntosh. Há também tradução para o português (Francisco Alves).

Murphy, G., & Medin, D. L. 1985. The role of theories in conceptual coher*ence. Psychological Review* 92, 289-316.

*Nagel, E., & Newman, J. R. 1958. *Gödel's proof.* London: Routledge and Kegan Paul.
Uma das melhores exposições dos teoremas de Gödel. Infelizmente as traduções disponíveis não são confiáveis.

Neapolitain, R. 1990. *Probabilistic reasoning in expert systems.* New York: Wiley.

Nelson, G., Thagard, P., Hardy. S. 1994. lntegrating analogies with rules and explanations. ln Holyoak K. J. & Barnden, J. A. eds., *Advances in connectionist and neural computational theory.* Vol. 2, *Analogical connections,* 181-205. Norwood, NJ.: Ablex.

Osherson, D. N. 1995. *An invitation to cognitive science.* 3 vols. 2. ed. Cambridge, MA: The MIT Press.

Pearl, J. *1988. Probabilistic reasoning in intelligent systems.* San Francisco, California: Morgan Kaufmann.

*Penrose, R. 1989. *The emperor's new mind: Concerning computers, minds, and the laws of physics.* Oxford: Oxford University Press.

Este livro é um verdadeiro *best-seller*, tendo sido traduzido para vários idiomas, inclusive o português (Editora Campus – Rio de Janeiro). Nele, Penrose faz um longo percurso, passando pela teoria da Computabilidade e pela Física para mostrar por que ele não acredita na possibilidade de simulação completa das atividades mentais humanas.

Penrose, P,. 1994. *Shadows of the mind: A search for the missing science of consciousness.* Oxford: Oxford University Press.

Pinker, S. 1994. *The language ínstinct: How the mind creates language.* New York: Morrow.

*Popper,K. & Eccles, J. (1977). *The Self and its Brain.* Berlin: Springer International

Livro instigante, aborda o problema mente-cérebro na perspectiva filosófica (Popper) e na perspectiva neurofisiológica (Eccles). Ambos defendem uma interessante variedade de dualismo. Há tradução para o português (Editora Papirus, Campinas).

*Posner, M. I., ed. 1989. *Foundations of cognitive science.* Cambridge, MA: The MIT Press.

A mais completa e abrangente coletânea de trabalhos em Ciência Cognitiva. Embora bastante extensa, é leitura recomendada para o neófito.

Poundstone, W. 1991. *Labyrinths of Reason.* London:Penguin Books.

*Putnam, H. 1975. *Mind, language, and reality.* Cambridge: Cambridge University Press.

Esta coletânea do filósofo norte-americano Hilary Putnam (em 3 volumes) contém importantes artigos que relacionam Inteligência Artificial e Filosofia da Mente. Nela está o artigo clássico "*Minds and Machines*", no qual é proposto um modelo das relações mente-cérebro baseado em conceitos oriundos da Inte-ligência Artificial.

*Pylyshyn, Z. 1984. *Computation and cognition: Toward a foundation for cognitive science*. Cambridge, MA.: MIT Press.

Livro importante para quem procura uma abordagem mais detalhada do paradigma simbólico ou IA representacionalista.

*Rich, E. 1983. *Artificial Intelligence.* New York: McGraw Hill.

Manual que aborda vários aspectos técnicos da IA, passando por resolução de problemas, representação do conhecimento, linguagem natural, etc. A edição mais atualizada tem uma parte sobre redes neurais. Há tradução para o português pela Editora McGraw Hill Ltda.

Riesbeck, C. K., & Schank, R. C. 1989. *Inside case-based reasoning.* Hillsdale, NJ.: Erlbaum.

*Robinson, D. (1973). *Introdução Analítica à Neuropsicologia.* São Paulo: E.P.U.

Livro escrito em linguagem simples e clara, introduz o leitor no conhecimento do cérebro humano.

Rorty, R. 1965. "Mind-body identity, privacy and categories". *The Review of Metaphysics,* **19** 22-33

*Rumelhart, D. E; McClelland, J. L. e o PDP Research Group. 1986. *Parallel distributed processing: Explorations in the microstructure of cognition.* Cambridge, MA.: The MIT Press.

Livro fundamental para quem quer se iniciar no conexionismo. É uma espécie de "bíblia" sobre o assunto, reunindo artigos de vários autores que analisam modelos conexionistas em várias áreas da ciência cognitiva.

Schank, R. C. & Abelson, R. P. 1977. *Scripts, plans, goals, and understanding: An inquiry into human knowledge structures.* Hillsdale, NJ.: Erlbaum.

Schank, P.; Kass C., A. & Piesbeck, C. K. 1994. *Inside case-based explanation.* Hillsdale, NJ.: Erlbaum.

Searle, J. 1980. "Minds, Brains and Programs"in *Mind Design.* J. Haugeland (ed). Cambridge, MA, MIT Press/Bradford Books, 282-306.

Searle, J. 1980a. "Intrinsic Intentionality" *Behavioural and Brain Sciences*, v 3. 307-309

Searle, J. 1982. "What is an intentional state?" in Dreyfus, H. (ed) *Husserl, intentionality and cognitive science.* Vermont:Bradford Books. 259-276.

*Searle, J. 1984. *Minds, Brains and Science.* Cambridge, MA: Harvard University Press.

Um dos livros mais importantes de J. Searle, em que ele explica, em linguagem simples, o argumento do quarto do chinês e sua teoria da intencionalidade baseada em princípios biológicos. O livro surgiu de uma série de palestras feitas por J. Searle, as "*Reith Lectures*". Há tradução para o português (Edições 70 – Portugal).

*Searle, J. 1992. *The rediscovery of the mind.* Cambridge, MA.: MIT Press.

Livro recente de Searle, que contém várias críticas à Ciência Cognitiva e à Inteligência Artificial. Há tradução para o português (Editora Martins Fontes).

Shannon, C. 1948. "The mathematical theory of communication" – *Bell System Technical Journal*, **27** 379-423.

Simon, H. (1969). *The Sciences of the Artificial* Cambridge, MA: MIT Press.

Coletânea de quatro ensaios sobre os fundamentos da Inteligência Artificial.

*Smolensky, P. 1988. On the proper treatment of connectionism. *Behavioral and Brain Sciences,* **2:** 1-74.

Artigo fundamental onde são discutidas as bases teóricas do conexionismo bem como suas diferenças em relação ao paradigma simbólico.

Teixeira, J. de F. 1990. *O que é Inteligência Artificial.* S. Paulo: Editora Brasiliense. Coleção Primeiros Passos.

Teixeira, J. de F. 1994. *O que é Filosofia da Mente.* S. Paulo: Editora Brasiliense. Coleção Primeiros Passos.

Teixeira, J.de F. 1996. *Filosofia da Mente e Inteligência Artificial.* Campinas: Edições CLE-UNICAMP.

Teixeira, J. de F. (org) 1996a. *Cérebros, Máquinas e Consciência: uma introdução à Filosofia da Mente.* S. Carlos: EDUFSCAR (Editora da Universidade Federal de S. Carlos).

Teixeira, J. de F. 1996b. "A Ciência Cognitiva para além de Representação. São Paulo: Coleção Documentos, Série Ciência Cognitiva, Instituto de Estudo Avançados da USP.

*Thagard, P. 1996. *Mind: an introduction to cognitive science.* Cambridge, MA: The MIT Press.

Livro recente, constitui uma das melhores introduções à Ciência Cognitiva em língua inglesa. A tradução para o português será publicada pela Editora Artes Médicas.

*Walnum, Clayton (1993). *Adventures in Artificial Life*, Que@Corporation.

Livro interessante que contém a descrição de vários programas de vida artificial. Em linguagem simples. Há tradução para o português pela Berkeley Brasil Editora, com o título: *Aventuras em Realidade Virtual.*

*Varela, F. (1988). *Conocer.* Barcelona: Gedisa.

Livro introdutório, mas excelente. Nele Varela analisa, de forma sucinta e clara os principais paradigmas da Ciência Cognitiva: o simbólico, o conexionista e o "enactivo", desenvolvido pela Escola Chilena, da qual ele faz parte.

*Waterman, D. 1986. *A Guide to Expert Systems.* Reading, MA: Addison Wesley.

Um dos melhores livros sobre sistemas especialistas. Detalhado, expõe os princípios de construção destes sistemas e apresenta quase todos os sistemas especialistas construídos até a metade da década de 80.

Winograd, T. & Flores, F. 1986. *Understanding computers and cognition.* Reading, MA.: Addison-Wesley.

Winston, P. 1993. *Artificial intelligence.* 3. ed. Reading, MA.: Addison-Wesley.