UEPB

Introdução à Estatística

Me. Janaína Aparecida

O que é Estatística ?

Usa-se por vezes a Estatística como um bêbedo usa um poste de luz: Mais para suporte do que para iluminação...

ESTATÍSTICA: conjunto de técnicas que permite, de forma sistemática, coletar, organizar, descrever, analisar e interpretar dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento.

Algumas Atividades que Envolvem Estatística.

- Área Social: O censo populacional.
- Área Industrial: Confiabilidade de Sistemas, Controle Estatístico de Qualidade, etc.
- Área Agropecuária: Identificação de melhores formas de manejo, etc.
- Área Bancária: Concessão de Crédito, Atuária.
- Marketing: Pesquisas de Mercado, Inferência, etc.

Principais Áreas da Estatística

- **Estatística Descritiva:** Utilizada na etapa inicial da análise, quando tomamos contato com os dados pela primeira vez. É o conjunto de técnicas destinadas a descrever e resumir os dados a fim de que possamos tirar conclusões a respeito da característica de interesse.
- **Probabilidade:** Teoria matemática utilizada para se estudar a incerteza oriunda de fenômenos de caráter aleatório.
- **Inferência Estatística:** Estudo de técnicas que possibilitam a extrapolação, a um grande conjunto de dados, das informações e conclusões obtidas a partir de subconjuntos de valores, usualmente de dimensão muito menor.

Exemplos de Aplicação

- **Comparação entre tratamentos ou processos:**

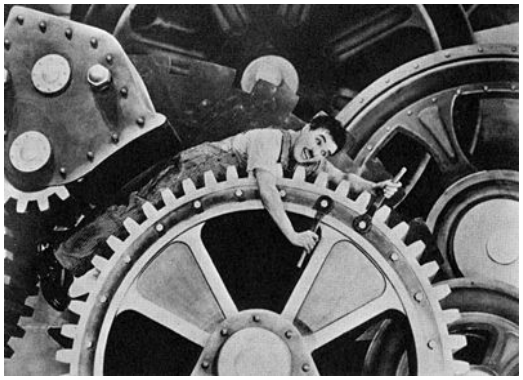

Tratamento Tipo 1

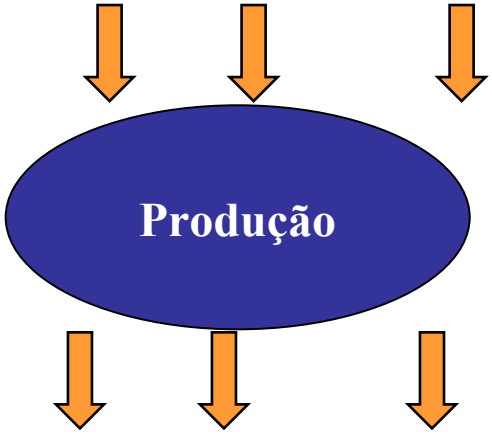

x_{11} x_{12} ... x_{1n}

Tratamento Tipo 2

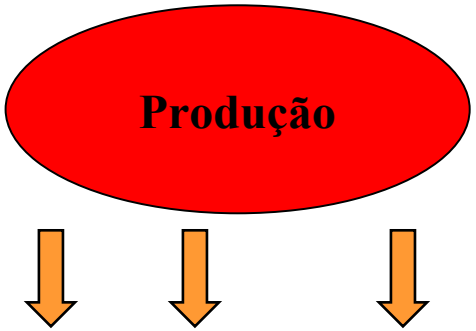

x_{21} x_{22} ... x_{2n}

Tipo 1 é mais produtivo do que o Tipo 2?

Raciocínio Estatístico

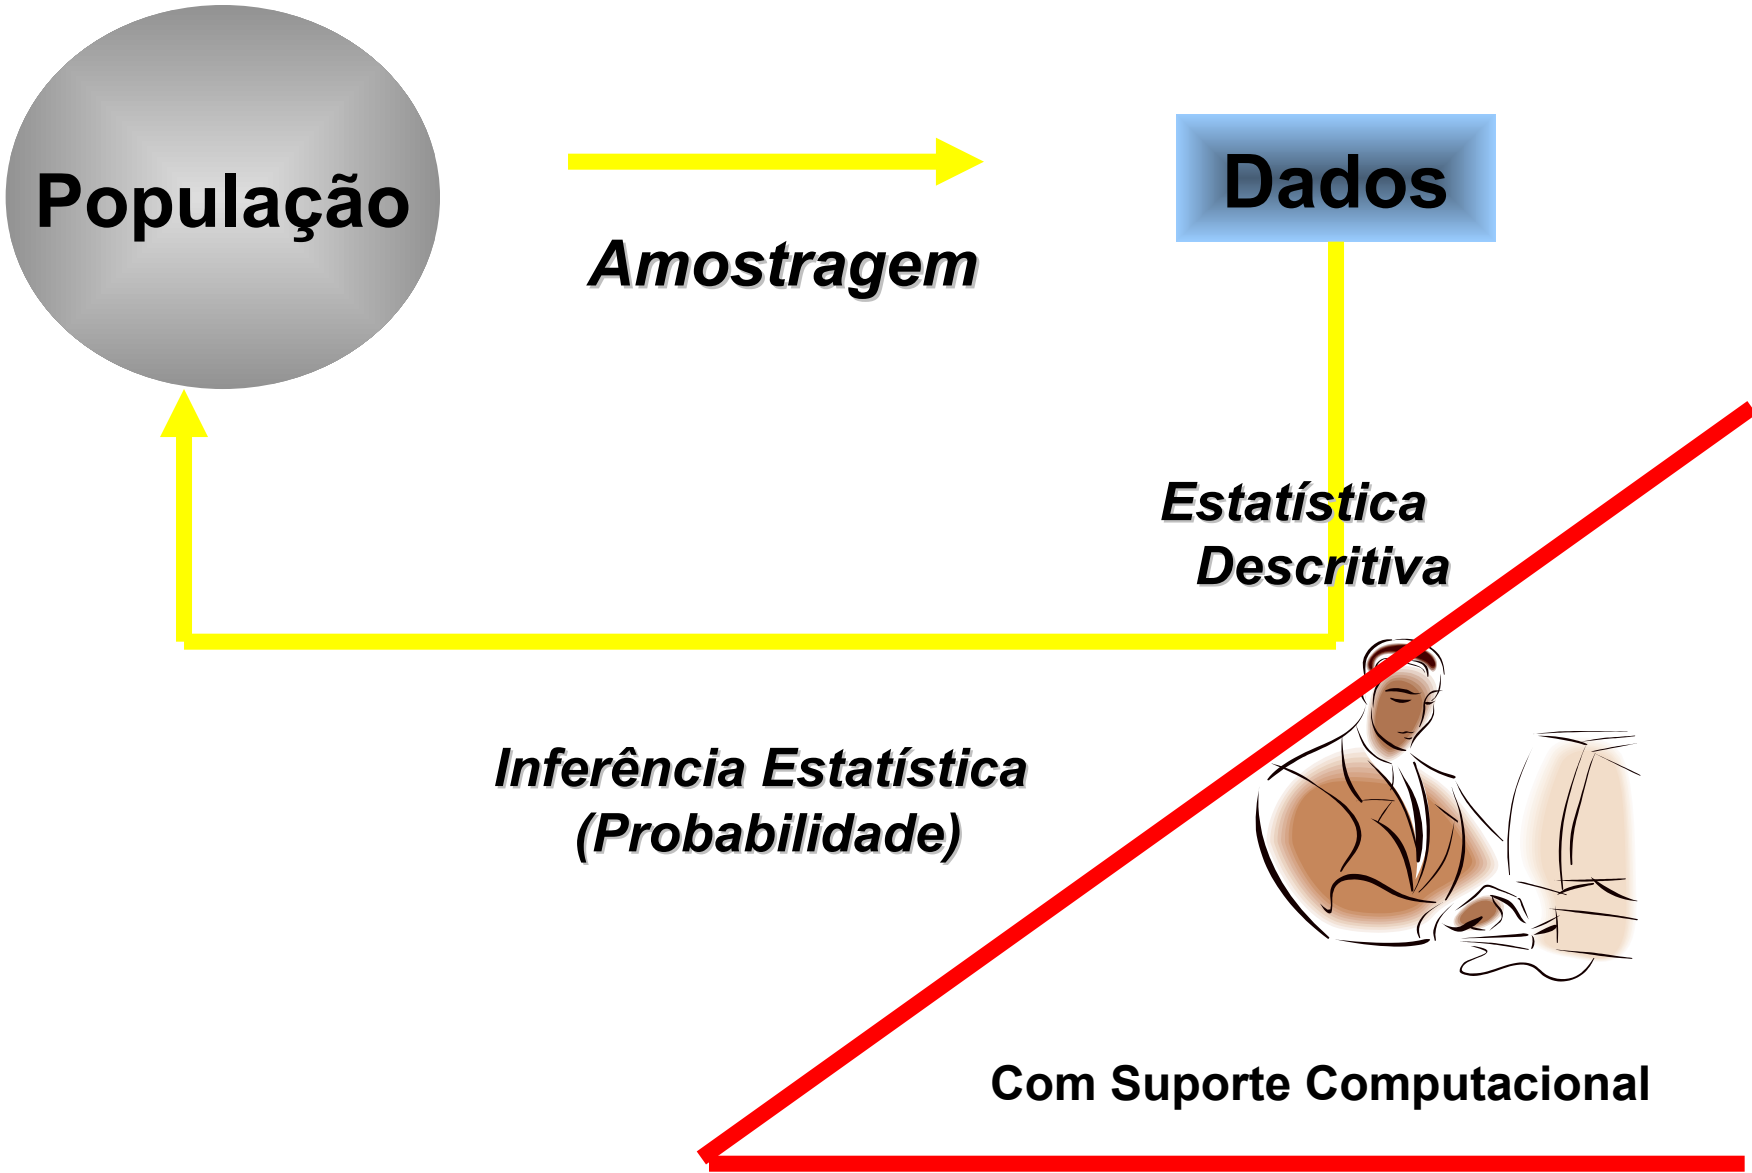

Técnicas de Amostragem

Noções Básicas

- Definição de População: Ao grande conjunto de elementos que contém determinada característica comum, que temos interesse recebe o nome de **população.**

População 1

População 2

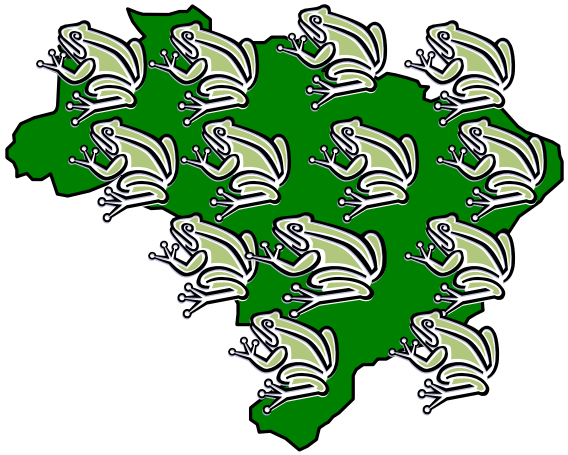

Ex1: Toda a população brasileira.

Ex2: Toda a população de sapos brasileiros.

Noções Básicas

Quando observamos todos os dados, procedemos ao Censo.

Exemplo: Examinar todos os brasileiros quanto a condição de nutrição.

População

Qual é a proporção de brasileiros desnutridos?

$\pi = ?$

- Um **parâmetro** é uma medida numérica que descreve uma característica de uma população. Ex: 20% dos brasileiros estão desnutridos.

Noções Básicas

Quase não se trabalha com população.

Motivos Principais

- Alto custo da pesquisa/experimento (material, pessoal, logística, etc);

- Resultados demorados;

- Razões Éticas (experimentos com animais);

- Impossibilidade (Linha de produção, sangue, etc).

Noções Básicas: Amostra.

Definição: subconjunto da população, em geral com dimensão sensivelmente menor.

População

Amostra

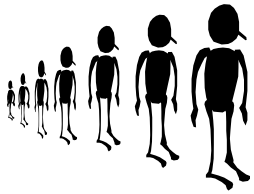

$\overline{x}$: Estatística.

• **Estatística**: é uma medida numérica que descreve uma característica de uma amostra. Ex: média da altura da pop. Brasileira, proporção de desnutridos, etc.

Vantagens da Amostragem.

- Baixo custo operacional.

- Maior rapidez na execução da pesquisa ou estudo.

- Maior segurança nos resultados

Tipos de Amostragem

Amostra casual simples: Existência de um “frame”. **Todos os elementos da população devem ter chance igual de escolha**. Procedimento baseado no sorteio aleatório.de escolha.

Figura 1: Sorteio Aleatório

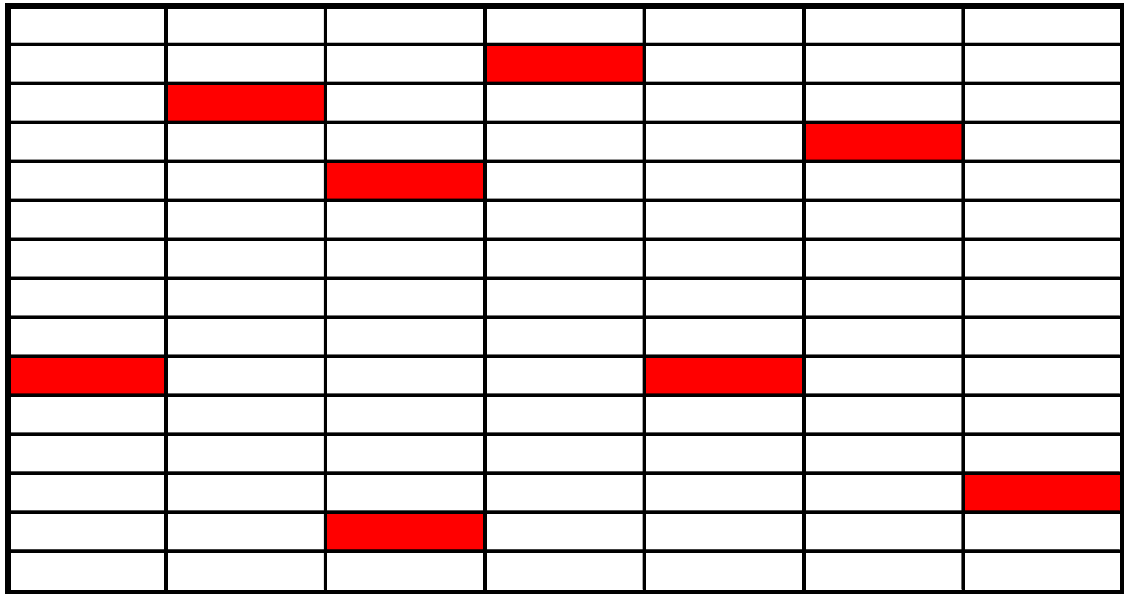

Tipos de Amostragem

Amostra Estratificada: Na amostra estratificada os elementos são provenientes de todos os estratos da população.

Em cada estrato é feito o sorteio aleatório.

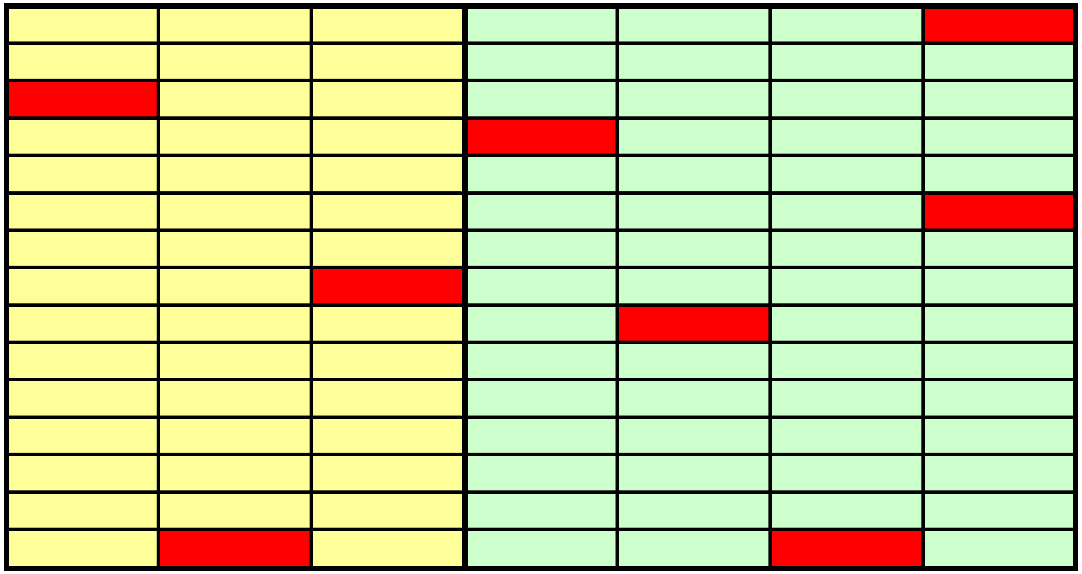

Ex: Pesquisas em um cidade; pesquisas em florestas; etc.

Tipos de Amostragem

Amostra Sistemática: Na amostra sistemática os elementos são escolhidos não por acaso, mas por um sistema.

No primeiro período o sorteio é aleatório.

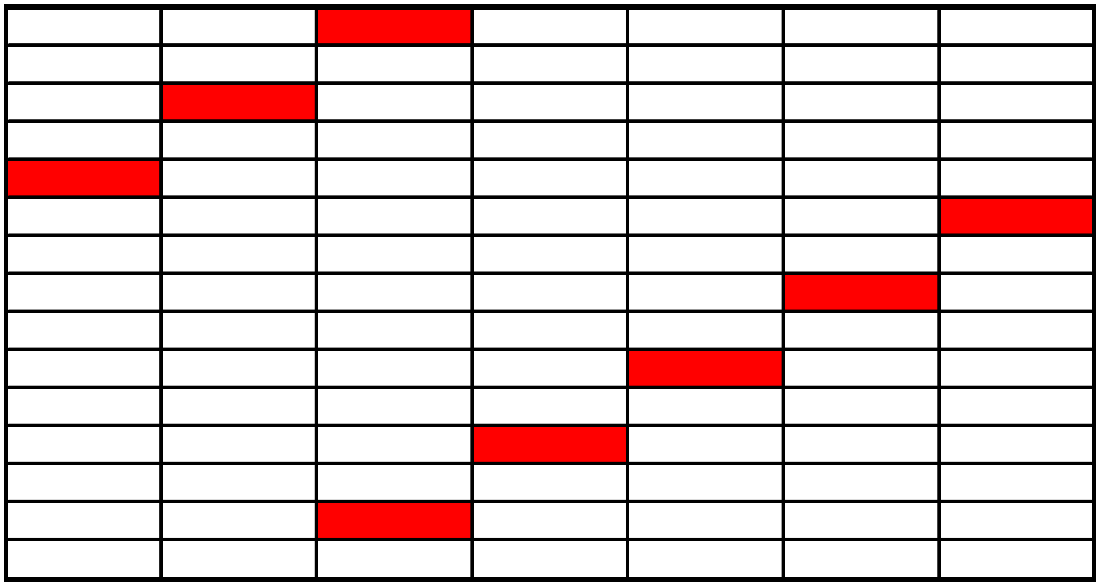

Exemplo: Linha de Produção; Pesquisas em formulários; etc.

Tipos de Amostragem

Amostra por conglomerado: Amostra feita em vários estágios. Maior economia.

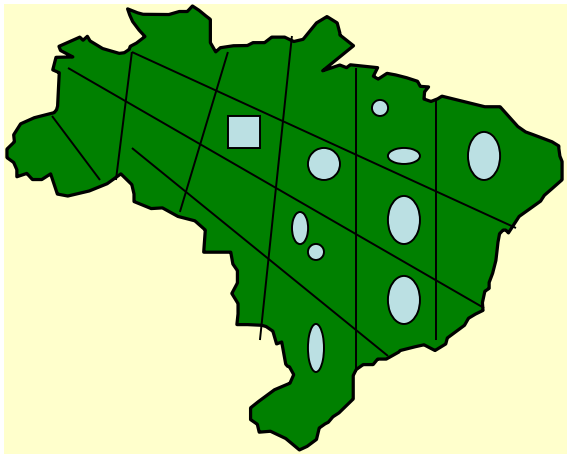

Ex: Em uma pesquisa feita no pais, primeiro sorteamos os estados, depois as cidades, depois os bairros, os setores censitários, os domicílios e os indivíduos.

Tipos de Amostragem: Exercícios

A- Identifique o tipo de amostra:

1. Obtém-se uma amostra de um produto extraindo-se cada 100º unidade da linha de produção;
2. Um fabricante de automóveis faz um estudo de mercado compreendendo testes de direção feitos por uma amostra de 10 homens e 10 muheres em cada uma das quatro diferentes faixas etárias;
3. Geram-se números aleatórios em um computador para selecionar números de séries de carros a serem escolhidos para uma amostra teste.

4. Em uma linha de produção são produzidos 1000 comprimidos por hora, sabendo que a linha funciona por 8 horas seguidas por dia e que deve ser extraída uma amostra de 400 comprimidos por dia, qual seria o processo de amostragem mais indicado e como seria a seleção dessa amostra?

Análise Exploratória de Dados Estatística Descritiva 1

Organização dos dados em Tabelas?

O que é uma variável ?

- **Variável** é uma característica, propriedade ou atributo de uma unidade da população, cujo valor pode variar entre as unidades da população.

Tipos de Variáveis

- **Variáveis Qualitativas ou Categóricas**: Quando os possíveis valores assumem atributos ou qualidades. Ex: sexo, cor, escolaridade, doença, condição do ar, condição da água, etc.

- **Variáveis Quantitativas ou de Medidas:** Quando seus valores são expressos em números. Ex: altura, peso, número de filhos, pH, concentração do reagente, etc .

Especificando os tipos de variáveis

As variáveis qualitativas podem ser classificadas ainda como:

- Ordinais: quando o atributo tem uma ordenação natural, indicando intensidade crescente de realização. Ex: grau de escolaridade, classe social, condição do ar, condição da água,estado clínico, etc.
- Nominais: quando o atributo não se estabelece ordem. Ex: sexo, cor, raça, doença, etc.

Já as variáveis quantitativas podem ser:

- Discretas: resultantes de contagens, assumindo assim, em geral valores inteiros. Ex: número de filhos, número de peças defeituosas, nº de pessoas doentes na região, etc.

- Contínuas: assumem valores em intervalos de números reais e geralmente, são provenientes de uma mensuração. Ex: peso, altura, pH,concentração do reagente, etc..

Resumo geral: tipo de variável

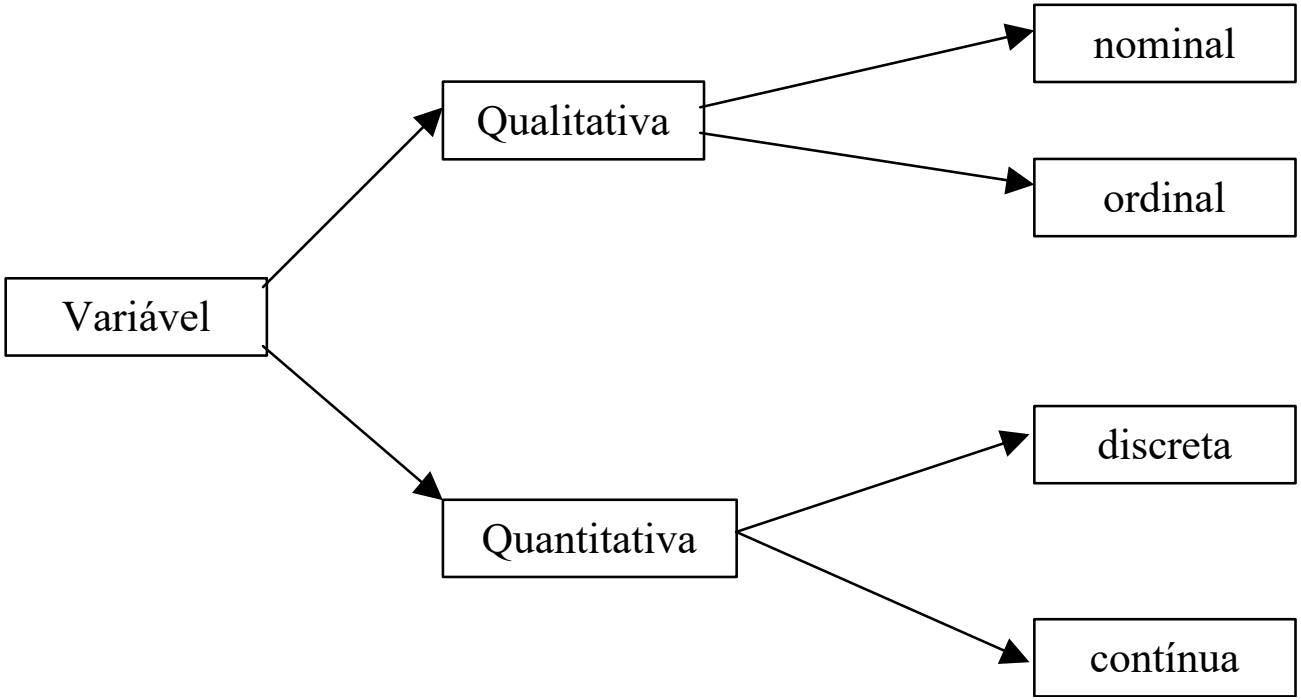

Apresentação dos dados em tabela

Tabela 1.1: Número de Nascimentos segundo o sexo

Sexo	Freqüência
Masculino	10
Feminino	8
Total	18

Fonte: E.W.

Para efeito de comparação: Tabela de freqüência relativa

Tabela 1.2: Número de Nascimentos segundo sexo.

Sexo	Freqüência	Freqüência relativa(%)
Masculino	10	55,56%
Feminino	8	44,44%
Total	18	100,00%

Fonte: E.W.

Tabelas de distribuição de freqüência.

Quando os dados são quantitativos contínuos, não conseguimos resumir a informação da mesma forma anterior. Neste caso precisamos organizar os dados em uma tabela de distribuição de freqüências. Veja os dados abaixo,

Tabela 1.7: Peso ao nascer de nascidos vivos, em quilogramas

2,522	3,200	1,900	4,100	4,600	3,400
2,720	3,720	3,600	2,400	1,720	3,400
3,125	2,800	3,200	2,700	2,750	1,570
2,250	2,900	3,300	2,450	4,200	3,800
3,220	2,950	2,900	3,400	2,100	2,700
3,000	2,480	2,500	2,400	4,450	2,900
3,725	3,800	3,600	3,120	2,900	3,700
2,890	2,500	2,500	3,400	2,920	2,120
3,110	3,550	2,300	3,200	2,720	3,150
3,520	3,000	2,950	2,700	2,900	2,400
3,100	4,100	3,000	3,150	2,000	3,450
3,200	3,200	3,750	2,800	2,720	3,120
2,780	3,450	3,150	2,700	2,480	2,120
3,155	3,100	3,200	3,300	3,900	2,450
2,150	3,150	2,500	3,200	2,500	2,700
3,300	2,800	2,900	3,200	2,480	
3,250	2,900	3,200	2,800	2,450	

Fonte: IBGE

Exemplo de tabela de distribuição de freqüência.

Tabela 1.9: Peso de recém nascidos.

Classe	Ponto médio	Freqüência
1,5 |--- 2,0	1,750	3
2,0 |--- 2,5	2,250	16
2,5 |--- 3,0	2,750	31
3,0 |--- 3,5	3,250	34
3,5 |--- 4,0	3,750	11
4,0 |--- 4,5	4,250	4
4,5 |--- 5,0	4,75	1

Numa tabela de distribuição de freqüência também podem ser apresentados os pontos médios de classe. O ponto médio é dado pela soma dos extremos de uma classe, dividida por 2. Para a classe 1,5 |--- 2,0, o ponto médio é: (1,5+2)/2=1,75.

Exemplo de tabela de distribuição de freqüência.

Tabela 1.9: Peso de recém nascidos.

Classes Pesos	Ponto Médio	freq.	freq. relativa	freq. absoluta	freq. acumulada	proporção
	x_i	n_i	$f_i = \frac{n_i}{n}$	Fab	Fac	f_i X 100%
1.5 ⊢ 2.0	1.750	**3**	0,03	**3**	0,03	**3%**
2.0 ⊢ 2.5	2.250	**16**	0,16	**19**	0,19	**16%**
2.5⊢ 3.0	2.750	**31**	0,31	**50**	0,5	**31%**
3.0 ⊢ 3.5	3.250	**34**	0,34	**84**	0,84	**34%**
3.5 ⊢ 4.0	3.750	**11**	0,11	**95**	0,95	**11%**
4.0 ⊢ 4.5	4.250	**4**	0,04	**99**	0,99	**4%**
4.5 ⊢ 5.0	4.750	**1**	0,01	**100**	1	**1%**
Total		**100**	1			**100%**

Cálculo da amplitude de classes

- Ordenar os dados
- Intervalo da amostra= Maior valor – menor valor
- Número de classes = raiz de n = $\sqrt{Tamanho\ da\ amostra}$
- Amplitude = $\dfrac{Intervalo\ da\ amostra}{Número\ de\ classes}$
- Construir os intervalos = limite inferior + amplitude

Análise Exploratória de Dados
Estatística Descritiva 2

- Representação Gráfica de Dados

Gráfico de Setores ou Pizza.

Usado para representar variáveis qualitativas, quando os dados apresentam poucas características.

Figura1.1: Fonte de Emissão de CO na RMSP-2003.

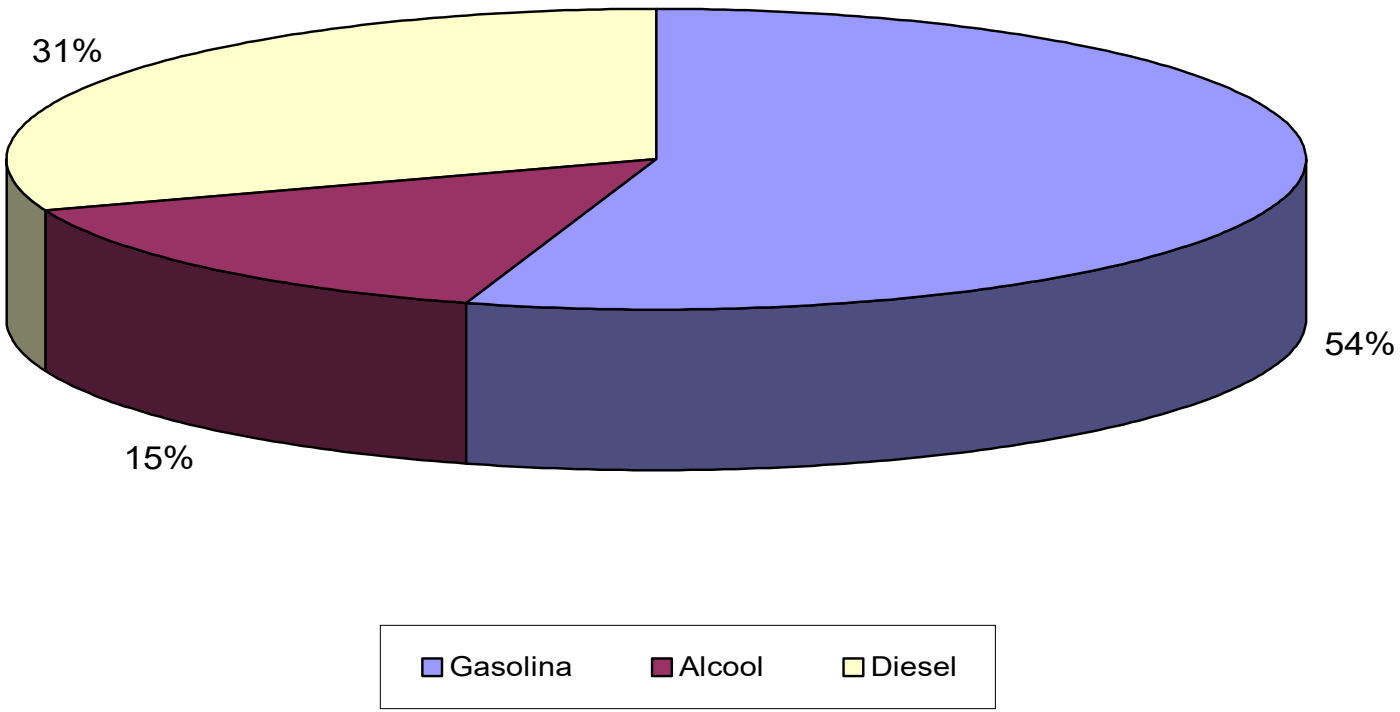

Gráficos de pizza

Para fazer gráficos de pizza a função `pie`.

```
> pie(c(1,5,7,10))
```

Veja os exemplos de gráficos de pizza

```
> example(pie)
```

Gráfico de Barras.

Gráfico de barras bastante usado com variáveis qualitativas e quantitativas discretas. Ideal para quando temos várias classes de categorias.

Figura 1.2: Distribuição das reclamações via 0800.

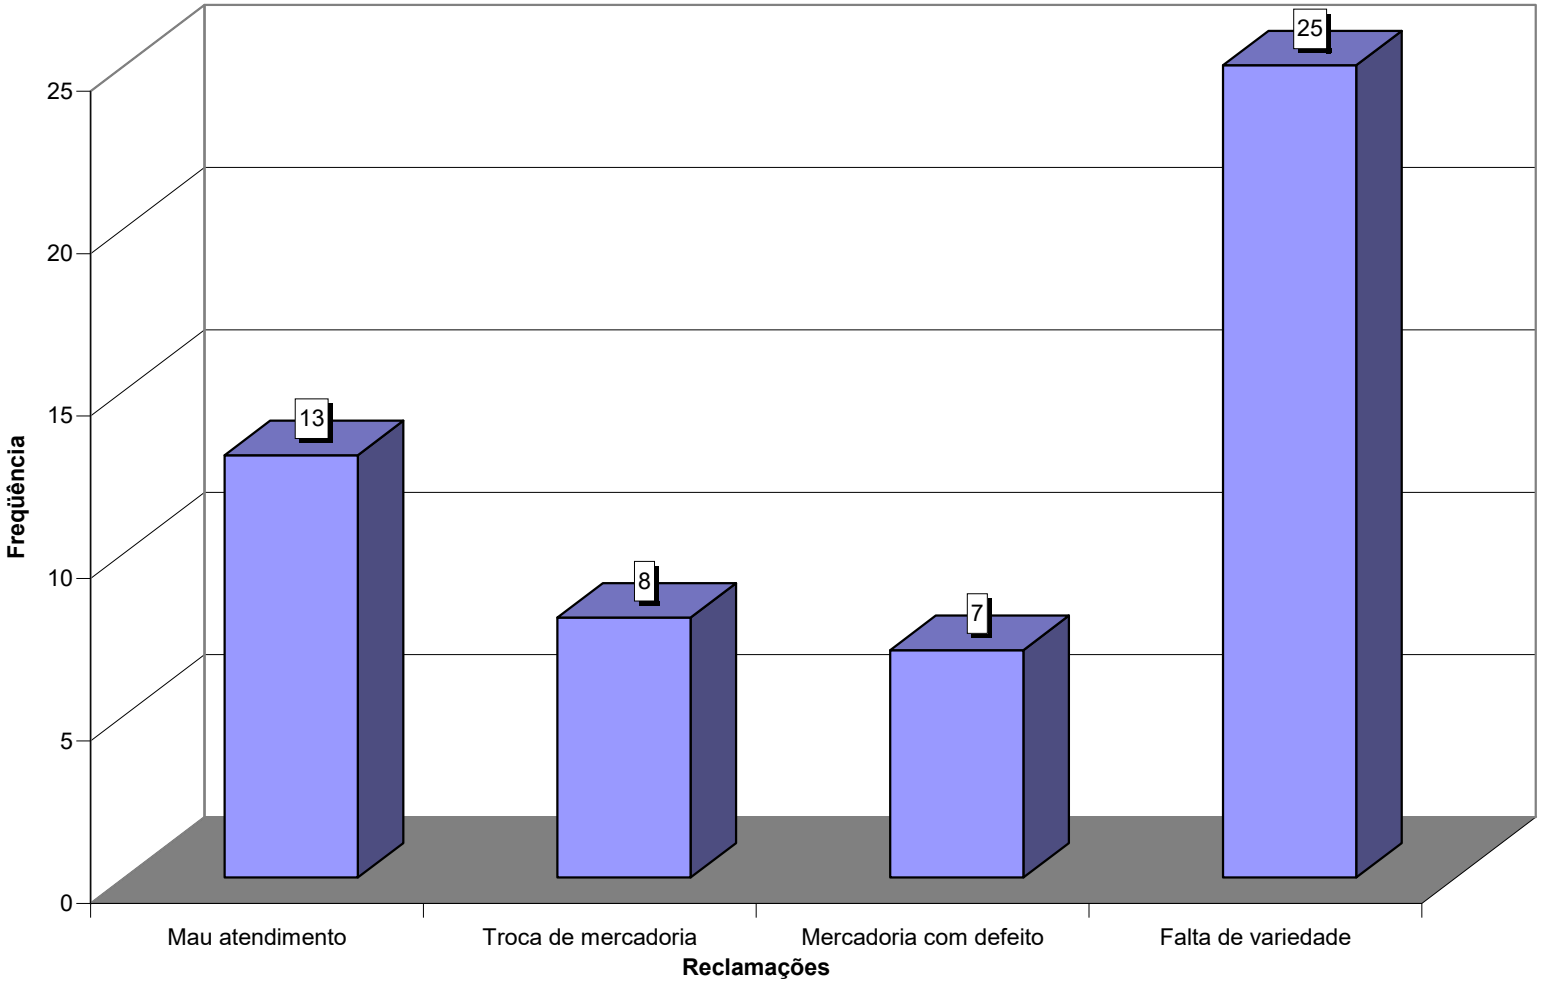

Gráficos de barras

Para fazer gráficos de barras no R a função é `barplot`.

```
> barplot(sample(10:100,10))
```

Veja os exemplos de gráficos de barras:

```
> example(barplot)## clique na janela do gráfico para ir passando os exemplos.
```

TABELA 2.1: DADOS DOS PROFESSORES E ALUNOS MATRICULADOS EM ESCOLAS DO MUNICÍPIO DE NITERÓI EM 2009.

Escola de Ensino Fundamental	Matrículas de professores	Matrícula de alunos
Privada	1751	25280
Pública Estadual	1186	21328
Pública Municipal	947	18432
Pública Federal	29	280

Fonte:www.ibge.com.br

O primeiro passo na construção do gráfico é ter os dados armazenados em objeto apropriado. No caso de gráfico de barras é necessário que os dados estejam armazenados em um vetor ou matriz.

```
prof<-c(1751,1186,947,29)
```

Vamos nomear cada barra:

```
escola<-c("privada","estadual","municipal","federal")
barplot(prof, names.arg=escola)
```

Gráfico dos Professores

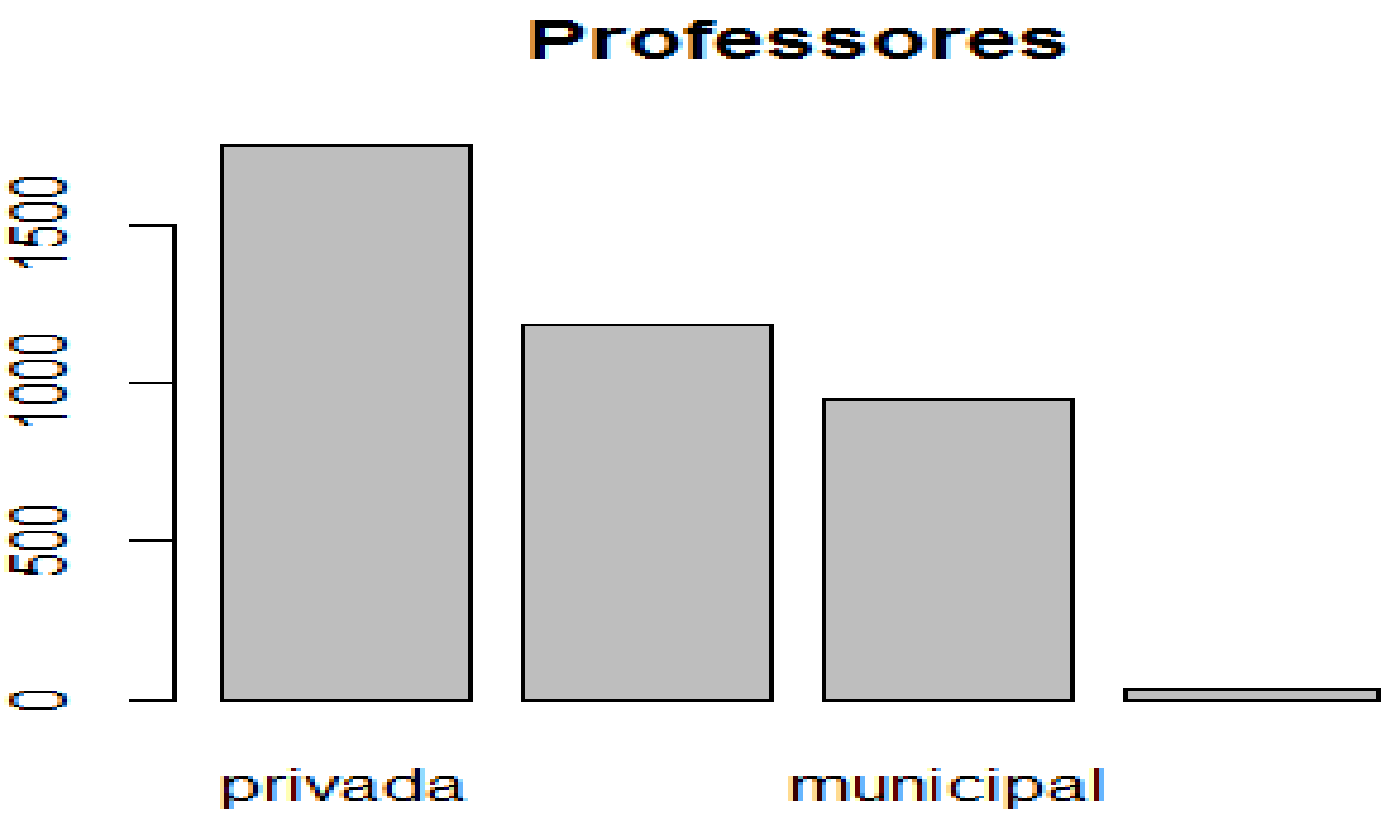

Ramo e folhas

- O gráfico de ramo e folhas é uma representação gráfica dos números que permite organizar os dados de forma a chamar a atenção para algumas características do conjunto de dados. São elas: forma da distribuição (**simetria/assimetria**), **dispersão** dos dados e existência de **outliers.**

- O gráfico de ramo e folhas possui muita semelhança com o histograma, porém possui a vantagem de exibir o formato da distribuição sem que haja perda de informação. A desvantagem do ramo-e-folhas está no fato de ser um gráfico que deve ser utilizado com **conjuntos dados de pequena dimensão**.

Ramo e folhas

Na sua construção, cada observação é dividida em duas partes:

- **Ramo**
- **Folhas**

The decimal point is at the |

```
 4 | 0637
 6 | 379446
 8 | 15791388
10 | 5816
12 | 08268
14 | 77
16 | 0263
18 | 84
20 |
22 | 3
```

> stem(x)

Disposição Ramo e folhas

3	2					
4	3					
5	1	4	9			
6	0	1	3	5	8	9
7	0	1	3	5	6	
8	0	2	7			
9	3					

Horizontal

			9			
			8	6		
			5	5		
		9	3	3	7	
		4	1	1	2	
2	3	1	0	0	0	3
3	4	5	6	7	8	9

Vertical

Histograma

O histograma é a representação gráfica para variáveis quantitativas contínuas. Este tipo de representação mostra a forma da distribuição da variável. É de fundamental importância na aplicação dos conceitos de inferência estatística

Figura 1.3: Histograma do Peso Recém Nascido.

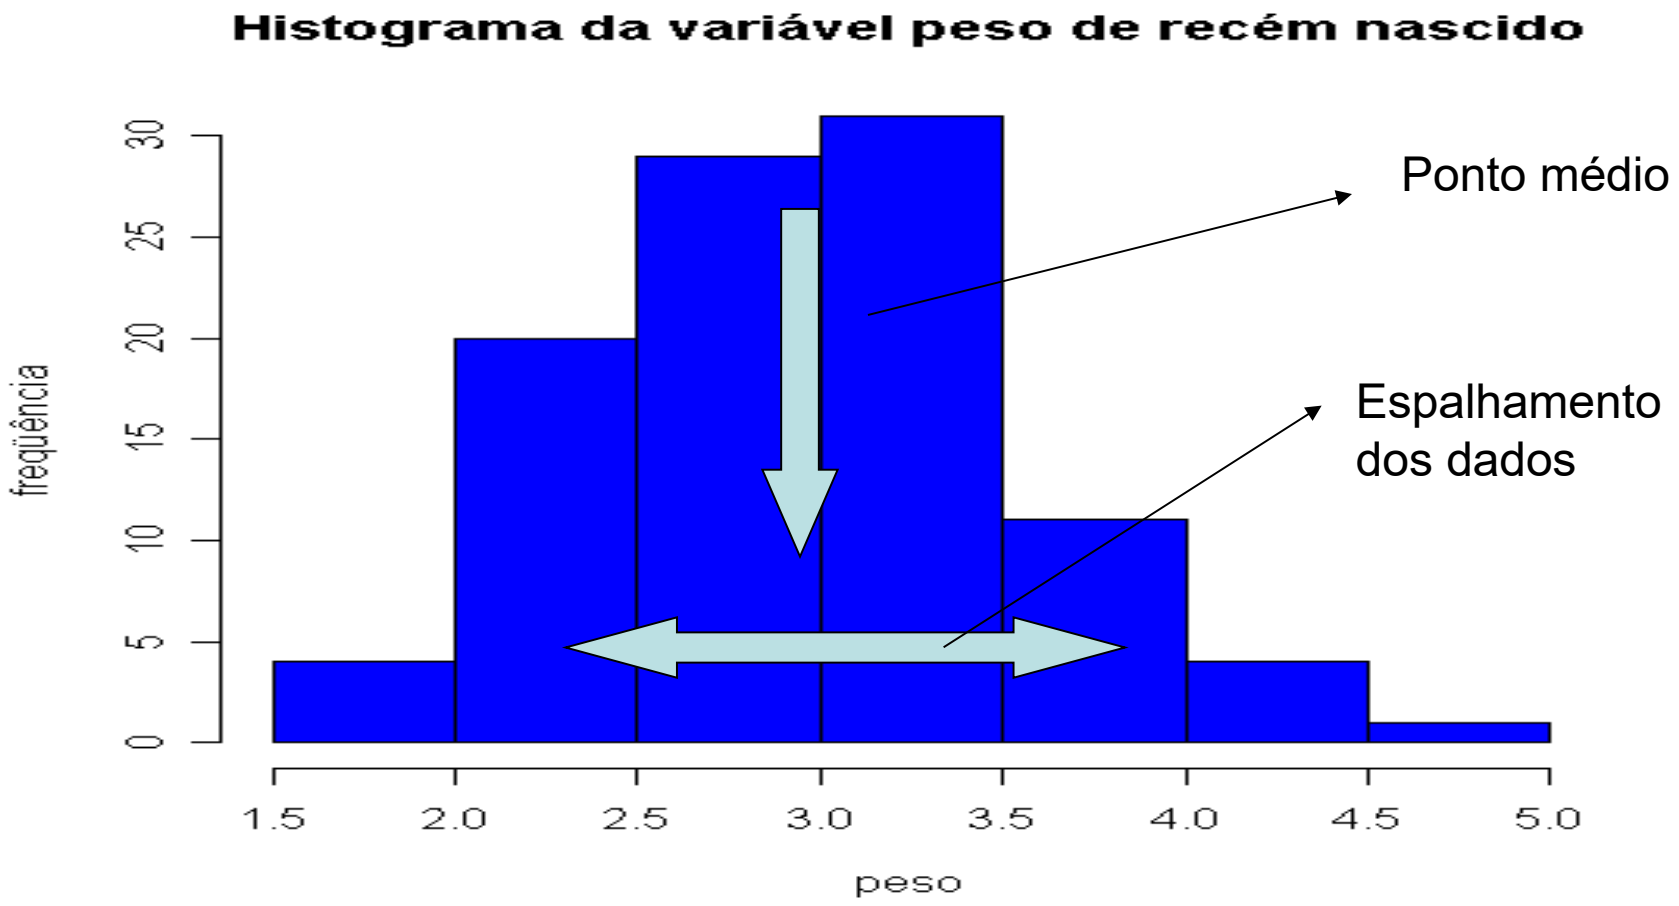

Gráfico Histograma

Gere 50 observações com distribuição normal, média 10 e variância 5, e faça os gráficos de diagnósticos: Histograma, boxplot e de normalidade. Os gráficos devem ser colocados em uma janela gráfica com 1 linhas e 3 colunas.

A função para gerar *n* valores com distribuição normal com média *m* e desvio padrão *dp*, é definida como:

rnorm(n,m,dp)

onde: n é o número de observações

m a média e

dp o desvio padrão.

Solução:

```
y <- rnorm(50,10,sqrt(5)); y
par(mfrow=c(1,3))
hist(y); boxplot(y);;qqnorm(y)
```

Gráfico Histograma

- **Histograma simétrico**,

  tipo distribuição Normal:

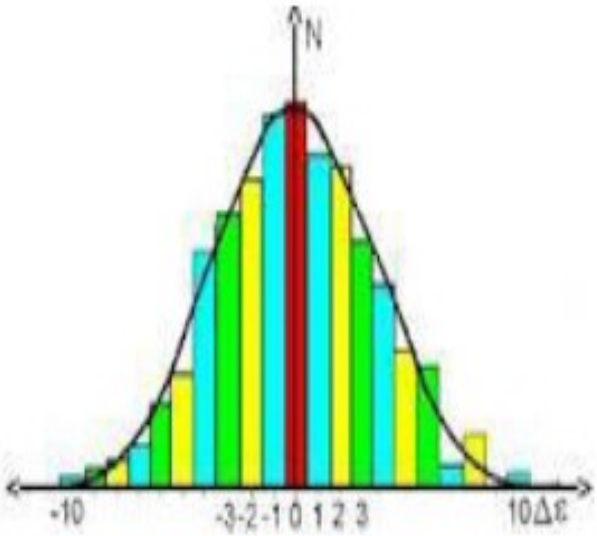

- **Histograma assimétrico**

  com apenas um pico:

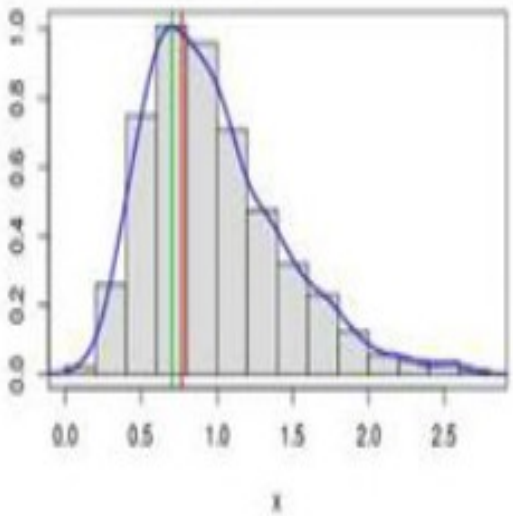

Ferramenta de diagnóstico – avaliação do comportamento da variável

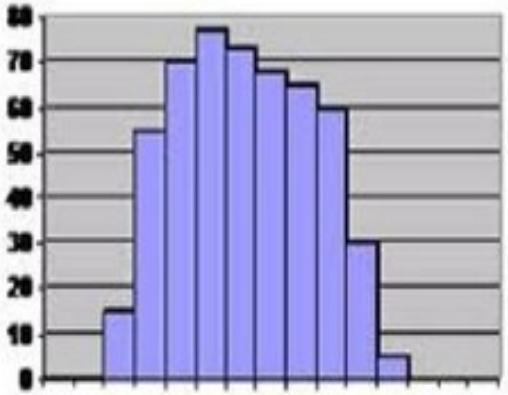

Histograma do tipo "platô":

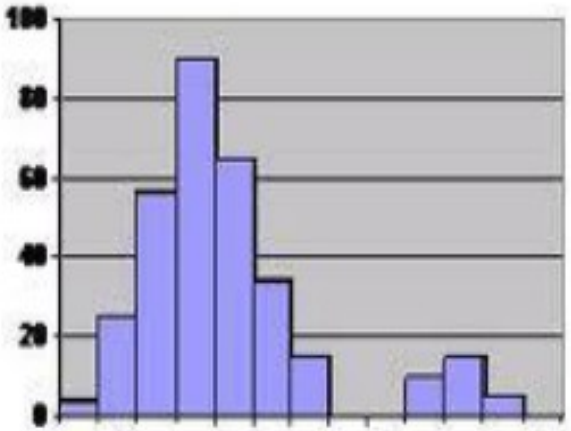

Histograma com uma pequena "ilha" isolada

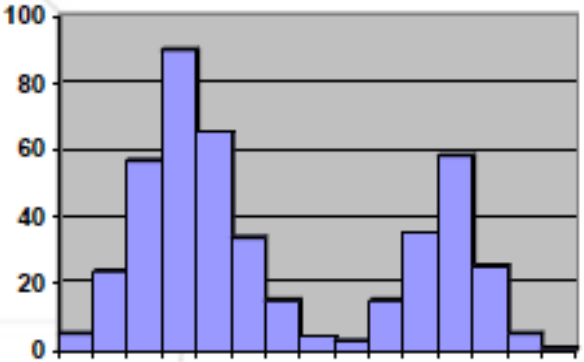

Histograma com dois picos:

Box Plot

A linha central marca a mediana do conjunto de dados;

A parte inferior da caixa é delimitada pelo primeiro quartil (*Q1) e a parte superior*

pelo terceiro quartil (*Q3);*

Podemos, com isso, verificar também o intervalo interquartil dado pela diferença

entre o primeiro e o terceiro quartil (*DIQ= Q3 – Q1);*

As hastes inferiores e superiores se estendem, respectivamente, do quartil inferior

até o menor valor não inferior a *Q1 – 1.5 DIQ e do quartil superior até o maior*

valor não superior a *Q3 + 1.5 DIQ;*

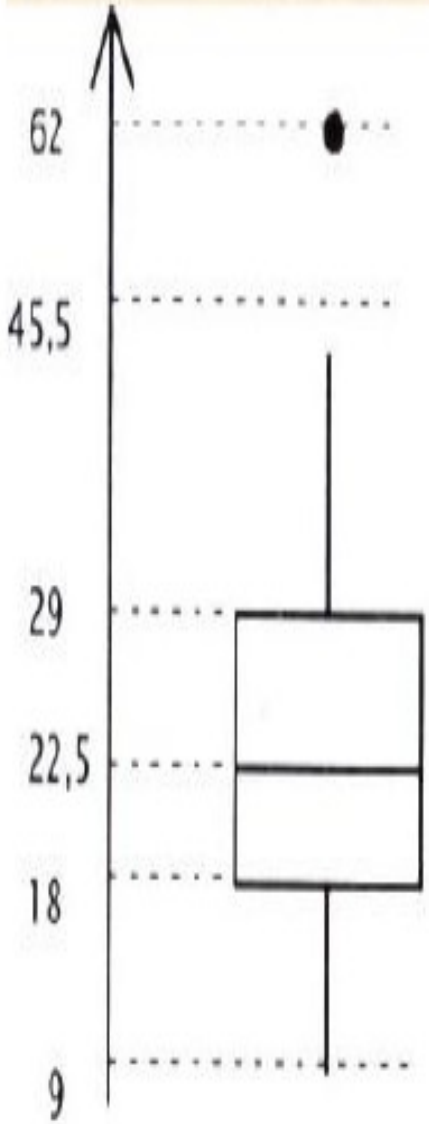

Box Plot

Os valores inferiores a *Q1–1.5 DIQ e superiores a Q3+1.5 IQR são representados* individualmente no gráfico sendo estes valores caracterizados como outliers, ou seja, que estão fora do intervalo *Q1 – 1.5 IQR < valor < Q3 + 1.5 DIQ;*

As quantidades *Q1 – 1.5 DIQ e Q3 + 1.5 DIQ delimitam as cercas inferior e* superior, respectivamente, e constituem limites para além dos quais, como visto, os dados passam a ser considerados ***outliers.***

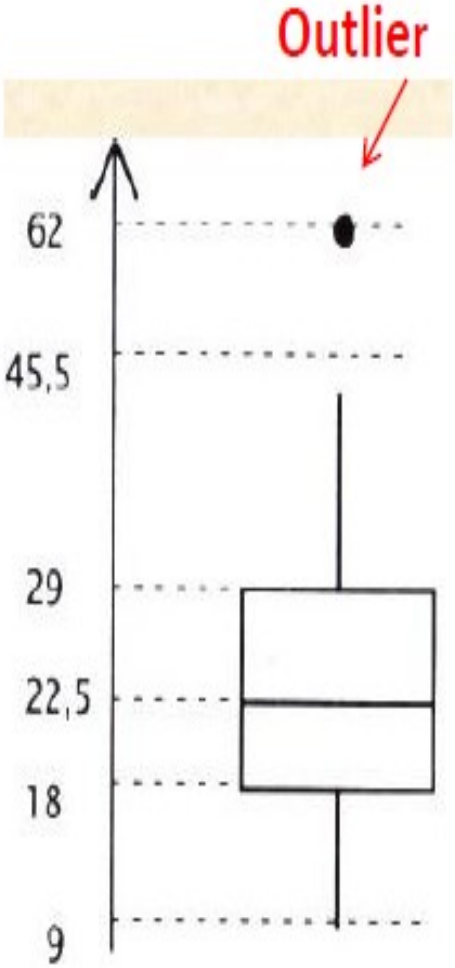

Box plot x Histograma

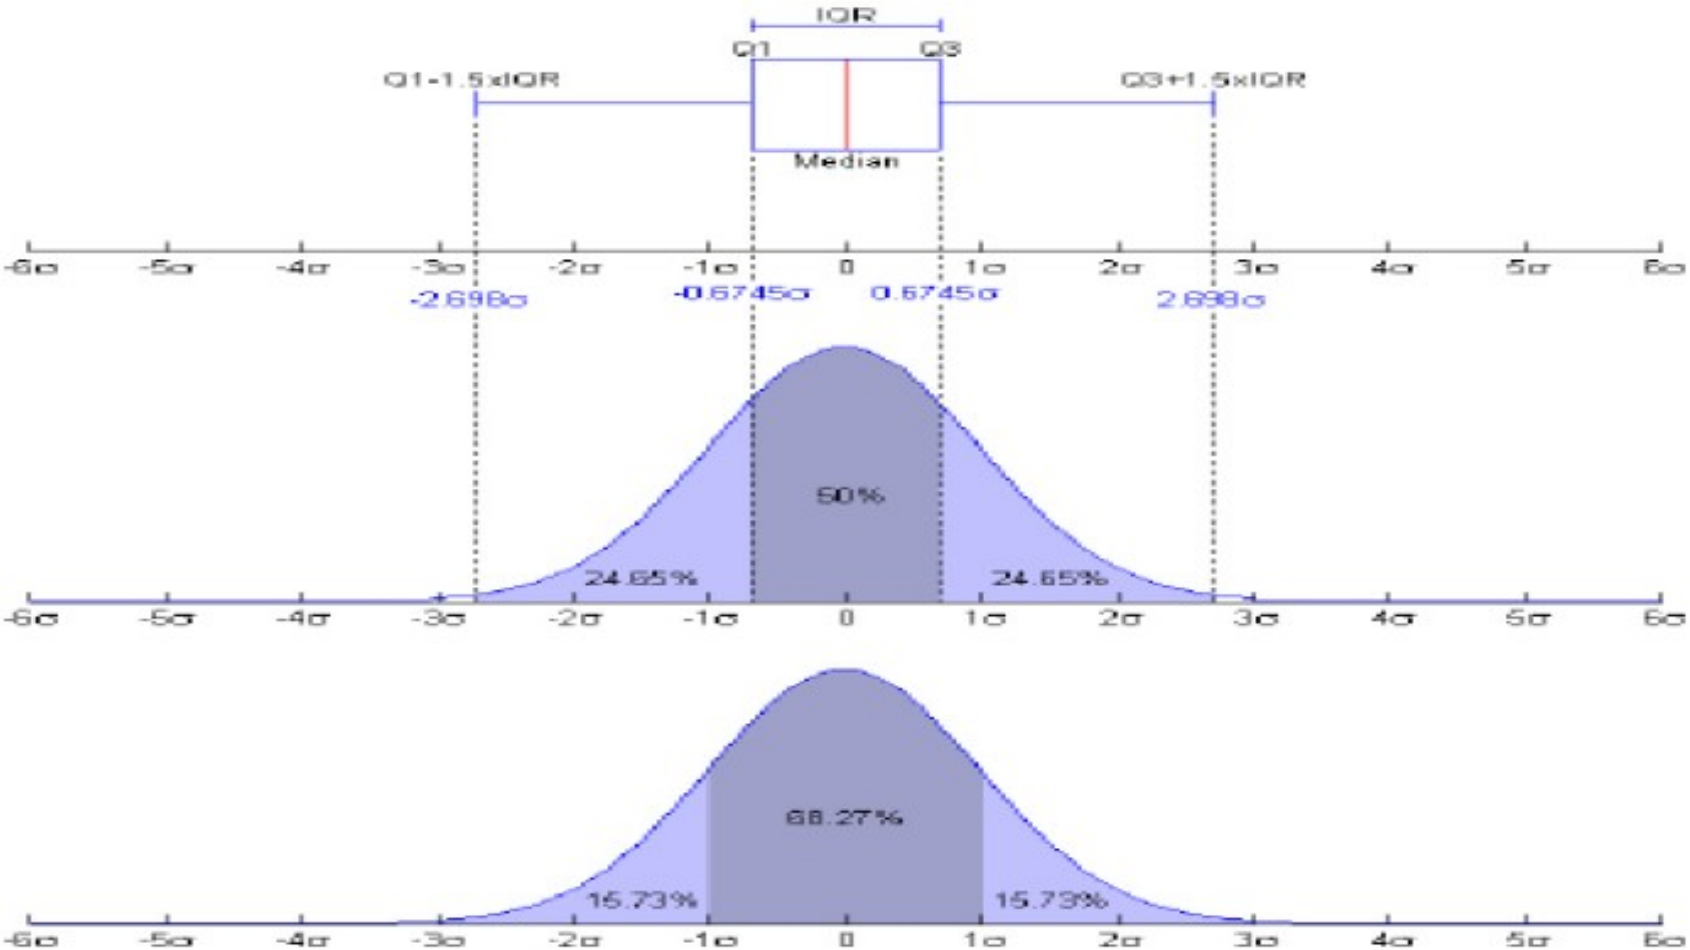

Interpretação do gráfico de caixas (boxplot)

Interpretação do box plot

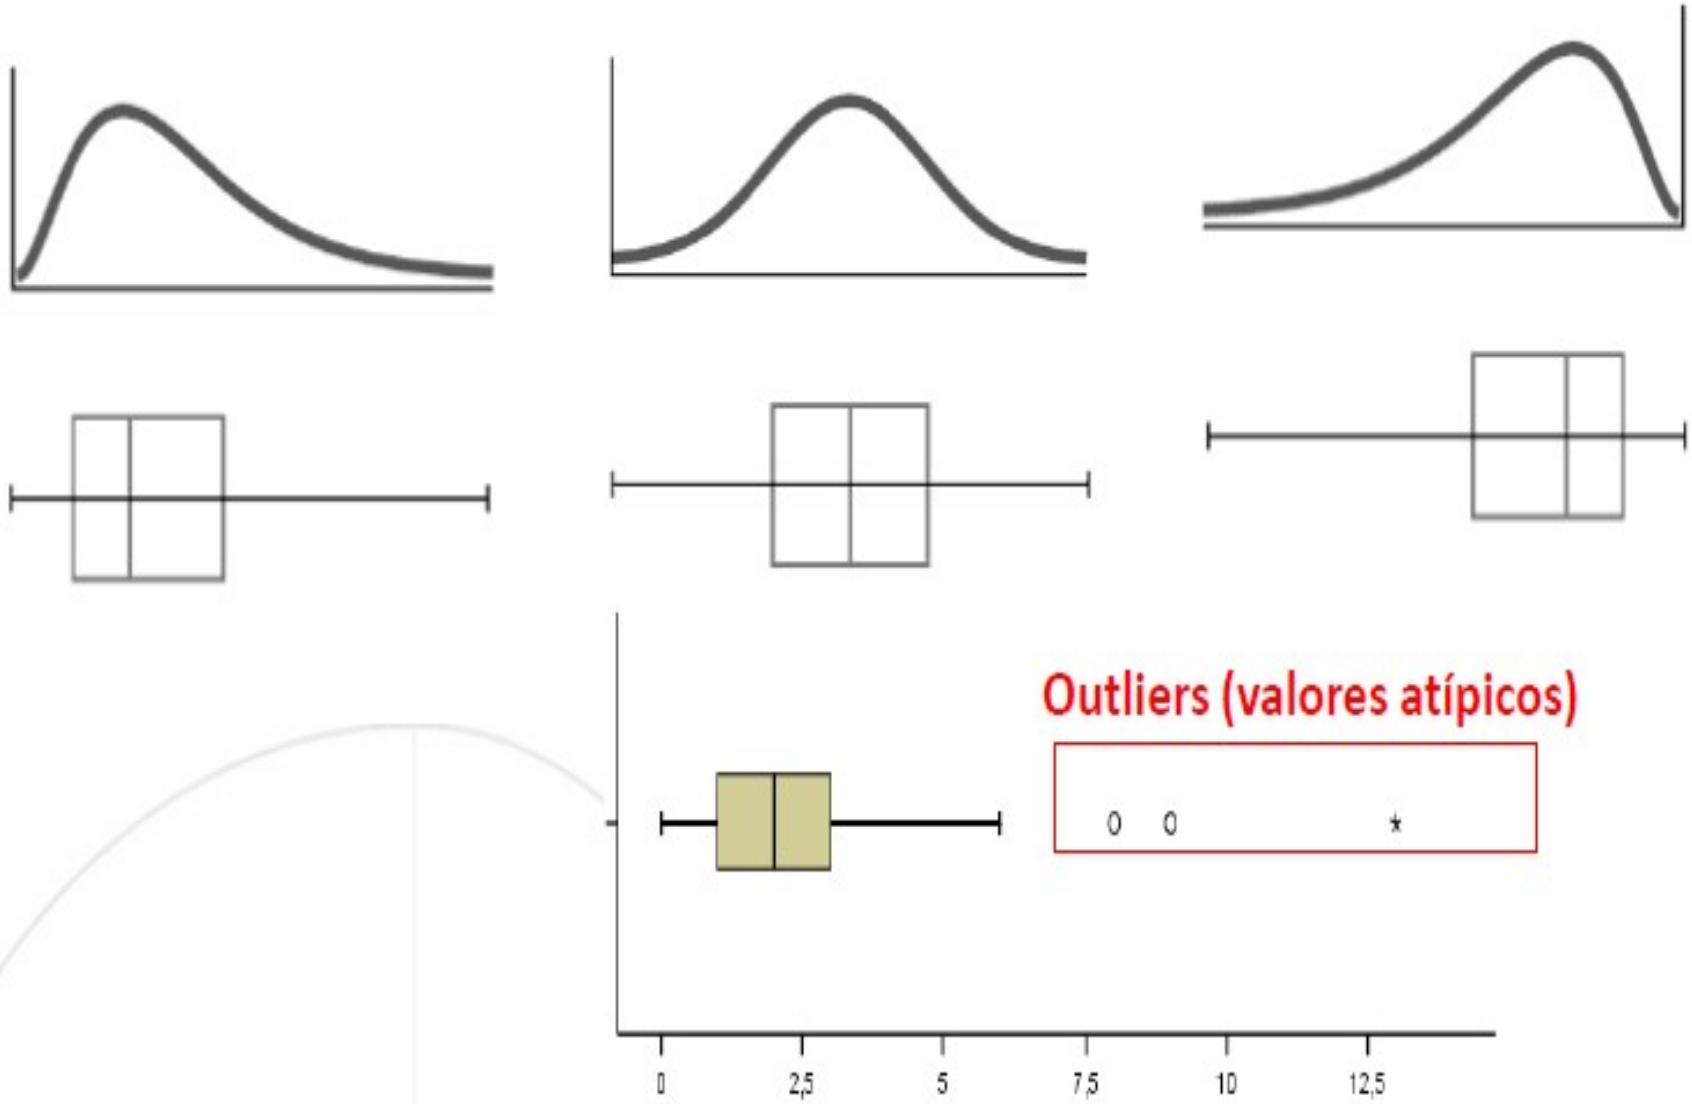

Diagramas de Dispersão

Quando temos dados emparelhados e desejamos verificar de existe uma associação entre esses dados, usamos como análise preliminar o diagrama de dispersão.

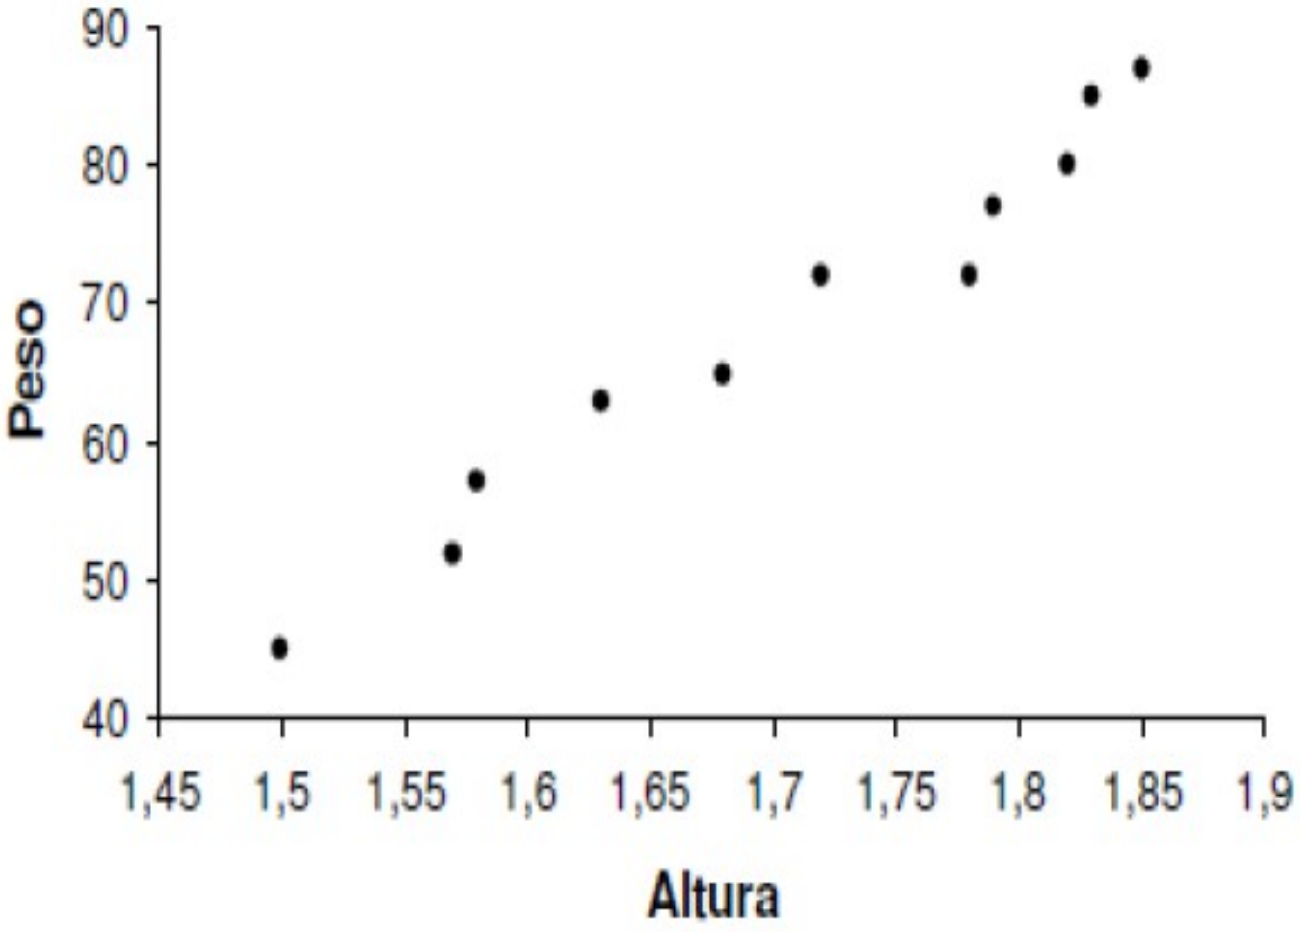

Gráfico de pontos (gráficos de dispersão)

Gráficos com variáveis numéricas

Primeiro vamos inserir os dados de duas variáveis numéricas. Lembre que a forma mais simples de inserir dados no R é usando a função de concatenar dados "c".

```
> y<-c(110,120,90,70,50,80,40,40,50,30)
> x<-1:10
```

y geralmente é a letra usada em livros texto para indicar a variável resposta, a que aparece no eixo Y. Apesar de não ser uma norma, colocar a variável resposta no eixo y (vertical) dos gráficos é um consenso entre a maioria dos estatísticos, daí a letra y para dados resposta. x é chamada de variável independente e aparece no eixo x (horizontal).

É extremamente simples fazer um gráfico de pontos de y contra x no R. A função utilizada é `plot()` e precisa de apenas dois argumentos: o primeiro é o nome da variável do eixo X, o segundo é o da variável do eixo Y.

```
> plot(x,y)
```

Análise Exploratória de Dados

Estatística Descritiva 3

Medidas de Centralidade.

Medidas de Posição.

Medidas de Centralidade

- **Média Aritmética** de um conjunto de valores é o valor obtido somando-se todos eles e dividindo-se o total pelo número de valores.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Exemplo 1: Os valores em gramas referentes aos pesos de recém nascidos de uma pequena cidade em um dia específico foram: 2500, 2350, 3400, 3280, 2650, 4010 e 2910.

Assim o peso médio é calculado como:

$$\bar{x} = \frac{2500 + 2350 + ... + 2910}{7} = \frac{21100}{7} = 3014{,}28$$

Medida descritiva de tendência central **(média)**

- #sintaxe:
- > mean(dados)
- #Exemplo:
- > x <- c(10, 14, 13, 15, 16, 18, 12)
- > mean(x)
- [1] 14

Medidas de Centralidade

Se os dados apresentam observações extremas, a média pode não ser a medida mais indicada para centralidade, pois sobre influência direta de observações extremas. Por exemplo:

Em uma pesquisa sobre salário de um Tecnólogo em Química Fármaco Industrial observamos os seguintes valores: $1000,00; $1200,00; $1800,00; $2500,00; $2700,00 ; $3200,00 e $15000,00

A média é: **3914,28.** Essa medida é representativa para este conjunto de dados.

Solução: O uso da mediana.

Mediana (Me) é o valor que divide a amostra ou população em duas partes iguais.

Para o exemplo, **Me = $2500,00**

Medidas de Centralidade

Figura 2.1 : Salários dos Tecnólogos

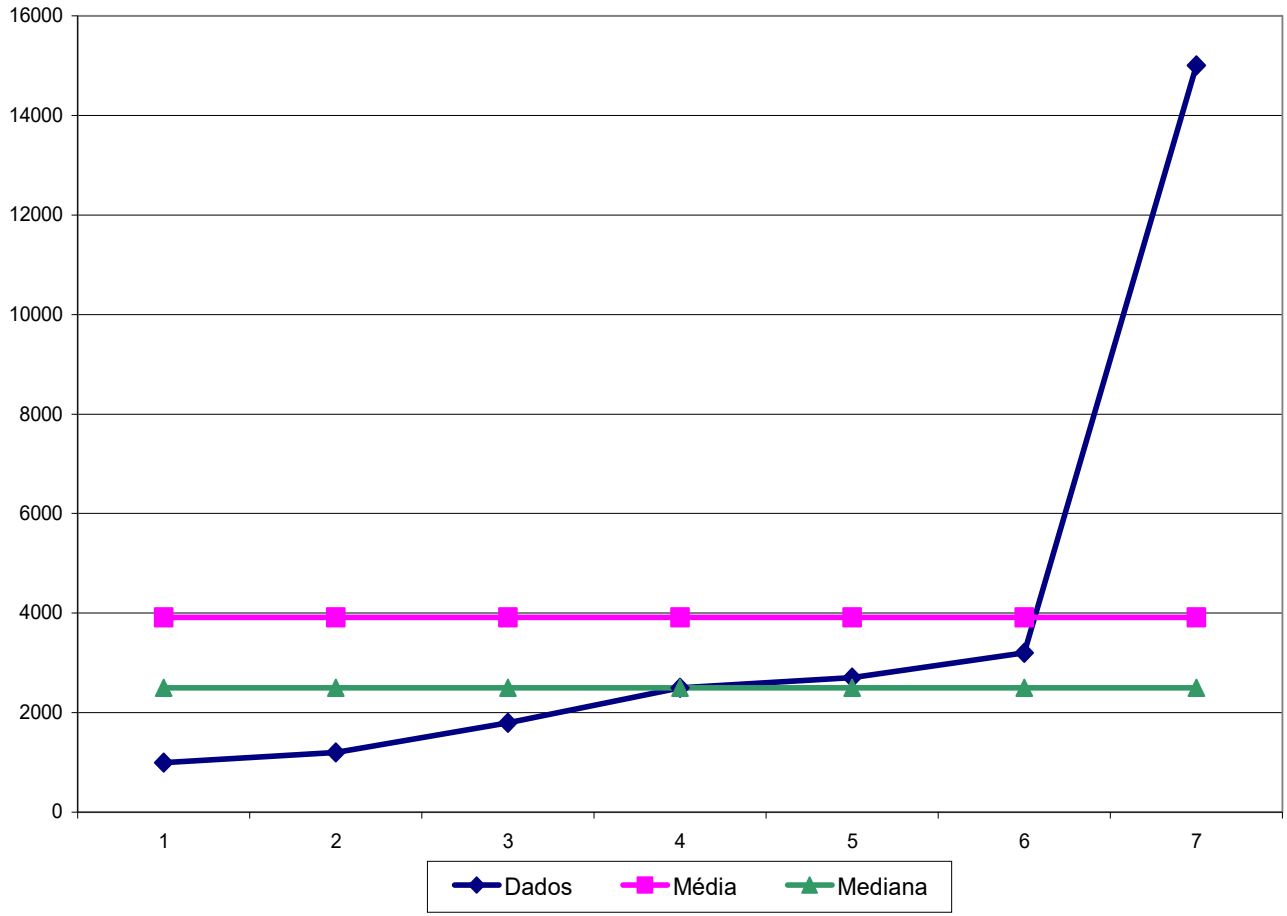

Medidas de Centralidade

Como calcular a mediana?

Se o número n de observações na amostra ou população for impar, então a mediana será o elemento de ordem $\frac{n+1}{2}$, ou seja :

$$Me = x_{\left(\frac{n+1}{2}\right)}$$

Se o número for de ordem par, então a mediana será a média entre os elementos centrais ou seja:

$$Me = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}$$

Exemplos para o cálculo da Mediana:

Serie 1: 12, 124, 32, 10, 18, 29 e 100 n= 7; impar

Ordenar : 10, 12, 18, 29, 32, 100 e 124.

$$Me = x_{\left(\frac{n+1}{2}\right)} = x_{(4)} = 29$$

Serie 2: 12, 124, 32, 10, 18 e 29 n= 6; par.

Ordenar : 10, 12, 18, 29, 32, 124.

$$Me = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} = \frac{x_{(3)} + x_{(4)}}{2} = \frac{18+29}{2} = 23.5$$

Medida descritiva de tendência central (mediana)

Medida descritiva de tendência central (mediana)

#sintaxe:

```
> median(dados)
```

#Exemplo: Tomando os exemplos acima para simples conferência, obteremos:

```
> k <- c(1,3,0,0,2,4,1,2,5)
> median(k)
[1] 2
```

Medida descritiva de tendência central **(moda)**

Medida descritiva de tendência central (moda)

```
#Exemplo:
> y <- c(7,8,9,10,10,10,11,12)
> table(y)
y
7 8 9 10 11 12
1 1 1  3  1  1
> subset(table(y),table(y)==max(table(y)))
10
 3
```

Medidas Separatrizes

As medidas de posição possibilitam um melhor entendimento dos dados, focalizando sua posição relativa em relação ao conjunto como um todo.

Mediana: divide os dados ordenados em duas partes iguais.

Quartis: Dividem os dados ordenados em 4 partes iguais.

Decis: Dividem os dados ordenados em 10 partes iguais.

Percentis: Dividem os dados ordenados em 100 partes iguas.

Medidas Separatrizes

Calculando o percentil (medida geral)

Ordenar a série de n observações em ordem crescente de valores, definimos como **0%** à posição de ordem **1** e **100%** a observação de ordem **n**. Portanto uma observação com ordem **x** terá uma posição **p**.

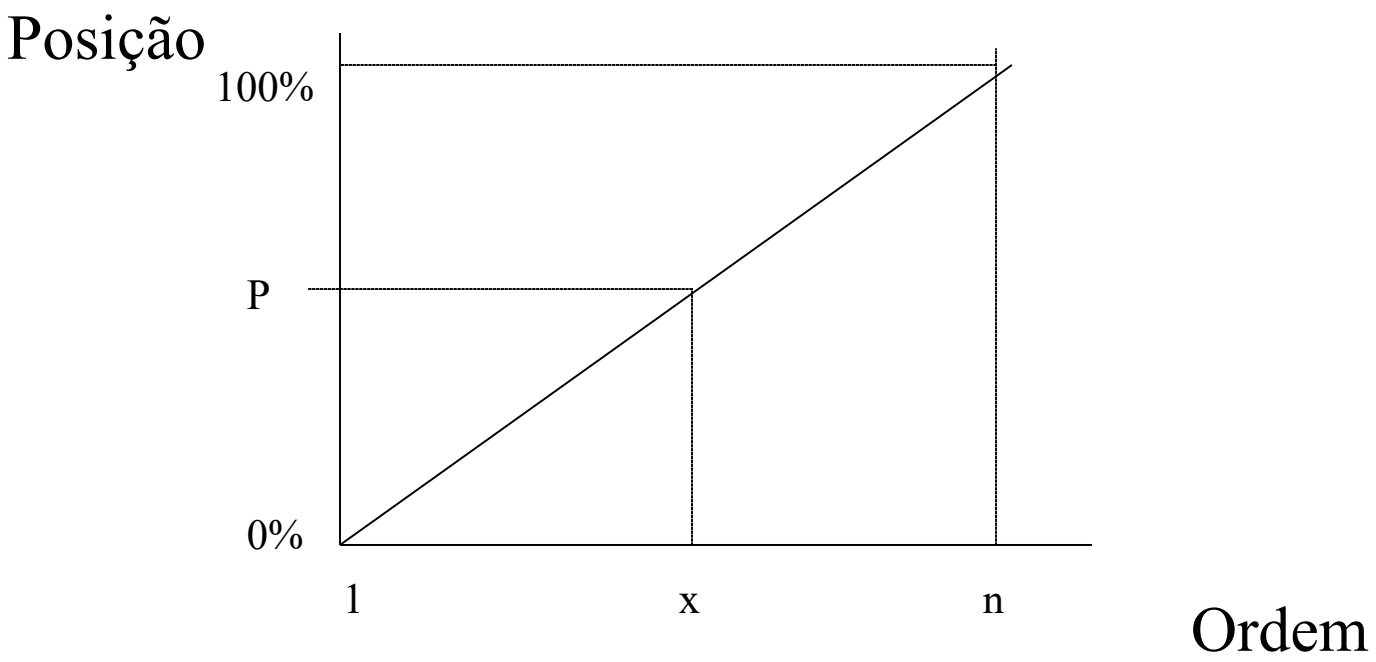

Medidas Separatrizes

- Usando a semelhança de triângulos, vamos ter:

$$\frac{n-1}{100-0} = \frac{x-1}{P-0}$$

n : número total de observações na série.

x : é a ordem de uma determinada observação.

P : é o percentil dessa observação.

$$P = \frac{x-1}{n-1} * 100\%$$

$$x = (n-1) * \frac{P}{100} + 1$$

Medidas Separatrizes: Exemplo1.

Série de	27	32	64	65	58	62	59	54	29	30	26	48	47
Dados	46	43	38	29	32	35	37	31	43	45	42	37	36

Calcular o valor da observação para o percentil P = 32%.

Primeiro Passo: Ordenar os dados.

Série	26	27	29	29	30	31	32	32	35	36	37	37	38
Ordem	1	2	3	4	5	6	7	8	9	10	11	12	13
Série	42	43	43	45	46	47	48	54	58	59	62	64	65
Ordem	14	15	16	17	18	19	20	21	22	23	24	25	26

Medidas Separatrizes: Exemplo.

Agora vamos encontrar a ordem x correspondente:

$$x = (n-1) * \frac{P}{100} + 1 = (26-1) * \frac{32}{100} + 1 = 9$$

Portanto o valor na série de ordem x=9 é 35. Ou seja, o valor que separa a série de dados entre os 32% menores valores é 35.

Medida descritiva de posição **(quartis)**

Denominamos quartis os valores de um conjunto que o dividem em quatro partes iguais.

Precisamos, portanto, de três quartis (Q1, Q2 e Q3) para dividir o conjunto em quatro partes iguais.

Medida descritiva de posição **(quartis)**

Veja a figura abaixo:

Observação: o quartil Q2 sempre será igual à mediana da série.

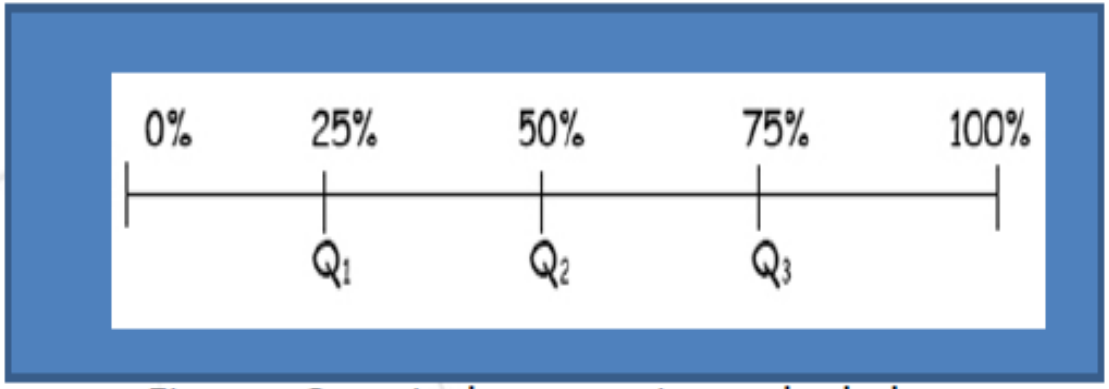

Figura : Quartis de um conjunto de dados

Medidas descritivas de posição **(quartis)**

Exemplo: Calcule os quartis da série:

{5, 2, 6, 9, 10, 13, 15}

```
x <-c(5,2,6,9,10,13,15)
> x
[1]  5  2  6  9 10 13 15
> quantile(x)
  0%  25%  50%  75% 100%
 2.0  5.5  9.0 11.5  15.0
```

Cálculo de Médias

- $$\overline{X} = \frac{\sum_{i=1}^{n} x_i}{n} = \mu$$

- $$\overline{X} = \frac{\sum_{i=1}^{n} x_i . n_i}{n} = \mu$$

- $$\overline{X} = \sum_{i=1}^{n} x_i . f_i = \mu$$

Onde

x_i = i-ésimo elemento da amostra ou o ponto médio da variável contínua.

f_i = i-ésimo elemento da frequência relativa.

n_i = i-ésimo elemento da frequência.

Descritiva 4

Medidas de dispersão.

Medidas de dispersão

Problema:

Uma empresa farmacêutica realiza um teste com dois medicamentos para a mesma finalidade em um grupo de 14 pessoas, sendo que 7 tomaram o medicamento A e as outras 7 o B.O tempo de reação foi anotado para cada individuo:

Tabela 1: Tempo de reação dos medicamentos.

	Tempo de Reação							**Média**
Med.A	15	61	48	16	72	17	16	35
Med.B	35	35	36	34	33	35	37	35

Fonte: E.W.

As médias para os dois grupos são iguais. Qual é o melhor medicamento?

Medida de Dispersão

Só utilizando a média como medida resumo para um conjunto de dados, não vamos ter uma boa representação. Necessitamos de outras medidas para avaliar o grau de variabilidade, ou dispersão dos valores em torno da média. As medidas de dispersão medem a representatividade da média.

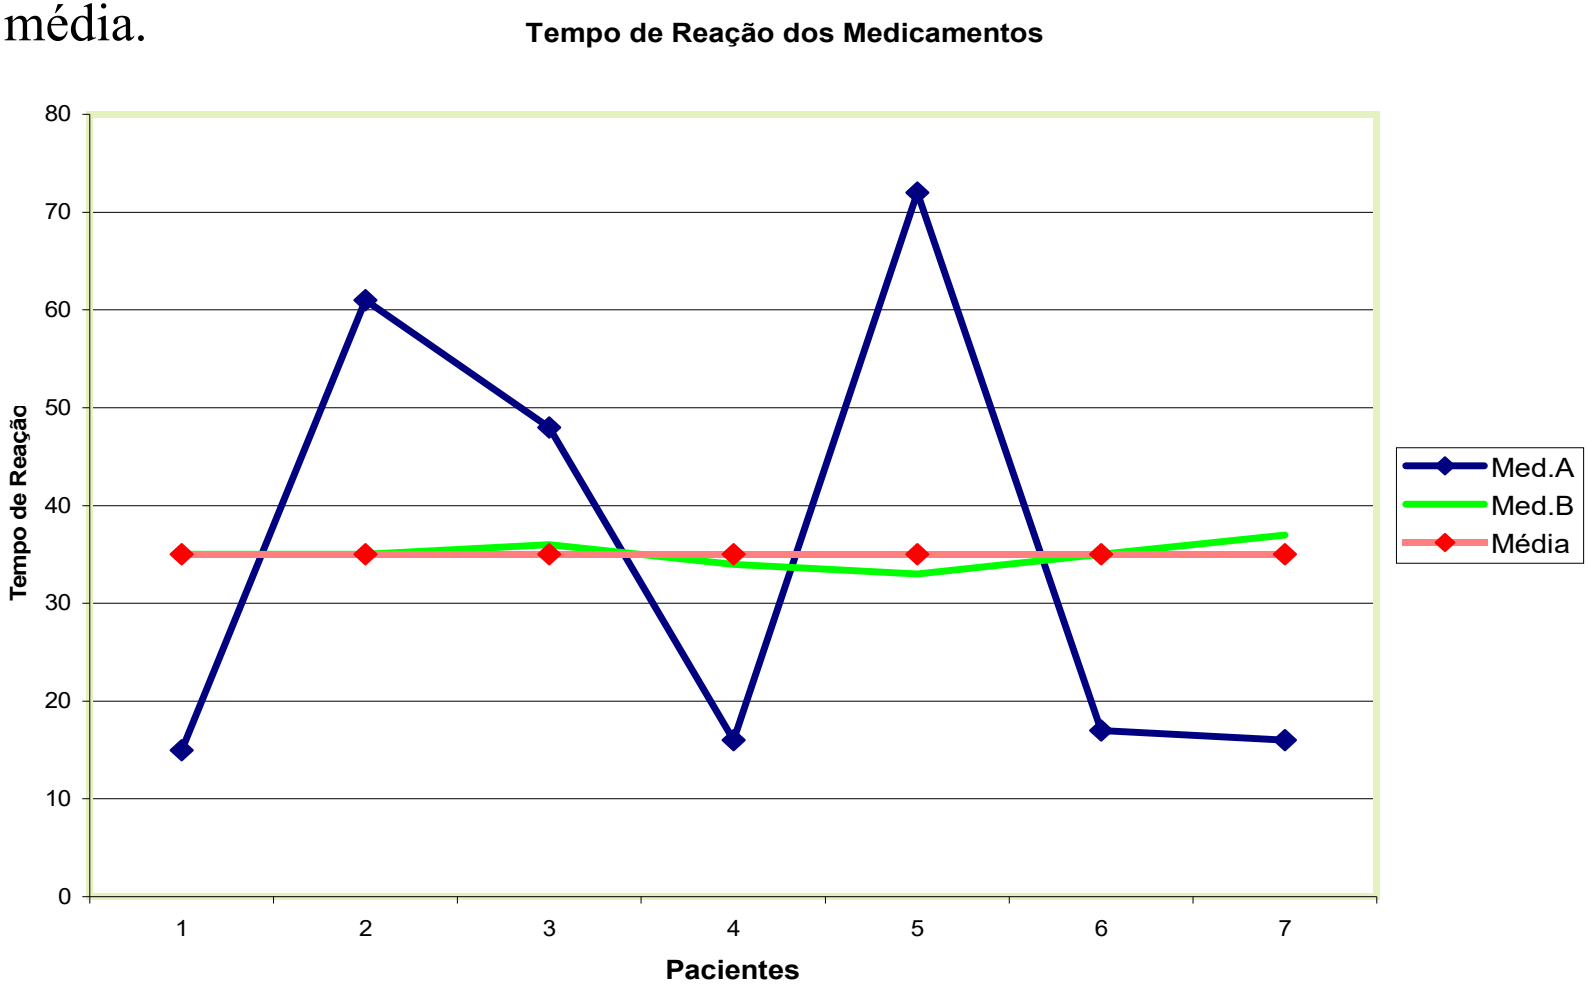

Medidas de Dispersão

- **Amplitude Total:** Diferença entre o maior e menor valor da série de dados. No exemplo temos.

$$\text{MedA}: \quad 72 - 15 = 57$$

$$\text{MedB}: \; 37 - 33 = 4$$

Temos uma idéia da dispersão.

Problema: Depende dos valores extremos.

Não é avaliada a dispersão dos **valores internos**.

Medida descritiva de variabilidade **(amplitude)**

É a diferença entre o maior e menor dos valores do conjunto.

Ou seja:

$$A = xmax - xmin$$

#Sintaxe:

```
> max(dados)
> min(dados)
```

Medidas de Dispersão

Os desvios de uma série de dados com relação a média são dados por :

$$x_i - \bar{x}\,, \quad \text{onde} \quad i = 1,2,\ldots,n.$$

Portanto o desvio médio seria uma boa taxa de dispersão entre os dados. No entanto:

$$\sum_{i=1}^{n} (x_i - \bar{x}) = 0$$

Medidas de Dispersão.

Confirmando o resultado.

Med.A	
x_i	$(x_i - \bar{x})$
15	-20
61	26
48	13
16	-19
72	37
17	-18
16	-19
Soma	0

Med.B	
x_i	$(x_i - \bar{x})$
35	0
35	0
36	1
34	-1
33	-2
35	0
37	2
Soma	0

Medidas de Dispersão.

Ainda utilizando os desvios, mas agora ao quadrado chegamos a variância.

Variância Amostral: Quando trabalhamos com a amostra,

$$S^2(X) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

$$S^2 = \frac{\sum_{i=1}^{n} n_i(x_i - \bar{x})^2}{n-1}$$

Medidas de Dispersão.

Calculando a variância amostral para o MedA, temos:

$$S^2 = \frac{(15-35)^2 + (61-35)^2 + \ldots + (16-35)^2}{7-1} = \frac{3660}{6} = 610$$

Calcular a variância para o MedB.

$$S^2 = \frac{(35-35)^2 + (35-35)^2 + \ldots + (35-37)^2}{7-1} = \frac{10}{6} = 1.666$$

Medidas de Dispersão.

Algumas conclusões relacionadas com a variância.

O valor da variância é sempre positivo.

Quando todos os elementos da série são iguais, a variância é igual a zero.

O valor da variância é uma medida em escala diferente dos dados.

Medidas de Dispersão.

Para resolver o problema da diferença de escala entre variância e os dados, utilizamos o **desvio padrão**. O desvio padrão é a raiz quadrada da variância.

$$S = \sqrt{S^2}$$

Para o exemplo anterior.

Med. A: S = 24,698. Med. B : S = 1,29.

Cálculo de Variâncias Populacionais

- $$Var(X) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n} = \sigma^2$$
- $$Var(X) = \frac{\sum_{i=1}^{n} n_i(x_i - \bar{x})^2}{n} = \sigma^2$$
- $$Var(X) = \sum_{i=1}^{n} f_i(x_i - \bar{x})^2 = \sigma^2$$

Onde

x_i = i-ésimo elemento da amostra ou o i-ésimo ponto médio da variável contínua.

f_i = i-ésimo elemento da frequência relativa.

n_i = i-ésimo elemento da frequência.

Medidas descritivas de variabilidade **(variância)**

- #Sintaxe:
- > **var(dados)**
- #Exemplo: Para o conjunto {10,11,9,10,10,9,11} obtenha a variância.
- > x <-c(10,11,9,10,10,9,11)
- > **var(x)**
- [1] 0.6666667

Medidas descritivas de variabilidade **(desvio padrão)**

Medidas descritivas de variabilidade (desvio padrão)

#Sintaxe:

```
> sd(dados)
```

#Exemplo: Para o exemplo anterior, do cálculo da variância.

```
> x <-c(10,11,9,10,10,9,11)
> sd(x)
[1] 0.8164966
> sqrt(var(x))
[1] 0.8164966
```

Medidas descritivas de variabilidade **(Desvio Interquartil)**

A medida anterior tem a grande desvantagem de ser muito sensível à existência, na amostra, de uma observação muito grande ou muito pequena. Assim, define-se uma outra medida, o desvio interquartil, que é, em certa medida, uma solução de compromisso, pois não é afetada, de um modo geral, pela existência de um número pequeno de observações demasiado grandes ou demasiado pequenas.

Medidas descritivas de variabilidade **(Desvio Interquartil)**

Esta medida é definida como sendo a diferença entre os 1º e 3º quartis

Desvio interquartil = Q3 - Q1

Do modo como se define a amplitude interquartil, concluímos que 50% dos elementos do meio da amostra, estão contidos num intervalo com aquela amplitude.

Esta medida é não negativa e será tanto maior quanto maior for a variabilidade nos dados.

Desigualdade de Chebychev:

Em *qualquer* distribuição de frequências, independentemente de sua forma, a porção de dados que está dentro de k desvios padrão ($k > 1$) da média é *pelo menos* $1 - 1/k^2$.

Se $k = 2$, ***pelo menos*** $1 - 1/4 = ¾ = 75\%$ dos dados estão dentro de dois desvios padrão da média.

Se $k = 3$, ***pelo menos*** $1 - 1/9 = 8/9 = 88{,}9\%$ dos dados estão dentro de três desvios padrão da média.

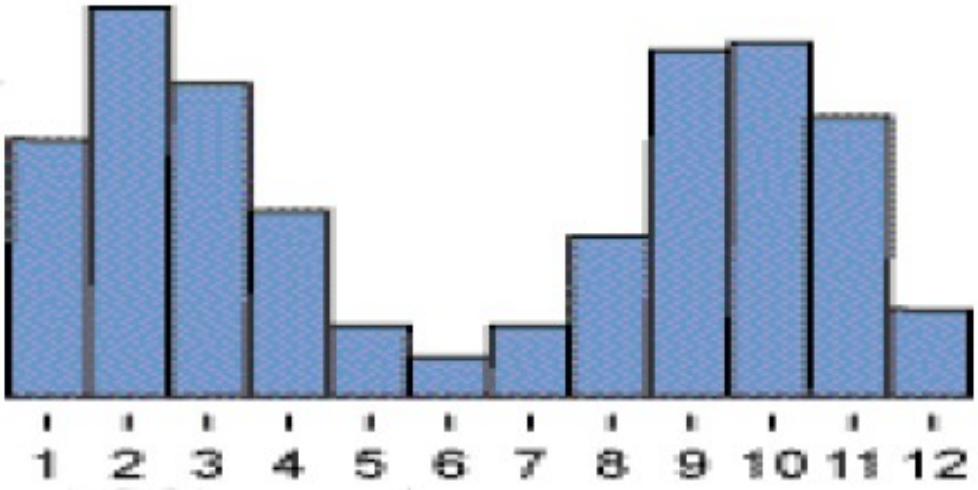

Medidas de Dispersão.

Coeficiente de variação: Mede a variabilidade em termos relativos, dividindo o desvio padrão pela média.

$$CVa = \frac{S}{\bar{x}} \times 100\%$$

Índices para avaliar a variação dos dados.

Baixa: menor que 10%

Médio: de 10% a 20%

Alto: de 20% a 30%

Muito Alto: acima de 30%

Coeficiente de Variação CV:

#Sintaxe:

```
> 100*sd(dados)/mean(dados)      #dado em porcentagem
```

#Exemplo: Para o exemplo anterior, do cálculo do desvio-padrão.

```
> x <-c(10,11,9,10,10,9,11)
> CV = 100*sd(x)/mean(x)
> CV
[1] 8.164966            #em torno de 8%
```

Resumo descritivo básico para um conjunto de dados quantitativos.

n	Média	Mediana	Desvio-Padrão	CV	Q1	Q3

n : nº de dados na pesquisa

Média : média aritmética dos dados (centralidade).

Mediana : valor mediano dos dados (centralidade).

Desvio Padrão: Desvio padrão dos dados (Dispersão).

CV: Coeficiente de Variação (Dispersão).

Q1: Primeiro Quartil (Posição).

Q3: Terceiro Quartil (Posição).

Introdução à Teoria das Probabilidades

Conceitos Básicos

Experimento Aleatório ou Fenômeno Aleatório

Situações ou acontecimentos cujos resultados não podem ser previstos com certeza.

Exemplos:

- Condições climáticas do próximo domingo;
- Taxa de inflação do próximo mês;
- Resultado ao lançar um dado ou moeda;
- Tempo de duração de uma lâmpada.

Espaço Amostral (Ω)

Conjunto de todos os possíveis resultado de um experimento aleatório ou fenômeno aleatório.

Exemplos:

1. Lançamento de um dado. $\Rightarrow \Omega=\{1,2,3,4,5,6\}$
2. Tipo sanguíneo de um individuo. $\Rightarrow \Omega=\{A, B, AB,0\}$
3. Opinião de um eleitor sobre um projeto. $\Rightarrow \Omega=\{$Favorável,Contrário$\}$
4. Tempo de duração de uma lâmpada $\Rightarrow \Omega=\{t; t>0)$

Evento subconjunto do espaço amostral Ω

Notação: A, B, C,...

Exemplos: No exemplo 1, alguns eventos:

A: sair face par: $\Rightarrow A=\{2,4,6\} \subset \Omega$

B: Sair face maior que 3 $\Rightarrow B=\{4,5,6\} \subset \Omega$

C: sair face 1 $\Rightarrow C=\{1\} \subset \Omega$

D: sair face 7 $\Rightarrow D=\{\ \}$ (evento impossível)= $\varnothing$ (conjunto vazio) $\subset \Omega$

Operação com eventos

Sejam os eventos A e B definidos no mesmo espaço amostral

•$A \cup B$: União dos eventos A e B.

Representa a ocorrência de <u>pelo menos</u> um dos eventos A ou B

•$A \cap B$: Intersecção dos eventos A e B.

Representa a ocorrência simultânea dos eventos A e B.

• A e B são disjuntos ou mutuamente exclusivos quando não têm elementos em comum, isto é, $A \cap B = \varnothing$

• A e B são complementares se sua intersecção é vazia e sua união o espaço amostral, isto é. $A \cap B = \varnothing$ e $A \cup B = \Omega$.

• O complementar de um evento A é representado por A^C *ou* $\overline{A}$

Exemplo: Lançamento de um dado

$\Omega = \{1, 2, 3, 4, 5, 6\}$

Eventos: $A = \{2, 4, 6\}$, $B = \{4, 5, 6\}$ e $C = \{1\}$

- $A \cap B: = \{2, 4, 6\} \cap \{4, 5, 6\} = \{4, 6\}$
- $A \cap C = \{2, 4, 6\} \cap \{1\} = \varnothing$
- $A \cup B = \{2, 4, 6\} \cup \{4, 5, 6\} = \{2, 4, 5, 6\}$
- $A \cup C = \{2, 4, 6\} \cup \{1\} = \{1, 2, 4, 6\}$
- $A^C = \{1, 3, 5\}$

Probabilidade

Pergunta: *Como atribuir probabilidade aos elementos do espaço amostral?*

Definições de probabilidades

Definição Clássica ou a priori

Se um experimento aleatório tiver n(Ω) resultados mutuamente exclusivos e igualmente prováveis e se um evento A tiver n(A) desses resultados. A probabilidade do evento A representado por P(A), é dado por:

$$P(A) = \frac{n(A)}{n(\Omega)}$$

Exemplo: Considere o lançamento de 2 dados balanceados. Calcular a probabilidade de:

a) Obter soma 7;

b) Obter soma maior que 10;

c) Que o resultado do primeiro dado seja superior ao resultado do segundo.

$$\Omega = \begin{Bmatrix} 1,1 & 1,2 & 1,3 & 1,4 & 1,5 & 1,6 \\ 2,1 & 2,2 & 2,3 & 2,4 & 2,5 & 2,6 \\ 3,1 & 3,2 & 3,3 & 3,4 & 3,5 & 3,6 \\ 4,1 & 4,2 & 4,3 & 4,4 & 4,5 & 4,6 \\ 5,1 & 5,2 & 5,3 & 5,4 & 5,5 & 5,6 \\ 6,1 & 6,2 & 6,3 & 6,4 & 6,5 & 6,6 \end{Bmatrix}$$

a) A={(1,6),(5,2),(4,3),(3,4),(2,5),(6,1)} $\Rightarrow$ P(A)=n(A)/n(Ω)=6/36=1/6

b) B={(5,6),(6,5),(6,6)} => P(B) = 3/36.

c) P(C)= 15/36.

Definição frequentista ou a posteriori

Suponhamos que realizamos um experimento n vezes (n grande) e destas o evento A ocorre exatamente r<n vezes, então a frequência relativa de vezes que ocorreu o evento A, "r/n", é a estimação da probabilidade que ocorra o evento A, ou seja,

$$P(A) = \frac{r}{n}$$

Essa estimação da probabilidade por frequência relativa de um evento A, é próxima da verdadeira probabilidade do evento A, quando n tende ao infinito.

Exemplo: Considere o lançamento de uma moeda. Calcular a probabilidade de A={ resultado obtido é cara}.

	fr_1	fr_2	fr_3	fr_4		fr_A
Cara	2/5	6/10	22/50	47/100		0,5
Coroa	3/5	4/10	28/50	53/100		0,5
n	5	10	50	100		∞

Definição axiomática

A probabilidade de um evento A define-se com o número P(A), tal que satisfaz os seguintes axiomas:

$$(i)\ \ 0 \le P(A) \le 1,\ \ \forall A \subset \Omega$$

$$(ii)\ \ P(\Omega) = 1$$

$$(iii)\ \ Se\ \ A_1, \ldots, A_n \text{ são eventos mutuamente exclusivos, então}$$

$$\mathrm{P}\left(\bigcup_{\mathrm{i}=1}^{\mathrm{n}} \mathrm{A}_{\mathrm{i}}\right) = \sum_{i=1}^{n} P(A_i)$$

Propriedades

1. $P(\Phi) = 0$

Regra da adição de probabilidades

2. $Se\ \ A \subset \Omega\ \ então,\ P(A) = 1 - P(A^c)$

3. $Se\ \ A \subset B \subset \Omega\ \ então,\ \ P(A) \le P(B)$

4. $Se\ \ A, B \subset \Omega\, então, P(A \cup B) = P(A) + P(B) - P(A \cap B)$

5. $Se\ \ A, B, C \subset \Omega\, então,$

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(B \cap C) - P(A \cap C) + P(A \cap B \cap C)$$

Exemplo 1. Na tabela 1, apresenta-se a composição por raça e sexo de uma população de um país.

Tabela 1: *Distribuição da população por raça e sexo.*

Raça	Sexo		Total
	Masculino	Feminino	
Branca	1726384	2110253	3836637
Outra	628309	753125	1381434
Total	2354693	2863378	5218071

Suponha que selecionamos um habitante desse país e consideremos os eventos:

H: "o habitante selecionado é do sexo masculino"
H^c:"o habitante selecionado é do sexo feminino"
B: "o habitante selecionado é da raça branca"
B^c: "o habitante selecionado é de outra raça"
$H \cap B$: "o habitante selecionado é de sexo masculino e da raça branca"
$H \cup B$: "o habitante selecionado é de sexo masculino ou da raça branca"
$H^c \cap B$: "o habitante selecionado é de sexo feminino e da raça branca"
$H^c \cup B$: "o habitante selecionado é de sexo feminino ou da raça branca"
$H^c \cap B^c$:"o habitante selecionado é de sexo feminino e de outra raça "
$H^c \cup B^c$ "o habitante selecionado é de sexo feminino ou de outra raça"

As probabilidades de cada um destes eventos são:

$$P(H) = \frac{2354693}{5218071} = 0{,}451;$$

$$P(H^c) = 1 - P(H) = 1 - 0{,}451 = 0{,}549;$$

$$P(B) = \frac{3836637}{5218071} = 0{,}735$$

$$P(B^c) = 1 - P(B) = 1 - 0{,}735 = 0{,}265;$$

$$P(H \cap B) = \frac{1726384}{5218071} = 0{,}331$$

$$P(H \cup B) = P(H) + P(B) - P(H \cap B) =$$

$$= 0{,}451 + 0{,}735 - 0{,}331 = 0{,}855;$$

$$P(H^c \cap B) = \frac{2110253}{5218071} = 0{,}404;$$

$$P(H^c \cup B) = P(H^c) + P(B) - P(H^c \cap B) =$$

$$= 0{,}549 + 0{,}739 - 0{,}404 = 0{,}880.$$

Definição:[Probabilidade condicional] Sejam *A* e *B* dois eventos em um mesmo espaço amostral, Ω, a probabilidade condicional de *A* dado que ocorreu o evento *B*, é representado por *P(A|B)* é dado por:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0. \qquad (1)$$

Exemplo 2. Selecionamos uma semente, ao acaso, uma a uma e sem reposição de uma sacola que contem 10 sementes de flores vermelhas e 5 de flores brancas. Qual é a probabilidade de que :

(a) a primeira semente seja vermelha. ?

(b) a segunda seja branca se a primeira foi vermelha.?

Sejam os eventos:

$$V_1 : \text{"A } 1^a \text{ semente é vermelha"};$$

$$V_1^c : \text{"A } 1^a \text{ semente é branca"}$$

$$V_2 : \text{"A } 2^a \text{ semente é vermelha"};$$

$$V_2^c : \text{"}A\ 2^a \text{ semente é branca"}$$

(a) $$P(V_1) = \frac{10}{15} = \frac{2}{3}$$

(b) $$P(V_2^c \mid V_1) = \frac{5}{14}$$

Essas probabilidades podem ser representados em um diagrama da árvore de probabilidades, a qual é mostrado na figura 1

Figura 1: Diagrama de árvore de probabilidade

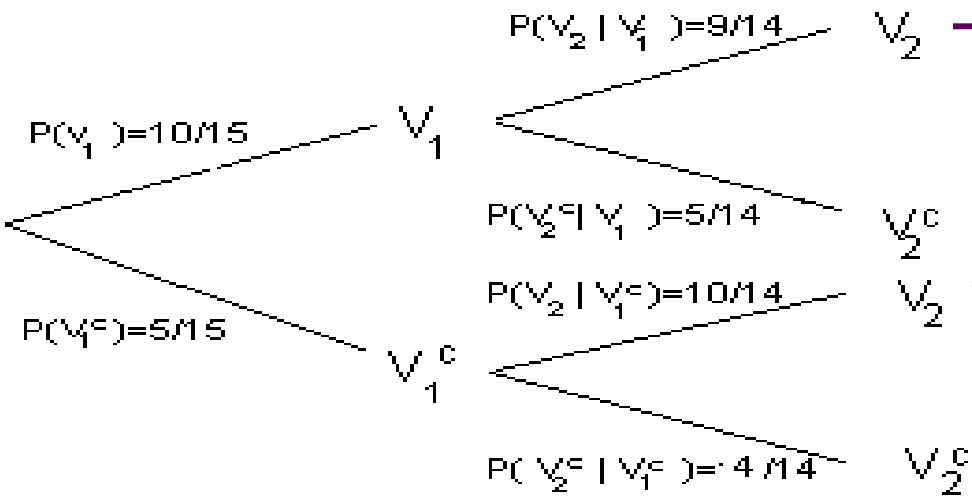

Resultados	Probabilidade
V_1V_2	$\frac{10}{15}\times\frac{9}{14}=\frac{3}{7}$
$V_1V_2^c$	$\frac{10}{15}\times\frac{5}{14}=\frac{5}{21}$
$V_1^cV_2$	$\frac{5}{15}\times\frac{10}{14}=\frac{5}{21}$
$V_1^cV_2^c$	$\frac{5}{15}\times\frac{4}{14}=\frac{2}{21}$
Total	1

$$P(A \cap B) = P(B)P(A \mid B),$$

Que é conhecida como regra do produto de probabilidades ou probabilidade da interseção

Exemplo 3: No exemplo 2, suponha que temos interesse em determinar a probabilidade que as duas sementes selecionadas sejam brancas.

$$\text{O evento é } V_1^c \cap V_2^c : \quad \text{"a 1}^{\text{a}} \text{ e 2}^{\text{a}} \text{ semente são brancas"}$$

$$\mathrm{P}(V_1^c \cap V_2^c) = P(V_1^c)P(V_2^c \mid V_1^c) = \frac{5}{15} \times \frac{4}{14} = \frac{2}{21}$$

Se B é um evento em Ω, tal que P(B)>0, então:

$$1. P(\phi \mid B) = 0$$

$$2. \text{Se } \mathrm{A}, \mathrm{B} \subset \Omega, \text{ então}: \mathrm{P}(\mathrm{A}^{\mathrm{c}} \mid B) = 1 - P(A \mid B) \ ou \ P(A \mid B) = 1 - \mathrm{P}(\mathrm{A}^{\mathrm{c}} \mid B)$$

$$3. Se\ A, B, C \subset \Omega, então:$$

$$P(A \cup C \mid B) = P(A \mid B) + P(C \mid B) - P(A \cap C \mid B).$$

Exemplo 3: Na Cidade de São Paulo, a probabilidade de chuva no primeiro dia de setembro é 0,50 e a probabilidade de chuva nos dois primeiros dias de setembro é 0,40. Se no primeiro de setembro choveu, qual é a probabilidade que no dia seguinte não chova ?

Solução: Sejam os eventos: A:" chove no primeiro de setembro", B:"chove no segundo dia de setembro".

Do enunciado do problema temos : P(A)=0,50 e P(A∩B)=0,40. A probabilidade pedida é:

$$P(B^c \mid A) \overset{*}{=} 1 - P(B \mid A) = 1 - \frac{P(A \cap B)}{P(A)} = 1 - \frac{0{,}40}{0{,}50} = 0{,}20$$

* Pelo teorema 1.2.

Definição[Independência de eventos] Dois eventos A e B são independentes se a informação da ocorrência ou não de B não altera a probabilidade da ocorrência de A. Isto é,

$$P(A|B)=P(A), \quad P(B)>0$$

Conseqüentemente, temos que dois eventos A e B são independentes se somente se,

$$P(A\cap B)=P(A)P(B).$$

Exemplo 4: Em uma escola 20% dos alunos tem problemas visuais, 8% problemas auditivos e 4% tem problemas visuais e auditivos. Selecionamos um aluno desta escola ao acaso:

(a) os eventos de ter problemas visuais e auditivos são eventos independentes?

(b) se aluno selecionado tem problemas visuais, qual é a probabilidade de que tenha problemas auditivos?

(c)qual é a probabilidade de não ter problemas visuais ou ter problemas auditivos ?

Solução: sejam os eventos:

V:” o aluno tem problemas visuais”

A:” o aluno tem problemas auditivos”.

Do enunciado temos: P(V)=0,20, P(A)=0,08 e P(A∩V)=0,04.

$$(a)\ P(V)P(A) = 0{,}2 \times 0{,}08 = 0{,}016$$

$$P(V \cap A) = 0{,}04.$$

Como $P(V \cap A) \neq P(V)P(A),\ A\, e\ V\ \ não\ são\ independentes.$

$$(b)\ P(A \mid V) = \frac{P(V \cap A)}{P(V)} = \frac{0{,}04}{0{,}20} = 0{,}20.$$

$$(c) P(V^c \cup A) = P(V^c) + P(A) - P(V^c \cap A) =$$

$$= 1 - P(V) + P(A) - P(A)P(V^c \mid A) = 1 - P(V) + P(A) - P(A)\left[1 - P(V \mid A)\right]$$

$$= 1 - P(V) + P(A) - P(A)\left[1 - \frac{P(V \cap A)}{P(A)}\right] =$$

$$= 1 - 0{,}2 + 0{,}08 - 0{,}08\left[1 - \frac{0{,}04}{0{,}08}\right] = 0{,}84$$

Teorema 2: Se A , B eventos em Ω são eventos independentes, então:

$$(i)\ A\ e\ B^c \text{ são independentes.}$$

$$(ii)\ A^c\ e\ B \text{ são independentes}$$

$$(\text{iii})\ A^c\ e\ B^c \text{ são independentes}$$

Exemplo 5: Um atirador acerta 80% de seus disparos e outro (na mesmas condições de tiro), 70%. Qual é a probabilidade de acertar se ambos atiradores disparam simultaneamente no alvo.? Considere que o alvo foi acertado quando pelo menos, uma das duas balas tenha feito impacto no alvo.

Sejam os eventos : B_i :"o atirador i acerta o alvo", $\mathrm{i} = 1,2$. $\mathrm{P}(\mathrm{B}_1) = 0{,}8$ e $P(B_2) = 0{,}7$. *Logo*,

$$P(B_1 \cup B_2) = \mathrm{P}(\mathrm{B}_1) + \mathrm{P}(\mathrm{B}_2) - P(B_1 \cap B_2) =$$

$$= \mathrm{P}(\mathrm{B}_1) + \mathrm{P}(\mathrm{B}_2) - \mathrm{P}(\mathrm{B}_1)P(\mathrm{B}_2) =$$

$$= 0{,}8 + 0{,}7 - 0{,}8 \times 0{,}7 = 0{,}94$$

Alternativamente este exemplo, pode ser resolvido de uma segunda forma

$$P(B_1 \cup B_2) = 1 - P(B_1^c \cap B_2^c) = 1 - P(B_1^c)P(B_2^c) =$$

$$= 1 - \left[1 - \mathrm{P}(\mathrm{B}_1)\right]\left[1 - \mathrm{P}(\mathrm{B}_2)\right] = 1 - [1 - 0{,}8][1 - 0{,}7] = 0{,}94.$$

Teorema de Bayes

Definição **[Partição do espaço amostral]**. Uma coleção de eventos $B_1, \cdots, B_k$ formam uma partição do espaço amostral se eles não têm intersecção entre si e sua união é igual ao espaço amostral.

$$B_i \cap B_j = \phi \text{ para } i \neq j \quad \text{e} \quad \bigcup_{i=1}^{k} B_i = \Omega$$

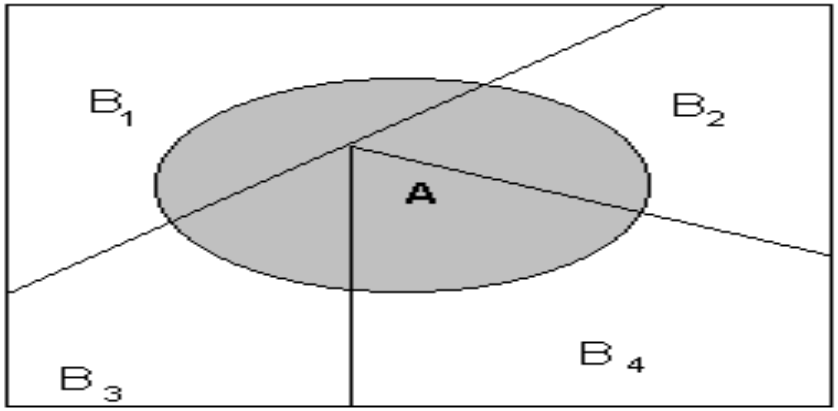

Condições da definição do teorema de Bayes para k=4

Teorema da probabilidade total. Se $B_1, \cdots, B_k$, formam uma partição do espaço amostral Ω, então qualquer evento A em Ω, satifaz:

$$P(A) = P(B_1)P(A|B_1) + \cdots + P(B_k)P(A|B_k) = \sum_{i=1}^{k} P(B_i)P(A|B_i)$$

Teorema Bayes. Se $B_1, \cdots, B_k$, formam uma partição do espaço amostral Ω, e A é qualquer evento em Ω, então:

$$P(B_i \mid A) = \frac{P(B_i)P(A \mid B_i)}{\sum_{i=1}^{k} P(B_i)P(A \mid B_i)}$$

Exemplo 6: Uma montadora trabalha com 2 fornecedores (A e B) de uma determinada peça. As chances de que uma peça proveniente dos fornecedores A e B esteja fora das especificações são 10% e 5% respectivamente. A montadora recebe 30% das peças do fornecedor A e 70% de B. Se uma peça do estoque inteiro é escolhido ao acaso:

(a) Calcule a probabilidade de que ela esteja fora das especificações.
(b) Se uma peça escolhida ao acaso está fora das especificações, qual é a probabilidade que venha do fornecedor fornecedor A ?

Solução:

Sejam os eventos:

A: “ peça selecionada seja do fornecedor A”

B:” peça selecionada seja do fornecedor B”

E:” peça selecionada esteja fora das especificações”

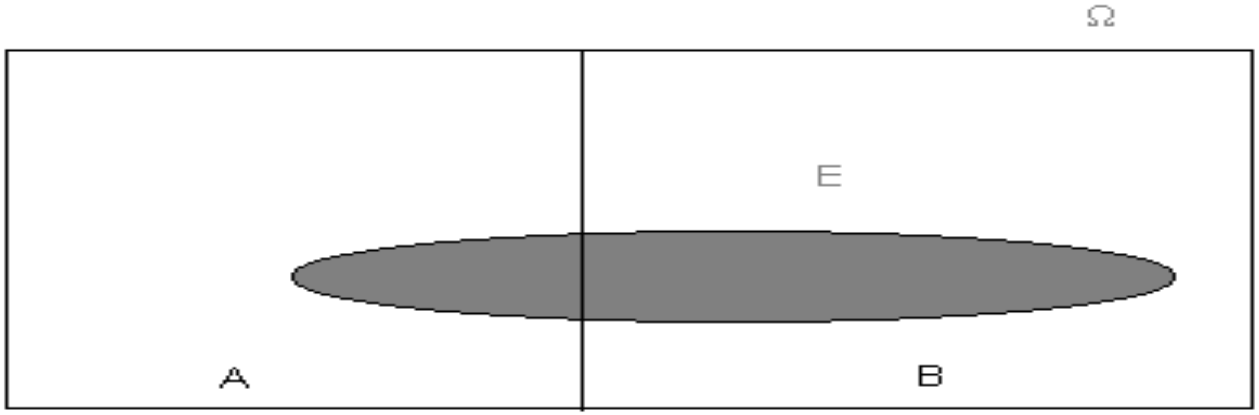

Do enunciado do problemas temos: $P(A)=0,30$; $P(B)=0,70$; $P(E|A)=0,10$ e $P(E|B)=0,05$.

Pelo teorema da probabilidade total temos:

(a) P(E)=P(A)P(E|A)+P(B)P(E|B)=(0,30)(0,10)+(0,70)(0,05)=0,065

(b) P(A|E)=?

Pelo teorema de Bayes temos:

$$P(A|E)=\frac{P(A)P(E|A)}{P(A)P(E|A)+P(B)P(E|B)}=\frac{0{,}30\times 0{,}10}{0{,}30\times 0{,}10+0{,}70\times 0{,}05}=\frac{0{,}03}{0{,}065}=0{,}46$$

A solução do exemplo anterior é facilitada pelo diagrama de árvore de probabilidades.

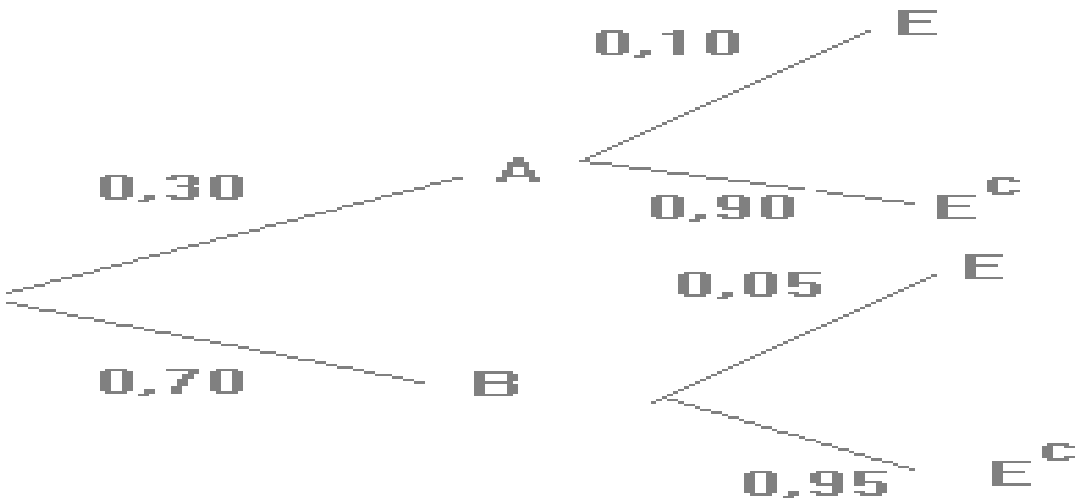

Funções de Distribuição de Probabilidades.

- Distribuição de Bernoulli.
- Distribuição Binomial.
- Distribuição Normal

Distribuição de Bernoulli

- Consideremos uma única tentativa de um experimento aleatório. Podemos ter sucesso ou fracasso nessa tentativa.
- Seja p a probabilidade de sucesso e q a probabilidade de fracasso, com $p + q = 1$.
- X: número de sucessos em uma única tentativado experimento.

$$X = \begin{cases} 0 & \text{fracasso;} \\ 1 & \text{sucesso,} \end{cases}$$

  com $P(X = 0) = q$ e $P(X = 1) = p$.
- A v.a. X tem distribuição de Bernoulli e sua função de probabilidade é dada por

$$P(X = x) = p^x q^{1-x}.$$

- **Exercício:** Mostre que $E(X) = p$ e $Var(X) = pq$.

Distribuição de Bernoulli - Exemplo

Uma urna tem 30 bolas brancas e 20 verdes. Retira-se uma bola dessa urna. Se X: o número de bolas verdes. Determine $P(X = x)$, $E(X)$ e $Var(X)$.

$$X = \begin{cases} 0 & \text{fracasso} \Rightarrow q = \frac{30}{50} = \frac{3}{5} \\ 1 & \text{sucesso} \Rightarrow p = \frac{20}{50} = \frac{2}{5} \end{cases}$$

$$P(X = x) = \left(\frac{2}{5}\right)^x \left(\frac{3}{5}\right)^{1-x}, \; E(X) = p = \frac{2}{5}$$

e

$$Var(X) = pq = \frac{2}{5} \times \frac{3}{5} = \frac{6}{25}.$$

Distribuição Binomial

- Consideremos agora n tentativas independentes de um mesmo experimento aleatório. Cada tentativa admite apenas dois resultados: fracasso com probabilidade q e sucesso com probabilidade p, $p + q = 1$.
- X: número de sucessos em n tentativas.
- A v.a. X tem distribuição Binomial e sua função de probabilidade é dada por

$$P(X = x) = \binom{n}{x} p^x q^{n-x},$$

  onde x é o número de sucessos e $n - x$ é o número de fracassos.
- **Notação:** $X \sim B(n, p)$
- $E(X) = np$ e $Var(X) = npq$.

Distribuição Binomial - Exemplos

Exemplo 1: Uma moeda é lançada 20 vezes. Qual a probabilidade de saírem 8 caras?

X: número de sucessos (caras)

$P(c) = 1/2$ e $n = 20$ logo,

$$X \sim B(20, 1/2).$$

Então,

$$\begin{aligned} P(X = 8) &= \binom{20}{8} (1/2)^8 (1/2)^{12} \\ &= 0,12. \end{aligned}$$

Distribuição Binomial - Exemplos

Exemplo 2: Numa criação de coelhos, 40% são machos. Qual a probabilidade de nascer pelo menos 2 coelhos machos num dia em que nasceram 20 coelhos?

X: número de coelhos machos (sucesso), $X = 0, 1, 2, 3, \ldots, 20$

$P(\text{coelhos machos}) = 0,40$ e $n = 20$ logo,

$$X \sim B(20; 0,40).$$

Então,

$$\begin{aligned} P(X \geq 2) &= 1 - P(X < 2) = 1 - \{P(X = 0) + P(X = 1)\} \\ &= 1 - \left\{ \binom{20}{0} (0,40)^0 (0,60)^{20} + \binom{20}{1} (0,40)^1 (0,60)^{19} \right\} \\ &= 0,99 \end{aligned}$$

Distribuição Normal

- Dizemos que a v.a. X tem distribuição normal com parâmetros μ e σ^2, $-\infty < \mu < \infty$ e $0 < \sigma^2 < \infty$ se sua f.d.p é dada por

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2}, \; x \in \mathcal{R}.$$

- $E(X) = \mu$ e $Var(X) = \sigma^2$.
- **Notação:** $X \sim N(\mu, \sigma^2)$.

Distribuição Normal

Para uma perfeita compreensão da distribuição normal procure visualizar as seguintes propriedades:

- A v.a. X pode assumir todo e qualquer valor real;
- A representação gráfica da distribuição normal é uma curva em forma de sino, simétrica em torno da média μ, que recebe o nome de curva normal;
- A curva normal é assintótica em relação ao eixo das abscissas, isto é, aproxima-se indefinidamente do eixo das abscissas sem, contudo, alcançá-lo;
- Como a curva é simétrica em torno de μ, a probabilidade de ocorrer valor maior do que a média é igual a probabilidade de ocorrer valor menor que a média, isto é, ambas as probabilidades sáo iguais a $0,5$. Escrevemos:

$$P(X > \mu) = P(X < \mu) = 0,5.$$

Distribuição Normal

- Se $X \sim N(\mu, \sigma^2)$ então a variável

$$Z = \frac{X - \mu}{\sigma}$$

tem distribuição **normal padrão** e escrevemos:

$$Z \sim N(0, 1).$$

- A tabela entregue é uma tabela de distribuição normal padrão, que nos dá a probabilidade de Z tomar qualquer valor entre a média 0 e um dado valor z, isto é, $P(0 < Z < z)$, onde $Z \sim N(0, 1)$

Tabela III — Distribuição Normal Padrão

$Z \sim N(0, 1)$

Corpo da tabela dá a probabilidade p, tal que $p = P(0 < Z < Z_c)$

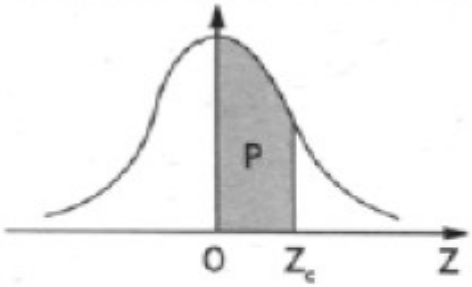

parte inteira e primeira decimal de Z_c	Segunda decimal de Z_c										parte inteira e primeira decimal de Z_c
	0	1	2	3	4	5	6	7	8	9	
	p = 0										
0,0	00000	00399	00798	01197	01595	01994	02392	02790	03188	03586	0,0
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535	0,1
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409	0,2
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173	0,3
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793	0,4
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240	0,5
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490	0,6
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524	0,7
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327	0,8
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891	0,9
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214	1,0
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298	1,1
1,2	38493	38686	38877	39065	39251	39435	39617	39796	39973	40147	1,2
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774	1,3
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189	1,4
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408	1,5
1,6	44520	44630	44738	44845	44950	45053	45154	45254	45352	45449	1,6
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327	1,7
1,8	46407	46485	46562	46638	46712	46784	46856	46926	46995	47062	1,8
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670	1,9
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169	2,0

Tabela III — Distribuição Normal Padrão

$Z \sim N(0, 1)$

Corpo da tabela dá a probabilidade p, tal que $p = P(0 < Z < Z_c)$

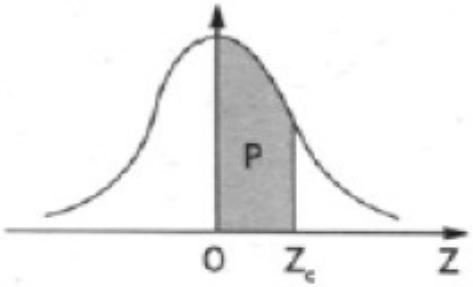

parte inteira e primeira decimal de Z_c	Segunda decimal de Z_c										parte inteira e primeira decimal de Z_c
	0	1	2	3	4	5	6	7	8	9	
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574	2,1
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899	2,2
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158	2,3
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361	2,4
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520	2,5
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643	2,6
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736	2,7
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807	2,8
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861	2,9
3,0	49865	49869	49874	49878	49882	49886	49889	49893	49897	49900	3,0
3,1	49903	49906	49910	49913	49916	49918	49921	49924	49926	49929	3,1
3,2	49931	49934	49936	49938	49940	49942	49944	49946	49948	49950	3,2
3,3	49952	49953	49955	49957	49958	49960	49961	49962	49964	49965	3,3
3,4	49966	49968	49969	49970	49971	49972	49973	49974	49975	49976	3,4
3,5	49977	49978	49978	49979	49980	49981	49981	49982	49983	49983	3,5
3,6	49984	49985	49985	49986	49986	49987	49987	49988	49988	49989	3,6
3,7	49989	49990	49990	49990	49991	49991	49992	49992	49992	49992	3,7
3,8	49993	49993	49993	49994	49994	49994	49994	49995	49995	49995	3,8
3,9	49995	49995	49996	49996	49996	49996	49996	49996	49997	49997	3,9
4,0	49997	49997	49997	49997	49997	49997	49998	49998	49998	49998	4,0
4,5	49999	50000	50000	50000	50000	50000	50000	50000	50000	50000	4,5

Distribuição Normal

Exemplo: Seja X a v.a. que representa os diâmetros dos parafusos produzidos por certa máquina. Vamos supor que essa variável tenha distribuição normal com média $\mu = 2$ e desvio padrão $\sigma = 0,04cm$. Pode haver interesse em conhecer a probabilidade de um parafuso ter um diâmetro com valor entre 2 e $2,05cm$.

Distribuição Normal

Exercício 1: Determine as probabilidades

a) $P(-1,25 < Z < 0)$;

b) $P(-0,5 < Z < 1,48)$;

c) $P(0,8 < Z < 1,23)$;

d) $P(Z > 0,6)$;

e) $P(Z < 0,92)$.

Exercício 2: Os salários semanais dos operários industriais são distribuídos normalmente, com média $R\$\ 500,00$ e desvio padrão $R\$\ 40,00$. Calcule a probabilidade de um operário ter um salário semanal entre $R\$\ 490,00$ e $R\$\ 520,00$.

Regressão Linear

Objetivo

Explicar uma variável quantitativa segundo uma outra variável quantitativa.

Exemplos

- Preço de um imóvel segundo a área construída
- Consumo de combustível segundo o preço do combustível e a região
- Valorização de uma ação segundo a valorização da bolsa
- Taxa de criminalidade segundo a taxa de desemprego
- Tempo de reação em um processo químico segundo a taxa de concentração do reagente.

Algumas definições

a) **diagrama de dispersão**: representação gráfica entre duas variáveis quantitativas

b) **correlação**: quantifica a força da relação linear entre duas variáveis quantitativas

c) **regressão linear**: explicita a forma da relação linear

Exemplo 1: nota da prova e tempo de estudo

X : tempo de estudo (em horas)

Y : nota da prova

Pares de observações (X_i , Y_i)

Tempo	Nota
3,0	4,5
7,0	6,5
2,0	3,7
1,5	4,0
12,0	9,3

Diagrama de Dispersão

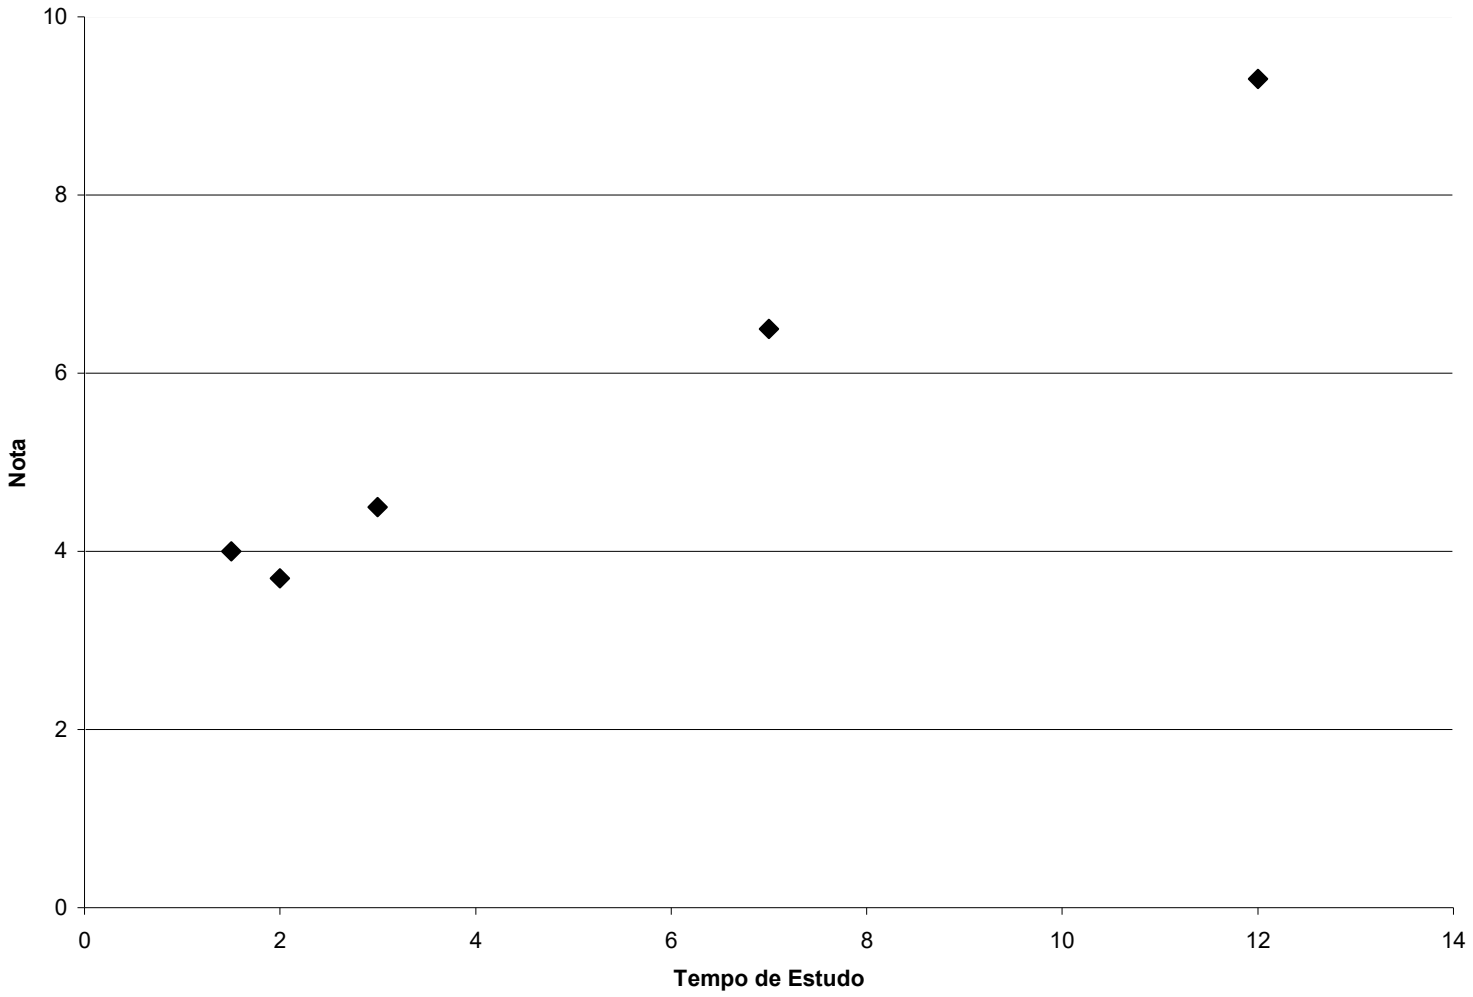

Coeficiente de correlação linear

O coeficiente de correlação linear é definido como

$$r = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}} = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left(\sum x^2 - \frac{\left(\sum x\right)^2}{n}\right)\left(\sum y^2 - \frac{\left(\sum y\right)^2}{n}\right)}}$$

Propriedades do coeficiente de correlação linear

<u>Propriedade</u>

$-1 \leq r \leq 1$

<u>Classificação da correlação</u>

r = 1, correlação linear positiva e perfeita

r = -1, correlação linear negativa e perfeita

r = 0, inexistência de correlação linear

Exemplo do cálculo da correlação

Tempo (X)	Nota (Y)	X^2	Y^2	XY
3,0	4,5	9	20,25	13,5
7,0	6,5	49	42,25	45,5
2,0	3,7	4	13,69	7,4
1,5	4,0	2,25	16	6
12,0	9,3	144	86,49	111,6
25,5	28	208,25	178,68	184

$$r = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left(\sum x^2 - \frac{\left(\sum x\right)^2}{n}\right)\left(\sum y^2 - \frac{\left(\sum y\right)^2}{n}\right)}} = \frac{184 - \frac{25{,}5 * 28}{5}}{\sqrt{\left(208{,}25 - \frac{(25{,}5)^2}{5}\right)\left(178{,}68 - \frac{(28)^2}{5}\right)}} = 0{,}9960$$

Gráficos - exemplos da classificação da correlação

Exemplo para **r = 1**

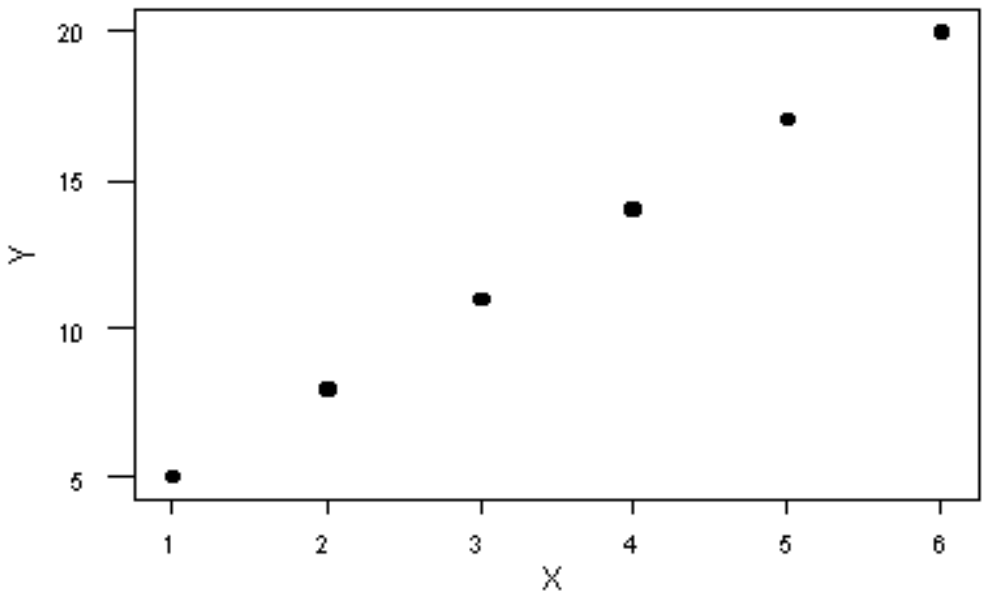

Gráficos - exemplos da classificação da correlação

Exemplo para **r = -1**

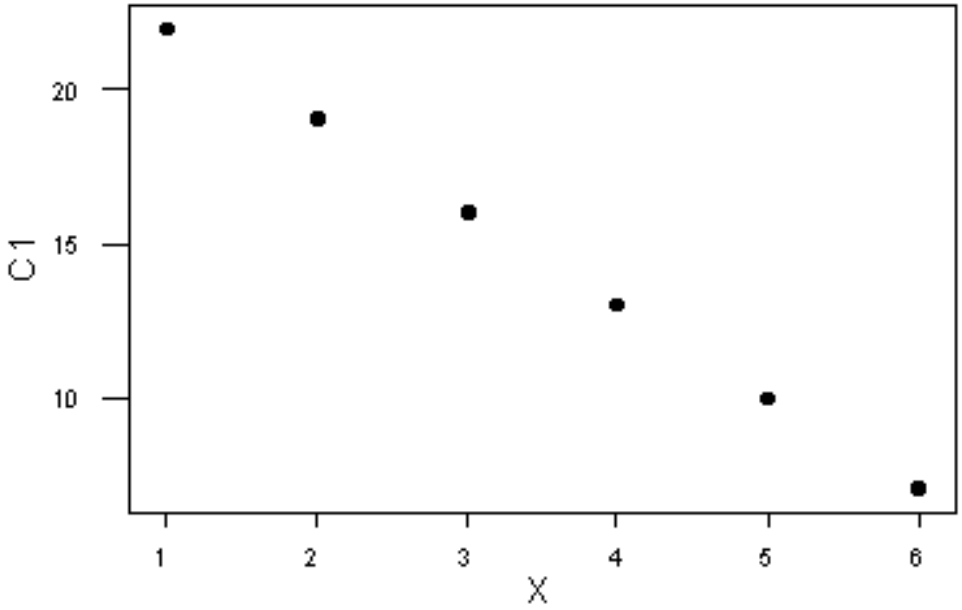

Gráficos - exemplos da classificação da correlação

Exemplo para **0 < r < 1**

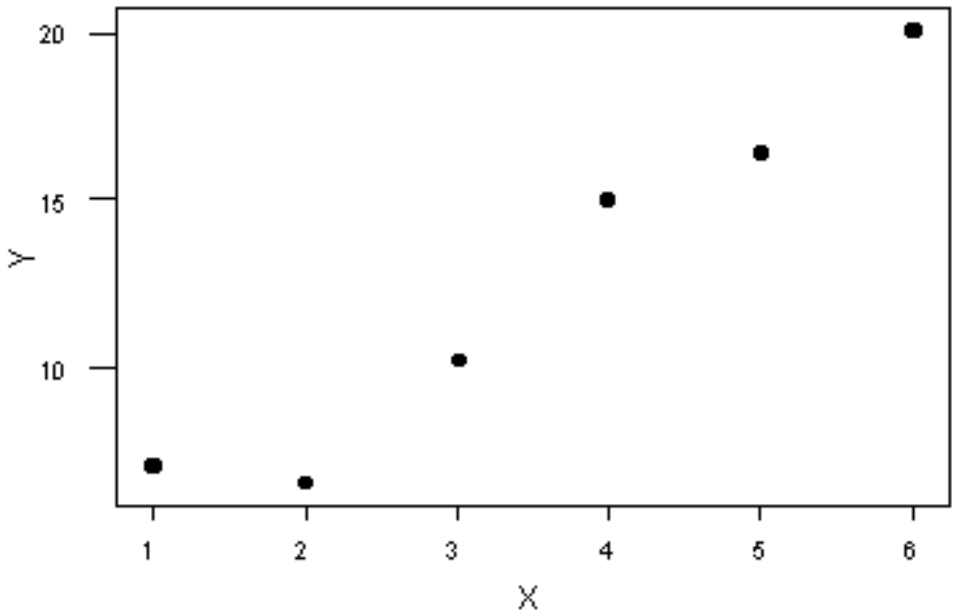

Gráficos - exemplos da classificação da correlação

Exemplo para **-1 < r < 0**

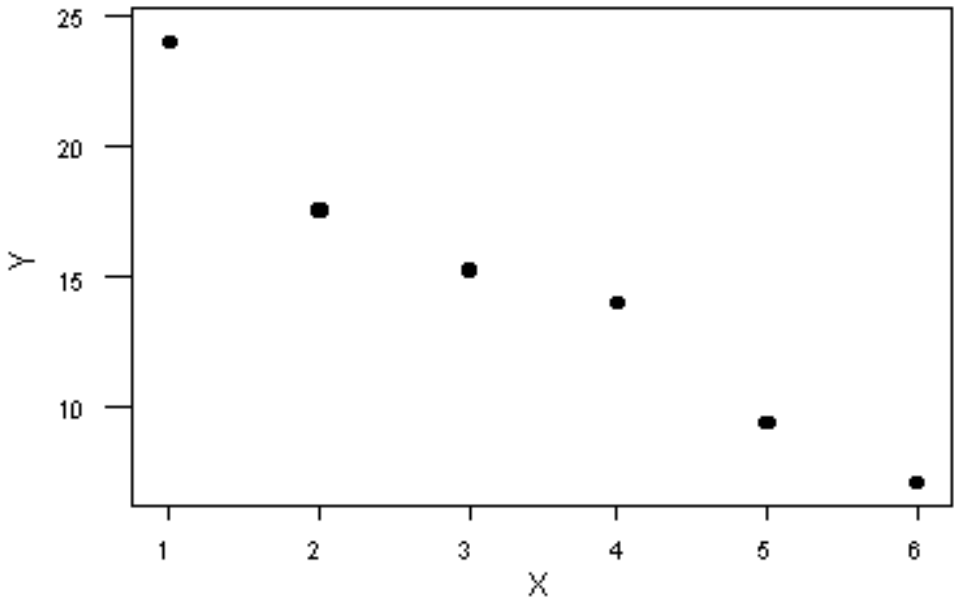

Gráficos - exemplos da classificação da correlação

Exemplo para **r = 0**

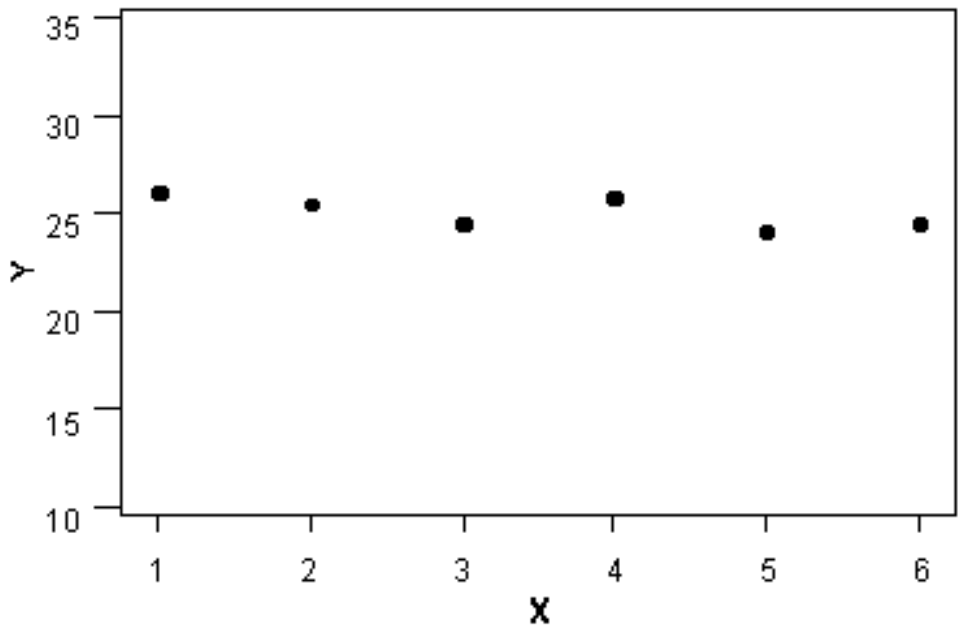

Gráficos - exemplos da classificação da correlação

Outro exemplo para **r = 0**

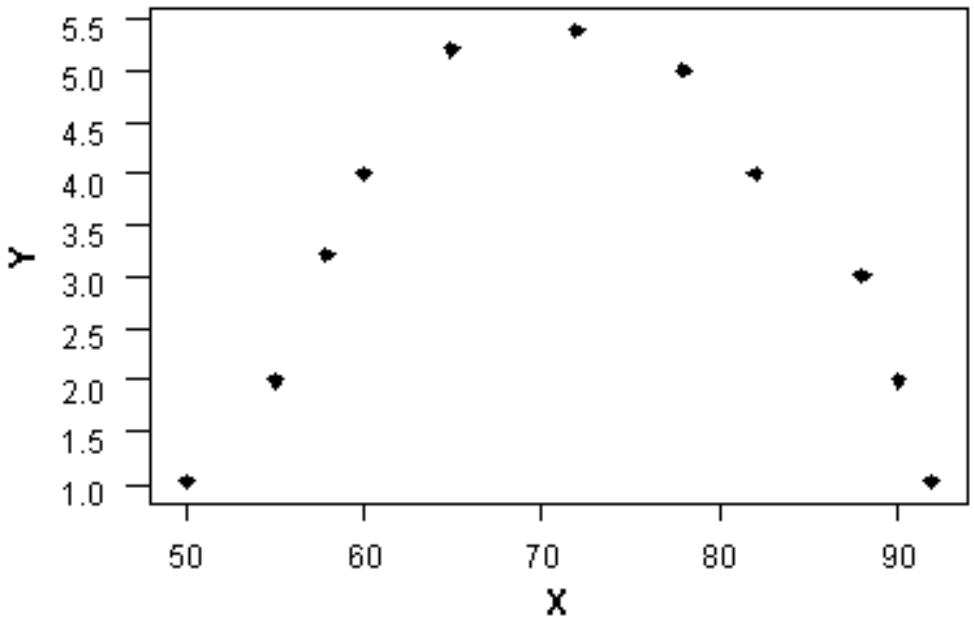

Exercício.

Considere a relação entre temperatura e rendimento em um processo químico . Os dados estão ilustrados abaixo:

Temperatura (ºC)	Rendimento (%)
30	35
35	40
40	42
60	70
70	85
90	87
100	91

Construa o diagrama de dispersão e encontre o coeficiente de correlação.

Diagrama de dispersão

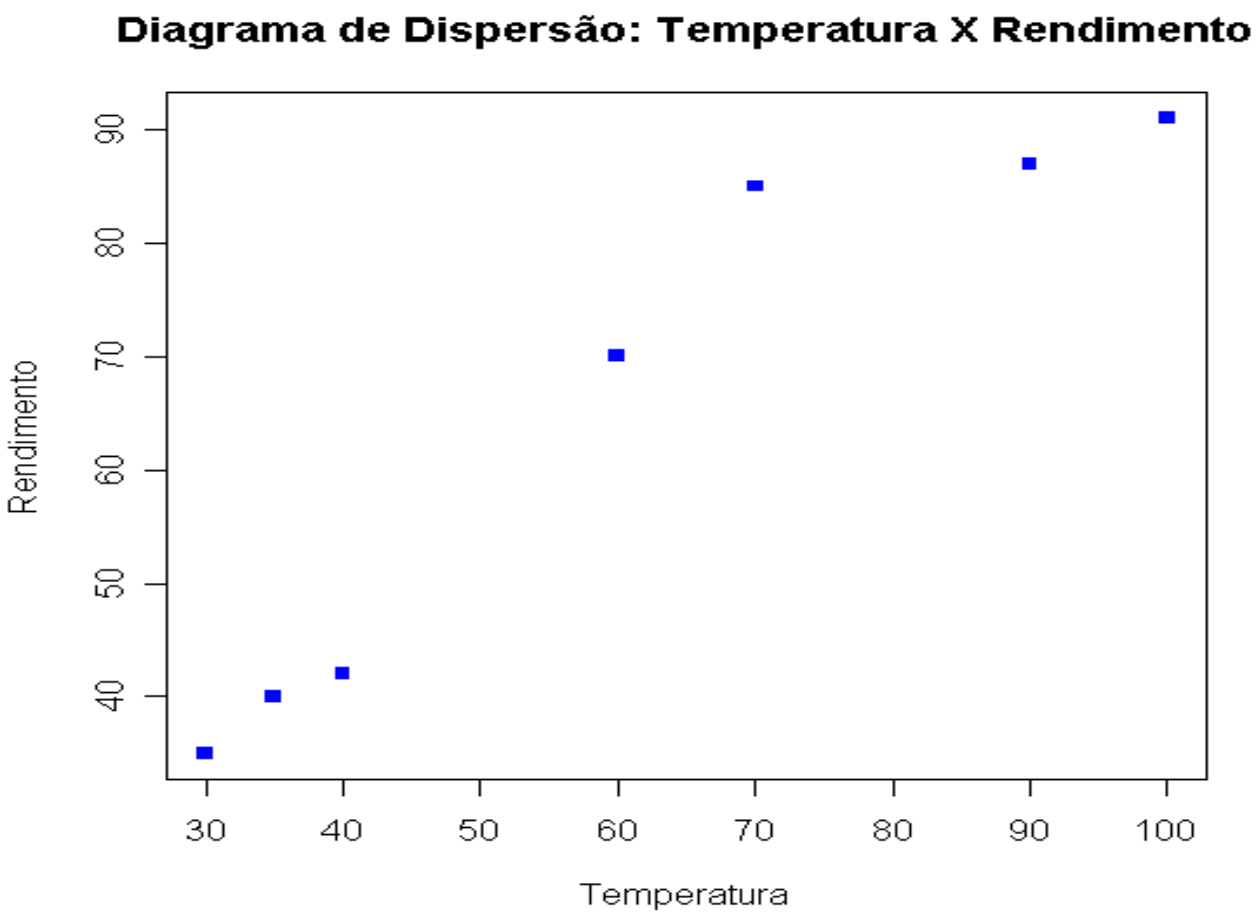

Coeficiente de correlação:

r = 0.9591233

Reta ajustada

$$\hat{Y} = a + bX$$

Definição de **a** e **b**

a : intercepto ou coeficiente linear

b : inclinação ou coeficiente angular

<u>Interpretação</u>

Para cada aumento de uma unidade em X, temos um aumento de **b** unidades em Y.

Cálculo dos Coeficientes de Regressão.

$$b = \frac{S_{xy}}{S_{xx}} = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sum x^2 - \frac{\left(\sum x\right)^2}{n}}$$

$$a = \bar{y} - b\bar{x}, \quad \text{onde} \quad \bar{y} = \frac{\sum y}{n} \quad \text{e} \quad \bar{x} = \frac{\sum x}{n}$$

Cálculo dos coeficientes de Regressão.

Tempo (X)	Nota (Y)	X^2	Y^2	XY
3,0	4,5	9	20,25	13,5
7,0	6,5	49	42,25	45,5
2,0	3,7	4	13,69	7,4
1,5	4,0	2,25	16	6
12,0	9,3	144	86,49	111,6
25,5	28	208,25	178,68	184

$$b = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sum x^2 - \frac{\left(\sum x\right)^2}{n}} = \frac{184 - \frac{25{,}5 * 28}{5}}{208{,}25 - \frac{25{,}5^2}{5}} = \frac{41{,}2}{78{,}2} = 0{,}5268$$

$$a = \overline{y} - b\overline{x} = 5{,}6 - 0{,}5268 * 5{,}1 = 2{,}9133$$

Equação da reta: Exemplo Notas

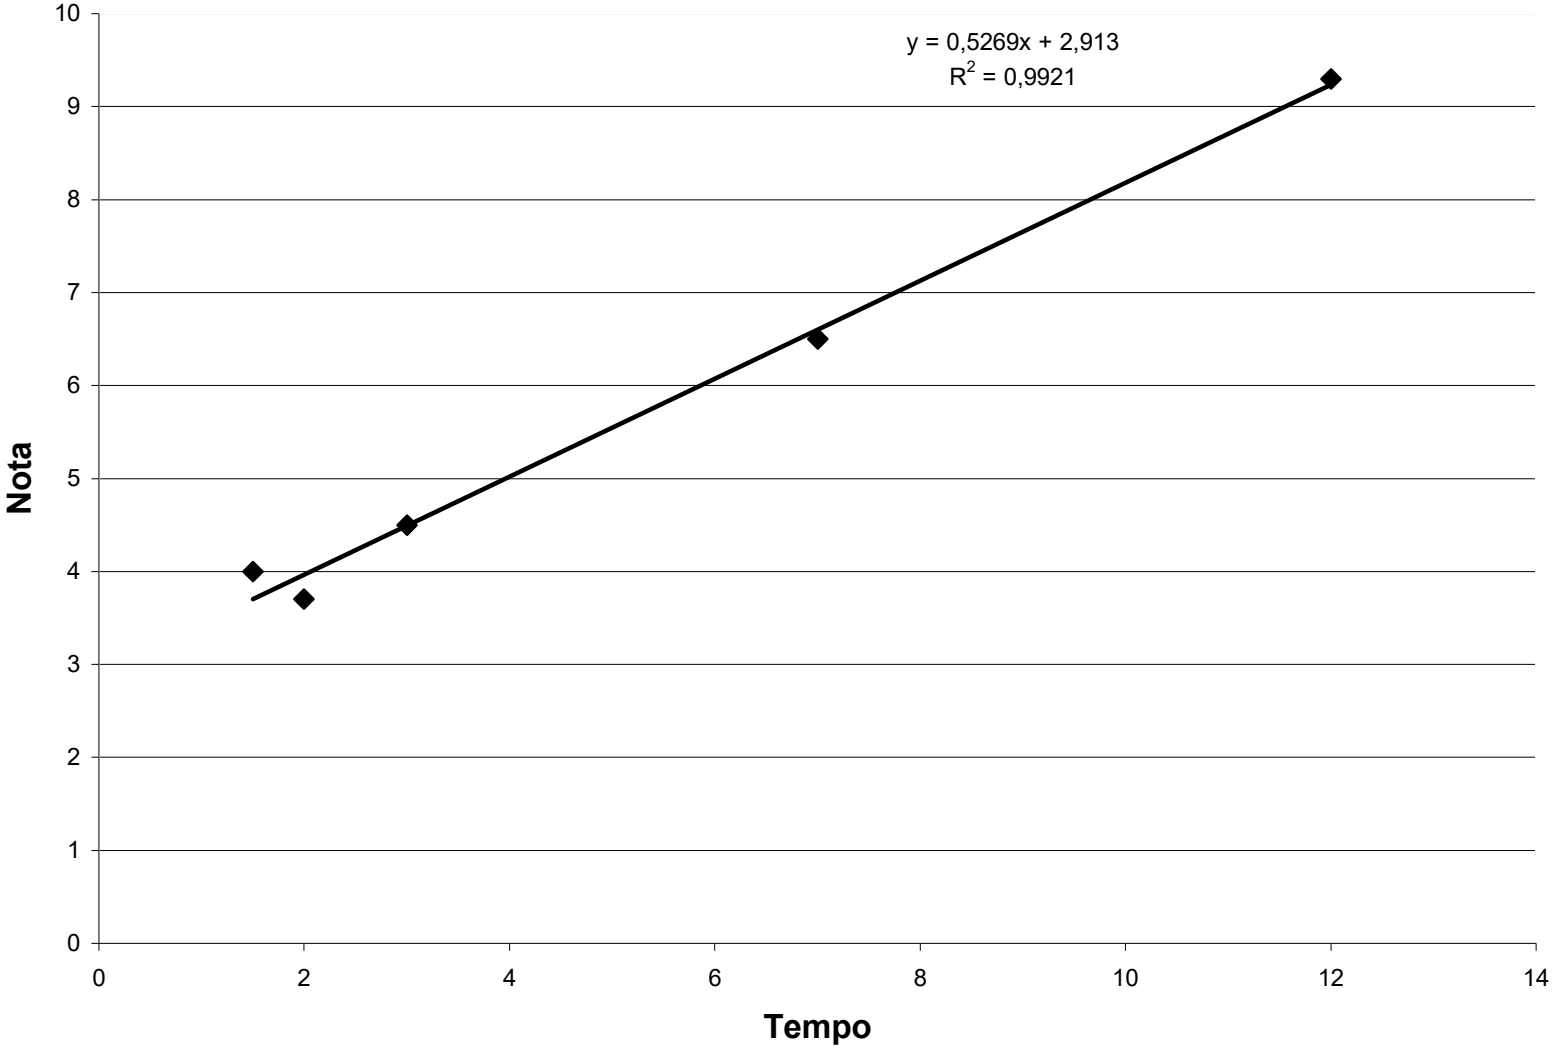

Exercício.

Considere a relação entre temperatura e rendimento em um processo químico . Os dados estão ilustrados abaixo:

Temperatura (ºC)	Rendimento (%)
30	35
35	40
40	42
60	70
70	85
90	87
100	91

Encontre a reta ajustada.

Exercício.

$$b = 0.86$$

$$a = 12.07$$

Coeficiente de Determinação:

$$R = 0.9591$$

Reta ajustada

$$\hat{y} = 12.07 + 0.87x$$

Interpretação: A cada unidade aumentada da temperada, o rendimento aumenta em média em 0.87%.